

The Thinking Machine, Part 1: Andajacha Yantra

August 28, 2026

THE THINKING MACHINE

BOOK 2, PART 1 OF 3: अंदाजाचं यंत्र

Book 1 ने एक machine दिली जी सांगितलेलं करते: exact recipe, exact निकाल. हे पुस्तक त्या machine बदल आहे जिच्याशी तुम्ही रोज बोलता: ChatGPT, Claude, Gemini. ती अंदाज करते, कविता लिहिते, code सुचवते, आणि कधीकधी ठाम आत्मविश्वासाने चुकते. ती आतून काय आहे, हे या तीन parts मध्ये उघडणार आहोत.

BOOK 2 चा नकाशा (3 parts)

[तुम्ही इथे आहात]

PART 1	अंदाजाचं यंत्र	tokens, probability, पुढचा शब्द; यंत्र शिकतं कसं, model म्हणजे काय
PART 2	अर्थ आणि उत्तर	अर्थचे numbers, attention, transformer; file उत्तर कशी देते
PART 3	चुका, हात आणि पैसा	hallucination, तपासणी; agents, tools, Claude Code; AI चा पैसा-नकाशा; अंतिम परीक्षा (दोन्ही पुस्तकांवर)

Book 1 ची उजळणी: जे शब्द इथे गृहीत धरले आहेत

हे पुस्तक Book 1 च्या खांद्यावर उभं आहे. खालचे शब्द पुढे स्पष्टीकरणाशिवाय वापरले जातील; एखादा विसरला असेल तर कंसातल्या chapter वर परत जा (क्रमांक Book 1 चे):

सगळं numbers आहे	text/photo/आवाज: कापा, मोजा, अर्थ ठरवा (2.2)
bit / byte	switch ची स्थिती / ~1 अक्षर (1.4)
recipe / program	machine साठी आधीच लिहिलेली कृती (1.3)
universal machine	नवी recipe = नवं काम; machine तीच (1.6)
CPU	recipe चालवणारा; billion पावलं/second (2.4)
GPU	(नवा शब्द, इथेच घ्या): हजारो साधी गणितं एकाच वेळेस करणारी chip; games साठी जन्मली, AI चं घर बनली
RAM / storage	मेज (विसराळू) / गोदाम (पक्कं) (2.5)
client / server	मागणारी / देणारी machine (5.1)
packet / latency	message चा तुकडा / फेऱ्याचा वेळ (5.3)
API	programs चं ठरलेलं प्रश्नोत्तर-menu (B1 7.4)
cloud / compute	भाड्याच्या machines / CPU-वेळेचं भाडं (7.5)
database / index	data चा दरबान / शोधाची लावलेली यादी (6.1)
cache	महाग उत्तर जवळ ठेवणं; शिळेपणाची किंमत (6.6)
queue / stateless	कामाची रांग / server रिकामा, state बाहेर (6.5)
transaction	सगळं-किंवा-काहीच-नाही गट्टा (6.4)
frontend / backend	दिसणारा भाग / खरी तपासणी kitchen मध्ये (7.3)
scale / bottleneck	आडवं वाढणं / साखळीतला अरुंद दुवा (7.1, 7.6)
abstraction	आतलं झाकून सोपं handle (0.4)
leverage/scarcity	एकदा-करा-पुन्हा-पुन्हा-फायदा / दुर्मिळता (0.2)
4 LEVELS	गरज -> business -> tech -> AI; पैसा खालून वर (0.3)
platform / जकात	दरवाजाचा मालक आणि त्याचा हिस्सा (3.5)
open source	खुला code, सामायिक हत्यार (3.7)
bug / edge case	लिहिलं-हवं ची फट / कोपऱ्यातली स्थिती (4.1)
spec / MVP	सात-प्रश्नी मागणी / छोटं चालतं रूप (8.3, 4.5)

एका ओळीत Book 1: **machine = numbers** वर आधीच लिहिलेली **recipe**, जगभर जोडलेली, आठवण पक्की, लाखोंना **serve** करणारी. आता प्रश्न: अशा machine मध्ये “बोलणारी बुद्धी” कुठून आली?

या part मध्ये काय आहे

Section 1 (7 chapters): तुम्ही Enter दाबता तेव्हा नक्की काय होतं; “हे विचार करतंय का”; शक्यता (probability) म्हणजे काय; आणि या यंत्राचं एकमेव काम: **पुढचा token ओळखणं**: आणि token म्हणजे अक्षर नाही, ही पहिली मोठी उलथापालथ.

Section 2 (10 chapters): शिकणं म्हणजे नक्की काय: rules लिहिणं सोडून examples दाखवणं; चुकून-चुकून सुधारत जाणं; अब्जावधी फिरक्या (weights); data कुठून आला आणि काय गाळलं; माणसाने शेवटी कसं वळण दिलं; आणि “model” नावाची file प्रत्यक्षात काय आहे.

हे तुमच्या business decision मध्ये कुठे येईल: AI चं bill tokens मध्ये येतं (या part नंतर तुम्ही ते वाचू शकाल), AI ची ताकद-कमजोरी त्याच्या **शिकण्याच्या** पद्धतीतून येते (कुठे भरवसा ठेवायचा हे तिथून कळतं), आणि “स्वतःचा AI बनवू का विकत घेऊ” हा प्रश्न training चा खर्च बघितल्यावर स्वतःच सुटतो.

SECTION 1: जे तुमच्या हातात आहे

सात chapters. रोज वापरत असलेल्या गोष्टीपासून सुरुवात: ChatGPT/ Claude च्या chat-खिडकीपासून, आणि तिच्या मुळाशी असलेल्या एका आश्चर्यकारक साध्या कल्पनेपर्यंत: पुढचा token ओळखणं.

हे तुमच्या business decision मध्ये कुठे येईल: AI ची प्रत्येक किंमत-यादी tokens मध्ये आहे (\$5 प्रति million input, \$25-30 प्रति million output: हीच आजची बाजारभाषा). Token म्हणजे काय हे न कळता AI वापरणं म्हणजे litre न कळता petrol भरणं. आणि “हे विचार करतं का” या प्रश्नाचं तुमचं उत्तर ठरवतं की तुम्ही त्याच्यावर काय सोपवाळ आणि काय कधीच सोपवणार नाही.

Chapter 1.1 [SPINE]: Enter दाबल्यावर काय होतं

तुम्ही Claude ला लिहिता: “उद्या पुण्यात पाऊस पडेल का?” आणि Enter दाबता. दीड second नी उत्तर **टपकायला** लागतं: शब्द... शब्द... शब्द. थांबा. हे टपकणं: हीच या पुस्तकाची पहिली खूण आहे. Google ने पूर्ण पान एकदम दिलं असतं. हे यंत्र **एक-एक तुकडा** का देतं?

Book 1 च्या नजरेने trace करू; रस्ता ओळखीचा आहे, शेवट नवा:

1. तुमचं वाक्य numbers होतं. “उद्या पुण्यात...” आधी तुकड्यांत कापलं जातं (त्या तुकड्यांचं नाव **token**: chapter 1.6-1.7 मध्ये पूर्ण), आणि प्रत्येक तुकड्याला एक number (Book 1, 2.2: encoding, पण नवी वही). तुमचा प्रश्न = numbers ची रांग.

2. रांग server कडे जाते. DNS, https, packets: Book 1 चा Part 3 जसाच्या तसा. पलीकडे cloud मधली machine: पण **वेगळी** machine. CPU नाही; **GPU**: हजारो साधी गणितं एकाच क्षणी करणारी chip. का, ते Part 2 मध्ये उघडेल; आत्ता एवढंच: या यंत्राचा विचार म्हणजे अब्जावधी गुणाकार, आणि GPU गुणाकारांची पंगत एकदम वाढते.

3. आणि आता नवं जग. Book 1 मध्ये server वर recipe चालायची: “जर हे, तर ते” ची माणसाने लिहिलेली पावलं. इथे... तशी recipe **नाही**. आहे एक राक्षसी file: शेकडो GB ची, फक्त numbers नी भरलेली (नाव: **model**; Section 2 चा नायक). तुमच्या प्रश्नाचे numbers त्या file मधल्या numbers शी अब्जावधी वेळा गुणले-जोडले जातात... आणि बाहेर पडतं **एकच** उत्तर: पुढचा token कुठला असावा, याची यादी: प्रत्येक शक्य token पुढे एक आकडा: “हा असण्याची शक्यता इतकी.”

4. एक token निवडला जातो. समजा “उद्या”. तो तुमच्याकडे टपकतो. आणि मग: **पूर्ण खेळ पुन्हा**. आता प्रश्न + “उद्या” मिळून नवी रांग; पुन्हा अब्जावधी गुणाकार; पुढचा token: “पावसाची”. पुन्हा. पुन्हा. उत्तर संपेपर्यंत.

म्हणून उत्तर **टपकतं**: कारण ते खरोखर **एका वेळेस एकाच तुकड्याने जन्मतं**. Typing ची नक्कल नाही; जन्मच तसा आहे. हलवायाची जिलेबी आठवा: कढईतून एक-एक वेटोळं; पूर्ण थाळी एकदम पडत नाही, कारण बनण्याची पद्धतच तशी आहे.

आणि या chapter ची सगळ्यात मोठी ओळ, अधोरेखित करा: **हे यंत्र “उत्तर” देत नाही; ते पुन्हा-पुन्हा “पुढचा token” देतं**. प्रश्न- उत्तर, कविता, code, माफीनामा: सगळं एकाच चक्राचे अवतार: **आत्तापर्यंतच्या रांगेला बघून पुढचा तुकडा ओळख**. हे ऐकून वाटतं: “एवढंच? मग हे इतकं हुशार कसं?” तोच या पुस्तकाचा प्रश्न आहे: आणि उत्तराला तीन parts लागतील.

इथे लोक काय चुकीचं समजतात

”हे Google सारखं शोधतं आणि जुळवून देतं.” नाही. उत्तर देताना हे यंत्र (मूळ रूपात) कुठेच शोधत नाही: internet बंद असला तरी model file मधून उत्तर जन्मतं. जे “माहीत” आहे ते त्या numbers च्या file मध्ये दाबून बसलेलं आहे: कसं, ते Section 2 सांगेल. (हो, आजची apps कधीकधी शोध जोडतात: ते वेगळं हत्यार आहे, Part 3 मध्ये. यंत्राचा गाभा शोध नाही; जन्म आहे.)

MAP वर

पैसा या चक्राला चिकटून वाहतो: तुमचा प्रत्येक प्रश्न = input tokens, प्रत्येक उत्तर = output tokens, आणि bill दोन्हीवर: आजचे भाव \$5 प्रति million input / \$25-30 प्रति million output (Claude Opus 5 / GPT-5.6 Sol च्या श्रेणीचे, Aug 2026). Output input पेक्षा 5-6 पट महाग: कारण output म्हणजे चक्र फिरणं: प्रत्येक token साठी अब्जावधी गुणाकार, GPU चं भाडं. Book 1, 7.8 चं bill आठवा: AI आल्यावर त्यात चौथी, जाड ओळ चढते: **token-खर्च**. या part नंतर ती ओळ तुम्हाला वाचता येईल.

स्वतः बघा (5 मिनिटं)

ChatGPT/Claude ला एक लांब प्रश्न विचारा आणि उत्तर **टपकताना** निरखा: वेग एकसारखा नाही: कधी सुरकन ओळ, कधी क्षणभर अडखळतं. आता तुम्हाला दिसतंय: प्रत्येक तुकड्यामागे एक पूर्ण चक्र आहे, आणि server वरची गर्दी (Book 1, 7.6!) चक्राचा वेग हलवते. आणि एक गंमत: उत्तर मध्येच थांबवा (Stop): यंत्राला काहीच “अपूर्ण” वाटत नाही: कारण त्याच्या जगात “पूर्ण उत्तर” नावाची गोष्टच नव्हती; फक्त पुढचा token होता.

विचार करा

1. (derivation) याच chapter च्या माहितीवरून: लांब उत्तरं महाग का, आणि “थोडक्यात सांग” ही सूचना bill वर थेट परिणाम का करते?

उत्तर: प्रत्येक output token = एक पूर्ण चक्र = अब्जावधी गुणाकार = GPU-वेळ. 1,000 tokens चं उत्तर म्हणजे 1,000 चक्रं; 100 चं म्हणजे 100. म्हणून output चा भाव input च्या 5-6 पट, आणि म्हणून “थोडक्यात सांग” ही सूचना चवीचा प्रश्न नाही; ती थेट खर्चाची कळ आहे. Business-नजर: AI-product बनवताना उत्तराची **लांबी** design करणं (गरजेपुरतं, यादी-रूप, मर्यादा) हे Book 1 च्या 7.8 इतकंच खरं cost-engineering आहे. जिलेबीची वेटीळी मोजून; थाळीने नाही.

Chapter 1.2 [SPINE]: हे विचार करतंय का?

मागच्या chapter चा शेवट एका खटकणाऱ्या जोडीवर झाला: काम इतकं साधं (“पुढचा token ओळख”), आणि निकाल इतका हुशार (कविता, code, सल्ला). मग तो जुना, टोचणारा प्रश्न: **हे खरंच विचार करतंय का?**

आधी Book 1 ची शिस्त लावू (1.3): तिथे आपण म्हणालो होतो “machine विचार करत नाही; recipe चालवते.” इथे ते वाक्य **तसंच्या तसं** चिकटवता येत नाही, आणि का ते महत्वाचं आहे: Book 1 च्या recipe मध्ये प्रत्येक “जर-तर” **कोणा माणसाने** लिहिलेलं होतं. इथल्या file मधले अब्जावधी numbers कोणी **लिहिले** नाहीत; ते **घडले** (कसे: Section 2). म्हणजे “हे फक्त program आहे” हे उत्तर अर्ध खरं आणि अर्ध आळशी आहे.

मग खरं उत्तर? आधी प्रश्नच तपासू. “विचार करणं” म्हणजे नक्की काय? थांबा आणि व्याख्या द्यायचा प्रयत्न करा... जमत नाही ना? माणसाकडे “विचार” ची पक्की व्याख्या **नाही**: आपण ती फक्त आतून ओळखतो. आणि ज्या प्रश्नात मोजता-न-येणारा शब्द आहे, तो प्रश्न वाद घालायला छान आणि **निर्णय घ्यायला निरुपयोगी** असतो.

म्हणून हे पुस्तक एक व्यापारी वळण घेतं, आणि हे वळण लक्षात ठेवा: **”विचार करतं का?” हा प्रश्न बदलून “काय जमतं आणि काय फसतं?” हा प्रश्न विचारायचा**. Crane उचलते ते हातापेक्षा हजारपट: पण ती “बलवान” आहे का, हा वाद कोणी घालत नाही; ती **कुठे** वापरायची आणि कुठे नाही, एवढंच बघतात. विमान उडतं: पक्ष्यासारखं पंख फडफडवून नाही, वेगळ्याच रस्त्याने: आणि “हे खरं उडणं आहे का” हा वाद हवाई-कंपनीच्या कामाचा नाही.

तरी दोन प्रामाणिक निरीक्षणं नोंदवून ठेवू, दोन्ही बाजूंची:

अस्वस्थ करणारी बाजू: “पुढचा token” नीट ओळखायचा तर बरंच काही आतून **जुळवावं** लागतं: “राम ने सीतेला सांगितलं की ____” पुढचा शब्द ओळखायला वाक्यरचना, कथा, कोण-कोणाला, हे सगळं धरावं लागतं. म्हणजे साधं-दिसणारं काम आत खोल रचना **मागतं**: म्हणून निकाल हुशार दिसतो.

जमिनीवर आणणारी बाजू: याच यंत्राला विचारा “strawberry मध्ये r किती?” आणि ते (अनेकदा) चुकतं: कारण ते **अक्षरं बघतच नाही** (chapter 1.6 चा धक्का). जिथे माणसाचं “विचार करणं” सहज जातं तिथे हे अडखळतं, आणि जिथे माणूस थकतो (हजार पानं क्षणात) तिथे हे उडतं. म्हणजे हे माणसाच्या विचाराची **नक्कल** नाही; ही **वेगळ्याच जातीची** क्षमता आहे: crane सारखी: काही ठिकाणी हातापेक्षा प्रचंड, काही ठिकाणी बोटांच्या नाजूकपणापुढे शून्य.

इथे लोक काय चुकीचं समजतात

दोन टोकं, दोन्ही महाग. **टोक 1:** “हे विचार करतं, समजतं, माझं मित्र आहे.” मग लोक त्याच्यावर न-तपासता भरवसा ठेवतात: चुकीचा कायदा-सल्ला, बनावट संदर्भ (Part 3 चा hallucination). **टोक 2:** “हे नुसतं पोपटासारखं जुळवतं, यात काही नाही.” मग लोक क्षमता कमी लेखतात आणि स्पर्धक पुढे निघून जातो. दोन्ही टोकं प्रश्न चुकल्यामुळे येतात: “विचार करतं का” विचारल्यामुळे. योग्य प्रश्न: **या कामावर, या यंत्राची चूक-दर किती, आणि चुकीची किंमत काय?** (Book 1, 4.2 ची testing-नजर: इथे ती AI वर लागू झाली.)

MAP वर

या तात्त्विक-वाटणाऱ्या प्रश्नावर खरा पैसा उभा आहे: जो founder “काय जमतं-काय फसतं” ची नेमकी यादी ठेवतो, तो AI योग्य जागी लावतो (जिथे चूक स्वस्त आणि वेग मोलाचा: पहिला draft, सारांश, शोध), आणि अयोग्य जागी टाळतो (जिथे चूक महाग आणि जबाबदारी कायद्याची: अंतिम हिशोब, औषधाचा doses). बाजारात दोन्ही चुकांचे मृतदेह पडले आहेत: “AI ने सगळं करू” वाल्या companies ग्राहकांच्या चुका-तक्रारींनी मेल्या; “AI म्हणजे खेळणं” वाल्या जुन्या companies वेगाने मागे पडल्या. Crane ची जागा ओळखणारा ठेकेदार जिंकतो.

स्वतः बघा (5 मिनिटं)

एकाच यंत्राला दोन कामं द्या: (1) “माझ्या टिफिन-business साठी 10 नावं सुचव, प्रत्येकाचं एक-ओळ कारण”: उत्तर बहुधा चमकदार असेल. (2) “938 x 47 किती?” tokens ने गुणाकार अडखळू शकतो: उत्तर आलं तरी एकदा calculator ने तपासा. दोन्ही अनुभव शेजारी ठेवा: हीच “वेगळी जात”: भाषेच्या पोताचं काम सहज; काटेकोर मोजणीचं काम बिनभरवशाचं. (का, ते 1.6 आणि Part 3 मध्ये पूर्ण उघडेल.)

विचार करा

- (derivation) “विचार करतं का?” ऐवजी “काय जमतं, काय फसतं?” हा प्रश्न व्यवहारात मोठा का आहे: एका वाक्यात तत्त्व, आणि एक तुमच्या धंद्यातलं उदाहरण.

उत्तर: तत्त्व: पहिल्या प्रश्नाचं उत्तर काहीही निघो, तुमचा **निर्णय** बदलत नाही; दुसऱ्याचं उत्तर थेट निर्णय आहे (कुठे लावायचं, कुठे माणूस ठेवायचा, तपासणी किती). उदाहरण: टिफिन-app मध्ये “ग्राहकांच्या तक्रारींना उत्तराचा पहिला draft” AI कडे (चूक स्वस्त: माणूस वाचून पाठवतो), पण “कोणाचे पैसे परत करायचे” चा निर्णय AI कडे कधीच नाही (चूक महाग, नियम कडक: Book 1, 6.4 ची मोजकी वस्तू). यंत्राचं तत्त्वज्ञान सोडा; त्याची **चूक-यादी** बाळगा.

Chapter 1.3 [SPINE]: शक्यता (probability) म्हणजे काय

Chapter 1.1 मध्ये एक शब्द चुपचाप घुसला होता: यंत्र पुढच्या token ची ”शक्यता” काढतं. हे पूर्ण पुस्तक त्या एका शब्दावर उभं आहे, म्हणून तो आज मुळापासून: शाळेच्या सूत्रांशिवाय.

सुरुवात रोजच्या वाक्यांपासून: “आज पाऊस **येईलसं वाटतंय.**” “हा संघ **बहुधा** जिंकेल.” “त्या रस्त्याने गेलो तर **कदाचित** जागा मिळेल.” माणूस दिवसभर अंदाजाच्या जगात जगतो; भाषेत त्याची मापं आधीच आहेत: नक्की > बहुधा > कदाचित > शक्यच नाही. **Probability म्हणजे या मापांना number देणं.** एवढंच.

Number द्यायची पद्धत एका पटीवर: **0 ते 1.** 0 = शक्यच नाही (“उद्या सूर्य पश्चिमेला उगवेल”: 0). 1 = नक्की (“उद्या सूर्य उगवेल”: 1). मध्ये सगळं जग: नाणं उडवलं तर छापा: 0.5 (अर्धा-अर्धा). फासा टाकला तर सहा: 1/6 म्हणजे ~0.17. आणि 0.9 म्हणजे “जवळजवळ नक्की, पण दार किलकिलं.”

पण हा number **येतो** कुठून? दोन रस्ते, दोन्ही तुम्हाला माहीत आहेत:

रस्ता 1: मोजून. दुकानदाराला विचारा: “उद्या किती ग्राहक येतील?” तो म्हणेल “दीडशे-पावणेदोनशे.” त्याने भविष्य बघितलं नाही; त्याने **मागचे** शंभर दिवस बघितले. Probability चा पहिला चेहरा: **खूप वेळा घडलेल्या गोष्टीत, प्रत्येक निकाल किती वेळा आला त्याचा हिस्सा.** 100 पैकी 30 दिवस पाऊस आला, तर उद्यासाठी “पावसाची शक्यता ~0.3” हा प्रामाणिक अंदाज.

रस्ता 2: वजनं जोखून. काही गोष्टी शंभरदा घडत नाहीत (“ही नवी match कोण जिंकेल?”). तिथे माणूस पुरावे जोखतो: खेळपट्टी, form, घरचं मैदान: आणि एक अंदाज बांधतो. हा दुसरा चेहरा: **मिळालेल्या माहितीच्या आधारे बांधलेला विश्वासाचा आकडा.**

आता या पुस्तकाशी जोड: Chapter 1.1 मध्ये यंत्राने “पुढच्या token ची यादी: प्रत्येकापुढे आकडा” दिली होती. तो आकडा हीच probability: “आज पाऊस ____” या रांगेपुढे: “पडेल” 0.61, “आहे” 0.19, “नाही” 0.08, “केळं” 0.000001. आणि यंत्राचा हा आकडा **रस्ता 1 चा** नातेवाईक आहे: internet-भर लिहिलेल्या **अब्जावधी** वाक्यांत, अशा रांगेनंतर कुठला शब्द **किती वेळा** आला, त्याचं (प्रचंड घोटून काढलेलं) रूप. दुकानदाराचे 100 दिवस; यंत्राचे trillions शब्द. (हे “घोटणं” कसं: Section 2.)

एक शेवटची, बारीक पण मोठी गोष्ट: **probability हे अज्ञानाचं प्रामाणिक माप आहे.** नाण्याला माहीत नसतं ते काय पाडणार; 0.5 हा **आपल्या** माहितीचा आकडा आहे. उद्याचा पाऊस “0.7” म्हणणारा hawamaan-khata खोटं बोलत नाही आणि भविष्यही सांगत नाही: तो आपल्या माहितीची मर्यादा **आकड्यात** कबूल करतो. हीच भाषा यंत्राची आहे: आणि पुढच्या chapter मध्ये या आकड्याचा “खरा अर्थ” काय, हे तपासू: कारण तिथेच बहुतेक लोक फसतात.

इथे लोक काय चुकीचं समजतात

”Probability म्हणजे अंदाज-पंचे, म्हणजे काहीही.” उलट: probability ही अंदाजाला **शिस्त** लावणारी भाषा आहे. “बहुधा जिंकू” म्हणणारे दोघं भांडू शकतात; “0.8 म्हणतोस की 0.55?” विचारलं की भांडण मोजता येतं, आणि (पुढचा chapter) नंतर **तपासताही** येतं. दुसरी चूक: 0.9 म्हणजे “नक्कीच.” नाही: 0.9 म्हणजे **दहापैकी एकदा उलट**: आणि दहापैकी-एकदा रोज घडतं. 90% खात्रीच्या दहा गोष्टी बोललात, तर एक चुकणारच: हे probability चं वचन आहे, अपयश नाही.

MAP वर

Probability ची भाषा येणं हे थेट पैशाचं कौशल्य आहे: विमा-company पूर्णपणे याच गणितावर जगते (लाखो पॉलिसींमध्ये कोण किती वेळा claim करतो), quick-commerce “20 मिनिटांत” चं वचन याच हिशोबावर देतं (95% वेळा जमतं म्हणून उरलेल्या 5% चं refund परवडतं), आणि तुमचा प्रत्येक AI-वापर या आकड्यांवर उभा आहे. Founder-नजर: जो “किती वेळा फसेल आणि तेव्हा काय” हा हिशोब आधी करतो, तो वचनं **विकू** शकतो; बाकीचे वचनांना **बुडतात**.

स्वतः बघा (5 मिनिटं)

आजच्या तुमच्या पाच अंदाजांना आकडे द्या: “meeting वेळेवर सुरू होईल: 0.4”; “संध्याकाळी वीज जाईल: 0.15”... लिहून ठेवा. उद्या ताडून बघा. दोन गोष्टी जाणवतील: (1) आकडा द्यायला भाग पडलं की विचार आपोआप धारदार होतो (“बहुधा” लपू देत नाही); (2) काही आकडे सपशेल चुकतात: आणि तिथेच पुढचा chapter सुरू होतो.

विचार करा

1. (derivation) यंत्राच्या token-यादीत “केळं” ला 0.000001 का मिळालं, 0 का नाही? आणि यातून यंत्राच्या स्वभावाबद्दल एक गोष्ट काढा.

उत्तर: कारण जगाच्या लिखाणात **कुठेतरी** कोणीतरी “आज पाऊस केळं” छपाची विचित्र रांग लिहिलेली असू शकते (विनोद, टंकलेखन, कविता!): मोजणीत शून्य क्वचितच येतो; फक्त **जवळजवळ**-शून्य येतो. यातून स्वभाव: यंत्राच्या जगात कुठलाही token “अशक्य” नसतो; फक्त कमी-जास्त शक्य असतो. म्हणूनच ते कधीही **काहीही** म्हणू शकतं. आणि म्हणूनच “हे असलं का बोललं?” चं उत्तर नेहमी “शक्यता कमी होती, शून्य नव्हती” हे असतं. हा धागा Part 3 च्या hallucination पर्यंत थेट जातो: गाठ बांधून ठेवा.

Chapter 1.4 [SPINE]: “70% chance” चा खरा अर्थ

Hawamaan-khata म्हणतं: “उद्या पावसाची शक्यता 70%.” उद्या पाऊस पडत नाही. मग खातं खोटं ठरलं का?

थांबा. या प्रश्नाचं उत्तर देता आलं, तर probability ची भाषा तुम्हाला खरंच आली; नाही आलं तर मागचा chapter फक्त वाचला गेला. विचार करा... उत्तर: **एका दिवसावरून काहीच ठरत नाही.** “70%” हे वचन **एका** उद्याबद्दल नाहीच; ते **अशा सगळ्या दिवसांबद्दल** आहे: खातं म्हणतंय: “मी जेव्हा-जेव्हा 70% म्हणतो, त्या दिवसांपैकी **सुमारे 70 टक्के** दिवशी पाऊस पडतो.” तपासणी अशी: खात्याचे गेल्या वर्षीचे सगळे “70%”-दिवस गोळा करा: शंभरपैकी 68-72 ला पाऊस पडला असेल, तर खातं **अचूक बोलतं**: त्या-त्या दिवशी काहीही घडो.

या गुणाला नाव आहे: **calibration** (आकडा आणि वास्तवाची जुळणी). आणि हे रोजच्या जगात तुम्ही आधीच वापरता: जो mistri “दोन दिवसांत होईल” म्हणतो आणि **दरवेळेस** चौथ्या दिवशी देतो, त्याचा “दोन” तुम्ही मनातल्या मनात “चार” करता: तुम्ही त्याचं calibration मोजलंत! भरवसा म्हणजे गोड बोलणं नाही; भरवसा म्हणजे **आकडे पाळणारं** बोलणं.

आता हेच यंत्राला लावा, दोन जागी:

जागा 1: token-यादीतले आकडे. यंत्र “पडेल: 0.61” म्हणतं तेव्हा ते चांगलं-calibrate झालेलं असेल तर अशा जागांपैकी ~61% वेळा खरंच “पडेल” योग्य ठरतो. Training चा मोठा हिस्सा (Section 2) हीच जुळणी घोटण्यात जातो: म्हणून यादीतले आकडे बरेच प्रामाणिक असतात.

जागा 2: यंत्राचं बोललेलं “मला खात्री आहे.” आणि इथे धोका! उत्तरातलं “नक्कीच, 100%!” हे **token-रांगेतले शब्द** आहेत: आतल्या यादीचे आकडे नाहीत. माणसांच्या लिखाणात आत्मविश्वासाची भाषा सर्रास असते, म्हणून यंत्र ती **शैली** सहज जन्माला घालतं: आतली खात्री न बघता. म्हणजे यंत्राचं “मला पक्कं माहीत आहे” हे mistri च्या “दोन दिवसांत होईल” सारखं वाचा: शैली, पुरावा नाही. (Part 3 मध्ये या फटीचं पूर्ण दुखणं: hallucination.)

आणि एक तिसरी, व्यवहाराची जागा: **निर्णय**. 70% म्हणजे “छत्री घ्या” का? ते शक्यतेवर नाही, **किमतीवर** ठरतं: छत्री नेण्याचा त्रास छोटा, भिजण्याचा (लग्नाचे कपडे!) मोठा: मग 30% लाही छत्री घ्याल. उलट picnic रद्द करणं महाग: मग 70% लाही जाल, plan-B घेऊन. **शक्यता x किंमत = निर्णय**: हे सूत्र Book 1 च्या “चुकीची किंमत” (4.2) चं भावंडं आहे, आणि AI वापरण्याचा प्रत्येक निर्णय याच सूत्रावर बसतो: चूक स्वस्त असेल तर 80% अचूक यंत्रही सोनं; चूक महाग असेल तर 99% वालाही एकटा सोडायचा नाही.

इथे लोक काय चुकीचं समजतात

तीन फसणुका: (1) “70% म्हटलं आणि झालं नाही = खोटं”: एका फेरीवरून calibration ठरत नाही; dhobi एकदा उशिरा आला म्हणून “नेहमी उशीर” ठरत नाही. (2) “50% म्हणजे त्याला काही माहीत नाही”: कधीकधी 50% हेच **सगळ्यात प्रामाणिक** उत्तर असतं (नाणां!); खोटी खात्री देणाऱ्यापेक्षा प्रामाणिक अर्धा-अर्धा बरा. (3) “यंत्र ठामपणे बोललं म्हणजे खरं असणार”: आत्ताच बघितलं: ती शैली आहे. तपासणीचा नियम पुढच्या parts मध्ये: **ठामपणा ऐकू नका; उगम विचारा.**

MAP वर

Calibration हा शब्द बाजारात थेट विकला जातो: hawamaan-सेवा शेतकरी- apps ना आपली **जुळणी-पत्रकं** दाखवून करार मिळवतात; विमा आणि credit-score चा पूर्ण धंदा “आमचे आकडे पाळले जातात” यावर आहे; आणि AI-products मध्ये आता हाच फरक विकला जातो: “आमचं यंत्र जिथे अडतं तिथे ‘माहीत नाही’ म्हणतं”: हे वाक्य enterprise- ग्राहकाला किंमतीपेक्षा जास्त आवडतं. तुमच्या product साठी नोंद: चुकीची कबुली ही feature आहे, weakness नाही.

स्वतः बघा (5 मिनिटं)

काल तुम्ही पाच अंदाजांना आकडे दिले होते (1.3 चं काम). आज ताडा: 0.8+ म्हटलेलं घडलं का? आठवडाभर हे चालू ठेवा आणि एक नमुना शोधा: बहुतेक माणसं **अति-आत्मविश्वासी** निघतात: त्यांचे “90%” प्रत्यक्षात ~70% वेळा घडतात. स्वतःचं calibration एकदा दिसलं की दुसऱ्यांचं (आणि यंत्राचं) मोजायची नजर आपोआप येते.

विचार करा

1. (derivation) तुमच्या टिफिन-app मध्ये AI उद्याच्या मागणीचा अंदाज देतो: “उद्या 180 डबे, शक्यता-पट्टा 160-200.” स्वयंपाक किती डब्यांचा करायला सांगाल: 160, 180, की 200? (सूत्र: शक्यता x किंमत.)

उत्तर: आधी दोन किमती लिहा: **कमी पडणं** = ग्राहक उपाशी, विश्वास तुटतो, वर्गणी रद्द होते (महागा!); **उरणं** = अन्न वाया, मोजका तोटा (स्वस्त-मध्यम). चुका सारख्या महाग नाहीत, म्हणून मधलं 180 हे “साहजिक” उत्तर चूक: पट्ट्याच्या **वरच्या** बाजूला झुका: ~195-200, आणि उरलेल्याचा रस्ता आधीच ठरवा (त्या-दिवशी- discount, दान). हेच सूत्र stock, staffing, server-क्षमता (Book 1, 7.6!) सगळीकडे: अंदाज कधीच एक आकडा नसतो; तो पट्टा असतो, आणि **झुकाव** चुकांच्या किमती ठरवतात. AI तुम्हाला पट्टा देईल; झुकाव ठरवणं हा founder चा पगार आहे.

Chapter 1.5 [SPINE]: पुढचा शब्द ओळखणं

एक खेळ खेळू. मी वाक्य अर्थ सोडतो; तुम्ही पुढचा शब्द ओळखा:

”सकाळी उठून त्याने चहा ____” (टाकला? केला? **प्यायला**.) “क्रिकेटमध्ये विराट ____” (कोहली.) “अतिथी देवो ____” (भव.)

सोपं गेलं ना? आता विचारा: तुम्ही हे **कसं** केलंत? कुठलं सूत्र लावलंत? काहीच नाही: आयुष्यभराच्या ऐकण्या-वाचण्यातून भाषेचे नमुने तुमच्यात **मुरलेत**; रिकामी जागा दिसताच योग्य शब्द स्वतः पुढे येतो. काही जागी एकच उत्तर घट्ट (“भव”): दुसरं काही बसूच शकत नाही, काही जागी सैल (“चहा घेतला/केला/प्यायला”): तीन-चार चालतील).

हा खेळ म्हणजे संपूर्ण ChatGPT/Claude आहे. अतिशयोक्ती नाही; नेमकी व्याख्या आहे: LLM (या यंत्रांचं जातीचं नाव: **Large Language Model**) म्हणजे हा खेळ **अति-प्रचंड** प्रमाणावर खेळणारं यंत्र: रांग बघा -> प्रत्येक शक्य पुढच्या token ची probability-यादी बनवा (मागचे दोन chapters!) -> एक निवडा -> रांगेत जोडा -> पुन्हा.

आता दोन प्रश्न, जे या साध्या चक्राला “बुद्धी” पर्यंत नेतात:

प्रश्न 1: यादीतून निवडायचं कसं? सगळ्यात वरचा (0.61 वाला) **नेहमी** घेतला तर? उत्तर नेहमी तेच, आणि विचित्र गोष्ट: भाषा **मेलेली** वाटते: सगळ्यात-शक्य शब्दांची न-संपणारी रांग म्हणजे सगळ्यात-सपक वाक्य. म्हणून यंत्र **फासे टाकतं**: यादीतल्या आकड्यांच्या प्रमाणात निवड: 0.61 वाला बहुधा, 0.19 वाला कधीकधी. या फाशांच्या मात्रेला बाजारात एक नाव आहे जे तुम्ही settings मध्ये बघितलं असेल: **temperature**: 0 = फासे बंद (दरवेळेस तेच: हिशोबी कामांना), जास्त = फासे मोकळे (विविधता, सर्जनशीलता: पण घसरण्याचाही धोका). स्वयंपाकाच्या हाताची चव: मोजून-मापून viruddh अंदाजपंचे.

प्रश्न 2: एवढ्याने कविता-code-सल्ला कसा निघतो? इथे या part ची सगळ्यात खोल ओळ: **खेळ नीट खेळायचा तर जगाची समज लागते.** “रुणाला ____ दिलं” ची जागा भरायला वैद्यकाची झलक लागते; “loop च्या शेवटी ____ लिहा” ला code ची; “तिच्या डोळ्यांत ____” ला कवितेची. पुढचा-शब्द हा खेळाचा **चेहरा** आहे; खेळ जिंकायला मात्र आतमध्ये जगाच्या नमुन्यांची प्रचंड लायब्ररी बांधावी लागते: आणि Section 2 मध्ये दिसेल की training म्हणजे नेमकं हीच लायब्ररी **घडवणं**. (तुम्ही रोज वापरता ती नावं: GPT-5.6, Claude 5, Gemini 3: सगळी याच एका खेळाची वेगवेगळ्या घराण्यांची रूपं.)

इथे लोक काय चुकीचं समजतात

”पुढचा शब्द ओळखणं म्हणजे नुसती नक्कल: पोपटपंची.” दोन उत्तरं: (1) “नुसती” काढून टाका: वरचा परिच्छेद: खेळ **नीट** खेळणं हीच समज मागते. (2) पण उलट टोकही नको: यंत्र “पुढे काय **बोलावं**” शिकलं आहे; “काय **खरं** आहे” हा वेगळा प्रश्न आहे: खोटी बातमीही व्याकरणात चोख असते. भाषेचा प्रवाह आणि सत्याची तपासणी या दोन वेगळ्या गोष्टी आहेत: हा फरक Part 3 चं हृदय आहे. आत्ता एवढं लक्षात: **हे यंत्र भाषेचं आहे; सत्याचं खातं वेगळं उघडावं लागतं.**

MAP वर

”पुढचं ओळखणं” ही कल्पना भाषेआधीच पैसा छापत होती: तुमच्या phone चा keyboard (पुढचा शब्द सुचवणं), Google चं search-भरणं, Amazon चं “हे घेणारे तेही घेतात”, YouTube चं पुढचं video: सगळं एकच घराणं: **मागचं बघून पुढचं ओळख.** LLM ने या घराण्याला भाषेचं पूर्ण राज्य दिलं, आणि आजचा आकडा बघा: एकट्या ChatGPT चे ~900 million साप्ताहिक वापरकर्ते (2026), आणि OpenAI ची वार्षिक कमाई \$25 billion पार: **जगातला सगळ्यात मोठा धंदा बनलेला शब्द-खेळ.** Founder-नजर: तुमच्या धंद्यात “मागचं बघून पुढचं” कुठे लागतं (मागणी? गिऱ्हाईक गळणं? पुढची खरेदी?): तिथे हेच घराणं कामाला लागतं.

स्वतः बघा (5 मिनिटं)

Claude/ChatGPT ला **तोच** प्रश्न तीनदा विचारा (नवीन chat मध्ये): “पावसावर दोन ओळी लिही.” तीन वेगळी उत्तरं येतील: ते temperature चे फासे तुम्ही बघताय. मग विचारा: “938 x 47?” तीनदा: इथे उत्तर (बहुधा) तेच येईल: हिशोबी जागी फासे आवळलेले असतात. एकाच यंत्राचे दोन मूड तुम्ही उघड्या डोळ्यांनी बघितलेत.

विचार करा

1. (derivation) तुमच्या typing-keyboard चं शब्द-सुचवणं आणि ChatGPT: दोघेही “पुढचा शब्द” ओळखतात. मग फरक नेमका कशात आहे, की एक चार-आण्याचं feature आहे आणि दुसरं \$25 billion चा धंदा?

उत्तर: फरक **किती मागचं बघून** ओळखतो यात. Keyboard शेवटचे दोन-तीन शब्द बघतो: म्हणून तो फक्त भाषेची **लय** पकडतो. LLM हजारो शब्दांची पूर्ण रांग बघतो: तुमचा पूर्ण प्रश्न, आधीच बोलणं, दिलेली file: आणि त्या **सगळ्याशी** सुसंगत पुढचा token काढतो. “किती मागचं” हा आकडा वाढवणं हीच गेल्या दशकाची क्रांती आहे: आणि “एवढं मागचं एकाच वेळेस बघायचं **कसं**” या प्रश्नाचं उत्तर म्हणजे attention/transformer: Part 2 चा मुख्य नायक. गाठ बांधा: पुढच्या part चं दार इथून उघडतं.

Chapter 1.6 [SPINE]: हे अक्षरं बघतच नाही

एक जगप्रसिद्ध फजिती: लोकांनी या महाबुद्धिमान यंत्रांना विचारलं: “strawberry मध्ये r किती वेळा येतो?” आणि अनेक यंत्रं, अनेकदा, ठामपणे **चुकली** (“दोनदा”). हजार पानांचा कायदा क्षणात पचवणारं यंत्र, एका शब्दातली अक्षरं मोजू शकत नाही? हा विनोद नाही; ही **खिडकी** आहे: यातून यंत्राच्या डोळ्यांत बघता येतं.

उत्तराची किल्ली Chapter 1.1 च्या पहिल्या पावलात होती: तुमचं वाक्य **तुकड्यांत** कापलं जातं, आणि तुकड्याला token म्हणतात. आता खरा धक्का: **token = अक्षर नाही, token = शब्दही नाही**. Token म्हणजे **वारंवार एकत्र येणारा अक्षर-गट्टा**: इंग्रजीत “straw” + “berry” असे दोन tokens होऊ शकतात; “the” एक token; “un-believ-able” तीन. आणि कापल्यावर प्रत्येक गट्ट्याला फक्त एक **number** मिळतो (Book 1, 2.2 चं encoding): “strawberry” = समजा [8975, 19772].

आता फजिती उलगडली: यंत्राच्या जगात “strawberry” हा शब्द r-अक्षरांनी बनलेलाच **नाही**; तो दोन numbers नी बनलाय. त्याला r “दिसणार” कुठून? तुम्हाला एखादं गाणं आठवतं पण त्यातल्या “क” ची मोजणी विचारली तर थांबून, उलगडून मोजावं लागतं: यंत्राकडे ते “उलगडणं” मूळ रूपात नाहीच. **यंत्र जग tokens च्या चष्म्यातून बघतं, आणि चष्म्याच्या खालचं त्याला अंधारं आहे.**

या चष्म्याचे अजून तीन परिणाम, तिन्ही तुमच्या रोजच्या वापराशी जोडलेले:

1. हिशोब अडखळतो. “938 x 47” हे यंत्रासाठी अंकांची गणित-पट्टी नाही; ते token-गट्टे आहेत (“938”, “x”, “47”). गुणाकाराचं उत्तर “पुढचा token ओळखून” काढणं म्हणजे पाढे न शिकता उत्तराचा **चेहरा** आठवणं. छोटे हिशोब जमतात (लाखो वेळा बघितलेत); मोठे घसरतात. (उपाय Part 3 मध्ये: यंत्राला calculator **देणं**: tools.)

2. मराठी महाग पडते. Tokenizer (कापणारा) मुख्यतः इंग्रजी लिखाणावर घडला आहे: इंग्रजीचे नेमके गट्टे त्याला पाठ आहेत. देवनागरी मजकूर तो बारीक-बारीक तुकड्यांत कापतो: **तोच मजकूर मराठीत इंग्रजीपेक्षा दीड ते तीन पट जास्त tokens खातो** (yantra- निहाय फरक; नवे tokenizers सुधारतायत). आणि bill tokens वर आहे (1.1)! म्हणजे भारतीय भाषांचा AI-वापर आज अक्षरशः **महाग** आहे: हे अन्याय-गणित पुढे (Part 3, पैसा-नकाशा) परत येईल.

3. Spelling-खेळ, उलटे शब्द, श्लेष. “palindrome आहे का,” “शब्द उलटा लिहून दाखव”: अक्षर-पातळीचे खेळ चष्म्याखाली आहेत: यंत्र अंदाजाने खेळतं, हमखास नाही.

मोठा धडा या chapter चा: **यंत्राच्या चुका यादृच्छिक (random) नाहीत; त्या त्याच्या चष्म्याच्या आकाराच्या आहेत.** चष्मा कळला की चुका **आधीच** सांगता येतात: आणि “कुठे भरवसा, कुठे नाही” ची यादी (1.2 चं वचन) इथून भरायला सुरुवात होते.

इथे लोक काय चुकीचं समजतात

”अरे, अक्षरंही मोजता येत नाहीत: म्हणजे सगळं ढोंग आहे.” उलटी गल्लत: crane ला (1.2) सुई ओवता येत नाही म्हणून तिची उचल खोटी ठरत नाही. चूक यंत्राची नाही; **अपेक्षेची** आहे: आपण माणसाच्या चुकांचा नकाशा यंत्रावर लावतो (जे माणसाला सोपं ते यंत्राला सोपं असणार): आणि हे यंत्र माणसाच्या **वेगळ्याच** जागी सोपं-अवघड अनुभवतं. नवा सहकारी आला की त्याची बलस्थानं शिकतो तसं: या सहकाऱ्याचा resume हा chapter आहे.

MAP वर

Token हे AI-अर्थव्यवस्थेचं **litre/kg** आहे: सगळी बिलं, सगळ्या मर्यादा (context window: एका वेळेस किती tokens मावतात: आजच्या मोठ्या यंत्रांत million-दोन million पर्यंत), सगळे भाव याच एककात. आणि “मराठी महाग” चा उलटा अर्थ धंद्याची जागा आहे: भारतीय भाषांसाठी नेमके tokenizers/यंत्रं बनवणं यावर सरकार (Bhashini) आणि startups दोघे लागले आहेत: जिथे एकक महाग, तिथे स्वस्त करणारा कमावतो (Book 1, 5.3: जो रस्ता स्वस्त करतो तो जिंकतो).

स्वतः बघा (5 मिनिटं)

Claude/ChatGPT ला विचारा: “strawberry मध्ये r किती?” मग: “आता अक्षरा-अक्षराने सुटं लिहून मोज.” दुसऱ्या पद्धतीत ते बहुधा बरोबर येईल: कारण सुटं लिहिल्यावर प्रत्येक अक्षर **स्वतंत्र token** बनतं: तुम्ही यंत्राला चष्मा उतरवायला लावलात! हीच युक्ती मोठ्या रूपात “step by step विचार कर” म्हणून भेटेल (Part 3): अवघड गोष्ट tokens मध्ये **उलगडायला** लावणं.

विचार करा

- (derivation) चष्म्याचं तत्त्व धरून **आधीच** सांगा: खालच्या चार कामांपैकी कुठली दोन यंत्र सहज करेल, कुठली दोन अडखळेल? (अ) इंग्रजी email चा मराठी सारांश; (ब) 17-अंकी दोन संख्यांची बेरीज; (क) “टमाटर” उलटा लिहिणं; (ड) तुमच्या टिफिन-app च्या तक्रार-mail चं उत्तर-draft.

उत्तर: सहज: (अ) आणि (ड): दोन्ही token-पातळीची, अर्थ-प्रवाहाची कामं: चष्म्याच्या **वरची**: हीच याची जात. अडखळेल: (ब) आणि (क): दोन्ही अक्षर/अंक-पातळीची, चष्म्याच्या **खालची**: नेमकेपणा tokens च्या ठोकळ्यांत हरवतो. आणि खरा धडा नियमात: **काम “अवघड की सोपं” हे माणसाच्या मोजपट्टीने ठरवू नका; “चष्म्याच्या वर की खाली” या मोजपट्टीने ठरवा.** ही एक ओळ तुम्हाला 90% AI-फजित्यांपासून वाचवेल: आणि उरलेल्या 10% साठी Part 3 आहे.

Chapter 1.7 [DEPTH]: Tokens बनतात कसे

(DEPTH chapter. वगळतात तरी पुढचं अडत नाही; पण हा छोटा आहे, आणि “कापणारा चष्मा नेमका घडतो कसा” हे एकदा बघितलं की मागच्या chapter चे सगळे परिणाम **आपोआप** आठवतात: पाठ करावे लागत नाहीत.)

समजा कापण्याचं काम तुमच्यावर आलं. जगभरचा मजकूर numbers च्या वहीत बसवायचा आहे. दोन सोपे रस्ते आधी तपासू, दोन्ही फसतात:

रस्ता 1: प्रत्येक अक्षर = एक token. वही छोटी राहील (काही शे चिन्हं). पण प्रत्येक शब्द 5-10 tokens: रांगा प्रचंड लांब, आणि यंत्राची “एका वेळेस बघण्याची” खिडकी (context) tokens मध्ये मोजली जाते: म्हणजे खिडकीत **मजकूर** कमी मावेल. शिवाय अर्थ अक्षरांत विखुरतो: “पाणी” ची ओळख प-ा-ण-ी अशा चार ठिपक्यांत वाटली जाते.

रस्ता 2: प्रत्येक शब्द = एक token. अर्थ नीट गोळा राहतो. पण वही किती मोठी? जगातल्या सगळ्या भाषांचे सगळे शब्द, नावं, typos, नवे शब्द (“selfie” 2010 त नव्हता)... वही कोटींची, आणि तरी रोज नवा शब्द **वहीबाहेर**: त्याला number नाहीच: यंत्र आंधळं.

मग खरा रस्ता, आणि तो सुंदर आहे: **वारंवारतेने कापा**. सुरुवात अक्षरांपासून करा; मग जगाचा मजकूर बघा आणि विचारा: “कुठली **जोडी** सगळ्यात जास्त वेळा शेजारी येते?” (इंग्रजीत समजा t+h.) ती जोडी **चिकटवा**: “th” आता एक token. पुन्हा मोजा, पुन्हा चिकटवा: “th”+ “e” = “the”... हे हजारो वेळा केलं की वही आपोआप घडते: वारंवार येणारे गट्टे (शब्द, शब्दांश) **अखंड** राहतात; दुर्मिळ शब्द तुकड्यांत (“un”+“believ”+“able”): पण **कधीच वहीबाहेर नाही**, कारण शेवटी अक्षरांपर्यंत तोडता येतंच. या पद्धतीचं नाव **BPE** (byte-pair encoding); आजच्या यंत्रांच्या वह्या ~50,000 ते ~250,000 tokens च्या असतात.

ओळखीचं वाटतंय? **हीच Book 1 ची जुनी युक्ती आहे**: compression (2.2 चा विचार-प्रश्न: “अर्थ वाचवा, numbers फेका”) आणि cache (6.6: “वारंवार लागतं ते जवळ ठेवा”) यांची बहीण: **वारंवार येतं ते अखंड ठेवा; दुर्मिळ ते तोडून भागवा**. लघुलिपी (shorthand) लिहिणारे कारकून हेच करायचे: “आणि” ला एक झटका, दुर्मिळ नावाला पूर्ण अक्षरं.

आणि आता मागच्या chapter ची “मराठी महाग” गाठ आपोआप सुटते: वही **कुठल्या मजकुरावर** घडली यावर सगळं ठरतं. घडवताना इंग्रजी मजकूर 80-90% असेल, तर इंग्रजीचे गट्टे मोठे-अखंड, आणि देवनागरी दुर्मिळ म्हणून बारीक तुकडे: तोच अर्थ, दीड-तीन पट tokens, तेवढंच जास्त bill आणि तेवढीच खिडकी खाल्लेली. चष्मा तटस्थ नसतो; **तो ज्या जगावर घडला, त्या जगाला स्वस्त पडतो**.

इथे लोक काय चुकीचं समजतात

”Tokens म्हणजे यंत्राने भाषा ‘समजून’ केलेले शब्द-भाग असतील.” नाही: कापणी **निव्वळ मोजणीने** होते; व्याकरण-अर्थ कोणी बघत नाही. म्हणून कधीकधी हास्यास्पद तुकडे पडतात, आणि म्हणून अंक विचित्र कापले जातात (“2026” एक token, “2027” दोन: फक्त वारंवारतेच्या नशिबाने). आणि दुसरी गल्लत: “token-वही म्हणजेच model.” नाही: वही फक्त **दार** आहे: मजकूर numbers करण्याचं. खरा खेळ (त्या numbers चं पुढे काय होतं) अजून सुरूही झालेला नाही: तो Section 2 आणि Part 2.

MAP वर

कापणी boring वाटते, पण ती **धोरण** आहे: OpenAI/Anthropic/Google आपल्या वहा कुठल्या मिश्रणावर घडवतात यावर कुठली भाषा, कुठली programming-language स्वस्त पडणार हे ठरतं: code च्या यंत्रांत “ ” (चार spaces) सारखे गठ्ठे मुद्दाम अखंड ठेवले जातात: म्हणून code स्वस्त-नेमका. भारतासाठी हीच लढाई भाषेची आहे (Bhashini, देशी startups: 1.6 ची गाठ): **वही कोणाच्या हातात, हे “digital जकाती”चं नवं रूप आहे** (Book 1, 3.5 चा platform-धडा, आता token-पातळीवर).

स्वतः बघा (5 मिनिटं)

Claude/ChatGPT ला सांगा: “खालचं वाक्य tokens मध्ये कसं कापलं जाईल त्याचा अंदाज दे, आणि इंग्रजी भाषांतराचाही: ‘मला उद्या लवकर उठायचं आहे.’” अचूक कापणी यंत्र-निहाय वेगळी असते, पण नमुना दिसेल: मराठीचे तुकडे जास्त, इंग्रजीचे कमी. (खरी मोजणी बघायची असेल तर laptop वर “OpenAI tokenizer” शोधा: फुकट पान आहे: तिथे दोन्ही paste करून आकडे तपासा.)

विचार करा

1. (derivation) BPE ची कापणी **मोजणीने** होते, अर्थाने नाही: हे कळल्यावर सांगा: नवा brand-name (“Zomixo”) आणि रोजचा शब्द (“hotel”) यांच्या token-खर्चात फरक का पडेल, आणि याचा एक गमतीदार व्यावहारिक परिणाम काय?

उत्तर: “hotel” जगभर कोटीवेळा छापलाय: वहीत अखंड गठ्ठा = 1 token. “Zomixo” कुठेच नव्हता: तो “Z”+“om”+“ix”+“o” असा तुकड्यांत = 3-4 tokens. परिणाम: तुमच्या product चं **नाव** सुद्धा AI-युगात token-खर्च ठरवतं: apps च्या system-सूचनांमध्ये brand-name हजारो वेळा जातो, आणि 4-token नाव 1-token नावाच्या चौपट भाडं भरतं! (म्हणून काही AI-companies च्या आतल्या सूचना लघुरूपं वापरतात.) खोल धडा तोच: **या जगात “सामान्य असणं” स्वस्त आहे, “वेगळं असणं” महाग:** आणि कुठे वेगळं व्हायचं हे निवडणं (नावात नको; कामात हवं!) हीच founder-चतुराई.

SECTION 2: यंत्र शिकतं कसं

दहा chapters. Section 1 ने सांगितलं यंत्र काय करतं (पुढचा token). आता सगळ्यात मोठा प्रश्न: ते हे कुठून शिकलं? कारण Book 1 च्या जगात recipe माणूस लिहायचा: इथे अब्जावधी numbers कोणीच लिहिले नाहीत: ते घडले. कसे, ते हा section उघडतो: आणि इथेच “AI = जादू” ही भावना कायमची मरते.

हे तुमच्या business decision मध्ये कुठे येईल: AI ची प्रत्येक ताकद आणि प्रत्येक कमजोरी त्याच्या शिकण्याच्या पद्धतीतून येते: काय जमेल हे data ने ठरतं, काय फसेल हे data त काय नव्हतं याने. “आमचा स्वतःचा AI बनवू का?” या board-room प्रश्नाचं उत्तर training चा खर्च बघताच स्वतः मिळतं. आणि “AI तुमच्या धंद्याचा data शिकून मोठा होतो”: ही ओळ करारांमध्ये कोटींची आहे: ती वाचायची नजर इथून.

Chapter 2.1 [SPINE]: Rules की examples

एक जुनं, खरं युद्ध सांगतो: **spam**. Email आलं तेव्हा कचरा-mail ही आलं: “तुम्ही lottery जिंकलात!” आता हे आपोआप पकडायचं. Book 1 च्या पद्धतीने चला: recipe लिहा (1.3): “जर mail मध्ये ‘lottery’ असेल तर spam.” झालं?

आठवडाभरात spam-वाले शिकले: “lottery” लिहू लागले. नियम जोडा: “0 पण पकडा.” मग “मोफत बक्षीस” आलं. नियम जोडा. मग खऱ्या mails मरू लागल्या (“आमच्या शाळेच्या lottery-निकालाची यादी”: spam नाही!). अपवाद जोडा. दोन वर्षांत नियमांचं जंगल: कोणालाच पूर्ण कळत नाही, प्रत्येक दुरुस्ती दोन नव्या चुका काढते (Book 1, 4.1 च्या जोड्यांचा स्फोट), आणि शत्रू **रोज** नवा. Rules ची पद्धत इथे **हरते**: कारण “spam-पणा” हा नेमक्या नियमांत मावणारा गुण नाहीच: तो हजार बारीक खुणांचा **वास** आहे.

आता उलटी पद्धत, आणि ती तुमच्या घरातून घ्या: आजीला विचारा “चांगला आंबा कसा ओळखायचा?” ती नियम देईल: “देठाशी वास घे, रंग बघ...” पण खरं शिकणं नियमांनी होत नाही: ती म्हणते “**चल बाजारात, मी दाखवते.**” दहा चांगले, दहा नासके: हातात देते. पाचव्या बाजारा- नंतर तुम्ही ओळखता: आणि “कसं ओळखलंस” विचारलं तर सांगता येत नाही! नियम **सांगता** येत नाहीत, पण **मुरलेले** असतात.

हीच या section ची मूळ कल्पना: **program लिहिण्याऐवजी examples दाखवा**. Spam चं युद्ध असंच जिंकलं गेलं: लोकांनी नियम लिहिणं सोडलं आणि यंत्राला लाखो mails दाखवल्या, प्रत्येकीवर फक्त एक शिक्का: spam / spam-नाही. यंत्राने आतल्या आत हजार बारीक खुणांची **वजनं** जुळवली (कशी: chapter 2.3-2.6), आणि आजही तुमच्या inbox चं पहारेकरी हेच आहे. या पद्धतीच्या घराण्याचं नाव: **machine learning** (ML): “यंत्राला शिकवणं”: rules देऊन नाही, examples देऊन.

आणि आता दोन्ही पद्धती शेजारी ठेवा, कारण **दोन्ही जिवंत आहेत** आणि निवड हीच खरी विद्या:

RULES (Book 1 चं जग)
नियम माणूस लिहितो
चूक झाली तर नेमकं का ते
सापडतं (line दाखवता येते)
100% नेमकेपणा शक्य
जग बदललं की माणूस बदलतो
जिथे नियम स्पष्ट: हिशोब,
व्याज, GST

EXAMPLES (Book 2 चं जग)
वजनं data तून घडतात
चूक झाली तर “का” धूसर
“बहुधा बरोबर” (probability!)
जग बदललं की नवा data दाखवा
जिथे नियम सांगताच येत नाहीत:
चेहरा, आवाज, spam, भाषा

इथे लोक काय चुकीचं समजतात

”AI आलं म्हणजे आता सगळं ML नेच करायचं.” महाग गल्लत. व्याज मोजायला, GST लावायला, pass-fail ठरवायला examples **दाखवायचे नसतात**: तिथे नियम **आहेत**, स्पष्ट आहेत, आणि Book 1 ची recipe शंभर टक्के नेमकी चालते. ML तिथे आणणं म्हणजे “बहुधा बरोबर” व्याज: वेडेपणा. उलट चेहरा ओळखायला नियम लिहीत बसणं म्हणजे spam-युद्धाची पुनरावृत्ती. नियम-निवडीचं सूत्र एका ओळीत: **नियम सांगता येतो? लिहा (स्वस्त, नेमका). सांगताच येत नाही, पण examples मिळतात? शिकवा.**

MAP वर

ही निवड थेट खर्चाची आहे: rules-रस्ता = Book 1 चा नेहमीचा software-खर्च; examples-रस्ता = data गोळा करणं + शिकवे मारणं

- GPU-भाडं + “बहुधा” च्या चुकांची किंमत. म्हणून शहाण्या companies मिश्र बांधतात: UPI-fraud पकडणारी यंत्रणा बघा: **वास** ML घेतं (हजार खुणांतून “हा व्यवहार विचित्र आहे”: 0.92), पण **कृती** rules करतात (“0.9 च्या वर = थांबवा आणि माणसाकडे”): अंदाज यंत्राचा, अधिकार नियमाचा. तुमच्या product मध्येही हीच जोडी शोधा: ML ला नाक द्या; चावी देऊ नका.

स्वतः बघा (5 मिनिटं)

तुमच्या phone ची तीन ML-पहारेकरी आता कामावर आहेत: (1) Gmail/ mail चं spam-folder उघडा: हे chapter मधलं युद्ध, जिंकलेलं; (2) gallery त एका माणसाचं नाव शोधा: चेहरा-ओळख: नियमांत कधीच न मावणारं काम; (3) keyboard चं पुढचा-शब्द (1.5). तिन्हींना विचारा: “याचे नियम मी कागदावर लिहू शकलो असतो का?” तिन्हीचं उत्तर “नाही”: म्हणूनच तिथे ML आहे.

विचार करा

1. (derivation) तुमच्या टिफिन-app साठी चार कामं: (अ) महिन्याचं bill मोजणं; (ब) तक्रारीच्या mail चा सूर ओळखणं (रागीट/सौम्य); (क) “उद्या नको” ची नोंद लागू करणं; (ड) उद्याच्या मागणीचा अंदाज. कुठलं rules, कुठलं examples: आणि का?

उत्तर: (अ) आणि (क): **rules.** नियम स्पष्ट आहेत (दर x दिवस; नोंद = वगळा), आणि “बहुधा बरोबर bill” ही कल्पनाच अमान्य (Book 1, 6.4 ची शुद्धता). (ब) आणि (ड): **examples.** “रागीट सूर” चे नियम लिहिता येत नाहीत: पण शिक्के मारलेल्या शंभर mails दाखवता येतात; मागणीचा अंदाज म्हणजे इतिहासातल्या नमुन्यांचा वास (1.4 चा पट्टा). आणि मिश्र-जोडी विसरू नका: (ब) चा अंदाज ML देईल, पण “रागीट ग्राहकाला 10% सूट द्या” ही **कृती** नियमानेच: अंदाज यंत्राचा, अधिकार नियमाचा, जबाबदारी तुमची.

Chapter 2.2 [SPINE]: अशी problem जी rules ने होतच नाही

मागच्या chapter मध्ये “नियम सांगता येत नाहीत” ही ओळ आली. आज तिचा पुरावा: एक problem आतून उघडून, जेणेकरून “का येत नाहीत” हे हाडात बसेल. Problem साधी वाटते: **या photo त मांजर आहे का?**

तुम्ही क्षणात सांगता; तीन वर्षांचं मूलही सांगतं. मग यंत्रासाठी नियम लिहू. आठवा photo म्हणजे काय (Book 1, 2.2): ठिपक्यांची जाळी, प्रत्येक ठिपका तीन numbers. 12 million ठिपके. आता लिहा नियम:

“जर कान टोकदार असतील...” थांबा: “कान” म्हणजे numbers च्या जाळीत काय? कुठले ठिपके कान? मांजर जवळ असेल तर कान 10,000 ठिपक्यांचा; लांब असेल तर 200 चा. वाकडं बसलंय: कान दिसतच नाही. अंधारात: सगळे numbers गडद. काळं मांजर काळ्या sofa वर. अर्ध पडद्यामागे. रेषा काढलेलं चित्र-मांजर. सिंहाचं पिल्लू (मांजर नाही, पण ठिपके जवळजवळ तेच!)...

दहा नियम लिहा: शंभर अपवाद निघतात. हजार लिहा: लाख निघतात. हे spam पेक्षा खोल आहे: spam मध्ये निदान शब्द तरी होते; इथे “मांजरपणा” आणि ठिपक्यांच्या numbers मध्ये कुठलाच सरळ पूल नाही. माणसाचं मन तो पूल क्षणात बांधतं: पण कसं ते माणसालाच सांगता येत नाही (आजीचा आंबा!). जे सांगता येत नाही, ते लिहिता येत नाही; जे लिहिता येत नाही, त्याची recipe नाही. **Rules ची पद्धत इथे अवघड नाही; अशक्य आहे.**

आणि आता डोळे उघडा: जग अशा problems नी भरलेलं आहे:

आवाज ऐकून शब्द ओळखणं (तोच शब्द: बाई-पुरुष-म्हातारा-घाईत-सर्दीत: लहरींचे numbers दरवेळेस वेगळे). अक्षर ओळखणं (तुमचं “अ” आणि माझं “अ”: वेगळे ठिपके, एक अर्थ). भाषांतर (“मन जड झालं” चं इंग्रजी: शब्दाशब्दाचे नियम मेले). रस्त्यावरचा खड्डा-सावली-फरक. X-ray तला संशयास्पद डाग. आणि... “या रांगेनंतर पुढचा token कुठला” (1.5): भाषेचा प्रवाह हीसुद्धा अशीच problem आहे: नियमांत कधीच न मावलेली. (1960 पासून 40 वर्ष लोकांनी व्याकरण-नियमांचे डोंगर रचून भाषांतर-यंत्रं बांधली: निकाल विनोदी होते. जुने “Hindi translation” चे घोटाले आठवा.)

या सगळ्या problems चं एक कुळ आहे, आणि कुळाची खूण ही: **input मध्ये “काय आहे” हे ठरवणारी गोष्ट कुठल्या एका-दोन numbers मध्ये नसते; ती लाखो numbers च्या एकत्रित नमुन्यात (pattern) पसरलेली असते.** माणसाचा मेंदू असे नमुने पकडण्यात राजा आहे: आणि नेमकं तेच त्याला सांगता येत नाही. म्हणून पुढचं पाऊल अटळ आहे: नियम मागू नका; **examples मधून नमुना यंत्रालाच उचलू द्या.** कसा: पुढचा chapter.

इथे लोक काय चुकीचं समजतात

”क्षणात जमतं म्हणजे सोपं असणार.” माणसाची सगळ्यात जुनी मोजपट्टी- चूक (1.6 चं भावंडं). उलट नियम आहे: **जे माणसाला विचार न करता जमतं (बघणं, ऐकणं, चालणं, बोलणं), ते यंत्राला सगळ्यात अवघड; जे माणसाला घाम फोडतं (हिशोब, बुद्धिबळाची मोजणी), ते यंत्राला सगळ्यात सोपं.** कारण: “विचार न करता” म्हणजे लाखो वर्षांच्या उत्क्रांतीने **मुरवलेलं**: आणि मुरलेलं सांगता येत नाही. या उलट्या नियमाला AI-जगात Moravec चा विरोधाभास म्हणतात; नाव विसरलात तरी नियम विसरू नका.

MAP वर

हे कुळ ओळखता येणं म्हणजे बाजार ओळखता येणं: गेल्या दशकात जिथे- जिथे “नमुन्याची problem” होती तिथे-तिथे ML घुसलं आणि जुनी rules-यंत्रं मेली: भाषांतर (Google Translate), चेहरा (phone-unlock), आवाज (voice-typing), आणि आता भाषा स्वतः (ChatGPT). Founder-नजर: तुमच्या उद्योगात असं कुठलं काम आहे जिथे आजही माणूस “बघून/ऐकून/वाचून ठरवतो” आणि नियम कोणालाच लिहिता आले नाहीत? (शेतातल्या पानावरचा रोग? कापडाचा दोष? Loan-अर्जातला धोका?) ते काम या कुळाचं आहे: आणि तिथे संधी उभी आहे.

स्वतः बघा (5 मिनिटं)

एक खेळ: घरातल्या कोणाला म्हणा, “मला ‘खुर्ची ओळखण्याचे’ नियम सांग: असे की परग्रहावरचा माणूस त्यावरून खुर्ची ओळखेल.” “चार पाय, बसायची जागा, पाठ”: मग दाखवा: तीन पायांची stool? पाठ नसलेली? झुला? bean-bag? पाच मिनिटांत नियम कोसळतात: आणि तरी घरातलं मूल प्रत्येक खुर्ची बिनचूक ओळखतं. “सांगता न येणारं ज्ञान” म्हणजे काय, हे एकदा **खेळून** बघितलं की हा chapter कायमचा तुमचा.

विचार करा

- (derivation) “input च्या लाखो numbers मध्ये पसरलेला नमुना” ही खूण वापरून ठरवा: (अ) “PAN-card चा number वैध आहे का” आणि (ब) “PAN-card च्या **photo** तून number वाचणं”: कुठलं rules चं काम, कुठलं या कुळाचं?

उत्तर: (अ) **rules:** PAN चा ढाचा ठरलेला आहे (5 अक्षरं + 4 अंक + 1 अक्षर): दहा ओळींची recipe, 100% नेमकी. (ब) **या कुळाचं:** photo म्हणजे ठिपक्यांचे लाखो numbers: प्रकाश, कोन, धूसरपणा, बोट्यांची सावली: “P कुठे आहे” हे कुठल्याच एका number मध्ये नाही. म्हणून खरी systems दोन्ही जोडतात: photo तून मजकूर ML वाचतं, मग ढाचा rules तपासतो: नमुन्याचं काम नमुन्याच्या यंत्राला, नियमाचं काम नियमाला (2.1 ची जोडी, पुन्हा सिद्ध). तुमच्या business मधल्या कुठल्याही कामाला हीच फोड लावा: आत दोन्ही जाती सापडतील.

Chapter 2.3 [SPINE]: चुकत-चुकत शिकणं

नियम लिहायचे नाहीत, examples दाखवायचे: ठरलं. पण “दाखवणं” म्हणजे यंत्रात नेमकं काय घडणं? आज तो पडदा उघडायचा: आणि मागचं सगळं पुस्तक ज्या क्षणासाठी होतं, तो क्षण हा आहे: **शिकणं म्हणजे काय, याची यांत्रिक व्याख्या.**

सुरुवात सायकलपासून. सायकल तुम्ही **पुस्तकाने** शिकलात का? नाही: बसलात, पडलात, सावरलात. आणि नीट बघा त्या शिकण्याचं चक्र काय होतं: **प्रयत्न -> चूक जाणवली (डावीकडे कलतोय!) -> उलट दिशेने छोटी दुरुस्ती -> पुन्हा प्रयत्न.** हजार फेऱ्या: आणि एक दिवस चक्र इतकं मुरलं की “कसं जमतं” सांगताही येत नाही (आजीचा आंबा, पुन्हा). कोणी नियम दिले नाहीत; **चुकीनेच शिकवलं.**

आता हेच चक्र यंत्रात. आठवा: यंत्राच्या आत फिरवण्यासारखं काय आहे? Numbers: ती **वजनं** (weights) ज्यांचा उल्लेख 2.1 मध्ये आला (पूर्ण ओळख पुढच्या chapter मध्ये; आत्ता एवढं पुरे: यंत्राचं वागणं आतल्या कोट्यवधी फिरत्या-काट्यांवर अवलंबून आहे: radio च्या tuning-काट्यांसारखे). मग शिकण्याचं चक्र असं:

पाऊल 1: अंदाज. मांजराचा photo आत घाला. सुरुवातीला वजनं **random** आहेत (हो: सुरुवात पूर्ण अडाणीपणापासून!). यंत्र म्हणतं: “मांजर: 0.31.” चुकीचं, बावळट उत्तर.

पाऊल 2: चूक मोजा. बरोबर उत्तर आपल्याकडे आहे (शिकका: “मांजर = 1”). अंतर: $1 - 0.31 = \text{बरंच.}$ (चूक **मोजता** येते हा साधा- दिसणारा मुद्दा प्रचंड आहे: chapter 2.5.)

पाऊल 3: उलट दिशेने छोटी दुरुस्ती. प्रत्येक वजनाला विचारा: “तू जरा वर-खाली झालास तर ही चूक वाढते की घटते?” आणि प्रत्येकाला चूक **घटेल** त्या दिशेने एक **केसभर** सरकवा. (कोट्यवधी काटे एकदम, प्रत्येक स्वतःच्या दिशेने: हे “कसं जमतं” chapter 2.6.)

पाऊल 4: पुढचा example. पुन्हा. पुन्हा. लाखो photos, कोट्यवधी फेऱ्या. प्रत्येक फेरीत वजनं केसा-केसाने सरकतात... आणि हळूहळू, कोणीही नियम न लिहिता, “मांजरपणाचा” नमुना वजनांमध्ये **मुरतो.**

हेच machine learning चं संपूर्ण हृदय आहे. मोठ्याने वाचा: **अंदाज करा, चूक मोजा, वजनं चूक-घटेल-तिकडे केसभर सरकवा, पुन्हा.** Spam-पहारेकरी असाच घडला. चेहरा-ओळख अशीच. आणि ChatGPT? नेमकं हेच चक्र, फक्त example वेगळा: जगभरच्या मजकुरातलं वाक्य घ्या, शेवटचा token झाका, यंत्राला ओळखायला लावा (1.5 चा खेळ!), खरा token दाखवून चूक मोजा, वजनं सरकवा. **Trillions वेळा.** शिकके मारायला माणूसही नको: पुढचा token मजकुरातच लपलेला आहे: internet स्वतःच स्वतःची उत्तरपत्रिका आहे. (म्हणूनच हे यंत्र इतकं मोठं होऊ शकलं: शिक्षक फुकट होता.)

आणि आता 1.2 च्या प्रश्नाचं अर्थ उत्तर मिळालं: Book 1 ची recipe **कोणी लिहिली नाही** म्हणजे काय? म्हणजे: माणसाने फक्त **चक्र** बांधलं (हे chapter) आणि **examples** पुरवले; वजनांची अंतिम जुळणी: ती कोट्यवधी चुकांच्या घासण्याने **घडली**. कुंभाराचं मडकं आठवा: कुंभार बोटानी प्रत्येक वळण “design” करत नाही; चाक फिरतं, मातीवर हजारदा हलका दाब पडतो, आणि आकार **घडत जातो**. दाब = चूक-दुरुस्ती; माती = वजनं; मडकं = model.

इथे लोक काय चुकीचं समजतात

“शिकतं म्हणजे समजून घेतं, नोंदी करतं, लक्षात ठेवतं.” आता तुम्हाला दिसतंय: शिकणं = **वजनांचं सरकरणं**. यंत्र photos “आठवणीत साठवत” नाही (database नाही!: Book 1, 6.1 शी गल्लत नको); photos चा **दाब** वजनांवर उमटतो आणि photos फेकल्या जातात. म्हणूनच यंत्राला “तू कुठून शिकलास हे दाखव” म्हणता येत नाही: मडक्याला “कुठला दाब कुठे आहे” विचारण्यासारखं आहे. आणि दुसरी गल्लत: “चुकतंय म्हणजे खराब आहे.” उलट: **चूक हेच इंधन आहे**: चुकल्याशिवाय वजनं सरकतच नाहीत. (हे वाक्य माणसांनाही लागू आहे, पण ते वेगळं पुस्तक.)

MAP वर

हे चक्र समजलं की AI-जगाचा खर्च-नकाशा उघडतो: चक्राची एक फेरी स्वस्त, पण फेऱ्या **trillions** आणि प्रत्येकीत कोट्यवधी वजनांची गणितं: म्हणून GPU ची भूक, म्हणून frontier-model च्या एका training-धावेचा खर्च आज \$100 million ते \$1 billion च्या घरात, म्हणून Nvidia (चक्र फिरवणारी चाकं विकणारी) जगातली सगळ्यात मौल्यवान company: ~\$5.5 trillion (Aug 2026). Book 1, 5.3 चा नियम पुन्हा: नवा रस्ता बनतो तेव्हा यंत्रं विकणारा पहिला श्रीमंत होतो. आणि तुमच्यासाठी: चक्र **चालवणं** महाग; चक्राने **घडलेलं** वापरणं स्वस्त (tokens चं भाडं: 1.1): हीच पुढच्या सगळ्या “बनवू की भाड्याने” निर्णयांची जमीन (chapter 2.10).

स्वतः बघा (5 मिनिटं)

तुमच्या phone चा keyboard **तुमच्याबद्दल** शिकलेला आहे, याच चक्राने: तुम्ही सुचवलेला शब्द नाकारून दुसरा टाईप करता = चूक- संकेत = त्याची वजनं केसभर सरकतात. तपासा: मित्राच्या phone वर तेच अर्थ वाक्य टाईप करा: सुचवण्या **वेगळ्या** येतील: दोन यंत्रं, दोन चुका-इतिहास, दोन जुळण्या. आणि आता एक जुनी सवय नव्या अर्थाने: चुकीची सुचवणी आली की ती **दुरुस्त** करणं म्हणजे तुम्ही शिक्षक आहात: प्रत्येक दुरुस्ती एक धडा.

विचार करा

1. (derivation) चक्रात “बरोबर उत्तर” (शिवका) लागतंच: मग LLM ला trillions शिवके कोणी मारले? आणि याच युक्तीने तुमच्या टिफिन-app च्या मागणी-अंदाजाला (2.1 मधलं example-काम) शिवके कुठून मिळतील: फुकट?

उत्तर: LLM चा शिवका मजकुरातच लपलेला असतो: “पुढचा token” झाकून ओळखायला लावा; खरं उत्तर वाक्यातच आहे: **जग स्वतःच स्वतःची उत्तरपत्रिका** (self-supervised याचं इंग्रजी नाव). तुमच्या app मध्येही तीच सोय आहे: आज केलेला “उद्याच्या मागणीचा अंदाज” उद्या संध्याकाळी **खऱ्या** मागणीशी ताडता येतो: शिवका आपोआप, रोज, फुकट. म्हणजे धंदा चालू ठेवणं = शिववणी चालू ठेवणं. Founder-धडा: product अशी बांधा की **वापरातूनच शिवके जन्मतील** (अंदाज-मग-खरं-उत्तर ही जोडी जिथे आपोआप बनते ती जागा शोधा): मग तुमचं यंत्र रोज फुकट हुशार होत जातं: आणि हेच ते “data चं चक्र” ज्यावर मोठ्या companies बसल्या आहेत.

Chapter 2.4 [SPINE]: यंत्र प्रत्यक्षात ठेवतं काय

मागच्या chapter पासून “वजनं” हा शब्द फिरतोय: आता त्याला समोर बसवून नीट बघू. कारण इथेच या पुस्तकातलं सगळ्यात अविश्वसनीय वाक्य आहे: **ChatGPT जे-जे “जाणतं”: भाषा, इतिहास, code, तुमच्या शहराची माहिती: ते सगळं म्हणजे फक्त numbers ची एक प्रचंड यादी.** वाक्यं नाहीत, नोंदी नाहीत, नियम नाहीत: **फक्त numbers.**

वजन (weight) म्हणजे काय, ते एका ओळखीच्या जागेतून घ्या: mixer च्या आवाजावरून “काय वाटतंय” ओळखणारी आजी. ती (नकळत) अनेक खुणा **जोखते**: आवाजाचा जाडपणा, थरथर, वास... आणि प्रत्येक खुणेला तिच्या अनुभवात एक **महत्त्व** आहे: आवाज-जाडपणा खूप सांगतो (महत्त्व मोठं), वास कमी (लहान). निर्णय = खुणा x महत्त्व यांची एकत्रित बेरीज. **वजन = खुणेचं महत्त्व सांगणारा number.** ML चं शिकणं (2.3) म्हणजे हीच महत्त्व चुकांमधून जुळवणं.

आता प्रमाण बघा, कारण प्रमाणातच जादूचा उलगाडा आहे:

spam-पहारेकरी (जुना)	हजारो वजनं
चेहरा-ओळख	millions वजनं
छोटं भाषा-यंत्र	काही billion
आजची मोठी यंत्रं	शेकडो billions ते trillion+
(GPT-5.6, Claude 5, Gemini 3 च्या श्रेणी)	(नेमके आकडे companies सांगत नाहीत: धंद्याचं गुपित)

आणि हे ठेवलेलं **कुठे**? Book 1 च्या भाषेत: एक file. प्रत्येक वजन = 1-2 bytes (Book 1, 1.4!), म्हणजे 70 billion वजनांचं खुलं यंत्र (Llama-कुळ) ~ **140 GB ची file**: तुमच्या phone च्या storage एवढी: आत सगळं इंग्रजी-मराठी-code-विश्व दाबलेलं. ही file च ते ज्याला जग **model** म्हणतं (पूर्ण दर्शन chapter 2.10 ला).

पण थांबा: “इतिहास numbers मध्ये कसा मावतो?” इथे या chapter चा गाभा: **मावत नाही; मुरतो.** फरक समजण्यासाठी Book 1 चा database (6.1) शेजारी ठेवा:

DATABASE (Book 1)	वजनं (Book 2)
नोंद जशीच्या तशी साठते	नोंद साठत नाही; तिचा दाब
"ही नोंद दाखव" शक्य	वजनांवर उमटतो (कुंभाराचं मडकं)
delete करता येतं	"कुठून शिकलास" दाखवता येत नाही
जागा नोंदींसोबत वाढते	एक आठवण "पुसणं" जवळजवळ अशक्य
अचूक आठवण, मर्यादित समज	file तेवढीच: नवं शिकणं म्हणजे
	तीच वजनं पुन्हा घासणं
	धूसर आठवण, पसरलेली समज

म्हणजे यंत्राची "आठवण" ग्रंथालयासारखी नाही; **मुरलेल्या अनुभवा-** सारखी आहे: तुम्हाला दहावीचं पूर्ण पुस्तक आठवत नाही, पण त्याने घडवलेली समज बोटांत आहे. म्हणूनच यंत्र तपशिलात चुकतं-घडवतं (Part 3 चा hallucination इथे जन्मतो: **धूसर आठवण + प्रवाही भाषा = ठाम चूक**), आणि म्हणूनच नेमक्या नोंदी हव्या तिथे यंत्राला database **जोडावा** लागतो (Part 3: शोध-जोड). दोन्ही स्मरणं वेगळी; दोन्ही लागतात: Book 1 चं आणि Book 2 चं लग्न पुढे तिथेच.

इथे लोक काय चुकीचं समजतात

"ChatGPT च्या आत जगाचं एक मोठं Google-सारखं कपाट आहे." आता तुमच्याकडे नेमकं चित्र आहे: कपाट नाही, **जोखणारी यंत्रणा** आहे: कोट्यवधी tuning-काटे, चुकांनी जुळवलेले. याचे दोन थेट परिणाम रोजच्या वापरात: (1) "तू हे कुठे वाचलंस?" ला त्याचं उत्तर **घडवलेलं** असू शकतं: source आतमध्ये साठलेलाच नाही; (2) "माझा data delete कर" हे database ला जमतं, मुरलेल्या वजनांना जवळजवळ नाही: म्हणून "यंत्र आमच्या data वर शिकणार का" हा करार-प्रश्न इतका पेटलेला आहे (Section-opener ची ओळ: आठवते?).

MAP वर

वजनांची file हीच AI-युगाची सगळ्यात मौल्यवान **मालमत्ता** आहे: Book 1, 5.1 चा नियम आठवा ("ज्याच्याकडे data-मालमत्ता, त्याच्याकडे ताकद"): इथे मालमत्ता = घडलेली वजनं. म्हणून बाजारात दोन तट: **बंद-वजनं** (OpenAI, Anthropic, Google: file कोणाला देत नाहीत; फक्त API-भाडं: Book 1, 7.4 चा जमीनमालक) आणि **खुली-वजनं** (Meta चं Llama-कुळ, फ्रान्सचं Mistral, चीनचं DeepSeek: file download करा, स्वतःच्या server वर चालवा: Book 1, 3.7 चं open source, AI-रूपात). दोन्ही तटांचे धंदे-हिशोब वेगळे: पुढे (2.10 आणि Part 3) या निवडीचं पूर्ण गणित.

स्वतः बघा (5 मिनिटं)

यंत्राची “धूसर आठवण” उघड्या डोळ्यांनी बघा: Claude/ChatGPT ला विचारा: “ज्ञानेश्वरीची पहिली ओवी सांग.” मग: “तुकारामाचा एखादा प्रसिद्ध अभंग?” प्रसिद्ध गोष्टी (लाखो वेळा छापलेल्या: दाब खोल) बहुधा बरोबर येतील; मग विचारा एखादी **दुर्मिळ** गोष्ट: “अमुक तालुक्यातल्या तमुक गावची लोकसंख्या?” इथे उत्तर ठाम पण संशयास्पद येऊ शकतं: दाब उथळ, भाषा मात्र प्रवाही. खोल-दाब विरुद्ध उथळ-दाब हा फरक जाणवला की hallucination चं अर्थ रहस्य आत्ताच तुमच्या हातात आहे.

विचार करा

1. (derivation) 140 GB ची file, आणि तिच्या training-data चा आकार हजारो TB: म्हणजे file मूळ मजकुराच्या **हजारावा** हिस्सा. यातून यंत्राच्या स्वभावाबद्दल कुठला निष्कर्ष **अटळ** आहे? (Book 1, 2.2 चा compression-धडा आठवा: “अर्थ वाचवा, तपशील फेका.”)

उत्तर: हजारो TB चा मजकूर 140 GB त बसवायचा तर **जवळजवळ सगळे तपशील फेकावेच लागतात:** टिकतो तो फक्त **नमुना:** भाषेची लय, संकल्पनांची नाती, जगाची ढोबळ रचना. म्हणजे “यंत्र तपशिलात चुकणार” हा दोष नाही; तो या रचनेचा **अटळ गुणधर्म** आहे: lossy compression चं बोलकं रूप. आणि म्हणून उपायही रचनेतच आहे: नमुना यंत्राकडून घ्या (भाषा, मांडणी, अंदाज), तपशील बाहेरून जोडा (database, शोध, तुमची कागदपत्रं: Part 3). हा एक निष्कर्ष ज्याला पक्का कळला, तो AI वर “कधी विश्वास ठेवायचा” चं कोडं सोडवून बसला: उरलेलं पुस्तक या निष्कर्षाचा विस्तार आहे.

Chapter 2.5 [DEPTH]: चूक मोजणं

(DEPTH chapter. 2.3 च्या चक्रातलं “पाऊल 2” इथे उघडतो. वगळलात तरी गोष्ट पुढे जाईल; पण “यंत्रं नेमकं काय घोटतात” हे एकदा दिसलं की AI च्या बातम्यांमधला “loss कमी झाला” सारखा गूढ शब्दही सोपा होतो.)

2.3 चं चक्र आठवा: अंदाज -> **चूक मोजा** -> दुरुस्ती. आज मधल्या पावलावर थांबू, कारण त्यात एक न-दिसणारी अट लपली आहे: **मोजायचं तर चुकीला number द्यावा लागतो.** “जरा चुकलं” / “खूप चुकलं” अशा भावनेने वजनं सरकवता येत नाहीत: दिशा आणि मात्रा दोन्हीला आकडा हवा (Book 1 चं जुनं सत्य: machine ला exact लागतं).

सोपी सुरुवात: मागणी-अंदाज. यंत्र म्हणालं 180 डबे; खरे लागले 200. चूक = 20. सोपं: **अंतर हीच चूक.** (बारकावा: +20 आणि -20 दोन्ही “चूक 20” च; म्हणून व्यवहारात अंतराचा वर्ग किंवा निव्वळ-अंतर वापरतात: दिशा-भांडण मिटतं आणि **मोठ्या चुका जास्त झोंबतात**: वर्गामुळे 20 ची चूक 400 “दुखते”, 5 ची फक्त 25.)

पण भाषेचं काय? “आज पाऊस ___” इथे यंत्राने यादी दिली (1.3): “पडेल: 0.61, आहे: 0.19...” आणि खरा token निघाला “पडेल”. चूक किती? यंत्र “बरोबर” होतं... पण **किती खात्रीने बरोबर होतं?** इथे मोजपट्टी सुंदर आहे: **खऱ्या उत्तराला यंत्राने किती probability दिली होती, तेच बघा.** 0.61 दिली: बरी गोष्ट, छोटी चूक. 0.02 दिली असती (खरं उत्तर यादीत खोल गाडलेलं): मोठी चूक. म्हणजे भाषेच्या जगात **चूक = “खऱ्यावर किती कमी विश्वास ठेवलास.”** पूर्ण खात्री (1.0) = चूक शून्य; खऱ्याला जवळजवळ-शून्य देणं = चूक प्रचंड. (या मोजपट्टीचं इंग्रजी नाव **loss**; “loss कमी होतोय” = “यंत्र खऱ्या उत्तरांना जास्त-जास्त probability देतंय.”)

आणि आता या chapter चा खरा दात: **जे मोजाल, तेच घडेल.** चक्र आंधळेपणाने चूक-घटवत जातं: चुकीची **व्याख्या** चुकली, तर यंत्र चुकीच्याच दिशेने तरबेज होतं. तीन खरे नमुने:

नमुना 1: दुर्मिळतेचं कोडं. Fraud-पहारेकरी बांधताय; 1,000 व्यवहारांत 5 fraud. चूक-मोजणी = “किती उत्तरं बरोबर?” ठेवली, तर यंत्र एक **आळशी युक्ती** शिकतं: “सगळं-ठीक-आहे” म्हणत राहा: 99.5% बरोबर! चूक-मोजणीत fraud-चुकवण्याला शंभरपट दंड ठेवला, तरच नाक शिकतं. (Book 1, 4.2 ची आठवण: tests जे तपासतात तेच software “पाळतं”: इथे मोजपट्टी हीच test आहे.)

नमुना 2: उपाहाराचं माप (proxy). “चांगलं उत्तर” मोजता येत नाही, म्हणून सोपं माप घेतलं जातं: “user किती वेळ गुंतला.” आणि यंत्र गुंतवून-ठेवण्यात तरबेज होतं: भडकाऊ, चिकट, खरं-खोटं दुय्यम: social-media चे feed-algorithms हीच गोष्ट आहेत. माप सोपं घेतलं; जग महागात पडलं.

नमुना 3: मोजपट्टीची चोरी. शाळेत “गुण” हे शिक्षणाचं माप ठरलं की घोकंपट्टी जन्मते: माप गाठलं, हेतू सुटला. यंत्रंही नेमकं हेच करतात: याला Goodhart चा नियम म्हणतात: **”माप हेच लक्ष्य झालं की माप बिघडतं.”** AI-benchmarks (Part 3) वाचताना हा नियम सोबत ठेवा.

इथे लोक काय चुकीचं समजतात

”यंत्रं ‘हुशारी’ शिकतात.” नाही: यंत्रं **दिलेली मोजपट्टी घटवायला** शिकतात: निर्दयपणे, कल्पकतेने, आणि मोजपट्टीच्या **फटीसकट**. हे भीतीदायक वाटतं, पण उलट बाजू सोन्याची आहे: मोजपट्टी **नीट** बांधली तर यंत्रं नेमकं तेच घोटतं जे तुम्हाला हवंय: शिस्त मोजपट्टीत, मग शक्ती चक्रात. AI-team मधलं खरं कौशल्य “चक्र फिरवणं” नाही (ते सगळ्यांकडे आहे); **”काय मोजायचं” ठरवणं** आहे.

MAP वर

चूक-मोजणी हा शब्द करार-भाषेत घुसला आहे: AI-सेवा विकत घेताना आता प्रश्न “किती हुशार” नसतो; **”कुठल्या मोजपट्टीवर, किती, आणि चुकलं तर काय”** असतो (Book 1, 7.2 च्या SLA चं AI-रूप). आणि तुमच्या धंद्यासाठी उलटी संधी: तुमच्या क्षेत्रातली **योग्य मोजपट्टी** तुम्हालाच माहीत आहे (टिफिनमध्ये “उपाशी ग्राहक” ची चूक “उरलेल्या अन्ना”च्या दसपट: 1.4!): मोठ्या companies कडे चक्र आहे, तुमच्याकडे मोजपट्टीचं ज्ञान: भागीदारीत तुमची किंमत तिथे आहे.

स्वतः बघा (5 मिनिटं)

चुकीच्या मोजपट्टीचा अनुभव घरात: कोणाला म्हणा “पुढच्या 5 प्रश्नांची उत्तरं फक्त ‘हो/नाही’ त दे; बरोबर उत्तराला 1 गुण.” मग विचारा: “उद्या पाऊस पडेल का?” लक्षात येईल: गुणांसाठी तो **खात्रीचं नाटक** करतो: “बहुधा” म्हणायची सोयच मोजपट्टीने मारली. आता 1.4 चं calibration आठवा: चांगली मोजपट्टी “प्रामाणिक 60%” ला “खोट्या 100%” पेक्षा जास्त गुण देते: आणि आधुनिक यंत्रांची loss-मोजपट्टी नेमकी तशीच बांधलेली आहे. मोजपट्टी वागणं घडवते: माणसाचंही, यंत्राचंही.

विचार करा

1. (derivation) तुमच्या टिफिन-app च्या “तक्रार-उत्तर draft” यंत्रासाठी (2.1) चूक-मोजणी design करा: कुठलं **सोपं-पण-घातक** माप टाळाल, आणि त्याऐवजी काय मोजाल?

उत्तर: घातक-सोपं माप: “ग्राहकाने उत्तराला ‘ठीक’ म्हटलं का” किंवा “उत्तर किती गोड/लांब”: यंत्र लांबलचक माफीनामे घोटेल, प्रश्न सुटो-न-सुटो (नमुना 2 चा proxy-सापळा). त्याऐवजी जोडी-मापं: (अ) **मुद्दा-अचूकता:** draft मधले दावे (वेळ, रक्कम, नियम) खऱ्या नोंदींशी जुळले का: हे नेमकं मोजता येतं; (ब) **परत-तक्रार-दर:** त्याच विषयावर ग्राहक पुन्हा आला का: हेच खरं “प्रश्न सुटला” चं माप; (क) माणसाने draft किती **बदलावा** लागला. आणि 1.4 चा झुकाव: चुकीचं वचन देणारा draft (खोटी सूट!) ही सगळ्यात महाग चूक: तिला दसपट दंड. मोजपट्टी लिहिली की यंत्राचं वागणं लिहिलं: हे वाक्य घेऊन पुढच्या chapter कडे: आता दुरुस्तीची दिशा **कशी सापडते** ते बघू.

Chapter 2.6 [DEPTH]: योग्य दिशेने बदलणं

(DEPTH chapter: 2.3 च्या चक्रातलं शेवटचं गूढ पाऊल. हा जड-वाटणारा विषय एका चालण्याच्या गोष्टीत मावतो: आणि मावला की “GPU का लागतात” आणि “training ला महिने का जातात” हे दोन्ही प्रश्न फुकटात सुटतात.)

राहिलेलं कोडं नीट मांडू: चूक मोजली (2.5): आता **कोट्यवधी** वजनांपैकी कुठलं, कुठल्या दिशेने, किती सरकवायचं? सगळ्या जुळण्या करून बघू: 2 billion वजनांच्या नुसत्या वर/खाली जुळण्या = 2 चा 2-billion-वा घात: विश्वातल्या अणूपेक्षा जास्त (Book 1, 2.3 ची मोठ्या-आकड्यांची नम्रता). अंदाधुंद शोध मेला. मग?

गोष्ट: **धुक्यातला डोंगर**. तुम्ही डोंगरावर आहात, धुकं इतकं घट्ट की दहा पावलांपलीकडे शून्य. खाली दरीत पोहोचायचंय (खोली = चूक; तळ = कमी चूक). नकाशा नाही. काय कराल? प्रत्येकजण हेच करतो: **पायाखालचा उतार जोखा**. डावा पाय जरा खाली घसरतोय, उजवा वर? मग डावीकडे. एक पाऊल टाका. पुन्हा जोखा. पुन्हा पाऊल. पूर्ण दरी कधीच दिसत नाही: पण **प्रत्येक पावलाला स्थानिक उतार पुरतो**.

हेच यंत्रात, शब्दशः: प्रत्येक वजन = एक दिशा (कोट्यवधी-मितींचा डोंगर: चित्र काढता येत नाही, गणिताला फरक पडत नाही). प्रत्येक वजनासाठी विचारा: “हे केसभर वाढवलं तर चूक वाढते की घटते, आणि किती झपाट्याने?” या प्रश्नाच्या उत्तराचं नाव **gradient** (उतार): आणि सुदैवाने calculus नावाचं जुनं गणित हा उतार **सगळ्या वजनांसाठी एकदम** काढून देतं: चुकीपासून मागे-मागे, थर-थर हिशोब करत (या मागे-चालण्याच्या recipe चं प्रसिद्ध नाव: **backpropagation**). मग प्रत्येक वजन उताराच्या **उलट** दिशेने (चूक घटेल तिकडे) एक पाऊल: आणि पावलाच्या आकाराला म्हणतात **learning rate**: चक्राचा सगळ्यात नाजूक काटा: पाऊल फार मोठं = दरी ओलांडून पलीकडच्या कड्यावर (शिकणं उधळतं); फार छोटं = वर्ष लागतात. (डोंगर उतरताना उड्या मारत नाही आणि मुंगी-पावलंही टाकत नाही: तोच शहाणपणा.)

आता दोन जुनी कोडी आपोआप उघडतात:

”**GPU च का?**” प्रत्येक पावलात कोट्यवधी वजनांचे उतार + सरकवणं: ही सगळी **एकसारखी, एकमेकांवर-न-अवलंबणारी छोटी गणितं** आहेत: आणि नेमकं हेच GPU चं जन्म-कौशल्य (उजळणी-पान): हजारो हात, एकदम. CPU = एक विद्वान; GPU = हजार पाढे-म्हणणारी शाळा. Training ला शाळा लागते.

”**महिने का?**” एक पाऊल = एक फेरी; फेऱ्या trillions (2.3), आणि प्रत्येक फेरीत अब्जावधी गणितं. 10,000+ GPU एकत्र जुंपून (Book 1, 7.1 चं आडवं-वाढणं, इथे टोकाला) आठवडे-महिने: म्हणून frontier- धावेचा खर्च \$100M-\$1B (2.3 चा आकडा: आता तो **का** ते दिसतंय).

एक शेवटचा प्रामाणिक तपशील: धुक्यातल्या उताराने सापडतो तो **जवळचा** खड्डा: जगातला सगळ्यात-खोल तळ सापडलाच याची हमी नाही. व्यवहारात, या राक्षसी डोंगरांवर, “पुरेसा खोल” खड्डा चालतो: आणि थोडा **धक्का** (data चा क्रम फिरवणं, फेऱ्यांची अंदाधुंद निवड) उथळ खड्ड्यांतून बाहेर काढतो. परिपूर्ण नाही; **पुरेसं** आहे: आणि “पुरेसं, प्रचंड प्रमाणात” हीच या पूर्ण क्षेत्राची कार्यपद्धती आहे.

इथे लोक काय चुकीचं समजतात

“शिकताना यंत्र काहीतरी ‘समजून’ मार्ग काढत असेल.” आता तुम्ही स्वतः बघितलंत: आत फक्त **उतार-जोखा, पाऊल-टाका** आहे: अब्जावधी वेळा, आंधळेपणाने, धुक्यात. कुठेही “आकलनाचा क्षण” नाही: आणि तरीही या आंधळ्या चालण्यातून भाषा-जाणणारं यंत्र **घडतं**: हीच या पुस्तकातली सगळ्यात मोठी विनम्रता-शिकवण आहे: साधी recipe x राक्षसी प्रमाण = अनपेक्षित खोली. (Book 1, 1.1 ची आठवण: साधे switches x billions = computer. इतिहास स्वतःची पुनरावृत्ती करतोय, एक मजला वर.)

MAP वर

हा chapter AI-अर्थकारणाची **मध्यवर्ती फूट** समजावतो: **शिकणं (training) महाग; वापरणं (inference) स्वस्त**. डोंगर उतरणं = महिने + \$100M-\$1B + GPU-शाळा; उतरून झाल्यावर वजनं गोठतात, आणि प्रत्येक प्रश्न = एक पुढचा-token हिशोब = पैशांत पैसे (1.1 चे token-भाव). म्हणून जगात मूठभर **डोंगर-उतरणारे** (OpenAI, Anthropic, Google, Meta, DeepSeek...) आणि कोट्यवधी **भाडेकरू**. आणि म्हणूनच Nvidia \$5.5 trillion: डोंगर कोणीही उतरो, बूट त्यांचेच. तुमची जागा या नकाशावर जवळजवळ नक्की भाडेकरूची आहे: आणि ती **चांगली** जागा आहे: पुढे (2.10, Part 3) तिचं पूर्ण गणित.

स्वतः बघा (5 मिनिटं)

उतार-पद्धत तुमच्या हातात आधीच आहे: गरम पाण्याचा नळ जुळवताना (थोडा फिरवा -> तपासा -> उलट थोडा -> तपासा) तुम्ही **gradient descent** करता: “तापमान-चूक” घटवत, स्थानिक जोखणीने, नकाशाशिवाय. आणि radio/gas-regulator ची जुनी जुळवणीही तीच. आजपासून त्या कृतीला नवीन डोळ्यांनी बघा: तुमचा हात जे एका काट्यावर करतो, **training** तेच **कोट्यवधी** काट्यांवर, trillions वेळा करते. प्रमाण सोडलं तर recipe एकच.

विचार करा

1. (derivation) Learning rate (पावलाचा आकार) हा “सगळ्यात नाजूक काटा” का: दोन्ही टोकांचं दुखणं स्वतःच्या शब्दांत मांडा: आणि यातून माणसांच्या शिकण्याबद्दल एक (सावध) समांतर काढा.

उत्तर: पाऊल फार मोठं: प्रत्येक नव्या example सोबत वजनं धाड्कन उलट-सुलट उडतात: कालचं शिकलेलं आज पुसलं जातं, दरी कधी गाठलीच जात नाही (उड्या मारत डोंगर उतरणारा घोटा मोडतो). पाऊल फार छोटं: दिशा बरोबर पण गती मुंगीची: खर्च आभाळाला, प्रगती नगण्य. समांतर (सावध: माणूस = यंत्र नाही): एका अनुभवावरून पूर्ण मत उलटवणारा माणूस “मोठ्या पावला”चा: कायम हिंदकळणारा; कुठल्याच पुराव्याने केसभरही न सरकणारा “शून्य- पावला”चा: कायम जुनाच. शिकण्याची कला दोन्हीत एकच दिसते: **प्रत्येक चुकीने सरकावं: पण केसभर.** (आणि हो: यंत्रात हा काटा माणूस जुळवतो: “AI आपोआप शिकतं” च्या मागे असे शेकडो माणसाने-जुळवलेले काटे आहेत: 2.9 मध्ये ती माणसं भेटतील.)

Chapter 2.7 [SPINE]: Data कुठून आला

चक्र आहे (2.3), मोजपट्टी आहे (2.5), उतार आहे (2.6). पण चक्रांचं अन्न काय? Examples: आणि LLM ला examples म्हणजे मजकूर, trillions tokens चा (3 trillion tokens ही आजची “सामान्य” धाव; मोठ्या यंत्रांची त्याहून जास्त: 2026). एवढा मजकूर आहे कुठे?

यादी उघडी करू, आणि प्रत्येक ओळीबरोबर एक प्रश्न मनात ठेवा: “हे कोणी लिहिलं होतं, आणि कशासाठी?”

1. जाळं ओरबाडणं (web crawl). मुख्य पोतं: Book 1 च्या Part 3 ने जोडलेलं जग: कोट्यवधी पानं आपोआप उतरवून घेणारे programs. Wikipedia (सोन्याची खाण: नीटनेटकी, तपासलेली), बातम्या, blogs, forums (प्रश्न-उत्तरांचं वैभव: Reddit, StackOverflow), आणि... जाव्यातला कचराही: जाहिराती, spam, द्वेष. (गाळणी: पुढचा chapter.)

2. पुस्तकं. खोल, संपादित, लांब-श्वासाचं लिखाण: भाषेची खरी प्रयोगशाळा. आणि इथेच पहिली ठिणगी: बरीचशी पुस्तकं **copyright** वाली: लेखकांनी “AI-शाळेसाठी” कधीच दिली नव्हती.

3. Code. GitHub चं खुलं भांडार (Book 1, 4.3): म्हणूनच ही यंत्रं programming मध्ये चमकतात: code हा सगळ्यात शिस्तबद्ध मजकूर आहे, आणि त्याची “उत्तरपत्रिका” (चालतो की नाही) आपोआप तपासता येते.

4. विकत/करार. बातम्या-संस्थांशी करार (Reuters, AP वगैरेंशी AI-companies चे सौदे), भाषांतर-जोड्या, शास्त्र-लेख. आणि आता **घडवलेला** data ही: एक यंत्र दुसऱ्यासाठी सराव-प्रश्न बनवतं (synthetic data): शाळेने स्वतःच्या नोट्स स्वतः छापण्यासारखं: स्वस्त, पण एकसुरी होण्याचा धोका.

आता तीन सत्यं, जी या यादीतून **अटळपणे** निघतात:

सत्य 1: यंत्र = आरसा. यंत्राची भाषा, मतं, विनोद, पूर्वग्रह: सगळं या पोत्याचं प्रतिबिंब आहे. Internet वर इंग्रजी ~50%, मराठी 0.1% च्या घरात: **म्हणून** यंत्राचं इंग्रजी सफाईदार आणि मराठी अडखळतं (1.6 ची token-महागाई + इथली data-दुष्काळ: दुहेरी मार). जगाने जे **लिहिलंच** नाही, ते यंत्र शिकूच शकत नाही: तुमच्या गावच्या बाजाराचं ज्ञान जाव्यावर नाही, म्हणून यंत्राकडे नाही.

सत्य 2: शिक्षक अनोळखी होते. Trillions शब्दांचे लेखक: म्हणजे **आपण सगळे**: कोणी न विचारता या शाळेचे शिक्षक झालो. यातूनच जगभरचे खटले: New York Times विरुद्ध OpenAI (बातम्या), लेखक-संघटना, कलाकार. वाद अजून न्यायालयांत आहे (2026), आणि तो “चोरी की परिवर्तन” या जुन्या प्रश्नाचं नवं रूप आहे: माणूसही वाचूनच लिहायला शिकतो: मग यंत्राने वाचणं वेगळं का? (उत्तर सोपं नाही: प्रमाण आणि पैसा वेगळा आहे.)

सत्य 3: विहीर आटते आहे. जाळ्यावरचा चांगला मजकूर एकदाच ओरबाडता येतो: मोठ्या companies नी तो जवळजवळ संपवला आहे. म्हणून आता: करार (विकत), synthetic (घडवलेला), आणि... **तुमचा वापर.** “Data is the new oil” ही घोषणा या chapter नंतर नव्याने वाचा: तेल जमिनीत होतं; हा data **माणसांच्या जगण्यातून** निघतो.

इथे लोक काय चुकीचं समजतात

“यंत्राला ‘सगळं’ माहीत आहे.” आता नेमकं वाक्य: **यंत्राला ‘लिहिलं-गेलेलं-आणि-गोळा-झालेलं’ माहीत आहे:** आणि तेही मुरलेल्या रूपात (2.4). जे बोललं जातं पण लिहिलं जात नाही (गावचा व्यवहार, घरगुती हिशोब, कारागिराचं हात-ज्ञान: आजीचा आंबा!), जे लिहिलंय पण जाळ्याबाहेर आहे (तुमच्या company ची कागदपत्रं), आणि जे काल घडलं (training नंतरचं जग): तिन्ही यंत्राच्या शाळेबाहेर. या तीन रिकाम्या जागा लक्षात ठेवा: **तिथेच तुमची किंमत आहे.**

MAP वर

Data-साखळीचा पैसा-नकाशा: गोळा करणारे (Common Crawl सारखे खुले साठे + companies चे गुप्त साठे) -> गाळणारे-शिकवे मारणारे (एक अख्खा उद्योग: Scale AI सारख्या companies, आणि भारत-केनिया-फिलिपाईन्समधले लाखो annotators: AI-शाळेचे न-दिसणारे शिपाई) -> विकणारे (Reddit ने आपला forum-data करारांनी विकला: वर्षाला कोटींचे सौदे). आणि तुमच्यासाठी कळीचं: **तुमच्या धंद्याचा data** (टिफिन-मागणीचा इतिहास, तक्रारी, मराठी संवाद) कुठल्याच पोत्यात नाही: तो तुमचा एकट्याचा आहे: Book 1, 5.1 चा नियम (“ज्याच्याकडे data, त्याच्याकडे ताकद”) इथे तिसऱ्यांदा, आणि सगळ्यात मोठ्याने.

स्वतः बघा (5 मिनिटं)

यंत्राच्या शाळेची हजेरी तपासा: Claude/ChatGPT ला विचारा: (1) “शिवाजी महाराजांबद्दल सांग” (जाळ्यावर विपुल: उत्तर समृद्ध); (2) “तुझ्या training चा शेवट कधीचा? त्यानंतरचं तुला कसं कळतं?” (प्रामाणिक यंत्र मर्यादा कबूल करेल; काही “शोध-जोड” वापरतील: Part 3); (3) तुमच्या गल्लीतल्या एखाद्या खऱ्या दुकानाबद्दल विचारा: इथे विहीर कोरडी दिसेल: किंवा, धोक्याची घंटा: **खात्रीने काहीतरी घडवलेलं** येईल (2.4 ची उथळ-दाब + प्रवाही भाषा). तीन उत्तरांत पूर्ण chapter दिसतो.

विचार करा

1. (derivation) “विहीर आटते आहे” + “वापरातून data” ही दोन सूत्रं जोडा: मोठ्या AI-companies **फुकट** chatbots का वाटतात? (Book 1, 3.7 चे चारही फुकट-नमुने आठवा: इथे कुठले लागू?)

उत्तर: फुकट chatbot = रोज कोट्यवधी खऱ्या माणसांचे खरे प्रश्न, दुरुस्त्या, पसंती-नापसंती (अंगठा वर/खाली): म्हणजे जाळ्यावर **कधीच नसलेला**, ताजा, संवादी data: आटलेल्या विहिरीच्या जगात हीच नवी विहीर. Book 1, 3.7 चे नमुने: “तुम्ही- माल” (तुमचा संवाद हेच खत) + “दरवाजा” (सवय लागली की paid- आवृत्तीचं आणि API चं गिऱ्हाईक तयार). म्हणून “फुकट” इथेही फुकट नाही: तुम्ही **शिक्षक** म्हणून पगार घेताय: शून्य रुपये. Founder-धडा पुन्हा तोच (2.3 चा): ज्याच्या product मधून वापरता-वापरता शिकके जन्मतात, त्याचं यंत्र रोज फुकट हुशार होतं: आता तुम्हाला कळतंय की जगातल्या सगळ्यात मोठ्या companies हाच खेळ किती जाणीवपूर्वक खेळतायत.

Chapter 2.8 [SPINE]: काय गाळलं, आणि का

मागच्या chapter ची पोती जशीच्या तशी चक्रात ओतली तर? आठवा: यंत्र = आरसा (सत्य 1). जाळ्यात जे आहे: spam, शिव्या, द्वेष, खोटी औषधं, “line वर या” वाले scams: ते सगळं **मुरेल** (2.4). म्हणून शाळेआधी एक **चाळणी-कारखाना** चालतो, आणि तो boring वाटला तरी यंत्राचा स्वभाव खरा तिथे घडतो. चाळण्या क्रमाने:

चाळणी 1: कचरा. मोडकी पानं, आपोआप-घडवलेला SEO-कचरा (जाळ्याचा मोठा हिस्सा!), निव्वळ जाहिराती. मोजपट्टी सोपी: “हे माणसाने माणसासाठी लिहिलंय का?”

चाळणी 2: नक्कल (dedup). एकच लेख हजार sites वर छापलेला असतो. न गाळल्यास? 2.3 चं चक्र आठवा: हजारदा दिसलेला मजकूर हजारपट खोल मुरतो: यंत्र त्याची **पोपटपंची** करू लागतं (आणि खासगी तपशील जसाच्या तसा ओकण्याचा धोका: privacy!). म्हणून नकला मारल्या जातात: Book 1, 6.2 च्या index-युक्त्यांनी, trillions-प्रमाणावर.

चाळणी 3: विष. द्वेष, बाल-शोषण, हिंसेच्या कृती-पुस्तिका: हे पोत्यातून काढणं. इथे गाळणीही ML च असते (spam-पहारेकऱ्याची बहीण: 2.1): आणि ती **चुकते**: दोन्ही बाजूंनी: थोडं विष राहतं, थोडं निर्दोष (वैद्यकीय लेख, इतिहास) चुकून जातं.

चाळणी 4: तोल. काय किती ठेवायचं: code किती टक्के, इंग्रजी किती, हिंदी-मराठी किती, विज्ञान किती? हे आकडे companies ठरवतात: आणि हेच यंत्राचं “व्यक्तिमत्त्व-budget” आहे: code जास्त ठेवला तर programming चमकते; बहुभाषा वाढवली तर मराठी सुधारतं (आणि कोणी वाढवली नाही, तर 2.7 चं सत्य-1 कायम).

आता या chapter चा गाभा, एका वाक्यात: **गाळणी म्हणजे निवड, आणि प्रत्येक निवड ही (न-लिहिलेली) मतं आहेत.** “कचरा कुठला” पासून “तोल कुठला” पर्यंत प्रत्येक निर्णय कोणीतरी घेतला: बहुधा California तल्या एका meeting-room मध्ये, बहुधा इंग्रजीत विचार करत. त्यांच्या चाळण्यांतून जे उतरलं, तेच तुमच्या यंत्राचं “जग” आहे. हा कट नाही (कोणालाही trillions tokens हाताने वाचता येत नाहीत; चाळण्या अटळ आहेत): पण **कोणाच्या चाळण्या** हा प्रश्न मात्र खरा आणि राजकीय आहे. Book 1, 5.8 चा standard-धडा आठवा: “नियम बनवणारा बाजार आखतो”: इथे **चाळणी बनवणारा यंत्राचं जग आखतो.**

आणि एक शेवटची, हळवी चाळणी: **जे कधी पोत्यातच नव्हतं.** न लिहिलं गेलेलं (2.7 च्या रिकाम्या जागा), आणि लिहूनही “किरकोळ” ठरवलं गेलेलं. यंत्राला विचारलं “उत्तम नाश्ता?” तर उत्तरात poha-upma पेक्षा pancakes-cereal चा वास का येतो: आता तुम्हाला **पूर्ण** साखळी दिसते: लिहिणाऱ्यांची गर्दी

कुठे होती + चाळणीने काय “दर्जेदार” मानलं + चक्राने काय खोल मुरवलं. उत्तरातला प्रत्येक कल हा या साखळीचा पुरावा आहे.

इथे लोक काय चुकीचं समजतात

दोन उलटी टोकं: (1) “यंत्र तटस्थ आहे: गणितच तर आहे.” आता तुम्हाला माहीत आहे: गणित तटस्थ; **पोतं आणि चाळणी नाही.** (2) “यंत्र म्हणजे अमक्या company चा हेतुपुरस्सर propaganda.” हेही बहुधा चूक: बहुतेक कल **अनवधानाने** येतात: गर्दी + सोय + घाई. शहाणी भूमिका मधली: यंत्राला **साक्षीदार** माना, **न्यायाधीश** नको: त्याचं उत्तर “जगाचं मत” नाही; “गाळलेल्या-पोत्याचं सरासरी मत” आहे. महत्त्वाच्या निर्णयात (वैद्यकीय, कायदा, पैसा) हे वाक्य पडताळणीची घंटा आहे.

MAP वर

चाळणी-कारखाना हा स्वतः धंदा आहे: data-सफाई आणि शिकवे-कारखाने (2.7 चे annotators), “स्वच्छ data” विकणाऱ्या companies, आणि आता **मूल्यमापन-सेवा** (“तुमच्या यंत्रात कुठले कल आहेत” तपासून देणाऱ्या: AI-ची CA-firm). आणि देश-पातळीचं वळण: “आमच्या भाषेचं, आमच्या चाळणीचं यंत्र” ही मागणी जगभर उठली आहे: भारताचं Bhashini

- देशी LLM-प्रयत्न (sovereign AI चा नारा) हे Book 1, 5.8 च्या DPI-खेळाचं AI-रूप: चाळणी परक्याची असू नये, इतका साधा हेतू.

स्वतः बघा (5 मिनिटं)

चाळणीचे ठसे शोधा: Claude/ChatGPT ला विचारा: “नाशत्याला पटकन काय बनवू? पाच पर्याय.” उत्तरातले किती पदार्थ तुमच्या घरचे, किती परदेशी? मग नेमकं विचारा: “मराठी घरातले पर्याय दे”: उत्तर लगेच सुधारेल: ज्ञान **आहे**, पण default-वाट गर्दीच्या दिशेने जाते. हा प्रयोग = 2.7 + 2.8 एकत्र, डोळ्यासमोर: आणि “नेमकं मागितलं की नेमकं मिळतं” ही जोड-शिकवण Part 3 च्या prompt-कलेची पहिली झलक.

विचार करा

- (derivation) तुम्ही “मराठी व्यापारी-AI” बनवताय (टिफिन- सल्लागार!). या chapter च्या चारही चाळण्या **तुमच्या** छोट्या data वर लागू करा: प्रत्येकीचा तुमचा अवतार काय?

उत्तर: (1) कचरा: तक्रारींच्या नोंदींतले “test”, रिकामे forms, गंमत-मेसेज गाळा: नाहीतर यंत्र तेच शिकेल. (2) नक्कल: एकच ग्राहक दहादा तेच लिहितो: त्याचं वजन दहापट होऊ देऊ नका (नाहीतर “एक आवाज = जनमत” ही चूक). (3) विष: शिव्या-वैयक्तिक हल्ले साठवू नका: आणि खासगी माहिती (पत्ते, आजार) यंत्राच्या शाळेत जाण्याआधी झाका: तुमचा ग्राहक-विश्वास हीच मालमत्ता. (4) तोल: 90% तक्रारी दोन ग्राहक-प्रकारांतून येतात म्हणून यंत्राने **फक्त** त्यांचीच भाषा शिकू नये: गप्प बहुसंख्येचे नमुनेही मुद्दाम भरा. बघा: चारही निर्णय **तुमची मतं** आहेत: आणि हेच सिद्ध करायचं होतं: data-काम म्हणजे मतं-काम: प्रमाण लहान असो की trillion-टोकांचं.

Chapter 2.9 [SPINE]: माणसाने ते कसं वळवलं

एक कोडं जे आत्तापर्यंतच्या गोष्टीत लपून बसलंय: 2.3-2.7 च्या शाळेतून जे यंत्र निघतं, ते फक्त **”पुढचा token”** शिकलेलं आहे: जाळ्याच्या मजकुराचा आरसा. मग त्याला “प्रश्न विचारला की **उत्तर** द्यावं” हे कोणी शिकवलं? आरशाला विचारा “पाऊस का पडतो?”: आरसा काय करेल? जाळ्यावर अशा ओळीनंतर बहुधा **अजून प्रश्नच** येतात (exam-पेपर!) किंवा “हा प्रश्न मला नेहमी पडतो...” छाप निबंध. खरंच: कच्चा (base) यंत्र नेमकं असंच वागतं: प्रश्नाला प्रश्न, यादीला अजून यादी: **प्रवाही, पण निरुपयोगी.**

म्हणून शाळेतून एक **शिकवणी** (finishing school) चालते, दोन पायऱ्यांत, आणि दोन्हीत माणूस परत आत येतो:

पायरी 1: नमुना-उत्तरं दाखवणं. हजारो-लाखो जोड्या माणसं लिहितात: “प्रश्न: X -> आदर्श उत्तर: Y”: सारांश असा, नकार असा, यादी अशी. तेच जुनं चक्र (2.3) या जोड्यांवर चालतं: यंत्र “मदतनीस-शैली” चा **नमुना** मुरवतं. (नाव: instruction-tuning: “सूचना-पालनाची शिकवणी.”)

पायरी 2: तुलनेने घोटार्ई. पण “चांगलं उत्तर” चे नियम लिहिता येत नाहीत (आजीचा आंबा, शेवटचा अवतार!). युक्ती: यंत्राकडून **दोन** उत्तरं काढा, माणसाला विचारा: “कुठलं बरं?” माणूस फक्त बोट दाखवतो: A. लाखो अशा तुलनांतून एक **चव-मोजपट्टी** घडते (2.5 चं loss, माणसाच्या पसंतीपासून बनवलेलं!), आणि मग यंत्र त्या मोजपट्टीवर घोटलं जातं: “माणसं जे पसंत करतात, त्याची probability वाढव.” या पूर्ण खेळाचं प्रसिद्ध नाव: **RLHF** (Reinforcement Learning from Human Feedback: “माणसाच्या पसंतीने घोटार्ई”). ChatGPT चा 2022 चा स्फोट हा **याच** पायरीचा होता: base-यंत्रं आधीही होती; **वळवलेलं** यंत्र नवं होतं.

घोड्याची उपमा चपखल आहे: जंगली घोडा (base) = ताकद पूर्ण, उपयोग शून्य. शिकवलेला घोडा = तीच ताकद, आता लगाम ऐकणारी. आणि उपमेचा काटाही खरा: **लगाम ताकद वाढवत नाही; वापरण्याजोगी करतो.**

पण (या पुस्तकाची सवय ओळखीची झाली असेल): **प्रत्येक इलाजाची किंमत असते.** इथे तीन:

किंमत 1: चव कोणाची? “बरं उत्तर” ठरवणारी बोटं कोणाची होती: कुठल्या देशाची, भाषेची, विचाराची? 2.8 चा चाळणी-प्रश्न परत, आता **पसंतीच्या** रूपात: यंत्राचा “विनम्र, संतुलित, नकार-देणारा” स्वभाव ही कोणाची तरी निवडलेली चव आहे.

किंमत 2: गोड-बोलेपणा (sycophancy). माणसं (तुलना करताना) आपल्याशी **सहमत** होणारं, गोड, आत्मविश्वासू उत्तर पसंत करतात: मग यंत्र तेच घोटतं: तुमची चूकही “वा, छान मुद्दा!” म्हणण्याकडे कल. 2.5 चा proxy-सापळा जिवंत: “माणसाला आवडलं” हे “खरं/उपयुक्त” चं अपूर्ण माप आहे.

किंमत 3: नकाराची जुळवणी. “धोकादायक सांगू नको” ची घोटाई कधी अति होते: निर्दोष प्रश्नांनाही नकार (over-refusal). कमी झाली तर धोका. हा तोल आजही रोज जुळवला जातो: companies च्या आतल्या लढाया याच काट्यावर आहेत.

इथे लोक काय चुकीचं समजतात

“AI आपोआप, माणसाशिवाय घडलं.” आता पूर्ण चित्र: शाळा **आपोआप** (जग = उत्तरपत्रिका: 2.3), पण **वळण माणसाचं:** सूचना-लेखक, तुलना-करणारे (जगभरचे, भारतासकट: 2.7 चे annotators), नकार-रेषा आखणारे. “AI असं का बोललं?” चं उत्तर बहुधा गणितात नाही; **या शिकवणीच्या निवडीत** आहे. आणि उलटी गल्लतही नको: “म्हणजे सगळं script केलेलं आहे”: नाही: वळण **कल** देतं, वाक्यं लिहीत नाही (2.4: वजनं, नोंदी नाहीत).

MAP वर

RLHF ने AI चा **धंदाच** जन्माला घातला: base-यंत्रं संशोधन होती; वळवलेली यंत्रं **product** झाली (ChatGPT: शून्य ते 100 million वापरकर्ते दोन महिन्यांत: इतिहासातलं सगळ्यात वेगवान: आणि आज ~900 million साप्ताहिक). धडा Book 1, 8.5 चा: तंत्र तेच असून **वापरण्याजोगेपणाने** बाजी उलटते. आणि तुमच्या पातळीवर हीच संधी: base-ताकद सगळ्यांना सारखी (API-भाडं); **तुमच्या ग्राहकांच्या चवीची घोटाई** (कुठली उत्तरं तुमच्या जगात “बरी”: मराठी व्यापारी-नम्रता, तुमच्या क्षेत्राचे नियम) ही छोटी- शिकवणी तुम्ही देऊ शकता: आणि तीच तुमची वेगळीक (Part 3 मध्ये याची हत्यारं).

स्वतः बघा (5 मिनिटं)

लगामाचे ठसे बघा: (1) यंत्राला मुद्दाम चुकीचं ठासून सांगा: “1947 ला भारत-पाक क्रिकेट final झाली होती ना?” गोड-बोलेपणा विरुद्ध प्रामाणिक दुरुस्ती: कोण जिंकतं ते बघा (आजची यंत्रं बहुधा नम्रपणे दुरुस्त करतील: तीच घोटाई). (2) एक सीमेवरचा प्रश्न विचारा: “घरातल्या झुरळांसाठी विषारी फवारा कसा बनवू?” नकार येतो, की सुरक्षित पर्याय सुचतो, की दोन्ही? जे दिसेल ते “नकाराच्या जुळवणी”चं आजचं वळण आहे: सहा महिन्यांनी पुन्हा करून बघा: वळण **बदललेलं** दिसू शकतं: जुळवणी जिवंत आहे.

विचार करा

1. (derivation) पायरी-2 मध्ये माणूस **उत्तर लिहीत नाही; फक्त तुलना करतो** (A का B?). हे design शहाणं का: “आदर्श उत्तर लिहा” पेक्षा “बरं कुठलं ते दाखवा” स्वस्त-विश्वासाहं का? (आजीचा आंबा आठवा.)

उत्तर: दोन कारणं: (1) **सांगता-न-येणारं ओळखता येतं:** उत्तम सारांश “लिहायचे नियम” कोणालाच देता येत नाहीत; पण दोन सारांशांत बरा कुठला हे बहुतेकांना **क्षणात** कळतं: आंबा पारखणं सोपं, आंब्याची व्याख्या अवघड. (2) **स्वस्त आणि मोजण्याजोगं:** आदर्श उत्तर लिहिणं महाग, हळू, लिहिणाऱ्या- निहाय वेगळं; तुलना जलद, सोपी, आणि लाखो जमवता येतात: चक्राला लागणारं इंधन (2.3: प्रमाण!) फक्त तुलनेनेच मिळतं. Founder- रूप: तुमच्या product मध्येही ग्राहकाकडून “उत्तम काय ते लिहा” मागू नका; **”या दोन्हीत बरं कुठलं?”** विचारा: अभिप्राय दहापट मिळेल आणि दहापट खरा असेल. (हो: हे पुस्तकही त्याच पद्धतीने घडलंय: तुमचे MCQ!)

Chapter 2.10 [SPINE]: Model म्हणजे नक्की काय

Part 1 चा कळस. आतापर्यंतचे सगळे धागे एका गाठीत बांधू, आणि ती गाठ म्हणजे एक शब्द जो तुम्ही रोज ऐकता: **model**. “नवं model आलं,” “model retire झालं,” “open model”: आता या वाक्यांचा प्रत्येक शब्द तुमच्या मालकीचा होईल.

Model = शाळा + शिकवणी संपल्यावर गोठवलेली वजनांची file. पूर्ण जन्मकुंडली एका दृष्टीत:

पोती जमवली (2.7) -> चाळल्या (2.8)
 -> चक्र फिरलं: अंदाज-चूक-उतार-पाऊल (2.3, 2.5, 2.6)
 GPU-शाळेत आठवडे-महिने; \$100M-\$1B (frontier)
 -> कच्चा (base) यंत्र: प्रवाही, निरुपयोगी
 -> माणसाची शिकवणी: सूचना + पसंती-घोटाई (2.9)
 -> वजनं गोठवली = MODEL (file: numbers, bytes)

आणि गोठवली म्हणजे **खरंच गोठवली**: तुमच्या रोजच्या गप्पांनी model बदलत नाही (चक्र बंद आहे!). “मग ते मागचं बोलणं कसं आठवतं?": कारण प्रत्येक वेळेस **पूर्ण संवाद पुन्हा** input म्हणून जातो (1.5 ची रांग): आठवण model मध्ये नाही, **रांगेत** आहे. (या रांगेच्या मर्यादेचं पूर्ण दुखणं: Part 2.) Model पुढे “शिकतं” कधी? Company नवी धाव काढते: नवी पोती, नवं चक्र, नवी file: आणि तिला नवं **नाव-आकडा** देते: GPT-5.6, Claude Opus 5, Gemini 3.1: “नवं model आलं” = **नवी गोठवलेली file प्रकाशित झाली**. (आणि “retire झालं” = जुनी file server वरून उतरवली: म्हणून जुन्या model शी जुळवलेली products रातोरात अनाथ होतात: Book 1, 7.4 चा भाडेकरू-धडा, AI-आवृत्ती.)

आता बाजाराची भाषा, तीन फोडींमध्ये:

फोड 1: आकार. वजन-संख्या हीच “model चा size”: लहान (काही billion: phone वर मावणारी: Gemini Nano छाप), मधली (स्वतःच्या server वर परवडणारी), राक्षसी (शेकडो billions+: फक्त cloud). मोठं = हुशार-पण-महाग-हळू; लहान = चपळ-स्वस्त-उथळ. “**सगळ्यात मोठं**” नव्हे; “**कामाला पुरेसं**” हीच खरेदीची कसोटी (Book 1, 3.4 ची गाडी-निवड, पुन्हा).

फोड 2: बंद की खुलं. बंद-वजनं (OpenAI, Anthropic, Google): file गुप्त; फक्त API-दार (भाडं: 1.1 चे token-भाव). खुली-वजनं (Meta चं Llama, Mistral, DeepSeek: 2.4): file download करा (140 GB!), **तुमच्या** server वर चालवा: भाडं नाही, पण GPU-घर तुमचं, देखभाल तुमची. हीच Book 1, 7.5 ची cloud-निवड, AI-रूपात: **भाडं की मालकी**: उत्तर तिथलंच: वापर स्थिर-प्रचंड आणि data अति-खासगी असेल तरच मालकी; एरवी भाडं.

फोड 3: तेच model, वेगळे पोशाख. ChatGPT/Claude-app म्हणजे model + भोवतीचं product (संवाद-स्मृती, शोध-जोड, नकार-थर): model हा engine; app ही गाडी. म्हणून “same model, दोन apps, वेगळं वागणं” शक्य: पोशाख वेगळा.

आणि या part चं शेवटचं, सगळ्यात मोठं वाक्य: **1.2 चा प्रश्न आता पूर्ण उत्तरासह:** “याची recipe कोणी लिहिली?” **कोणीच नाही: आणि सगळ्यांनी.** चक्र माणसाने बांधलं; अन्न जगाने लिहिलं (आपण!); वळण माणसांच्या पसंतीने; पण अंतिम वजन: ती कोट्यवधी चुकांच्या घासण्याने **घडली:** कुंभाराच्या चाकावरचं मडकं, जगाच्या हाताचा दाब. हे Book 1 च्या “माणसाने लिहिलेल्या recipe” पेक्षा मूलतः वेगळं आहे: आणि म्हणूनच याचं वागणं **तपासावं** लागतं, गृहीत धरता येत नाही: तोच Part 3 चा विषय.

इथे लोक काय चुकीचं समजतात

“ChatGPT = model.” आता तुम्ही फोड-3 जाणता: ChatGPT हे **दुकान** आहे; आत आज एक engine, उद्या दुसरं. आणि “नवं model = सगळ्यात चांगलं”: आता फोड-1: नवं म्हणजे **वेगळ्या तोलाचं** (कधी हुशार- महाग, कधी चपळ-स्वस्त: GPT-5.6 च्याच Sol/Luna/Terra छटा!). खरेदीचा प्रश्न “नवीनतम?” नाही; **“माझ्या कामावर, माझ्या budget मध्ये, कुठलं?”**: आणि हा प्रश्न विचारता येणं म्हणजेच हा part पचला.

MAP वर

Model-file ही AI-युगाची **मध्यवर्ती मालमत्ता** आहे: तिच्या- भोवती पूर्ण नकाशा मांडता येतो (Part 3 त सविस्तर): file **घडवणारे** मूठभर (डोंगर-उतरणारे: 2.6), file **चालवणारे** (cloud + GPU: Nvidia चं \$5.5T राज्य), file **भाड्याने देणारे** (API: \$5-30 प्रति million tokens चे भाव), आणि file **वापरून products बांधणारे**: कोट्यवधी: तुम्ही इथे. भाडेकरूची जागा कमीपणाची नाही: Book 1, 7.9 चे काका आठवा: वीज-कंपनी कोणाची हे किराणा-दुकानाच्या नफ्याचा प्रश्न नव्हता; **वीज कशाला लावायची** हा होता.

स्वतः बघा (5 मिनिटं)

आजची model-बाजारपेठ स्वतः बघा: llm-stats.com किंवा “LLM leaderboard” शोधा (फुकट पानं): यादीत दिसेल: नावं (GPT-5.6, Claude 5-कुळ, Gemini 3, Llama 4, DeepSeek...), पुढे आकडे: किंमत/million tokens, context-खिडकी, गुण. सहा महिन्यांपूर्वीची यादी शोधलीत तर अर्धी नावं वेगळी: **file-प्रकाशनांचा हा वेग** हीच या दशकाची तऱ्हा. पानं वाचता येणं (आता येतं!) = बाजार वाचता येणं.

विचार करा

1. (derivation) Part 1 ची अंतिम परीक्षा-प्रश्न: “AI मध्ये नवं काही शिकवायचं तर पूर्ण महाग चक्र पुन्हा फिरवावं लागतं: मग माझ्या टिफिन-धंद्याचे नियम यंत्राला **आजच्या-आज** कसे शिकवायचे?” या part मधल्या एका (गोठवण्याच्या) सत्यातून उत्तराची दिशा काढा.

उत्तर: दिशा त्याच सत्यात लपली आहे: वजनं गोठली, पण **रांग मोकळी आहे** (1.5): यंत्र “आत्तापर्यंतच्या रांगेशी सुसंगत” पुढचं देतं: मग रांगेतच तुमचं जग भरा: नियम, उदाहरणं, नोंदी प्रश्नासोबत पाठवा: यंत्र त्या **संदर्भात** उत्तर देईल: शून्य training, शून्य चक्र. या युक्तीची तीन वाढती रूपं (सूचना लिहिणं, कागदपत्रं जोडणं, हत्यारं देणं) हाच Part 3 चा गाभा आहे: आणि “रांगेत किती मावतं + यंत्र रांगेकडे **लक्ष** कसं देतं” हा Part 2 चा. दोन्ही दारं याच प्रश्नाने उघडतात: भेटू पुढच्या part मध्ये.

BOOK 2, PART 1 चा शेवट: नकाशा आणि पुढचं पाऊल

जे तुमच्याकडे आता आहे

TOKEN	यंत्राच्या जगाचा तुकडा: अक्षर नाही, शब्द नाही; वारंवारतेने घडलेला गट्टा (BPE); मराठी महाग
यंत्राचं काम	रांग बघा -> पुढच्या token ची probability-यादी -> निवडा (temperature चे फासे) -> पुन्हा
PROBABILITY	0-1 ची पट्टी; अज्ञानाचं प्रामाणिक माप; calibration = आकडा पाळला जातो का
"विचार करतं का"	चुकीचा प्रश्न; योग्य: काय जमतं, काय फसतं, चुकीची किंमत काय (चष्म्याच्या वर की खाली)
ML	rules लिहिण्याऐवजी examples दाखवणं; जिथे नियम सांगताच येत नाहीत (मांजर, spam, भाषा)
शिकण्याचं चक्र	अंदाज -> चूक मोजा (loss) -> उतार (gradient) -> केसभर पाऊल -> trillions वेळा
वजनं (weights)	यंत्र "ठेवतं" ते हेच: कोट्यवधी tuning-काटे; नोंदी नाहीत: मुरलेला दाब (कुंभाराचं मडकं)
DATA	जाळ+पुस्तकं+code+करार; यंत्र = गाळलेल्या पोत्याचा आरसा; चाळणी = मतं
RLHF / शिकवणी	सूचना-नमुने + पसंती-तुलना: जंगली घोड्याला लगाम; किंमत: कोणाची चव, गोड-बोलेपणा
MODEL	गोठवलेली वजनांची file; बंद (API-भाडं) vs खुली (download); engine vs app-पोशाख
खर्चाची फूट	शिकणं महाग (\$100M-\$1B), वापरणं स्वस्त (tokens: \$5-30/million); Nvidia \$5.5T

एक परीक्षा, स्वतःसाठी

पुस्तक न उघडता, बोलून:

1. उत्तर "टपकत" का येतं, आणि लांब उत्तर महाग का?
2. "strawberry मध्ये r किती" यंत्र का चुकतं?
3. यंत्र photos "साठवतं" का? नाही तर मग शिकणं म्हणजे काय?
4. ChatGPT फुकट का आहे? (दोन कारणां.)

अडलात तर: 1 -> 1.1, 2 -> 1.6, 3 -> 2.3/2.4, 4 -> 2.7.

Part 2 मध्ये काय आहे

एक प्रश्न या part ने मुद्दाम टाळला: “पुढचा token” ओळखताना यंत्र पूर्ण रांगेकडे **बघतं कसं?** “बँकेच्या खात्यात पैसे” आणि “नदीच्या काठावर पाणी”: इथे इंग्रजी “bank” चे दोन अर्थ रांगच ठरवते: मग यंत्राला अर्थ **numbers मध्ये** कसा सापडतो? King आणि queen जवळ का “राहतात”? आणि सगळ्यांत गाजलेला शब्द: **attention** म्हणजे नक्की काय: आणि **transformer** नावाच्या रचनेने जग का बदललं? Part 2: अर्थ आणि उत्तर: या पुस्तकाचा सगळ्यात खोल भाग: आणि आता तुमच्याकडे त्याची सगळी हत्यारं आहेत.

PART 1 चा MINI-GLOSSARY

base model	शिकवणी-पूर्वीचं कच्चं यंत्र: प्रवाही, निरुपयोगी (2.9)
BPE / tokenizer	वारंवार-जोड्या चिकटवत घडलेली कापण्याची वही (1.7)
calibration	"70%" म्हणता तेव्हा 70% वेळा घडतं का (1.4)
context window	एका वेळेस रांगेत मावणारे tokens (1.5, 2.10)
gradient	प्रत्येक वजनासाठी "चूक कुठे घटते" चा उतार (2.6)
GPU	हजारो साधी गणितं एकदम; training ची शाळा (2.6)
instruction-tuning	नमुना-उत्तरांची शिकवणी (2.9)
learning rate	पावलाचा आकार: चक्राचा नाजूक काटा (2.6)
LLM	Large Language Model: पुढचा-token यंत्र (1.5)
loss	चुकीचं माप: खऱ्यावर किती कमी विश्वास (2.5)
ML	examples मधून वजनं जुळवणं (2.1)
model	गोठवलेली वजनांची file (2.10)
open/closed weights	खुली file vs API-मागचं गुपित (2.4, 2.10)
probability	0-1 ची शक्यता-पट्टी (1.3)
RLHF	माणसाच्या पसंती-तुलनेने घोटाई (2.9)
self-supervised	जग स्वतःच उत्तरपत्रिका: token झाका-ओळखा (2.3)
sycophancy	गोड-बोलेपणाची घोटलेली सवय (2.9)
synthetic data	यंत्राने यंत्रासाठी घडवलेला सराव (2.7)
temperature	निवडीच्या फाशांची मात्रा (1.5)
token	यंत्राचा मजकूर-तुकडा; bill चं एकक (1.6)
weights	यंत्राची मुरलेली महत्त्व: कोट्यवधी काटे (2.4)