

# The Lens, Part 2: शक्यतांचं जग

---

August 30, 2026

# THE LENS

## Book 7, Part 2: शक्यतांचं जग

**मागच्या भागाचा शेवट:** थेंबूने आजच्या हवेतून “पाऊस-गुण 2.0” काढला. पण पाऊस हो/नाही नसतो: “किती शक्यता” असतो. हा भाग अनिश्चिततेचं गणित शिकवतो: शक्यता म्हणजे काय, “70%” चा खरा अर्थ, पुराव्याने मत कसं बदलावं, आणि Book 2 चं loss नक्की काय: सगळं थेंबूसोबत, खऱ्या आकड्यांनी.

## सूत्र (पुन्हा)

गणित म्हणजे आकडेमोड नव्हे; न दिसणारं दाखवणारा चष्मा.  
जे मोजता येतं, ते सुधारता येतं.  
Part 2 चा भर: अनिश्चितता मोजता येते, म्हणून हाताळता येते.

## कपाटावर एक नजर

Book 1-5 (पाया ते रचना)    Book 7    The Lens    <- Part 2

## Part 1 ची उजळणी: 4 प्रश्न (बोलून; उत्तरं खाली)

1. “अर्थ यंत्राला कसा कळतो” चं गणिती उत्तर?

| अर्थ = दिशा; शब्दाला बाण (embedding); जवळच्या दिशा = जवळचे अर्थ. (1.1)

2. Dot product काय मोजतं?

| दोन बाणांची जवळीक (जोडीने गुणा+बेरीज); attention चं हृदय. (1.2)

3. यंत्राचा थर = गणितात?

| matrix (रूपांतर) + वाकडी कृती; weights = matrix-आकडे. (1.3)

4. उच्च-मितींत डोळ्यांवर का विसंबू नये?

तिथे सगळे बाण लांब-लंब होतात (curse); फक्त dot सारखी मापं खरी. (1.5)

## या भागात काय

Probability (विश्वासाचं माप), distribution (शक्यतांचा डोंगर), Bayes (पुराव्याने मत हलवणं: doctor-test), entropy (आश्चर्याचं माप), cross-entropy (loss चं खरं रूप), softmax + temperature. सगळं थेंबूच्या पाऊस-अंदाजावर.

## विभाग 2: शक्यतांचं जग

Book 2 चं सर्वात मोठं सत्य आठवा: यंत्र हो/नाही देत नाही, ते **probability-यादी** देतं (पुढच्या token ची शक्यता). म्हणजे AI च्या हृदयात निश्चितता नाही, **अनिश्चितता** आहे: आणि तिचं गणित म्हणजे probability. हा विभाग ते शिकवतो: शक्यता म्हणजे विश्वासाचं माप, आणि तो मोजता आला की यंत्राचा आत्मविश्वास, त्याच्या चुका, आणि त्याचं शिकणं: सगळं दिसायला लागतं. **हे तुमच्या शिक्षणात कुठे येईल:** temperature, hallucination, calibration, loss: हे सगळे शब्द इथून जन्मतात.

# Chapter 2.1 [SPINE]: Probability:

## विश्वासाचं माप

थेंबूला “पाऊस पडेल” हे हो/नाही न सांगता “70% शक्यता” सांगायचंय. पण “70%” म्हणजे नक्की काय? इथे probability चा खरा, खोल अर्थ आहे, आणि तो दोन प्रकारे बघता येतो.

**अर्थ 1: वारंवारता (frequency).** “पाऊस 70% शक्यता” म्हणजे: “अशी हवा असलेले 100 दिवस घेतले, तर त्यातल्या ~70 दिवशी पाऊस पडला.” भूतकाळातल्या मोजणीतून. फासाची उपमा: फासा टाकल्यावर 6 येण्याची शक्यता  $1/6$ , म्हणजे “पुष्कळ वेळा टाकलं तर ~सहावा हिस्सा वेळा 6.” हे मोजता-तपासता येतं.

**अर्थ 2: विश्वासाची मात्रा (belief).** पण “उद्या पाऊस” हा तर एकच दिवस, 100 वेळा घडणार नाही. मग 70% म्हणजे? ”मला किती खात्री आहे” ची मात्रा: 0 = अजिबात नाही, 1 = पूर्ण खात्री, 0.7 = बऱ्यापैकी खात्री पण पूर्ण नाही. Probability हे विश्वासाचं थर्मामीटर आहे: 0 ते 1 च्या पट्टीवर. आणि AI साठी हाच अर्थ मुख्य: यंत्र “पुढचा शब्द ‘पाऊस’ असण्याची probability 0.7” म्हणतं म्हणजे “मला 0.7 इतकी खात्री.”

**तीन लोखंडी नियम (probability चे, पाठ करा):**

1. प्रत्येक शक्यता 0 आणि 1 च्या दरम्यान (कधीच उणे नाही, कधीच 1 पेक्षा जास्त नाही).
2. सगळ्या शक्यतांची बेरीज = 1 (काहीतरी घडणारच).  
पाऊस 0.7 -> पाऊस-नाही 0.3; बेरीज 1.
3. probability 0 म्हणजे अशक्य, 1 म्हणजे निश्चित; मध्ये सगळी अनिश्चितता.

नियम 2 महत्वाचा: थेंबूचं यंत्र “पाऊस, ढगाळ, कोरडं” या तीन शक्यतांना उदा 0.6, 0.3, 0.1 देईल: बेरीज **नेहमी 1**. यंत्र शक्यता “वाटतं”, एकूण 1 चा केक तीन तुकड्यांत.

**आणि इथे Book 2 चं मोठं सत्य नव्या प्रकाशात:** ChatGPT चं “पुढचा token” म्हणजे नक्की काय? शब्दकोशातल्या प्रत्येक शब्दाला एक probability (बेरीज 1): “the” ला 0.3, “cat” ला 0.05, “पाऊस” ला 0.001... हजारो शब्द, हजारो शक्यता, बेरीज

1. यंत्र एका शब्दाची खात्री देत नाही; अख्ख्या शब्दकोशावर विश्वास वाटून देतं. हेच LLM चं गणिती हृदय: आणि म्हणूनच ते कधीच “नक्की” नसतं, नेहमी “किती शक्यता” असतं. Book 2 चं “यंत्र फासे टाकतं” आता नेमकं दिसतं: शब्दकोशावरच्या probability-यादीतून एक निवडणं.

## इथे लोक काय चुकीचं समजतात

”70% म्हणजे यंत्राला बऱ्यापैकी माहीत आहे.” धोकादायक. Probability हे यंत्राच्या **आत्मविश्वासाचं** माप आहे, **बरोबरपणाचं** नाही. यंत्र 0.99 खात्रीने **साफ चुकीचं** सांगू शकतं (Book 2, 5.1: hallucination = ठाम-खोटं). “किती खात्री” आणि “किती बरोबर” या दोन वेगळ्या गोष्टी; त्या जुळतात का हे तपासणं म्हणजे calibration (2.6 च्या पुढे, आणि Book 2, 1.4). आत्मविश्वास = बरोबरपणा हे गृहीत धरणं म्हणजे ठाम-चुकीच्या यंत्रावर विश्वास ठेवणं.

## नकाशावर

(दर chapter ला एक ओळ.)

2.1 probability = विश्वासाचं माप (0-1); बेरीज=1; LLM = शब्दकोशावर वाटलेला विश्वास; खात्री म्हणजे बरोबरपणा नव्हे

**सूत्रावर:** probability हा चष्मा यंत्राची अनिश्चितता **मोजता येण्याजोगी** करतो: “यंत्राला माहीत नाही” ही अस्पष्ट गोष्ट “0.5 probability” या नेमक्या आकड्यात. आणि मोजता आलं की हाताळता येतं: पुढचं सगळं Part 2 यावर.

## स्वतः बघा (5 मिनिटं)

हवामान-app उघडा: “पाऊस 40%” दिसेल. आता विचारा: याचा अर्थ (अ) “40% भाग आकाशात पाऊस” नाही; (ब) “अशा दिवशी 100 पैकी ~40 वेळा पाऊस पडतो” हो. आणि लक्षात घ्या: app कधीच “पाऊस: हो” म्हणत नाही, नेहमी टक्केवारी: कारण भविष्य अनिश्चित, आणि प्रामाणिक यंत्र अनिश्चितता लपवत नाही, मोजून दाखवतं.

## विचार करा

थेंबूचं यंत्र आता तीन शक्यता देतं: पाऊस 0.6, ढगाळ 0.3, कोरडं 0.1. पण थेंबूला वाटतं: “ही तीन-शक्यतांची यादी म्हणजे यंत्राचं पूर्ण ‘मत’ आहे. या यादीलाच काही आकार आहे का? कधी ती ‘एका शक्यतेवर ठाम’ असते, कधी ‘सगळीकडे पसरलेली गोंधळलेली’: हा फरक कसा बघायचा?”

ती शक्यतांची यादी म्हणजे एक “आकार” आहे: distribution (शक्यतांचा डोंगर). तो कधी एका शिखरावर तीव्र (खात्री), कधी सपाट पसरलेला (गोंधळ). त्या आकाराचं गणित: पुढचा chapter.

## Chapter 2.2 [SPINE]: Distribution: शक्यतांचा डोंगर

थेंबूचा प्रश्न: शक्यतांच्या यादीला आकार असतो का? हो: आणि त्या आकाराचं नाव **distribution** (वाटणी). तो आकार यंत्राचं मन उघडून दाखवतो: खात्री की गोंधळ.

**Distribution म्हणजे काय.** सगळ्या शक्यतांची यादी, एकत्र बघितलेली: एक “आकार.” थेंबूची तीन-शक्यतांची यादी दोन वेगळ्या दिवशी बघा:

दिवस A (खात्रीचा): पाऊस 0.9, ढगाळ 0.08, कोरडं 0.02  
दिवस B (गोंधळाचा): पाऊस 0.4, ढगाळ 0.35, कोरडं 0.25

दोन्हींची बेरीज 1 (नियम पाळला). पण **आकार** वेगळा: A मध्ये एक **तीव्र शिखर** (पाऊस-वर सगळं वजन): यंत्र ठाम. B मध्ये **सपाट, पसरलेला** डोंगर (तिन्हींत वाटलेलं): यंत्र गोंधळलेलं. तेच यंत्र, दोन दिवस, दोन मनःस्थिती: आणि distribution चा आकार ती मनःस्थिती **दाखवतो**. शिखर तीव्र = खात्री; डोंगर सपाट = अनिश्चितता.

**दोन टोकं (लक्षात ठेवा):** (1) **सर्वात तीव्र:** एका शक्यतेला 1, बाकी सगळ्यांना 0: पूर्ण खात्री, शून्य अनिश्चितता (“नक्की पाऊस”). (2) **सर्वात सपाट:** सगळ्यांना **सारखीच** शक्यता (तीन असतील तर प्रत्येकी 0.33): पूर्ण गोंधळ, कमाल अनिश्चितता (“काहीच अंदाज नाही, सगळं सारखं”). खऱ्या यंत्राचं distribution या दोन टोकांच्या मध्ये कुठेतरी: आणि **किती तीव्र की सपाट** हेच त्याचा आत्मविश्वास सांगतं.

**हे AI मध्ये कुठे दिसतं:** LLM चं प्रत्येक token हे शब्दकोशावरचं distribution (2.1). पुढचा शब्द “स्पष्ट” असेल (“भारताची राजधानी \_\_\_\_” -> “दिल्ली” ला 0.95: तीव्र शिखर) तर distribution तीव्र; “अनेक शक्य” असेल (“मला आवडतं \_\_\_\_” -> हजारो शब्द थोडी-थोडी शक्यता: सपाट) तर distribution पसरलेलं. आणि इथे एक व्यावहारिक सोनं: **distribution चा आकार बघून यंत्र किती “खात्रीशीर” आहे हे कळतं**. सपाट distribution म्हणजे यंत्र गोंधळलंय: तिथे त्याच्या उत्तरावर कमी भरवसा (hallucination चा धोका जास्त). तीव्र शिखर म्हणजे यंत्र ठाम (पण ठाम-चुकीचंही असू शकतं: 2.1 चा इशारा).

## इथे लोक काय चुकीचं समजतात

“यंत्र एक उत्तर देतं.” नाही: यंत्र **पूर्ण distribution** काढतं (हजारो शक्यता), मग त्यातून एक निवडतं (2.6 चा softmax/ temperature). तुम्हाला फक्त निवडलेलं दिसतं, पण मागे अख्खा डोंगर असतो. आणि तो डोंगर **फेकून** दिला जातो हे दुखणं: कारण त्या डोंगरात “यंत्र किती गोंधळलेलं होतं” ही अमूल्य

माहिती असते, जी अंतिम उत्तरात दिसत नाही. म्हणून calibration-अभ्यास (Book 2, 1.4) या डोंगराकडे बघतो, उत्तराकडे नाही.

## नकाशावर

- 2.1 probability = विश्वासाचं माप; बेरीज=1
- 2.2 distribution = शक्यतांचा आकार; तीव्र शिखर=खात्री, सपाट=गोंधळ; यंत्राचं मन उघडतं

**सूत्रावर:** distribution हा चष्मा यंत्राचा आत्मविश्वास **दृश्य** करतो: “यंत्र गोंधळलंय” ही भावना “सपाट distribution” या मोजता- येणाऱ्या आकारात. मोजता आलं, म्हणून वापरता आलं (कमी-खात्रीच्या उत्तरांना जास्त तपासा).

## स्वतः बघा (5 मिनिटं)

दोन प्रश्न कल्पना करा: “ $2+2 = ?$ ” (उत्तर distribution: “4” ला  $\sim 1.0$ , बाकी  $\sim 0$ : तीव्र शिखर) आणि “एक चांगलं नाव सुचव” (उत्तर: हजारो नावांना थोडी-थोडी शक्यता: सपाट). पहिल्यावर यंत्र ठाम, दुसऱ्यावर मुक्त. तुम्ही AI ला हे दोन प्रश्न विचारून बघा: पहिल्याचं उत्तर नेहमी तेच, दुसऱ्याचं दर वेळी वेगळं: distribution चा आकार वर्तनात दिसतो.

## विचार करा

थेंबूचं यंत्र कालपासून शिकतंय, आणि आज सकाळी त्याने अंदाज लावला: “पाऊस 0.6.” पण दुपारी अचानक **नवा पुरावा** आला: आकाशात काळे ढग दाटले. थेंबूला वाटलं: “आता माझा अंदाज बदलायला हवा: 0.6 वरून वर. पण **किती** वर? नव्या पुराव्याने जुनं मत नक्की किती हलवायचं: याचा काही नियम आहे का, की मनाने ठरवायचं?”

नव्या पुराव्याने जुनं मत **किती** हलवायचं याचा एक अचूक, सुंदर नियम आहे: आणि तो जगातल्या सर्व विज्ञान, वैद्यक, आणि यंत्र-शिक्षणाचा पाया आहे. त्याचं नाव Bayes: पुढचा chapter, आणि तो या विभागातला सर्वात शक्तिशाली.



## Chapter 2.3 [SPINE]: Bayes: पुराव्याने मत हलवणं

थेंबूचा प्रश्न: नव्या पुराव्याने जुनं मत **किती** हलवायचं? याचं उत्तर विज्ञानातल्या सर्वात शक्तिशाली कल्पनांपैकी एक आहे. आणि ती समजायला एक धक्कादायक वैद्यकीय उदाहरण घेऊ: जे बहुतेक लोक (आणि डॉक्टरही) चुकतात.

**धक्कादायक doctor-test.** एक आजार 1000 माणसांत 1 ला असतो (दुर्मिळ). त्याची चाचणी 99% “अचूक” आहे. तुमची चाचणी **positive** आली. तुम्हाला आजार असण्याची खरी शक्यता किती? बहुतेक म्हणतात “99%.” **चुकीचं.** खरं उत्तर ~9% आहे. का, ते आकडे मोजून बघू (हेच Bayes):

1000 माणसं घ्या.  
 आजारी: 1 (दुर्मिळता). निरोगी: 999.  
 - आजारी 1: चाचणी 99% बरोबर -> ~1 positive (खरा).  
 - निरोगी 999: चाचणी 99% बरोबर म्हणजे 1% चुकीची ->  
 $999 \times 0.01 = \sim 10$  जणांना चुकून positive (खोटे).  
 एकूण positive: 1 खरा + 10 खोटे = 11.  
 यातले खरे आजारी: 1 पैकी 11 = ~9%.

म्हणजे positive येऊनही आजार असण्याची शक्यता फक्त ~9%! कारण आजार इतका **दुर्मिळ** होता की चाचणीच्या “छोट्या चुका” (999 पैकी 10) खऱ्या केसपेक्षा जास्त झाल्या. **मूळ दुर्मिळता (1 in 1000) चा विसर पडला की सगळं चुकतं.**

**Bayes चा गाभा एका वाक्यात: नवं मत = जुनं मत (मूळ शक्यता) + नवा पुरावा, दोन्ही मिळून.** पुरावा जुन्या मताला पूर्ण उलथवत नाही; तो त्याला **हलवतो**, आणि किती हलवायचं हे जुनी शक्यता किती होती यावर ठरतं. जुनं मत “आजार दुर्मिळ” (1/1000) होतं; एका positive ने ते 9% पर्यंत वर नेलं (90 पट वाढ!), पण 99% पर्यंत नाही (कारण दुर्मिळता प्रचंड होती). दुसरी positive चाचणी आली तर आता जुनं मत 9% (पहिल्यापेक्षा जास्त), म्हणून ती अजून वर नेईल. **पुरावा साचत जातो, मत टप्प्याटप्प्याने सरकतं.**

**थेंबूवर:** थेंबूचं जुनं मत “पाऊस 0.6.” नवा पुरावा “काळे ढग” (जे पावसाच्या दिवशी अनेकदा दिसतात, कोरड्या दिवशी क्वचित). Bayes म्हणतो: 0.6 वर ढगांचा पुरावा जोडून नवं मत काढ: म्हणा 0.85. किती वर? ढग पावसाशी किती जोडलेले यावर. मनाने नाही, **गणिताने**. आणि हेच यंत्र-शिक्षणाचं हृदय: प्रत्येक नवं उदाहरण म्हणजे पुरावा, जो यंत्राचं “मत” (weights) थोडं हलवतो (Part 3 चा gradient descent हा Bayes चा चुलतभाऊ).

हे सर्वत्र आहे: spam-गाळणी ("हा शब्द spam मध्ये किती वेळा येतो" वरून email चं मत), वैद्यकीय निदान, न्यायालयातले पुरावे, आणि AI चा अख्खा अंदाज-खेळ. **Bayes = तर्कशुद्ध मत-बदलाचं गणित:** आणि जो हे शिकतो तो बातम्या, आकडे, दावे: सगळं जास्त शहाणपणाने वाचतो.

## इथे लोक काय चुकीचं समजतात

"चाचणी 99% अचूक, positive आलं, म्हणजे 99% आजार." जगातली सर्वात सामान्य आकडे-चूक (base rate neglect: मूळ-दुर्मिळतेचा विसर). लोक चाचणीच्या अचूकतेकडे बघतात, आजाराच्या दुर्मिळतेकडे नाही. Bayes शिकवतो: **दुर्मिळ गोष्टीचा पुरावा नेहमी संशयाने बघा:** कारण दुर्मिळतेमुळे "खोटे positive" खऱ्यापेक्षा जास्त असू शकतात. हीच चूक AI मध्येही: "यंत्र 99% खात्रीने म्हणालं" पण ती गोष्ट मुळात दुर्मिळ/अशक्य असेल तर खात्रीलाही संशयाने बघा.

## नकाशावर

- 2.1 probability = विश्वासाचं माप    2.2 distribution = आकार  
2.3 Bayes: नवें मत = जुनं मत + पुरावा; दुर्मिळतेचा विसर =  
मोठी चूक (doctor-test 9%); पुरावा हलवतो, उलथवत नाही

**सूत्रावर:** Bayes हा चष्मा "मत कसं बदलावं" ला **गणित** देतो: भावनेने नाही, पुराव्याच्या वजनाने. आणि यंत्राचं शिकणं हेच: पुरावा-पुरावा, मत सरकत जाणं. तर्कशुद्धता म्हणजे Bayes जगणं.

## स्वतः बघा (5 मिनिटं)

एक बातमी आठवा: "X चाचणीत 95% अचूक!" आता विचारा: ज्या गोष्टीची चाचणी आहे ती किती **दुर्मिळ** आहे? दुर्मिळ असेल तर 95% अचूकतेतही बहुतेक positive **खोटे** असू शकतात (doctor-test). ही एक नजर तुम्हाला आरोग्य-जाहिराती, सर्वेक्षणं, आणि AI-दावे: सगळं जास्त शहाणपणाने वाचायला लावेल.

## विचार करा

थेंबूला आता एक वेगळाच प्रश्न पडला: "मी शक्यता मोजायला शिकलो, मत बदलायलाही. पण एक गंमत: जेव्हा माझं distribution सपाट असतं (सगळं सारखं, गोंधळ), तेव्हा मला 'किती गोंधळ आहे' हे **एका आकड्यात** सांगता येईल का? 'खात्री' आणि 'गोंधळ' यांच्यातलं अंतर मोजायचं एक माप?"

हो, आणि ते माप AI मधलं सर्वात खोल, सर्वात सुंदर आहे: **entropy**: आश्चर्याचं/गोंधळाचं माप. आणि तेच Book 2 च्या loss चं मूळ आहे. पुढचा chapter.

## Chapter 2.4 [SPINE]: Entropy: आश्चर्याचं माप

थेंबूला “गोंधळ” एका आकड्यात हवाय. गणिताचं उत्तर एका सुंदर कल्पनेत आहे: **entropy**: आश्चर्याचं माप. आणि ते समजायला एक खेळ खेळू: विसाव्या प्रश्नांचा.

**20 प्रश्नांचा खेळ (entropy चा आत्मा).** मी एक गोष्ट मनात धरतो, तुम्ही हो/नाही प्रश्न विचारून ओळखा. जर मी “आठवड्याचा वार” धरला (7 शक्यता), तर तुम्हाला ~3 प्रश्न लागतात (हुशारीने: “पहिल्या सहामांत?” वगैरे, अर्ध-अर्ध कापत). जर मी “वर्षातला दिवस” धरला (365 शक्यता), तर ~9 प्रश्न. **जितक्या जास्त, तितकी अनिश्चितता जास्त, तितके जास्त प्रश्न.** Entropy म्हणजे नेमकं हेच: “ही अनिश्चितता संपवायला सरासरी किती हो/नाही प्रश्न लागतील”: गोंधळाचं मोजमाप, प्रश्नांच्या भाषेत.

थेंबूवर, दोन दिवस:

दिवस A (खात्री): पाऊस 0.9, ढगाळ 0.08, कोरडं 0.02  
 -> जवळजवळ नक्की पाऊस; ओळखायला ~शून्य प्रश्न;  
 entropy कमी (~0.5).  
 दिवस B (गोंधळ): पाऊस 0.4, ढगाळ 0.35, कोरडं 0.25  
 -> काहीच स्पष्ट नाही; ओळखायला जास्त प्रश्न;  
 entropy जास्त (~1.5).

(आकडे “bits” मध्ये; नेमकी मोजणी सोडा: दिशा पकडा.) तीव्र distribution (2.2) = कमी entropy = कमी आश्चर्य = ठाम. सपाट distribution = जास्त entropy = जास्त आश्चर्य = गोंधळ. **entropy हा distribution च्या “सपाटपणा”चा एक आकडा.**

“आश्चर्य” का म्हणतो. जी गोष्ट नक्की घडणार (probability

1. ती घडली तर आश्चर्य **शून्य** (“अर्थातच”). जी **दुर्मिळ** (probability कमी) ती घडली तर आश्चर्य **मोठं** (“अरे, हे कसं!”). Entropy = सरासरी आश्चर्य. खात्रीच्या यंत्राला जग “अपेक्षित” (कमी आश्चर्य); गोंधळलेल्या यंत्राला जग सतत “धक्कादायक” (जास्त आश्चर्य). आणि इथे AI चं खोल सत्य: **यंत्र शिकतं म्हणजे जगाचं आश्चर्य कमी करत जातं**: सुरुवातीला सगळं धक्कादायक (काहीच अंदाज नाही, प्रचंड entropy); शिकल्यावर “पुढचा शब्द असाच असणार” (कमी आश्चर्य, कमी entropy). **शिकणं = आश्चर्य कमी करणं.**

हे **compression** शीही जोडलेलं (गंमत): कमी entropy = कमी आश्चर्य = अंदाज सोपा = **कमी जागेत साठवता येतं** (zip files याच तत्वावर). आणि म्हणूनच काही संशोधक म्हणतात “समजणं म्हणजे compression”: जितकं चांगलं समजलं, तितकं कमी आश्चर्य, तितकं आवळता येतं. LLM हे एका अर्थाने

इंटरनेटचं आवळलेलं रूप: कमी entropy मध्ये बसवलेलं जग.

## इथे लोक काय चुकीचं समजतात

"Entropy म्हणजे भौतिकशास्त्रातली अस्ताव्यस्तता (गरम-थंड)." तिथूनच शब्द आला, पण माहिती-जगात entropy = **अनिश्चितता/ आश्चर्य**, तापमान नाही. आणि दुसरा गैरसमज: "कमी entropy = चांगलं." नेहमी नाही: यंत्र चुकीच्या गोष्टीवर कमी-entropy (ठाम- खोटं) असू शकतं (2.1 चा hallucination). Entropy फक्त "किती ठाम" मोजतं, "किती बरोबर" नाही. ठाम-आणि-चूक ही सर्वात धोकादायक जोडी.

## नकाशावर

2.1-2.3 probability | distribution | Bayes  
2.4 entropy = आश्चर्याचं/गोंधळाचं माप (किती हो/नाही प्रश्न लागतील); तीव्र=कमी, सपाट=जास्त; शिकणं = आश्चर्य कमी करणं

**सूत्रावर:** entropy हा चष्मा "गोंधळ" या अस्पष्ट गोष्टीला **एका आकड्यात** आणतो. आणि तो आकडा शिकण्याची दिशा दाखवतो: आश्चर्य कमी करत जा. जे मोजता येतं (आश्चर्य) ते सुधारता येतं (कमी करत जाणं): सूत्र प्रत्यक्षात.

## स्वतः बघा (5 मिनिटं)

20-प्रश्नांचा खेळ खेळा (कुणासोबत, किंवा मनात): एकदा "आठवड्याचा वार" (7 शक्यता), एकदा "जगातलं कुठलंही शहर" (हजारो). दुसऱ्याला किती जास्त प्रश्न लागतात बघा. तो फरक = entropy चा फरक. आणि लक्षात घ्या: प्रत्येक चांगला प्रश्न अनिश्चितता **अर्धी** करतो (अर्धी-अर्धी कापणं: Book 6 चा binary search इथे भेटेल): हुशार प्रश्न = जास्त entropy-कपात प्रति प्रश्न.

## विचार करा

थेंबूचं यंत्र आता शिकतंय: आश्चर्य कमी करतंय. पण थेंबूला मूळ प्रश्न आठवला: "यंत्र शिकतं म्हणजे नक्की **कशाकडून** शिकतं? Book 2 म्हणालं 'चूक (loss) मोजून, ती कमी करत.' पण ती 'चूक' नक्की काय? माझा अंदाज (पाऊस 0.6) आणि खरं घडलेलं (पाऊस पडला) यांच्यातलं अंतर एका आकड्यात कसं मोजायचं? आणि त्याचा entropy शी संबंध आहे का?"

आहे, आणि खोल आहे: Book 2 चं loss म्हणजे प्रत्यक्षात **cross-entropy**: entropy चंच जुळं भावंडं, जे "यंत्राचा अंदाज खऱ्यापासून किती दूर" मोजतं. loss चं खरं रूप: पुढचा chapter.

## Chapter 2.5 [SPINE]: Cross-Entropy: Loss चं खरं रूप

थेंबूचा प्रश्न: “चूक (loss)” नक्की काय? Book 2 ने loss ला “चुकीचं माप” म्हटलं (2.5); आता त्याचं खरं गणिती रूप उघडू: आणि ते entropy चंच जुळं भावंडं आहे: **cross-entropy**. हे समजलं की यंत्राच्या शिकवणीचं हृदय दिसतं.

**कल्पना: खऱ्याला तू किती probability दिलीस?** थेंबूने अंदाज लावला (distribution): पाऊस 0.6, ढगाळ 0.3, कोरडं 0.1. मग प्रत्यक्षात **पाऊस पडला**. आता चूक कशी मोजायची? सोपं तत्त्व: **जे खरं घडलं, त्याला यंत्राने किती probability दिली होती?** पाऊस पडला, यंत्राने पावसाला 0.6 दिलं होतं: बऱ्यापैकी, पण पूर्ण नाही. जर यंत्राने 0.95 दिलं असतं तर उत्तम (कमी चूक); 0.1 दिलं असतं तर वाईट (मोठी चूक: खऱ्या गोष्टीला यंत्र म्हणत होतं “अशक्य”).

**Cross-entropy loss (गाभा, सूत्राशिवाय):** खऱ्या घटनेला यंत्राने दिलेली probability जितकी जास्त, तितकी चूक कमी. आणि नातं उलटं-आणि-तीव्र आहे:

|                       |                  |
|-----------------------|------------------|
| यंत्राने खऱ्याला दिलं | -> loss (चूक)    |
| 0.9 (छान)             | -> लहान (~0.1)   |
| 0.6 (ठीक)             | -> मध्यम (~0.5)  |
| 0.1 (वाईट)            | -> मोठा (~2.3)   |
| 0.01 (भयंकर)          | -> प्रचंड (~4.6) |

लक्षात घ्या: probability जसजशी शून्याकडे, तसतशी loss **स्फोटक** वाढते. का? कारण **“खऱ्या गोष्टीला अशक्य म्हणणं” ही सर्वात मोठी चूक**. यंत्र 0.9 खात्रीने चुकीचं बोललं (आणि खरं वेगळं निघालं) तर loss प्रचंड: शिक्षा मोठी. हेच यंत्राला “ठाम-चूक” पासून परावृत्त करतं (किंवा करायला हवं: hallucination अजून का उरतं हे Book 2, 5.1). Loss = खऱ्याला दिलेल्या खात्रीची उलटी शिक्षा.

**Entropy शी नातं (सुंदर):** entropy होतं “यंत्राच्या स्वतःच्या अंदाजातलं सरासरी आश्चर्य” (2.4). Cross-entropy आहे “खऱ्या जगाशी ताडून यंत्राला किती आश्चर्य.” जर यंत्राचा अंदाज खऱ्याशी तंतोतंत जुळला तर cross-entropy = entropy (कमीत कमी). जितका अंदाज खऱ्यापासून दूर, तितकी cross-entropy entropy पेक्षा जास्त: आणि तो **जास्तीचा भाग म्हणजे यंत्राची चूक**. म्हणून training म्हणजे: cross-entropy कमी करत नेणं = यंत्राचा अंदाज खऱ्या जगाच्या जवळ नेणं = आश्चर्य कमी करणं (2.4 चा “शिकणं = आश्चर्य कमी करणं” आता नेमकं).

**हेच LLM चं संपूर्ण training (Book 2 उघडलं):** अब्जावधी वाक्यांत, प्रत्येक शब्दाला यंत्र अंदाज लावतं (पुढचा शब्द काय), खरा शब्द बघतं, आणि **खऱ्या शब्दाला यंत्राने किती probability दिली** यावरून cross-entropy loss. मग ती कमी करायला weights थोडे हलवतात (Part 3). ट्रिलियन वेळा. “यंत्र इंटरनेट वाचून शिकलं” म्हणजे: ट्रिलियन शब्दांवर cross-entropy कमी करत, आपला अंदाज खऱ्या मजकुराच्या जवळ नेत गेलं. Book 2 चं “अंदाज-चूक-सुधार” चक्र आता गणितात: चूक = cross-entropy.

## इथे लोक काय चुकीचं समजतात

“Loss म्हणजे यंत्राने किती उत्तरं चुकवली (टक्केवारी).” नाही: loss हे “किती चुकवली” नाही, “**किती खात्रीने चुकवली/बरोबर केली**” मोजतं. यंत्र बरोबर उत्तर देऊनही (जर कमी खात्रीने दिलं तर) थोडी loss घेतं; आणि चुकीचं उत्तर ठाम खात्रीने दिलं तर प्रचंड loss. म्हणून loss हे उत्तरांच्या **खात्रीचं** माप आहे, नुसत्या बरोबर-चूक चं नाही. हेच यंत्राला “नुसतं बरोबर” नाही तर “योग्य आत्मविश्वासाने बरोबर” व्हायला शिकवतं (आदर्शात; प्रत्यक्षात calibration अपुरं: Book 2, 1.4).

## नकाशावर

2.1-2.4 probability | distribution | Bayes | entropy  
 2.5 cross-entropy = loss चं खरं रूप; खऱ्याला दिलेली  
 probability जास्त -> loss कमी; अशक्य-म्हणणं = स्फोटक  
 शिक्षा; training = cross-entropy कमी करणं

**सूत्रावर:** cross-entropy हा चष्मा “यंत्र शिकतं म्हणजे काय” हे पूर्ण उघडतो: खऱ्या जगाशी आपला अंदाज ताडून, अंतर (loss) मोजून, ते कमी करणं. जे मोजता येतं (loss) तेच सुधारता येतं (कमी करत): सूत्र यंत्र-शिक्षणाच्या केंद्रस्थानी.

## स्वतः बघा (5 मिनिटं)

एक स्वतःची परीक्षा कल्पना करा जिथे तुम्ही प्रत्येक उत्तराला “किती खात्री” (%) लिहायची. आता cross-entropy चा नियम: बरोबर उत्तराला 90% खात्री दिली आणि बरोबर निघालं -> छान (कमी शिक्षा); पण चुकीच्या उत्तराला 90% खात्री दिली -> मोठी शिक्षा. हा नियम तुम्हाला “खात्री तेवढीच दाखवा जेवढी खरी आहे” शिकवतो: अति-आत्मविश्वासाला शिक्षा. यंत्रालाही तेच शिकवायचा प्रयत्न, cross-entropy ने.

## विचार करा

थेंबूला आता एक व्यावहारिक प्रश्न: “माझं यंत्र आतून ‘पाऊस-गुण’ काढतं (Part 1: matrix मधून, उदा 2.0, ढगाळ 1.8, कोरडं 0.5). पण हे ‘गुण’ कुठलेही आकडे असू शकतात (मोठे, उणे). त्यांचं 0-1 च्या, बेरीज-1 च्या **probability** मध्ये रूपांतर कसं? आणि मी ‘किती धीट अंदाज लावायचा’ (नेहमी सर्वात शक्य, की कधी जोखीम) हे कसं ठरवायचं?”

गुणांचं probability मध्ये रूपांतर करणारं एक सुंदर यंत्र आहे: softmax; आणि “किती धीट” ठरवणारी एक कळ: temperature (Book 2 ची तीच!). विभागाचा शेवटचा chapter, दोन्ही एकत्र.

## Chapter 2.6 [SPINE]: Softmax आणि Temperature

थेंबूचे दोन प्रश्न: कुठलेही गुण probability मध्ये कसे बदलायचे, आणि “किती धीट” कसं ठरवायचं. दोन्हींची उत्तरं एका सुंदर यंत्रात आणि एका कळीत आहेत: **softmax** आणि **temperature**. हे विभाग 2 आणि Part 1 ला जोडतात.

**Softmax: गुणांचं probability मध्ये रूपांतर.** थेंबूचे गुण: पाऊस 2.0, ढगाळ 1.8, कोरडं 0.5. हे 0-1, बेरीज-1 मध्ये कसे आणायचे? Softmax ची तीन पावलं (हाताने, ढोबळ):

1. प्रत्येक गुणाचा “स्फोट” (exponential: मोठा गुण जास्त मोठा होतो, फरक ठळक होतात):  
पाऊस 2.0  $\rightarrow \sim 7.4$ ; ढगाळ 1.8  $\rightarrow \sim 6.0$ ; कोरडं 0.5  $\rightarrow \sim 1.6$
2. बेरीज:  $7.4 + 6.0 + 1.6 = 15.0$
3. प्रत्येकाचा हिस्सा (भागा):  
पाऊस  $7.4/15 = 0.49$ ; ढगाळ  $6.0/15 = 0.40$ ; कोरडं  $1.6/15 = 0.11$

झालं: गुण (2.0, 1.8, 0.5)  $\rightarrow$  probability (0.49, 0.40, 0.11), बेरीज 1. **Softmax = कुठलेही आकडे घेऊन probability-वाटणी बनवणारं यंत्र.** आणि पायरी-1 चा “स्फोट” महत्त्वाचा: तो मोठ्या गुणाला **अप्रमाणात** जास्त probability देतो (फरक ठळक करतो): म्हणून “soft-max”: सर्वात मोठ्याला झुकतं, पण बाकीलाही थोडं (पूर्ण max नाही, soft). हेच LLM च्या शेवटच्या पायरीत: शब्दकोशाच्या गुणांचं (logits) probability मध्ये रूपांतर, प्रत्येक token ला.

**Temperature: “किती धीट” ची कळ (Book 2 ची तीच).** आता जादूची कळ. softmax च्या आधी सगळे गुण एका आकड्याने **भागा**: त्याचं नाव temperature (T).

- T कमी (उदा 0.5): गुण मोठे होतात  $\rightarrow$  स्फोट तीव्र  $\rightarrow$  सर्वात मोठ्याला अजून जास्त वजन  $\rightarrow$  distribution तीव्र (2.2)  $\rightarrow$  यंत्र “ठाम”, नेहमी सर्वात शक्य निवडतं. (कंटाळवाणं पण सुरक्षित.)
- T जास्त (उदा 1.5): गुण लहान होतात  $\rightarrow$  स्फोट मंद  $\rightarrow$  सगळे जवळ येतात  $\rightarrow$  distribution सपाट  $\rightarrow$  यंत्र “धीट/जुगारी”, कमी-शक्य पर्यायही निवडतं. (सर्जनशील पण जोखमीचं.)
- T = 1: मूळ, जसच्या तसं.

म्हणजे temperature ही **entropy ची कळ** (2.4): कमी T = कमी entropy (ठाम); जास्त T = जास्त entropy (गोंधळ/सर्जनशीलता). Book 2 मध्ये “temperature = निवडीच्या फाशांची मात्रा” म्हटलं होतं; आता नेमकं दिसतं: ती softmax च्या तीव्रतेची कळ, म्हणजे distribution च्या आकाराची कळ.



## सगळं जोडून (विभाग 2 चा कळस): एका token चा पूर्ण प्रवास.

1. matrix-थर (Part 1): शब्दाचा बाण -> गुण-यादी (logits), शब्दकोशातल्या प्रत्येक शब्दाला एक गुण.
2. temperature ने भागा: "किती धीट" ठरवा.
3. softmax: गुण -> probability-distribution (बेरीज 1).
4. त्या distribution मधून एक शब्द निवडा (फासे: 2.1).
5. training असेल तर: खऱ्या शब्दाशी ताडून cross-entropy loss (2.5) -> weights हलवा (Part 3).

Part 1 (बाण, matrix) + Part 2 (probability, softmax, loss): एकत्र म्हणजे LLM च्या एका पावलाचं पूर्ण गणित. थेंबूचं यंत्र आणि ChatGPT: हाच प्रवास, फक्त आकार वेगळा.

## इथे लोक काय चुकीचं समजतात

"Temperature वाढवली की यंत्र हुशार/सर्जनशील होतं." अर्धसत्य, धोकादायक. Temperature फक्त "किती कमी-शक्य पर्याय निवडायचे" ठरवते: जास्त T = जास्त विविधता, पण जास्त चुका/बरळणही (कमी-शक्य म्हणजे अनेकदा चुकीचं). "सर्जनशीलता" आणि "बरळण" दोन्ही जास्त-T चीच फळ: फरक फक्त तुम्हाला कोणतं हवं. तथ्यांच्या कामाला कमी T (ठाम, अचूक), कल्पक लेखनाला जास्त T (विविध). कळ हुशारीची नाही, जोखमीची आहे.

## नकाशावर

- 2.1-2.5 probability | distribution | Bayes | entropy | cross-entropy  
 2.6 softmax = गुण -> probability (स्फोट+भागा); temperature = धीटपणाची/entropy ची कळ (कमी=ठाम, जास्त=जुगारी);  
 पूर्ण token-प्रवास: बाण->गुण->softmax->निवड->loss

**सूत्रावर:** softmax+temperature हा चष्मा "यंत्र किती धीट/ठाम" ही कळ तुमच्या हातात देतो: entropy ची कळ फिरवता येते. आणि पूर्ण Part 1-2 मिळून यंत्राचं एक पाऊल आता संपूर्ण गणित आहे: कुठेही जादू उरली नाही.

## स्वतः बघा (5 मिनिटं)

अनेक AI-साधनांत “temperature” किंवा “creativity” ची कळ असते. असेल तर: तोच प्रश्न दोन T ला विचारा (कमी आणि जास्त). कमी T: उत्तर दर वेळी जवळपास तेच, सुरक्षित. जास्त T: दर वेळी वेगळं, कधी छान कधी विचित्र. तुम्ही entropy ची कळ प्रत्यक्ष फिरवताय: distribution तीव्र-सपाट करताय.

## विचार करा

विभाग 2 संपला. थेंबूला अनिश्चिततेचं पूर्ण गणित कळलं: शक्यता, आकार, पुरावा, आश्चर्य, चूक, धीटपणा. पण एक मोठा प्रश्न उरला, आणि तो सर्वात महत्वाचा: “मला ‘चूक (loss)’ मोजता येते, हे कळलं. पण Book 2 म्हणालं ‘चूक कमी करायला weights **हलवतात**.’ कुठल्या दिशेने, किती हलवायचे: हे यंत्राला कसं कळतं? लाखो weights आहेत; प्रत्येकाला किती ढकलायचं?”

हाच पुढच्या विभागाचा गाभा, आणि पूर्ण यंत्र-शिक्षणाचं हृदय: **उतार** (gradient). प्रत्येक weight ला “तू loss वर किती परिणाम करतोस, आणि कमी करायला कुठे सरकावं” हे सांगणारं गणित. उताराचं जग, Part 3.

# BOOK 7, PART 2 चा शेवट

## जे तुमच्याकडे आता आहे

|               |                                                                                                   |
|---------------|---------------------------------------------------------------------------------------------------|
| probability   | विश्वासाचं माप (0-1); बेरीज=1; LLM = शब्दकोशावर वाटलेला विश्वास; खात्री म्हणजे बरोबरपणा नव्हे     |
| distribution  | शक्यतांचा आकार; तीव्र शिखर=खात्री, सपाट=गोंधळ; यंत्राचं मन उघडतं                                  |
| Bayes         | नवं मत = जुनं मत + पुरावा; दुर्मिळतेचा विसर = मोठी चूक (doctor-test 9%); पुरावा हलवतो, उलथवत नाही |
| entropy       | आश्चर्याचं/गोंधळाचं माप; तीव्र=कमी, सपाट=जास्त; शिकणं = आश्चर्य कमी करणं                          |
| cross-entropy | loss चं खरं रूप; खऱ्याला दिलेली probability जास्त -> loss कमी; अशक्य-म्हणणं = स्फोटक शिक्षा       |
| softmax+temp  | गुण -> probability (स्फोट+भागा); temperature = धीटपणाची/entropy ची कळ; पूर्ण token-प्रवास         |

## स्वतःची परीक्षा (4 प्रश्न, बोलून; उत्तरं खाली)

1. LLM “एक उत्तर” देतं का, गणितात नक्की काय होतं?

नाही: शब्दकोशावर पूर्ण probability-distribution काढतं (बेरीज 1), मग softmax+temperature ने निवडतं. मागे अख्खा डोंगर. (2.1, 2.2, 2.6)

2. चाचणी 99% अचूक, positive आलं: आजार 99%? आणि खरा धडा?

नाही, ~9% (आजार दुर्मिळ तर खोटे-positive जास्त: Bayes). धडा: दुर्मिळतेचा विसर = मोठी चूक; पुरावा जुन्या मताला हलवतो, उलथवत नाही. (2.3)

3. Loss (cross-entropy) नक्की काय मोजतं, आणि सर्वात मोठी शिक्षा कधी?

खऱ्या घटनेला यंत्राने किती probability दिली (जास्त=कमी loss); “खऱ्याला अशक्य म्हणणं” (probability ~0) = स्फोटक शिक्षा. उत्तरांच्या खात्रीचं माप, नुसत्या बरोबर-चूक चं नाही. (2.5)

4. Temperature काय करते, आणि “सर्जनशीलता” चा सापळा?

distribution तीव्र (कमी T, ठाम) की सपाट (जास्त T, धीट) ठरवते = entropy ची कळ. सापळा: जास्त T = विविधता आणि बरळणं दोन्ही; कळ हुशारीची नाही, जोखमीची. (2.6)

## पुढच्या भागाची चाहल

थेंबूचा शेवटचा प्रश्न: loss कमी करायला weights **कुठल्या दिशेने, किती** हलवायचे? Part 3: उताराचं जग: derivative (बदलाचा दर), gradient (धुक्यातला डोंगर उतरणं), chain rule (चूक मागे वाटणं), आणि थेंबूवर **पूर्ण backpropagation हाताने, आकड्यांनिशी**. पूर्ण यंत्र-शिक्षणाचं हृदय.

## BOOK 7, PART 2 चा MINI-GLOSSARY

|               |                                                         |
|---------------|---------------------------------------------------------|
| Bayes         | नवं मत = जुनं मत + पुरावा (2.3)                         |
| base rate     | मूळ दुर्मिळता; हिचा विसर = मोठी चूक (2.3)               |
| calibration   | खात्री आणि बरोबरपणा जुळतात का (2.1)                     |
| cross-entropy | loss चं खरं रूप; खऱ्याला दिलेल्या खात्रीची शिक्षा (2.5) |
| distribution  | शक्यतांचा आकार (तीव्र/सपाट) (2.2)                       |
| entropy       | आश्चर्याचं/गोंधळाचं माप (2.4)                           |
| logits        | softmax च्या आधीचे कच्चे गुण (2.6)                      |
| probability   | विश्वासाचं माप (0-1); बेरीज=1 (2.1)                     |
| softmax       | गुण -> probability-वाटणी (2.6)                          |
| temperature   | धीटपणाची/entropy ची कळ (2.6)                            |