

The Lens, Part 4: परत AI कडे

August 30, 2026

THE LENS

Book 7, Part 4: परत AI कडे

मागच्या भागाचा शेवट: थेंबूचं सगळं गणित हातात: बाण, dot, matrix (Part 1), probability, softmax, loss (Part 2), gradient, backprop (Part 3). आता ते सगळं एकत्र येऊन ChatGPT चं हृदय उघडेल: **attention** आकड्यांनी पायरी-पायरी, एक transformer- मजला हाताने, scaling laws चं गणित, आणि एक खरा paper उलगडून वाचणं. हा भाग म्हणजे पूर्ण पुस्तकाचा कळस: जिथे थेंबू ChatGPT होतो.

सूत्र (शेवटच्या भागासाठी)

गणित म्हणजे आकडेमोड नव्हे; न दिसणारं दाखवणारा चष्मा.
जे मोजता येतं, ते सुधारता येतं.
Part 4 चा भर: सगळे तुकडे एकत्र = AI चं हृदय, आकड्यांत.

Part 3 ची उजळणी: 3 प्रश्न (बोलून; उत्तरं खाली)

1. “यंत्र शिकतं” चं गणित पाच पायऱ्यांत?

forward -> loss -> backward (chain rule) -> update (उलट उतार, learning rate) -> पुन्हा.
(3.4)

2. Gradient काय दाखवतो?

सर्वात तीव्र चढाची दिशा; loss कमी करायला उलट जा. (3.2)

3. “AI का चालतं” चं प्रामाणिक उत्तर?

पूर्ण कुणालाच माहीत नाही; सीमेवर सगळे नवखे; मोजून प्रगती. (3.6)

या भागात काय

Attention (query-key-value) आकड्यांनी हाताने, softmax-scaling का लागतं, एक पूर्ण transformer-मजला, scaling laws चं log-log गणित, एक खरा AI-paper वाचण्याची कला, आणि अंतिम परीक्षा + सूत्र-पत्र. थेंबूचं गणित ChatGPT होताना बघू.

विभाग 4: परत AI कडे

आता वर्तुळ पूर्ण करू. Book 2 ने attention उपमेने दिलं (बाजार, मागणी-पाटी-माल); या पुस्तकाने त्याखालचं गणित तुकड्यातुकड्याने दिलं. या विभागात ते सगळे तुकडे एकत्र येतील: dot product + softmax + weighted sum = attention, आकड्यांनी. मग transformer, scaling, आणि papers वाचणं. **हे तुमच्या शिक्षणात कुठे येईल:** हा विभाग संपला की तुम्ही Book 2 चं “उपमा-AI” आणि खरं “गणित- AI” यांना जोडाल, आणि सर्वात महत्वाचं: **AI-paper स्वतः उघडून वाचायची भीती कायमची जाईल.** थेंबूपासून सुरू झालेला प्रवास इथे ChatGPT च्या हृदयात पोहोचतो.

Chapter 4.1 [SPINE]: Attention

आकड्यांनी: पायरी-पायरी

हा chapter म्हणजे पूर्ण पुस्तकाचा कळस: **attention, आकड्यांनी, हाताने**. Book 2 ने उपमा दिली (query = मागणी, key = पाटी, value = माल); आता ती उपमा **आकड्यांत** बघू. कागद-पेन घ्या.

रचना: तीन शब्द, प्रत्येकाला तीन बाण. एक छोटं वाक्य: “पाऊस आज पडेल.” attention चं काम: प्रत्येक शब्दाने इतर शब्दांकडे **किती लक्ष द्यायचं** ठरवून, त्यानुसार माहिती मिसळणं. प्रत्येक शब्दाला तीन बाण (हे matrices ने बनतात, Part 1; इथे तयार धरू):

शब्द	query (q)	key (k)	value (v)
पाऊस	-	(1, 0)	(2, 0)
आज	-	(0, 1)	(0, 2)
पडेल	(1, 0)	(0.5, 0.5)	(1, 1)

query = “मला काय शोधायचं”; key = “माझ्याकडे काय आहे”; value = “मी काय माहिती देईन.” आपण **”पडेल” या शब्दाचं attention** काढू: तो इतर शब्दांकडे किती लक्ष देतो?

पायरी 1: जुळणी-गुण (query · प्रत्येक key): dot product (1.2).

$$\begin{aligned}
 \text{पडेल} \cdot \text{पाऊस} &= (1,0) \cdot (1,0) = 1 \times 1 + 0 \times 0 = 1.0 && (\text{जुळतं!}) \\
 \text{पडेल} \cdot \text{आज} &= (1,0) \cdot (0,1) = 1 \times 0 + 0 \times 1 = 0.0 && (\text{जुळत नाही}) \\
 \text{पडेल} \cdot \text{पडेल} &= (1,0) \cdot (0.5,0.5) = 1 \times 0.5 + 0 \times 0.5 = 0.5 && (\text{थोडं})
 \end{aligned}$$

”पडेल” ची मागणी (1,0) “पाऊस” च्या पाटीशी (1,0) सर्वात जुळते. गुण: 1.0, 0.0, 0.5.

पायरी 2: गुणांचं लक्ष-वाटप (softmax, 2.6). हे गुण probability मध्ये (बेरीज 1):

$$\begin{aligned}
 \text{स्फोट: } e^1 &= 2.72, \quad e^0 = 1.0, \quad e^{0.5} = 1.65 \\
 \text{बेरीज: } 2.72 + 1.0 + 1.65 &= 5.37 \\
 \text{लक्ष: पाऊस } 2.72/5.37 &= 0.51, \quad \text{आज } 1.0/5.37 = 0.19, \quad \text{पडेल } 1.65/5.37 = 0.31
 \end{aligned}$$

म्हणजे “पडेल” आपलं **51% लक्ष “पाऊस” कडे**, 19% “आज” कडे, 31% स्वतःकडे देतो. हेच “attention weights”: कुणाकडे किती बघायचं.

पायरी 3: माहिती मिसळण (लक्ष x value यांची बेरीज). आता प्रत्येक शब्दाचा value-बाण त्याच्या लक्ष-वाट्याने घ्या, बेरीज करा:

$$\begin{aligned}\text{output} &= 0.51 \times (2,0) + 0.19 \times (0,2) + 0.31 \times (1,1) \\ &= (1.02, 0) + (0, 0.38) + (0.31, 0.31) \\ &= (1.33, 0.69)\end{aligned}$$

झालं. “पडेल” चा नवा बाण = **(1.33, 0.69)**: मुख्यतः “पाऊस” च्या माहितीने (2,0) रंगलेला, कारण तिकडे सर्वात जास्त लक्ष. **हेच attention**: प्रत्येक शब्दाने इतरांकडे लक्ष-वाटून, त्यांची माहिती स्वतःत मिसळणं. “पडेल” ला आता “पाऊस” चा संदर्भ कळला: वाक्याचा अर्थ त्याच्या बाणात उतरला.

हेच ChatGPT करतं, फक्त: 3 शब्द ऐवजी हजारो, 2-आकड्यांचे बाण ऐवजी शेकडो-आकड्यांचे, आणि एका “लक्ष-नजरे” ऐवजी अनेक समांतर (multi-head: प्रत्येक नजर वेगळं नातं बघते: कोण-कुणाशी व्याकरण, कोण-कुणाशी अर्थ). पण **कृती तीच जी तुम्ही आता केलीत**: dot (जुळणी) -> softmax (लक्ष) -> weighted sum (मिसळण). Book 2 चा “मागणी-पाटी-माल बाजार” आता तीन ओळींचं अंकगणित आहे. Attention चं गूढ संपलं.

इथे लोक काय चुकीचं समजतात

”Attention म्हणजे यंत्र ‘लक्ष देतं’, म्हणजे त्याला जाणीव/समज आहे.” नाही: “लक्ष” हा फक्त softmax-चा वाटप-आकडा आहे (0.51, 0.19, 0.31). यंत्र “बघत” नाही, “जाणत” नाही; ते dot products चे गुण softmax मधून probability करतं आणि values ची भारित बेरीज घेतं. “attention” हे काव्यात्मक नाव आहे, यांत्रिक कृतीला. जाणीव तिथे नाही, फक्त जुळणी-वाटप-मिसळण आहे. (हा भेद Book 2 च्या “यंत्राला समज आहे का” वादाचा गाभा.)

नकाशावर

(दर chapter ला एक ओळ.)

4.1 attention आकड्यांनी: dot (जुळणी-गुण) -> softmax (लक्ष-वाटप) -> weighted sum (value मिसळण); “पडेल” 51% “पाऊस” कडे; हेच ChatGPT, अब्जावधी पट

सूत्रावर: attention हा सर्वात मोठा चष्मा-क्षण: Book 2 चं सर्वात गूढ यंत्र आता तीन ओळींचं अंकगणित. न दिसणारं (यंत्र शब्दांचा संदर्भ कसा जोडतं) पूर्ण आकड्यांत दिसलं. जादू कायमची संपली; समज उरली.

स्वतः बघा (5 मिनिटं)

वरचं attention स्वतः, हाताने करा: पण “पाऊस” या शब्दाचं (त्याचा query असेल समजा (0,1)). कुठल्या शब्दाकडे तो सर्वात जास्त लक्ष देईल? (key (0,1) असलेल्या “आज” कडे.) एकदा हाताने केलंत की attention चा “बाजार” तुमच्या बोटान्त उतरेल: आणि कुठलाही transformer-paper वाचताना हे चित्र डोळ्यांसमोर येईल.

विचार करा

थेंबूने attention काढलं, पण एक बारकावा दिसला: “मी गुण (1.0, 0.0, 0.5) थेट softmax मध्ये टाकले. पण Book 2 आणि papers मध्ये ‘गुणांना आधी भागतात’ असं काहीतरी असतं (scaled dot-product). का भागायचं? गुण जसेच्या तसे का चालत नाहीत?”

सूक्ष्म पण महत्त्वाचा प्रश्न: बाण मोठे (शेकडो आकडे) झाले की dot-गुणही मोठे होतात, आणि मोठे गुण softmax ला **अति-तीव्र** करतात (एकावर सगळं लक्ष, बाकी शून्य: शिकणं बिघडतं). तो का आणि उपाय: पुढचा chapter.

Chapter 4.2 [DEPTH]: Softmax-Scaling का लागत

थेंबूचा प्रश्न: attention मध्ये गुण आधी का भागतात? हा छोटा पण सुंदर मुद्दा आहे, आणि तो “papers मधले विचित्र भागाकार” समजायला किल्ली आहे. [DEPTH]: बारीक, पण एका खऱ्या नमुन्याचं स्पष्टीकरण.

समस्या: मोठे बाण = मोठे गुण = अति-तीव्र softmax. 4.1 मध्ये बाण छोटे (2 आकडे) होते, गुण छोटे (1.0, 0.5). पण खऱ्या यंत्रात बाण शेकडो आकड्यांचे. dot product म्हणजे शेकडो गुणाकारांची बेरीज (1.2): जितके जास्त आकडे, तितकी बेरीज **मोठी** होते. गुण 1-2 ऐवजी 20-50 होतात. आणि मोठे गुण softmax मध्ये घातले तर?

छोटे गुण (1, 0, 0.5): softmax $\rightarrow$ (0.51, 0.19, 0.31): मऊ वाटप
मोठे गुण (10, 0, 5): softmax $\rightarrow$ (0.99, 0.00, 0.01): अति-तीव्र!

मोठे गुण softmax ला **टोकाला** नेतात: जवळजवळ सगळं लक्ष एकावर, बाकीला शून्य (distribution अति-तीव्र, entropy जवळजवळ शून्य: 2.4). हे वाईट का? दोन कारणं: (1) यंत्र फक्त एकाच शब्दाकडे बघतं, बाकीचा संदर्भ गमावतं (मऊ मिसळण हवं). (2) आणि गंभीर: शिकवणीत **gradient जवळजवळ शून्य** होतो (vanishing: 3.3): कारण अति-तीव्र softmax चा उतार सपाट, म्हणून weights हलतच नाहीत, यंत्र शिकत नाही.

उपाय: गुणांना बाणाच्या-आकाराच्या मुळाने भागा. transformer चा नियम: dot-गुणांना **root(d)** ने भागा (d = बाणातल्या आकड्यांची संख्या). बाण 64 आकड्यांचा तर $\text{root}(64) = 8$ ने भागा; 100 आकड्यांचा तर 10 ने. का हे नेमकं? गणिती कारण: बाण मोठे झाले की dot-गुण साधारण $\text{root}(d)$ पटीने वाढतात; म्हणून $\text{root}(d)$ ने भागलं की गुण पुन्हा “वाजवी” आकारात येतात (1-2 च्या आसपास), softmax मऊ राहतो, शिकणं सुरळीत. एका ओळीत: **scaling म्हणजे बाण कितीही मोठे असोत, attention चे गुण वाजवी ठेवणं, म्हणजे softmax मऊ आणि शिकणं जिवंत.**

हे शिकण्याचा खरा फायदा (papers-वाचन): transformer च्या मूळ paper चं नावच “scaled dot-product attention” आहे. आता तुम्हाला “scaled” का ते नेमकं कळलं: तो $\text{root}(d)$ चा भागाकार, आणि तो का लागतो. papers मध्ये असे शेकडो “छोटे तांत्रिक तपशील” असतात जे भीतीदायक दिसतात पण **प्रत्येकामागे असंच एक साधं व्यावहारिक कारण** असतं (“हे न केलं तर हे बिघडतं”). गणिताचा चष्मा तुम्हाला ते कारण शोधायला शिकवतो: आणि मग paper भीतीदायक न राहता “समस्या-उपाय” ची यादी होतं.

इथे लोक काय चुकीचं समजतात

"Paper मधली प्रत्येक सूत्र-सजावट म्हणजे खोल, दुर्बोध गणित." बहुतेकदा उलट: प्रत्येक तपशीलामागे एक साधं, व्यावहारिक "नाहीतर हे बिघडतं" असतं (इथे: नाहीतर softmax तीव्र, शिकणं मरतं). papers अवघड दिसतात कारण संक्षिप्त भाषा आणि प्रतीक; पण आत बहुधा तुम्हाला समजणारी अभियांत्रिकी-कारणं. "हे प्रतीक का आहे" विचारत गेलं की paper उलगडतं. भीती प्रतीकांची असते, कल्पनांची नाही.

नकाशावर

- 4.1 attention आकड्यांनी: dot $\rightarrow$ softmax $\rightarrow$ weighted sum
- 4.2 scaling: मोठे बाण $\rightarrow$ मोठे गुण $\rightarrow$ अति-तीव्र softmax (शिकणं मरतं); उपाय $\sqrt{d}$ ने भागा $\rightarrow$ गुण वाजवी, softmax मऊ; papers चे तपशील = "नाहीतर हे बिघडतं"

सूत्रावर: scaling हा छोटा चष्मा मोठा धडा देतो: AI मधला प्रत्येक तांत्रिक तपशील एका मोजता-येणाऱ्या समस्येचा उपाय आहे. जे बिघडतं ते मोजता आलं (तीव्र softmax, मेलेला gradient), म्हणून उपाय (भागाकार) सापडला: सूत्र papers च्या तळाशीही.

स्वतः बघा (5 मिनिटं)

दोन softmax हाताने: गुण (2, 1, 0) आणि तेच 10-पट (20, 10, 0). पहिल्याचा softmax मऊ (तिन्हीना थोडं); दुसऱ्याचा जवळजवळ (1, 0, 0). बघा: गुण मोठे केले की softmax टोकाला जातो. हेच scaling टाळतं. आकड्यांचा "आकार" softmax च्या मऊपणावर किती परिणाम करतो, ते डोळ्यांनी दिसेल.

विचार करा

थेंबूला attention चा एक "मजला" कळला. पण Book 2 म्हणालं transformer-मजल्यात attention आणि आणखी काही (एकांत- खोली, वाकडी कृती) असतं, आणि असे शेकडो मजले. "एक पूर्ण मजला नक्की काय-काय करतो, आणि तो एका बाणावर पायरी-पायरी कसा चालतो? मला अख्खा मजला, आकड्यांनी, बघायचाय."

हाच पुढचा chapter, आणि थेंबूचा ChatGPT होण्याचा क्षण: एक पूर्ण transformer-मजला, सगळे तुकडे जोडून, एका बाणावर पायरी-पायरी. Part 1-4 चं सगळं एका चित्रात.

Chapter 4.3 [SPINE]: एक Transformer-मजला, पूर्ण

थेंबूचा ChatGPT होण्याचा क्षण. एक पूर्ण transformer-मजला, सगळे तुकडे जोडून, एका बाणावर पायरी-पायरी. Book 2 चा “बाजार + एकांत-खोली” आता आकड्यांच्या प्रवाहात.

मजल्याचे चार अवयव (एका शब्द-बाणावर): एक शब्द-बाण आत येतो; मजला त्याला चार पायऱ्यांतून नेतो, नवा (जास्त-समजलेला) बाण बाहेर.

पायरी 1: ATTENTION (बाजार): शब्द इतर शब्दांकडे लक्ष-वाटून त्यांची माहिती मिसळतो (4.1). “पडेल” $\rightarrow$ (1.33, 0.69), “पाऊस” चा संदर्भ आत आला. आउटपुट: संदर्भ-रंगलेला बाण.

पायरी 2: जोडणी (residual): मूळ बाण + attention-आउटपुट (बेरीज). का? म्हणजे मूळ माहिती हरवत नाही (attention ने फक्त “भर” घातली, मूळ पुसलं नाही); आणि हेच खोल यंत्रात gradient जिवंत ठेवतं (3.3 चा vanishing टाळतो). “जुनं ठेवून नवं जोडा.”

पायरी 3: एकांत-खोली (feed-forward): आता प्रत्येक शब्द एकटा, एका छोट्या 2-थरी यंत्रातून (matrix $\rightarrow$ वाकडी कृती ReLU $\rightarrow$ matrix: Part 1, 1.3-1.4). इथे शब्द बाजारात मिळालेली माहिती “पचवतो”, स्वतःपुरता विचार करतो. + पुन्हा जोडणी.

पायरी 4: ताळमेळ (normalization): बाणातले आकडे खूप मोठे/लहान होऊ नयेत म्हणून त्यांना “वाजवी” पट्ट्यात आणणं (scaling चा भाऊ, 4.2): पुढच्या मजल्याला स्वच्छ बाण मिळो.

आत बाण, बाहेर बाण: **पण बाहेरचा बाण “जास्त समजलेला”** (संदर्भ मिसळलेला + पचवलेला + नीटनेटका). आणि मग तोच बाण **पुढच्या मजल्यात**, तिथे पुन्हा चार पायऱ्या, आणि पुढच्या... GPT मध्ये असे **शेकडो मजले**. प्रत्येक मजला बाणाला थोडं जास्त अर्थ देतो: पहिले मजले व्याकरण-सारखं उथळ, वरचे मजले खोल अर्थ-तर्क. शेवटी शेवटच्या बाणातून पुढच्या token ची probability (softmax, 2.6). हेच ChatGPT चं एक पाऊल, पूर्ण.

थेंबू ते ChatGPT (पूर्ण प्रवास एका दृष्टिक्षेपात):

थेंबू: 2 आकडे -> 3 weights -> 1 अंदाज (एक ओळ)
 मजला: बाण -> attention + जोडणी + एकांत + ताळमेळ -> बाण
 ChatGPT: शब्द -> बाण (embedding) -> शेकडो मजले ->
 शेवटचा बाण -> softmax -> पुढचा token -> पुन्हा

तुकडे तेच जे थेंबूचे: बाण (Part 1), dot-matrix (Part 1), softmax-probability (Part 2), आणि हे सगळं शिकलं gradient descent-backprop ने (Part 3). **कुठेही नवीन जादू नाही; फक्त थेंबूचे तुकडे, अब्जावधी पट, शेकडो मजले उंच.** जो थेंबू समजला तो ChatGPT समजला: फरक आकाराचा, तत्वाचा नाही. हीच पूर्ण पुस्तकाची सर्वात मोठी कमाई: **AI ही थेंबूची मोठी आवृत्ती आहे, वेगळं जग नाही.**

इथे लोक काय चुकीचं समजतात

”शेकडो मजले म्हणजे यंत्र शेकडो पट ‘जास्त हुशार/जागरूक’.” मजले जास्त = जास्त **टप्प्याटप्प्याने अर्थ-शुद्धीकरण**, जागरूकता नाही. प्रत्येक मजला तेच चार यांत्रिक अवयव चालवतो; “समज” कुठल्याही एका मजल्यात नाही, ती अनेक साध्या रूपांतरांच्या साखळीतून **उगवते** (emergence: Book 2, 3.9). “मजला विचार करतो” ही उपमा; “मजला बाणावर चार गणिती कृती करतो” हे सत्य. आणि हेच का इतकं चांगलं चालतं: पूर्ण कुणालाच माहीत नाही (3.6): नम्रता कायम.

नकाशावर

4.1-4.2 attention आकड्यांनी | scaling
 4.3 transformer-मजला: attention (बाजार) + जोडणी (residual) +
 एकांत (feed-forward) + ताळमेळ (norm); शेकडो मजले;
 थेंबू ते ChatGPT: तेच तुकडे, अब्जावधी पट

सूत्रावर: हा chapter पूर्ण चष्मा-प्रवासाचा कळस: ChatGPT चं हृदय आता थेंबूच्या तुकड्यांचं बनलेलं दिसतं. सर्वात गुंतागुंतीचं यंत्र सर्वात साध्या कृतींची उंच रचना आहे: आणि ती रचना तुम्ही आता वाचू शकता.

स्वतः बघा (5 मिनिटं)

Book 2 चा transformer-chapter (3.8) परत उघडा आणि आता प्रत्येक उपमेखाली गणित बघा: “बाजार” = attention (dot+softmax+ मिसळण), “एकांत-खोली” = feed-forward (matrix+ReLU), “मजले x30-100” = शेकडो अशा रचना. उपमा आणि गणित जोडले जातील: आणि तेच खरं समजणं:

दोन्ही डोळ्यांनी एकच गोष्ट बघणं.

विचार करा

थेंबू ChatGPT झाला. पण एक मोठा प्रश्न उरला: “मजले, आकडे, सगळं कळलं. पण Book 4 म्हणालं ‘मोठं यंत्र = जास्त हुशार’ (scaling laws), आणि ते एका **सरळ रेषेवर** चालतं म्हणे. यंत्र मोठं केलं की हुशारी अंदाजपत्रे वाढते: हे कसं? आणि ‘सरळ रेषा’ म्हणजे नक्की कशाची रेषा?”

Scaling laws हे AI मधलं सर्वात आश्चर्यकारक गणित आहे: आकार वाढवला की चूक **अंदाजपत्रे** घटते, आणि ती एका विशिष्ट आलेखावर सरळ रेषा येते. ते गणित, आणि त्याचा अर्थ: पुढचा chapter.

Chapter 4.4 [SPINE]: Scaling Laws: सरळ रेषेचं गणित

थेंबूचा प्रश्न: यंत्र मोठं केलं की हुशारी अंदाजपत्रे वाढते: हे कसं, आणि “सरळ रेषा” कशाची? Scaling laws हे AI मधलं सर्वात आश्चर्यकारक, आणि व्यावहारिकदृष्ट्या सर्वात महत्वाचं गणित आहे (Book 4 चा अख्खा उद्योग यावर उभा).

निरीक्षण: आकार वाढवा, चूक अंदाजपत्रे घटते. संशोधकांना आढळलं: यंत्र मोठं करा (जास्त weights), data वाढवा, compute वाढवा: आणि loss (चूक, 2.5) **गुळगुळीत, अंदाजपत्रे घटते.** इतकी अंदाजपत्रे की छोट्या यंत्रांवरून **मोठ्या यंत्राची चूक आधीच भाकीत** करता येते (म्हणून labs अब्जावधी खर्चण्याआधी छोट्या प्रयोगांतून “हे मोठं यंत्र किती चांगलं होईल” ठरवतात). हे विलक्षण: गुंतागुंतीचं वर्तन, पण त्याची चूक एका साध्या नियमाने पडते.

”सरळ रेषा” कशाची: log-log आलेख. साध्या आलेखावर (आकार विरुद्ध चूक) रेषा वाकडी येते. पण **दोन्ही अक्ष “log” मध्ये** घेतले (म्हणजे 1, 10, 100, 1000 समान अंतरावर: गुणाकाराचे टप्पे, बेरजेचे नाही) तर ती वाकडी रेषा **सरळ** होते. याचा अर्थ: **आकार 10 पट केला की चूक ठराविक टक्क्याने घटते; पुन्हा 10 पट, पुन्हा तेवढीच टक्केवारी.** हा “power law” (घात-नियम): निसर्गात सर्वत्र (भूकंपांचे आकार, शहरांची लोकसंख्या, संपत्तीचं वाटप). AI ची चूकही याच कुळात: गुणाकाराच्या टप्प्यांत गुळगुळीत घट.

पण इथे कठोर सत्य (आणि आशा): रेषा सरळ, पण **खाली झुकती:** प्रत्येक 10-पट सुधारणा **आधीच्याइतकीच टक्केवारी** देते, म्हणजे **निरपेक्ष सुधारणा घटत जाते** (returns diminish). 100 वरून 1000 (10x) ने जेवढी सुधारणा, 1000 वरून 10000 (पुन्हा 10x, पण 9000 चा प्रचंड खर्च!) ने तेवढीच टक्केवारी: म्हणजे पुढची प्रत्येक सुधारणा **प्रचंड महाग.** म्हणूनच Book 4 (2.7) चा “scaling वळलं”: नुसतं मोठं करत राहणं परवडेनासं झालं, म्हणून खर्च नव्या जागी (post-training, विचार-वेळ) वळला. Scaling मेलं नाही; **घात-नियमाची किंमत असह्य झाली, म्हणून वाट बदलली.**

हे तुमच्यासाठी का महत्वाचं: (1) scaling laws समजले की “पुढचं यंत्र किती चांगलं” या चर्चा तुम्ही आकड्यांनी वाचता, hype ने नाही. (2) “AI अनंत वाढेल” (घात-नियम विसरून) आणि “AI थांबलं” (एका सपाटीकडे बघून) दोन्ही अतिरेक ओळखता: खरं मधे, घातनियमाच्या झुकत्या रेषेवर. (3) आणि सर्वात खोल: **एका साध्या रेषेने अब्जावधींचे निर्णय ठरतात** (labs किती खर्चायचं ठरवतात): गणिताचा चष्मा किती शक्तिशाली, याचं हे टोक.

इथे लोक काय चुकीचं समजतात

"Scaling laws म्हणजे यंत्र मोठं केलं की अनंत हुशार होईल." घात-नियमाची झुकती रेषा हेच नाकारते: सुधारणा **घटत** जाते, आणि खर्च **स्फोटक** वाढतो. आणि उलट गैरसमज: "एका सुधारणेचा वेग मंदावला = scaling मेलं." नाही: रेषा अजून सरळ (सुधारणा सुरू), फक्त निरपेक्ष घट लहान आणि खर्च मोठा. दोन्ही टोकं (अनंत-आशा, संपूर्ण-निराशा) घातनियम न समजल्याने येतात. रेषा वाचता आली की दोन्ही भ्रम विरतात.

नकाशावर

4.1-4.3 attention | scaling(softmax) | transformer-मजला
 4.4 scaling laws: आकार 10x -> चूक ठराविक % घट (घात-नियम);
 log-log आलेखावर सरळ-झुकती रेषा; सुधारणा घटती, खर्च
 स्फोटक -> "scaling वळलं"; रेषा वाचा, hype नको

सूत्रावर: scaling laws हा सर्वात भव्य चष्मा: AI च्या भवितव्याचा अंदाज एका सरळ रेषेत मोजता येतो. जे मोजता येतं (चूकीचा कल) त्यावर अब्जावधींचे निर्णय ठरतात: गणित इथे भविष्यवाणीचं साधन होतं.

स्वतः बघा (5 मिनिटं)

एक घात-नियम रोजचा: तुमच्या अभ्यासात/कौशल्यात पहिले 10 तास मोठी झेप देतात; पुढचे 10 कमी; पुढचे 10 अजून कमी (diminishing returns). पण थांबत नाही: प्रत्येक "दुप्पट मेहनत" ठराविक सुधारणा देतच राहते, फक्त लहान. AI ची चूकही असंच वागते. तुमच्या 90-दिवस-प्रवासालाही (The Climb) हेच लागू: सुरुवात झपाट्याने, नंतर संथ-पण-सतत.

विचार करा

थेंबू ChatGPT झाला, scaling ही कळलं. आता थेंबूला आत्मविश्वास आला: "मला बाण, dot, matrix, probability, gradient, attention, transformer, scaling: सगळं आकड्यांनी कळलं. आता मला एक **खरा AI-paper** उघडून वाचायचाय: बघायचंय की खरंच ही भीती संपली का, की फक्त थेंबूपुरतं समजलं. एक खरा paper समोर आला तर मी काय करू?"

हाच शेवटच्या-आधीचा chapter, आणि पूर्ण पुस्तकाची खरी परीक्षा: एक खरा AI-paper कसा उघडायचा, कुठून वाचायचा, कशाला घाबरायचं नाही. papers वाचण्याची कला: पुढचा chapter.

Chapter 4.5 [SPINE]: Paper वाचण्याची कला

पूर्ण पुस्तकाची खरी परीक्षा: एक खरा AI-paper उघडून वाचणं. कारण top 0.00001 ची सीमारेषा नेमकी हीच: papers स्वतः वाचता येणं. आणि हे chapter सांगतं की ती भीती **रचनेची** आहे, बुद्धीची नाही: आणि रचना शिकता येते.

आधी दिलासा: papers तुमच्यासाठीच लिहिलेली नाहीत. AI-papers तज्ज्ञांनी तज्ज्ञांसाठी, संक्षिप्त, प्रतीकांनी भरून लिहिलेली असतात: वाचकाला घाबरवायला नाही, पण **तसाच परिणाम** होतो. म्हणून पहिला नियम: **paper “समजलं नाही” म्हणजे तुम्ही कमी नाही; paper दुर्बोध भाषेत आहे.** आणि दुसरा: **पहिल्यांदा 100% समजायचं नसतंच**; अनुभवी संशोधकही paper 3-4 वेळा, वाढत्या खोलीने वाचतात.

वाचनाचा क्रम (छापून ठेवा): बाहेरून आत. paper पहिल्या ओळीपासून शेवटपर्यंत वाचू नका (तिथेच लोक बुडतात). ऐवजी थरांनी:

- थर 1 (5 मिनिटं): फक्त शीर्षक + सारांश (abstract) + निष्कर्ष (conclusion) + आकृत्यांचे कॅप्शन. प्रश्न: "हे कुठलं दुखणं सोडवतात, आणि निकाल काय?" (Book 1-4 चं जुनं सूत्र!)
- थर 2 (15 मिनिटं): प्रस्तावना (intro) + प्रत्येक विभागाचं पहिलं वाक्य. प्रश्न: "त्यांची मुख्य कल्पना काय, आधीच्यापेक्षा वेगळं काय?"
- थर 3 (खोल, गरज असेल तर): पद्धत (method) + आकडे नीट. इथे गणित येतं: आणि आता तुमच्याकडे चष्मा आहे: dot, softmax, gradient, attention: बहुतेक प्रतीक ओळखीची.

बहुतेक papers साठी थर 1-2 पुरतात ("हे काय, का, किती चांगलं"). थर 3 फक्त जे तुम्ही खरंच वापरणार/खोदणार त्यासाठी. **90% मूल्य पहिल्या 20 मिनिटांत**; उरलेलं 10% साठी तास.

प्रतीकांना घाबरू नका (सर्वात मोठा अडथळा). paper मधली भीतीदायक सूत्रं बहुधा तुम्हाला **आता माहीत असलेल्या** गोष्टीच: " $\text{softmax}(\text{QK}^T / \text{root}(d)) V$ " हे भयंकर दिसतं, पण तुम्ही ते आता वाचू शकता: Q,K,V = query-key-value बाण (4.1); QK^T = query-key चे dot products (जुळणी-गुण); $/\text{root}(d)$ = scaling (4.2); softmax = लक्ष-वाटप (2.6); V = values ची भारित बेरीज. **अख्खं attention एका ओळीत, आणि प्रत्येक तुकडा तुम्हाला माहीत.** हीच पूर्ण पुस्तकाची कमाई: प्रतीक बघून घाबरण्याऐवजी "हा कुठला ओळखीचा तुकडा" विचारणं. एक अनोळखी प्रतीक आलं तर थांबा, शोधा, तो एक तुकडा समजून घ्या: paper तुकड्यांचं बनलेलं आहे, अभेद्य भिंत नाही.

आणि सर्वात मोठा गुपित (Book 4 शी पूल): AI आता paper वाचायला मदत करतं. अडलेलं प्रतीक/परिच्छेद AI ला विचारा “हे सोप्या भाषेत समजाव”: पण **आंधळेपणाने नाही:** तुमच्या चष्म्याने त्याचं उत्तर **तपासा** (Book 4 चं evals-भान). AI + तुमचा गणिती पाया = papers ची भीती कायमची संपते. जो हे जोडतो (पाया + AI-मदत + तपासणी) तो कुठलंही नवं संशोधन, आठवड्याच्या आत, वाचू-समजू शकतो: आणि तेच top 0.00001 चं खरं रहस्य: **नवं ज्ञान स्वतः पचवण्याची यंत्रणा.**

इथे लोक काय चुकीचं समजतात

“Papers फक्त PhD-वाल्यांसाठी; मी वाचूच शकत नाही.” खोटं, आणि आत्म-पराभवी. papers दुर्बोध भाषेत आहेत, दुर्बोध **कल्पनांचं** नाहीत (बहुतेकदा): आणि भाषेचा अडथळा थर-वाचन + चष्मा + AI-मदत ने ओलांडता येतो. आणि उलट: “मी एक paper वाचलं, सगळं समजलं, आता मी तज्ज्ञ.” एक paper = एक तुकडा; खरी समज अनेक papers, प्रयोग, वेळ यांतून. नम्रता दोन्ही बाजूंनी: “वाचू शकतो” (आत्मविश्वास) आणि “सगळं कळलं नाही” (प्रामाणिकपणा): दोन्ही एकत्र.

नकाशावर

4.1-4.4 attention | scaling | transformer | scaling laws
 4.5 paper वाचन: बाहेरून-आत (abstract->intro->method); 90%
 मूल्य 20 मिनिटांत; प्रतीक = ओळखीचे तुकडे; AI-मदत +
 तपासणी = भीती संपली; हेच top-thinker चं रहस्य

सूत्रावर: paper-वाचन हा सर्वात व्यावहारिक चष्मा-क्षण: गणित शिकण्याचा खरा फायदा नवं बांधणं नाही, **जगातलं नवं ज्ञान स्वतः वाचता येणं.** आणि जे स्वतः वाचता-तपासता येतं, त्यावर कुणाच्या “सांगण्यावर” विसंबावं लागत नाही: तीच खरी बौद्धिक स्वातंत्र्य.

स्वतः बघा (5 मिनिटं)

“Attention Is All You Need” (transformer चा मूळ paper, 2017: जगातलं सर्वाधिक-cited AI-paper) चा फक्त abstract शोधून वाचा (एक परिच्छेद). बघा: किती शब्द तुम्हाला आता ओळखीचे (attention, encoder, translation)? दोन वर्षांपूर्वी ते चिनी वाटलं असतं; आता अर्थ वाचता येतं. हीच प्रगती: आणि थर-1 वाचन इतकंच.

विचार करा

पूर्ण पुस्तक संपत आलय. थेंबू ChatGPT झाला, आणि थेंबूचा मालक (तुम्ही) papers वाचू शकतो. शेवटचा प्रश्न, जो सगळं एका परीक्षेत बांधेल: “मी हे सगळं शिकलो: दिशा, शक्यता, उतार, attention. पण हे खरंच **मुरलं** का, की वाचून गेलं? आणि याचा मला **खरा** उपयोग काय: नुसतं ‘समजलं’ चं समाधान, की काहीतरी जास्त?”

तेच अंतिम परीक्षा ठरवेल: आणि उत्तर तुम्हाला माहीत आहे, फक्त शब्दांत यायचंय. गणिताचा चष्मा तुम्हाला “समजणाऱ्यां” कडून “तपासणाऱ्यां” कडे, आणि “ऐकणाऱ्यां” कडून “वाचणाऱ्यां” कडे नेतो: आणि तिथेच खरं leverage आहे. अंतिम परीक्षा, पुढे.

Chapter 4.6 [SPINE]: अंतिम परीक्षा

नियम आधीसारखेच: पुस्तक न उघडता, **बोलून** उत्तर द्या; गाभा खाली. हेतू गुण नाही: **गणिताचा चष्मा मुरला का** हे बघणं.

भाग अ: गणित मुरलं का (5 प्रश्न)

1. “यंत्राला शब्दाचा अर्थ कसा कळतो” चं पूर्ण गणिती उत्तर?

अर्थ = दिशा; शब्दाला आकड्यांचा बाण (embedding); जवळच्या दिशा = जवळचे अर्थ; जवळीक = dot product ने मोजतात. (1.1, 1.2, 1.5)

2. “यंत्र शिकतं” पाच पायऱ्यांत, आणि “चूक” नक्की काय?

forward (अंदाज) -> loss (cross-entropy: खऱ्याला दिलेली probability) -> backward (chain rule ने प्रत्येक weight चा उतार) -> update (उलट उतार, learning rate) -> पुन्हा. (2.5, 3.3, 3.4)

3. Attention तीन कृतींत?

dot (query-key जुळणी-गुण) -> softmax (लक्ष-वाटप) -> weighted sum (values ची भारित मिसळण). (4.1)

4. “AI मोठं केलं की हुशार” चं गणित, आणि दोन्ही टोकांचे भ्रम?

scaling laws: आकार 10x -> चूक ठराविक % घट (घात-नियम, log-log सरळ-झुकती रेषा); सुधारणा घटती + खर्च स्फोटक. भ्रम: “अनंत वाढ” आणि “पूर्ण थांबलं” दोन्ही रेषा न वाचल्याने. (4.4)

5. “AI का चालतं” चं प्रामाणिक उत्तर?

पूर्ण कुणालाच माहीत नाही (किमया > विज्ञान); सीमेवर सगळे नवखे; समजून नाही, मोजून प्रगती. (3.6)

भाग ब: थेंबू ते ChatGPT, आणि leverage (5 प्रश्न)

6. softmax मध्ये गुण आधी का भागतात (scaling)?

मोठे बाण -> मोठे dot-गुण -> अति-तीव्र softmax -> gradient मरतो, शिकणं थांबतं; root(d) ने भागून गुण वाजवी, softmax मऊ. (4.2)

7. transformer-मजल्याचे चार अवयव?

attention (बाजार: संदर्भ मिसळणं) + जोडणी (residual: जुनं ठेवून नवं) + एकांत (feed-forward: पचवणं) + ताळमेळ (norm). शेकडो मजले. (4.3)

8. थेंबू आणि ChatGPT यांत तत्त्वाचा फरक आहे का?

नाही: तेच तुकडे (बाण, dot, matrix, softmax, gradient), फक्त 3 weights ऐवजी अब्जावधी, शेकडो मजले उंच. फरक आकाराचा, तत्त्वाचा नाही. (4.3)

9. भीतीदायक सूत्र (उदा $\text{softmax}(QK^T/\text{root}(d))V$) समोर आलं तर?

तुकड्यांत फोडा: Q,K,V=बाण, QK^T =dot-जुळणी, $/\text{root}(d)$ =scaling, softmax=लक्ष, V=भारित बेरीज = attention. प्रत्येक तुकडा ओळखीचा; प्रतीकाला घाबरू नका, तुकडा शोधा. (4.5)

10. गणित शिकण्याचा खरा उपयोग काय (नुसतं “समजलं” पलीकडे)?

papers/दावे स्वतः वाचता-तपासता येणं: कुणाच्या सांगण्यावर विसंबावं लागत नाही. “समजणाऱ्या” कडून “तपासणाऱ्या” कडे, “ऐकणाऱ्या” कडून “वाचणाऱ्या” कडे: तेच leverage (Book 4, 9.2). (4.5, 1.6)

आणि आता खरी अंतिम परीक्षा: वरचे दहा नाही, खालचा एक, ज्याचं उत्तर पुस्तकात नाही, फक्त तुमच्याकडे आहे.

पुस्तकाच्या सुरुवातीला (front matter) एक भीती होती: “गणित म्हणजे सूत्रं-घोकंपट्टी, माझ्या आवाक्याबाहेर.” आता, थेंबूला हाताने शिकवल्यावर, attention आकड्यांनी काढल्यावर, तो कागद पुन्हा बघा. भीती कुठे गेली? बहुधा तिची जागा एका शांत आत्मविश्वासाने घेतली:

“AI मध्ये कुठेही जादू नाही. फक्त आकडे: बाण, गुणाकार, बेरीज, उतार. आणि आकडे मला समजतात. म्हणून AI मला समजतं: उपमेने नाही, गणिताने. आणि जे मला गणिताने समजतं, त्यावर मी कुणाच्या ‘सांगण्यावर’ विसंबत नाही: मी स्वतः तपासतो. हीच माझी उरलेली, न-नकलता-येणारी ताकद.”

थेंबूपासून ChatGPT पर्यंतचा प्रवास हेच शिकवतो: सर्वात गुंतागुंतीचं यंत्रही सर्वात साध्या कृतींची उंच रचना आहे, आणि त्या साध्या कृती तुम्हाला येतात. जादू संपली; चष्मा उरला.

शेवटचं “स्वतः बघा” (आयुष्यभराचं)

आजपासून, कुठलंही AI-सूत्र, कुठलाही “यंत्र हे करतं” चा दावा, कुठलाही paper: तीन प्रश्न विचारा: ”याखालचं गणित कुठलं, आणि ते मला माहीत असलेल्या तुकड्यांचं बनलंय का?” (Part 1-3), ”हा दावा किती वेळा, किती स्वच्छ चालतो: मोजलंय का?” (1.6), आणि ”हे मी स्वतः वाचून-तपासू शकतो, की फक्त ऐकतोय?” (4.5). हे तीन प्रश्न तुम्हाला AI-गर्दीतल्या कवितेतून आणि विक्रीतून कायमचे वेगळे काढतील: कारण तुमच्याकडे चष्मा आहे, आणि चष्मा असलेला माणूस भुलत नाही: तो बघतो.

सूत्र-पत्र: सगळं गणित एका पानावर (भिंतीवर लावा)

(थेंबूचा ChatGPT होण्याचा पूर्ण नकाशा, एका पानात.)

दिशांचं जग (Part 1):

vector	आकड्यांची यादी = दिशा (बाण); अर्थ = दिशा
dot product	जोडीने गुणा + बेरीज = जवळीकीचं माप सारखे->मोठा, लंब->शून्य, उलटे->उणे
matrix	रूपांतर-यंत्र (अनेक dot); बाण आत, फिरवलेला बाण बाहेर weights = matrix-आकडे
साखळी+खोली	रूपांतर + वाकडी कृती (ReLU), वारंवार = खोली
उच्च मिती	जागा स्फोटक (अर्थ मावतात); डोळे फसतात, गणित खरं

शक्यतांचं जग (Part 2):

probability	विश्वासाचं माप (0-1); बेरीज=1; खात्री-बरोबर वेगळे
distribution	शक्यतांचा आकार; तीव्र=खात्री, सपाट=गोंधळ
Bayes	नवं मत = जुनं मत + पुरावा; दुर्मिळतेचा विसर = चूक
entropy	आश्चर्याचं माप; शिकणं = आश्चर्य कमी करणं
cross-entropy loss	= खऱ्याला दिलेल्या खात्रीची शिक्षा
softmax+temp	गुण -> probability (स्फोट+भागा); temp = धीटपणा-कळ

उताराचं जग (Part 3):

derivative	बदलाचा दर; पायाखालचा उतार
gradient	सगळ्या weights चे उतार (बाण); उलट जा = शिकणं
chain rule	दर गुणत loss मागे वाटणं (backprop)
थेंबू-पाऊल	forward(अंदाज) -> loss -> backward(उतार) -> update(उलट, learning rate) -> पुन्हा
का चालतं	पूर्ण कुणालाच माहीत नाही; मोजून प्रगती

परत AI कडे (Part 4):

attention dot(जुळणी) -> softmax(लक्ष) -> weighted sum(मिसळण)
scaling root(d) ने भागा: softmax मऊ, शिकणं जिवंत
transformer attention + जोडणी + एकांत + ताळमेळ; शेकडो मजले
scaling laws आकार 10x -> चूक % घट (घात-नियम, log-log रेषा)
paper-वाचन बाहेरून-आत; प्रतीक = ओळखीचे तुकडे; AI-मदत+तपास

थेंबू ते ChatGPT (एका ओळीत):

शब्द -> बाण(embedding) -> [attention+एकांत] x शेकडो मजले
-> शेवटचा बाण -> softmax -> पुढचा token -> पुन्हा
शिकलं: gradient descent + backprop, ट्रिलियन पावलं.
तेच थेंबूचे तुकडे, अब्जावधी पट. जादू नाही, आकडे.

तीन आयुष्यभराचे प्रश्न:

1. याखालचं गणित कुठलं, माझ्या तुकड्यांचं बनलंय का? (Part 1-3)
2. हा दावा किती वेळा, किती स्वच्छ चालतो: मोजलंय का? (1.6)
3. हे मी स्वतः वाचून-तपासू शकतो, की फक्त ऐकतोय? (4.5)

सूत्र: गणित म्हणजे न दिसणारं दाखवणारा चष्मा.
जे मोजता येतं ते सुधारता येतं; ते तपासताही येतं.

पुस्तक संपलं. थेंबू ChatGPT झाला, आणि तुमच्या हातात चष्मा आला. आता कुठलंही AI-यंत्र बघाल तेव्हा जादू दिसणार नाही: बाण, गुणाकार, उतार दिसतील. आणि जादू न दिसणारा माणूस भुलत नाही: तो बांधतो, तपासतो, आणि पुढे जातो.

Book 6 (Computer च्या आत) या मालिकेचा पाया पूर्ण करेल: यंत्र **कसं मोजतं-वेगवान होतं** याचं गणित. पण तो वेगळा चष्मा; हा इथे संपतो. सुरू करा.