

The Lens (Full Book 7)

August 30, 2026

THE LENS

Book 7: AI चं गणित डोळ्यांनी

(उपमेखालचं खरं गणित, खऱ्या आकड्यांनी, सूत्रं-घोकंपट्टीशिवाय. Devanagari मराठी + English tech शब्द. चार भाग एका खंडात.)

अनुक्रम

PART 1: दिशांचं जग

- 1.1 Vector: आकड्यांची यादी म्हणजे...
- 1.2 Dot Product: जवळिकीचं माप
- 1.3 Matrix: रूपांतराचं यंत्र
- 1.4 रूपांतरांची साखळी आणि खोली
- 1.5 हजार मितींचं जग
- 1.6 राजा-राणी अंकगणित खरं का [दोन...

PART 2: शक्यतांचं जग

- 2.1 Probability: विश्वासाचं माप
- 2.2 Distribution: शक्यतांचा डोंगर
- 2.3 Bayes: पुराव्याने मत हलवणं
- 2.4 Entropy: आश्चर्याचं माप
- 2.5 Cross-Entropy: Loss चं खरं रूप
- 2.6 Softmax आणि Temperature

PART 3: उताराचं जग

- 3.1 Derivative: बदलाचा दर
- 3.2 Gradient: धुक्यातला डोंगर उतर...
- 3.3 Chain Rule: चूक मागे वाटणं
- 3.4 थेंबूला हाताने शिकवू: पूर्ण ए...
- 3.5 पाऊल-आकार आणि अडकणं
- 3.6 हे का चालतं: प्रामाणिक गूढ [द...

PART 4: परत AI कडे

- 4.1 Attention आकड्यांनी: पायरी-पा...
- 4.2 Softmax-Scaling का लागतं
- 4.3 एक Transformer-मजला, पूर्ण
- 4.4 Scaling Laws: सरळ रेषेचं गणित
- 4.5 Paper वाचण्याची कला
- 4.6 अंतिम परीक्षा

वाचनाची टीप: थेंबूचं यंत्र (2-neuron पाऊस-अंदाज) पूर्ण पुस्तकभर वाढत ChatGPT होतं. कागद-पेन सोबत ठेवा: बरंचसं हाताने करता येतं.

THE LENS

Book 7, Part 1: दिशांचं जग

हे पुस्तक कुणासाठी: Book 2 आणि Book 4 ने AI उपमांनी दिलं: attention म्हणजे बाजार, embedding म्हणजे अर्थ-नकाशा. उपमा समजायला उत्तम, पण एक सीमा आहे: उपमेवर थांबलात तर तुम्ही कायम “समजावून घेणारे” राहता. हे पुस्तक उपमेखालचं **खरं गणित** दाखवतं: आणि ते दिसलं की तुम्ही AI चे papers **स्वतः** वाचू शकता: आणि top 0.00001 ची खरी सीमारेषा नेमकी हीच आहे.

घाबरू नका: हे गणित वेगळं आहे

शाळेतलं गणित म्हणजे सूत्र-घोकंपट्टी, आकडेमोड, परीक्षा. हे पुस्तक तसं **नाही**. इथे एकही सूत्र घोकायचं नाही; प्रत्येक गोष्ट आधी **मराठी वाक्यात**, मग छोट्या-खऱ्या आकड्यांत. जिथे आकडेमोड येईल ती इतकी छोटी की मनातल्या मनात होईल. कारण हे पुस्तकाचं सूत्र आहे:

गणित म्हणजे आकडेमोड नव्हे; न दिसणारं दाखवणारा चष्मा.
जे मोजता येतं, ते सुधारता येतं.

गणित हा चष्मा आहे: तो लावला की AI मधलं “जादू” नाहीसं होतं आणि **यंत्र** दिसतं. प्रत्येक chapter शेवटी हे सूत्र परत भेटेल.

थेंबूचं यंत्र: या पुस्तकाचं चालतं उदाहरण

पूर्ण पुस्तकभर एक छोटं यंत्र आपल्यासोबत असेल: **थेंबू**. थेंबूचं काम एकच: उद्या **पाऊस पडेल का** याचा अंदाज. त्याच्याकडे दोनच माहिती: (1) आजची **आर्द्रता** (हवेतला ओलावा), (2) आजचा **ढगांचा** प्रमाण. थेंबू या दोन आकड्यांतून एक अंदाज काढतो. एवढंसं यंत्र; पण त्यात ChatGPT च्या मागचं **सगळं** गणित बीजरूपात आहे: दिशा, शक्यता, उतार, शिकणं. आपण थेंबूला हातानेच, खऱ्या आकड्यांनी चालवू, आणि तोच नंतर attention आणि transformer पर्यंत वाढेल. **मोठं यंत्र म्हणजे थेंबूच, फक्त अब्जावधी थेंबू एकत्र.**

कपाटावर एक नजर

Book 1	The Machine	Book 2	The Thinking Machine
Book 3	The Land Game	Book 4	The Harness
Book 5	The Blueprint	Book 7	The Lens <- हे: AI चं गणित

चार भागांचा नकाशा: तुम्ही इथे आहात

PART 1	दिशांचं जग	<- तुम्ही इथे
	vector, matrix:	अर्थाला दिशा, रूपांतराला यंत्र
PART 2	शक्यतांचं जग	
	probability, Bayes, entropy:	अनिश्चिततेचं गणित
PART 3	उताराचं जग	
	derivative, gradient:	शिकणं म्हणजे उतार उतरणं
PART 4	परत AI कडे	
	attention, transformer:	सगळं आकड्यांत, पायरी-पायरी

चला थेंबूच्या पहिल्या माहितीपासून: दोन आकडे म्हणजे एक दिशा.

विभाग 1: दिशांचं जग

AI च्या तळाशी एकच गणिती कल्पना आहे, आणि ती आश्चर्यकारक साधी आहे: **आकड्यांची यादी म्हणजे एक दिशा**. थेंबूची आर्द्रता आणि ढग: दोन आकडे: म्हणजे एक बाण. शब्दाचा अर्थ: शेकडो आकडे: म्हणजे शेकडो-मितींतला बाण. आणि यंत्राचं सगळं काम म्हणजे या बाणांना **फिरवणं, ताणणं, जुळवणं**. हा विभाग तो पाया घालतो: vector (दिशा) आणि matrix (दिशा फिरवणारं यंत्र). **हे तुमच्या शिक्षणात कुठे येईल:** embedding, attention, हे सगळे शब्द इथून जन्मतात; हा विभाग समजला की पुढचं सगळं “आकडे फिरवणं” इतकं सोपं होतं.

Chapter 1.1 [SPINE]: Vector: आकड्यांची यादी म्हणजे दिशा

थेंबूकडे आज दोन आकडे आहेत: आर्द्रता **0.8** (0 म्हणजे कोरडं, 1 म्हणजे पूर्ण दमट), आणि ढग **0.6** (0 म्हणजे निरभ्र, 1 म्हणजे पूर्ण भरलेलं). या दोन आकड्यांची यादी: **(0.8, 0.6)**: हाच एक **vector**. आणि गणिताची पहिली जादू: ही यादी म्हणजे नुसते दोन आकडे नाहीत, ती एक **जागा** आहे, एक **दिशा** आहे.

कागदावर बघा (मनातल्या मनात). एक कागद घ्या. डावी-उजवी रेषा = आर्द्रता, खाली-वर रेषा = ढग. आता (0.8, 0.6) म्हणजे: उजवीकडे 0.8, वर 0.6: तिथे एक टिंब. मध्यबिंदूपासून त्या टिंबापर्यंत **बाण** काढा: तो बाण म्हणजे थेंबूचा आजचा “हवामान- vector.” आजची पूर्ण हवा एका बाणात. उद्या हवा बदलली (0.3, 0.9: कोरडं पण ढगाळ) तर बाण वेगळ्या दिशेला. **प्रत्येक परिस्थिती = एक बाण; बदल = बाण फिरणं**.

दोन गोष्टी बाण सांगतो: दिशा आणि लांबी. दिशा = कुठल्या बाजूला झुकलंय (आर्द्रतेकडे की ढगांकडे). लांबी = किती “जोरात” (दोन्ही आकडे मोठे तर लांब बाण). ही दोन्ही पुढे कामाला येतील: दिशा म्हणजे **अर्थ** (कशासारखं), लांबी म्हणजे **तीव्रता**.

आणि आता खरी जादू: यादी कितीही लांब असू शकते. थेंबूकडे 2 आकडे, म्हणून 2-मितींचा (कागदावर काढता येणारा) बाण. पण कल्पना करा 3 आकडे (आर्द्रता, ढग, तापमान): आता बाण **खोलीत** (3D, खोलीतल्या दिशेसारखा). आणि AI मध्ये? एका शब्दाचा अर्थ **शेकडो किंवा हजारो** आकड्यांनी दाखवला जातो: म्हणजे शेकडो-मितींतला बाण. तो आपल्याला **काढता येत नाही** (आपले डोळे 3 मितींपुरते), पण गणित त्याला बाणासारखंच हाताळतं: दिशा, लांबी, फिरवणं: सगळं तेच, फक्त जास्त आकडे. **हीच AI ची पहिली गुरुकिल्ली**: शब्द, चित्र, आवाज: सगळं आकड्यांच्या याद्यांत, म्हणजे बाणांत, म्हणजे दिशांत बदलतं. (Book 2 चं embedding: आता कळलं ते नक्की काय: शब्दाला दिलेला बाण.)

थेंबूचं पहिलं पाऊल: थेंबू आजची हवा (0.8, 0.6) या एका बाणात बघतो. पुढच्या chapters मध्ये तो या बाणाला **तपासेल** (पावसाच्या दिशेशी किती जुळतो?), **फिरवेल** (यंत्रातून जाताना), आणि त्यातून अंदाज काढेल. सगळी सुरुवात या एका कल्पनेतून: यादी = दिशा.

इथे लोक काय चुकीचं समजतात

“Vector म्हणजे भौतिकशास्त्रातला बाण (वेग, बल).” तिथे सुरुवात झाली, पण AI मध्ये vector म्हणजे **कुठलीही आकड्यांची यादी**: तिला “दिशा” मानायचं ही गणिती सोय आहे, भौतिक बाण नाही. थेंबूचा (0.8, 0.6) हा हवेचा वेग नाही; तो फक्त “आर्द्रता-अक्षावर 0.8, ढग-अक्षावर 0.6” ही जागा आहे. आणि

दुसरा गैरसमज: “शेकडो मिती म्हणजे काहीतरी अतिमानवी.” नाही: 2 आकड्यांचं जे गणित, तेच 700 आकड्यांचं: फक्त आपल्याला डोळ्यांनी दिसत नाही, गणिताला दिसतं. मिती वाढणं म्हणजे यादी लांब होणं, जादू होणं नाही.

नकाशावर

(ही यादी दर chapter ला एक ओळ वाढेल.)

1.1 vector = आकड्यांची यादी = दिशा (बाण); दिशा=अर्थ, लांबी=तीव्रता; शब्द/चित्र/आवाज सगळं बाणांत

सूत्रावर: vector हा पहिला चष्मा: तो लावला की “शब्दाचा अर्थ यंत्राला कसा कळतो” हे गूढ नाहीसं होतं: अर्थ = दिशा, आणि दिशा = आकड्यांची यादी. न दिसणारं (अर्थ) आकड्यांत दिसायला लागलं.

स्वतः बघा (5 मिनिटं)

कागदावर दोन रेषा काढा (आडवी-उभी) आणि तीन टिंब ठेवा: (0.9, 0.1), (0.1, 0.9), (0.8, 0.7). प्रत्येकाला मध्यापासून बाण काढा. बघा: पहिले दोन जवळजवळ **उलट्या** दिशेला (विरुद्ध हवा), तिसरा पहिल्याच्या **जवळ** (सारखी हवा). दिशा जवळ = अर्थ जवळ: ही एक कल्पना पुढच्या chapter चं हृदय आहे.

विचार करा

थेंबूला दोन दिवसांची हवा तपासायची आहे: आज (0.8, 0.6) आणि पावसाळी-आदर्श दिवस (0.9, 0.7). “हे दोन बाण किती **सारखे** आहेत हे एका आकड्यात कसं सांगायचं? डोळ्यांनी ‘जवळ दिसतात’ ठीक, पण यंत्राला तर आकडा हवा.”

बाणांची “जवळीक” एका सुंदर गुणाकाराने मोजता येते: आणि तोच गुणाकार AI मधली सर्वात वापरली जाणारी गोष्ट आहे: attention चं बीज. त्याचं नाव dot product: पुढचा chapter.

Chapter 1.2 [SPINE]: Dot Product: जवळिकीच माप

थेंबूला दोन बाणांची जवळीक एका आकड्यात हवीय. गणिताचं उत्तर एका साध्या कृतीत आहे, आणि ती कृती AI मध्ये **सर्वात जास्त वेळा** घडते: म्हणून ती हातानेच करून बघू.

कृती: जोडीजोडीने गुणा, मग बेरीज. दोन बाण: आज = (0.8, 0.6), आदर्श-पावसाळी = (0.9, 0.7).

Dot product:

पहिले आकडे गुणा: $0.8 \times 0.9 = 0.72$
 दुसरे आकडे गुणा: $0.6 \times 0.7 = 0.42$
 बेरीज: $0.72 + 0.42 = 1.14$

झालं. दोन बाणांचा dot product = **1.14**. एका आकड्यात दोन बाणांची “जुळणी.” मनातल्या मनात झालं ना? यंत्रात हेच अब्जावधी वेळा घडतं: फक्त 2 ऐवजी शेकडो आकडे, पण कृती तीच: जोडीने गुणा, बेरीज.

हा आकडा काय सांगतो: तीन प्रसंग बघा. थेंबूची आजची हवा (0.8, 0.6) तीन वेगळ्या “आदर्शां”शी ताडू:

पावसाळी आदर्श (0.9, 0.7): $0.8 \times 0.9 + 0.6 \times 0.7 = 0.72 + 0.42 = 1.14$ (मोठा!)
 कोरडा आदर्श (0.1, 0.2): $0.8 \times 0.1 + 0.6 \times 0.2 = 0.08 + 0.12 = 0.20$ (छोटा)
 उलटा (-0.9, -0.7): $0.8 \times -0.9 + 0.6 \times -0.7 = -0.72 - 0.42 = -1.14$ (उणे!)

नियम स्पष्ट दिसतो: **बाण एकाच दिशेला (सारखे) -> dot मोठा सकारात्मक; लंब (असंबंधित) -> शून्याजवळ; उलट्या दिशेला (विरुद्ध) -> उणे.** म्हणजे dot product हे **जवळिकीच थर्मामीटर** आहे: एका आकड्यात “हे दोन बाण किती एकमेकांसारखे.” थेंबूला आता कळलं: आजची हवा पावसाळी-आदर्शाशी खूप जुळते (1.14), कोरड्याशी नाही (0.20): म्हणजे आज पाऊस शक्य.

आणि इथे AI ची दुसरी गुरुकिल्ली: Book 2 मध्ये attention म्हणजे “मागणी-पाटी जुळणी” (query-key match) होतं. ते नक्की काय? **प्रत्येक शब्दाचा query-बाण दुसऱ्या शब्दांच्या key-बाणांशी dot product.** मोठा dot = “हे दोन शब्द एकमेकांशी संबंधित, लक्ष दे”; छोटा = “दुर्लक्ष कर.” Attention चं हृदय म्हणजे लाखो dot products: जवळिकीची लाखो मापं. आणि embedding-शोध (RAG, Book 4): “या प्रश्नाशी जवळचे कागद” म्हणजे सर्वात मोठा dot product असलेले. **एक साधी कृती: जोडीने गुणा, बेरीज: AI च्या अर्ध्या कामाचा पाया.**

इथे लोक काय चुकीचं समजतात

”Dot product म्हणजे किचकट गणित.” आता तुम्ही ते मनातल्या मनात केलंत: दोन गुणाकार, एक बेरीज. किचकट काहीच नाही; फक्त AI मध्ये आकडे शेकडो आणि कृती अब्जावधी वेळा, म्हणून GPU लागतो (Book 2 चा कारखाना: तो हेच अब्जावधी गुणा-बेरीज करतो!). दुसरा गैरसमज: “जवळीक म्हणजे नेहमी चांगलं.” नाही: dot फक्त **मोजतो**; तो जवळ हवा की दूर हे कामावर ठरतं (query ला उत्तर जवळचं हवं, पण दोन वेगळ्या गोष्टी वेगळ्याच हव्यात). Dot हे थर्मामीटर आहे, ताप चांगला की वाईट हे तुम्ही ठरवता.

नकाशावर

- 1.1 vector = यादी = दिशा (बाण)
- 1.2 dot product = जोडीने गुणा+बेरीज = जवळीकीचं माप;
सारखे->मोठा, लंब->शून्य, उलटे->उणे; attention चं हृदय

सूत्रावर: dot product हा चष्मा “यंत्राला दोन शब्द संबंधित आहेत हे कसं कळतं” हे गूढ फोडतो: एका गुणा-बेरजेने. Attention ची जादू आता अंकगणित आहे: न दिसणारं (संबंध) आकड्यात दिसलं.

स्वतः बघा (5 मिनिटं)

तीन जोड्या हाताने करा: $(1,0) \cdot (0,1) = 1 \times 0 + 0 \times 1 = 0$ (लंब, असंबंधित); $(1,1) \cdot (1,1) = 1+1 = 2$ (तंतोतंत सारखे, मोठा); $(1,1) \cdot (1,-1) = 1-1 = 0$ (लंब!). शेवटचा गंमतीचा: $(1,1)$ आणि $(1,-1)$ उलटे वाटतात पण dot शून्य = लंब = असंबंधित. आकडा तुमच्या डोळ्याच्या अंदाजापेक्षा नेमका असतो: हीच गणिताची ताकद.

विचार करा

थेंबूचं यंत्र आता आर्द्रता आणि ढग यांना **वेगवेगळं महत्त्व** द्यायला शिकलय: “पावसासाठी ढग आर्द्रतेपेक्षा जास्त महत्त्वाचे.” म्हणजे त्याला दोन आकडे नुसते जुळवायचे नाहीत, तर **एका आकड्याचं दुसऱ्यात, महत्त्वानुसार, रूपांतर** करायचंय: (आर्द्रता, ढग) -> (पाऊस-गुण). “एका दिशेचं दुसऱ्या दिशेत, ठरलेल्या नियमाने रूपांतर: हे कसं मांडायचं?”

दिशा फिरवणारं, ताणणारं, रूपांतर करणारं एक यंत्र गणितात आहे: आणि तेच AI च्या प्रत्येक थराचं हृदय आहे. त्याचं नाव matrix: पुढचा chapter.

Chapter 1.3 [SPINE]: Matrix: रूपांतराचं यंत्र

थेंबूला (आर्द्रता, ढग) चं (पाऊस-गुण) मध्ये, महत्त्वानुसार, रूपांतर करायचंय. गणिताचं हत्यार म्हणजे **matrix**: आणि matrix हे “आकड्यांचा चौकोन” नसून एक **रूपांतर-यंत्र** आहे: बाण आत टाका, फिरवलेला-ताणलेला बाण बाहेर.

आधी सोपं: एका आकड्याचं रूपांतर. थेंबूला वाटतं ढग आर्द्रतेपेक्षा दुप्पट महत्त्वाचे. तो एक “वजन-यादी” बनवतो: आर्द्रतेला 1, ढगांना 2. आजची हवा (0.8, 0.6). पाऊस-गुण =

$$0.8 \times 1 + 0.6 \times 2 = 0.8 + 1.2 = 2.0$$

हे ओळखीचं आहे: हा dot product च आहे (1.2)! वजन-यादी (1, 2) आणि हवा (0.8, 0.6) यांचा dot = पाऊस-गुण 2.0. म्हणजे **एका बाणाचं एका आकड्यात रूपांतर = एक dot product.**

आता matrix: अनेक रूपांतरं एकत्र. समजा थेंबूला दोन गुण हवेत: “पाऊस-गुण” आणि “गारवा-गुण.” प्रत्येकाची वेगळी वजन- यादी:

$$\begin{aligned} \text{पाऊस-गुण} &= \text{वजनं } (1, 2): \quad 0.8 \times 1 + 0.6 \times 2 = 2.0 \\ \text{गारवा-गुण} &= \text{वजनं } (3, -1): \quad 0.8 \times 3 + 0.6 \times -1 = 2.4 - 0.6 = 1.8 \end{aligned}$$

या दोन वजन-याद्या एकत्र रचल्या की matrix होतो:

$$\begin{array}{cc} & \text{आर्द्रता} & \text{ढग} \\ \text{पाऊस} & [& 1 & 2 &] \\ \text{गारवा} & [& 3 & -1 &] \end{array}$$

आणि “हवा-बाण matrix मधून घालवणं” म्हणजे: **प्रत्येक ओळीचा हवेशी dot product.** आत (0.8, 0.6) टाकलं, बाहेर (2.0, 1.8) आलं. एक 2-आकड्यांचा बाण दुसऱ्या 2-आकड्यांच्या बाणात **रूपांतरित.** Matrix = अनेक dot products एका खोक्यात = एक रूपांतर-यंत्र.

हीच AI च्या प्रत्येक थराची कृती. Book 2 चा transformer-मजला (3.8) आठवा: प्रत्येक थर म्हणजे एक (किंवा अनेक) matrix, जो येणारा बाण (शब्दाचा अर्थ) घेऊन त्याला नव्या बाणात रूपांतरित करतो. “यंत्र विचार करतं” म्हणजे प्रत्यक्षात: **बाण -> matrix -> नवा बाण -> पुढचा matrix -> नवा बाण...** शेकडो वेळा. GPT मध्ये हे matrices अवाढव्य (शेकडो x शेकडो आकडे) आणि शेकडो थर, पण **कृती**

तीच जी थेंबूची: ओळीचा dot, नवा आकडा. यंत्राचं “वजन” (Book 2, 2.4: weights) म्हणजे नक्की हेच: या matrices मधले आकडे. अब्जावधी weights = अब्जावधी matrix-आकडे. **शिकणं म्हणजे हे matrix-आकडे बरोबर जुळवणं** (Part 3 चा विषय).

इथे लोक काय चुकीचं समजतात

”Matrix म्हणजे आकड्यांचा नुसता चौकोन/table.” घातक अर्थसत्य. Matrix हे **क्रियापद** आहे, नाम नाही: तो एक **कृती** आहे: “हा बाण घे आणि असा फिरव-ताण.” Excel-सारखा स्थिर table बघितलात तर matrix कधीच “जाणवणार” नाही; “रूपांतर-यंत्र” म्हणून बघितलात की AI ची अख्खी रचना उलगाडते. दुसरा गैरसमज: “matrix गुणाकार म्हणजे भयंकर किचकट नियम.” नियम एकच, तुम्ही आत्ता केलात: **ओळीचा येणाऱ्या बाणाशी dot product**. बाकी सगळं याचीच पुनरावृत्ती.

नकाशावर

- | | |
|--|------------------------|
| 1.1 vector = यादी = दिशा | 1.2 dot = जवळिकीचं माप |
| 1.3 matrix = रूपांतर-यंत्र (अनेक dot एकत्र); बाण आत -> फिरवलेला बाण बाहेर; AI चे weights = matrix-आकडे | |

सूत्रावर: matrix हा चष्मा “यंत्राचा थर म्हणजे नक्की काय” हे दाखवतो: एक रूपांतर, बाणाचं बाणात. “यंत्र विचार करतं” ही कविता; “बाण matrix मधून जातो” हे गणित. न दिसणारं (विचार) आकड्यांच्या फिरवणुकीत दिसलं.

स्वतः बघा (5 मिनिटं)

हा matrix हाताने चालवा: वजनं ओळ-1 (2, 0), ओळ-2 (0, 2), बाण (3, 5). प्रत्येक ओळीचा dot: $2 \times 3 + 0 \times 5 = 6$; $0 \times 3 + 2 \times 5 = 10$. बाहेर (6, 10): मूळ बाण **दुप्पट** झाला! हा matrix “सगळं दुप्पट कर” हे रूपांतर करतो. आता ओळी (0,1),(1,0) घ्या, बाण (3,5): बाहेर (5,3): आकडे **उलटे!** Matrix आकडे बदलून वेगवेगळी रूपांतरं: फिरवणं, ताणणं, अदलाबदल. खेळून बघा.

विचार करा

थेंबूचं यंत्र आता एक matrix आहे: हवा आत, गुण बाहेर. पण खरं यंत्र एका matrix चं नसतं; ते **अनेक matrices एकामागून एक** असतं (Book 2 चे शेकडो थर). थेंबूला प्रश्न पडला: “मी हवा पहिल्या matrix मधून घातली, नवा बाण आला; तो दुसऱ्या matrix मधून घातला... हे अनेक रूपांतरं एकामागून एक:

याला काही एकत्रित अर्थ आहे का? की नुसती साखळी?"

साखळीला सुंदर अर्थ आहे: अनेक रूपांतरं मिळून **एकच मोठं रूपांतर** होतं, आणि तेच AI च्या खोलीचं (depth) रहस्य आहे. रूपांतरांची साखळी: पुढचा chapter.

Chapter 1.4 [DEPTH]: रूपांतरांची साखळी आणि खोली

थेंबूचा प्रश्न: अनेक matrices एकामागून एक: याला एकत्रित अर्थ आहे का? उत्तर सुंदर आहे, आणि ते AI च्या “खोली” (depth: शेकडो थर) चं रहस्य उघडतं. [DEPTH]: थोडं खोलात, पण थेंबूसोबत सोपं.

साखळी म्हणजे काय. थेंबूची हवा (0.8, 0.6) पहिल्या matrix A मधून जाते -> नवा बाण; तो दुसऱ्या matrix B मधून -> आणखी नवा बाण. दोन रूपांतरं, एकामागून एक. गंमत: A नंतर B लावणं = एकच नवा matrix C लावण्यासारखं (C म्हणजे “आधी A मग B”). म्हणजे **अनेक रूपांतरांची साखळी = एकच (गुंतागुंतीचं) रूपांतर**. स्वयंपाकाची उपमा: भाजी चिरा -> तळा -> मसाला घाला: तीन कृती, पण मिळून “एक पदार्थ बनवणं” ही एकच मोठी कृती.

मग शेकडो थर कशाला, एकच मोठा matrix का नाही? इथे खरी गोम आहे, आणि ती समजली की deep learning मधलं “deep” कळतं. जर मध्ये काहीच घडलं नाही (नुसते matrices), तर खरंच शेकडो थर = एकच matrix (वाया). पण AI मध्ये प्रत्येक matrix नंतर एक छोटी वाकडी कृती घडते: याला “activation” म्हणतात, आणि ती साखळीला **सरळ रेषेपेक्षा जास्त** बनवते.

वाकडी कृती का लागते (सर्वात महत्वाचा मुद्दा). matrix फक्त सरळ रूपांतरं करतो: ताणणं, फिरवणं (म्हणून त्याला “linear” म्हणतात: रेषीय). पण जग सरळ नाही: “आर्द्रता 0.9 च्या पुढे गेली तरच पाऊस” असले उंबरठे, वळणं matrix ला जमत नाहीत. म्हणून प्रत्येक थरानंतर एक साधी वाकडी कृती: उदा “उणे आकडे शून्य कर, धन तसेच ठेव” (याला ReLU म्हणतात: सर्वात सामान्य). ही छोटी वाकडी कृती नसेल तर शंभर थर = एक थर (नुसती सरळ साखळी); ती असेल तर शंभर थर **खरोखर** शंभर पट गुंतागुंतीचं वळणदार रूपांतर शिकू शकतात. **खोली = सरळ रूपांतरं + वाकड्या कृती, आलटून-पालटून, शंभर वेळा: म्हणून यंत्र गुंतागुंतीचे नमुने पकडतं.**

थेंबूवर: थेंबूचा एक matrix “आर्द्रता + 2xढग” इतकंच सरळ काढू शकतो. पण “ढग भरपूर आणि आर्द्रता उंबरठ्यापुढे तरच जोरदार पाऊस” हा वाकडा नियम एका matrix ला जमत नाही: दोन थर + मधली वाकडी कृती लागते. म्हणून खरं यंत्र = अनेक थेंबू- matrices + वाकड्या कृती: आणि तेच ChatGPT, फक्त अब्जावधी पट.

इथे लोक काय चुकीचं समजतात

“जास्त थर = आपोआप जास्त हुशार.” अर्धसत्य: थर जास्त आणि मधल्या वाकड्या कृती आणि नीट शिकवणी (Part 3) असेल तरच. नुसते matrices रचले (वाकड्या कृतीशिवाय) तर शंभर थर = एक थर: वाया. आणि उलट: वाकडी कृती हे “यंत्राची जादू” नाही; ती “उणे शून्य कर” इतकी साधी असू शकते: जादू

खोली आणि शिकवणीत आहे, कुठल्या एका कृतीत नाही.

नकाशावर

1.1-1.3 vector | dot | matrix

1.4 साखळी: अनेक रूपांतर = एक मोठे रूपांतर; पण मधली
वाकडी कृती (activation) नसेल तर शंभर थर = एक थर;
खोली = सरळ+वाकडं आलटून-पालटून

सूत्रावर: हा चष्मा “deep learning मधलं deep का महत्वाचं” हे दाखवतो: खोली म्हणजे रूपांतर + वाकडी वळणं, वारंवार. न दिसणारं (यंत्राची गुंतागुंत पकडायची क्षमता) आकड्यांच्या साखळीत दिसलं.

स्वतः बघा (5 मिनिटं)

एक वाकडी कृती हाताने: ReLU = “उणे असेल तर 0, धन असेल तर तसंच.” आकडे (3, -2, 5, -1) वर लावा: (3, 0, 5, 0). बघा: वाईट (उणे) बातम्या गाळल्या, चांगल्या ठेवल्या. आता कल्पना करा हे प्रत्येक थरानंतर: यंत्र हळूहळू “काय ठेवायचं, काय गाळायचं” शिकतं. इतक्या साध्या कृतीतून गुंतागुंत जन्मतो: हेच आश्चर्य.

विचार करा

विभाग 1 संपत आलाय. थेंबूला दिशा (vector), जवळीक (dot), रूपांतर (matrix), खोली (साखळी) कळलं. पण एक गोष्ट खटकतेय: “AI मध्ये म्हणतात एका शब्दाचा अर्थ **शेकडो** आकड्यांनी दाखवतात. दोन आकडे मला कागदावर दिसतात; पण 700 आकडे? इतकी ‘जागा’ कशाला? आणि इतक्या मितींत काही विचित्र घडतं का?”

शेकडो मितींत खरंच विचित्र, आणि उपयोगी, गोष्टी घडतात: तिथे जवळ-दूर चा अर्थ बदलतो, आणि म्हणूनच अर्थ साठवता येतो. उच्च-मितींचं जग: विभागाचा शेवटचा chapter.

Chapter 1.5 [SPINE]: हजार मितींच जग

थेंबूचा प्रश्न: 700 आकडे कशाला, आणि तिथे काय घडतं? हा chapter उच्च-मितींच्या (high-dimensional) जगाची सफर आहे: आणि तिथे एक शाप आणि एक वरदान दोन्ही आहेत.

आधी वरदान: जागा प्रचंड असते. 2 मितींत (कागद) जागा मर्यादित: जवळपासच्या गोष्टी गर्दी करतात. पण मिती वाढल्या की **जागा स्फोटक वाढते**. कल्पना करा: 1 मितीत (रेषा) 10 जागा; 2 मितींत (चौरस) $10 \times 10 = 100$; 3 मितींत (घन) 1000; 700 मितींत? 10 च्या 700 घातांक: विश्वातल्या अणूपेक्षा अगणित पट जास्त. म्हणून AI ला **प्रत्येक शब्दाला स्वतःची वेगळी दिशा** द्यायला भरपूर जागा मिळते: लाखो शब्द, प्रत्येकाचा वेगळा बाण, तरी गर्दी नाही. **अर्थ साठवायला जागा हवी, आणि मिती ती देतात.** म्हणून embedding शेकडो-मितींचं: दोन मितींत अख्ख्या भाषेचे अर्थ मावणारच नाहीत.

आणि सूक्ष्म जादू: दिशांना अर्थ चिकटतात. उच्च-मितींत असं घडतं की **वेगवेगळ्या दिशा वेगवेगळे अर्थ** धरतात: एक दिशा “लिंग” (राजा-राणी), एक “संख्या” (एक-अनेक), एक “काळ” (आज- काल). म्हणून Book 2 चं गाजलेलं उदाहरण शक्य होतं: **राजा - पुरुष + स्त्री = राणी** (बाणांची वजाबाकी- बेरीज!). कारण “लिंग- दिशेत” राजा-वरून-राणीकडे सरकणं म्हणजे तेच जे पुरुष-वरून- स्त्रीकडे. अर्थाचं अंकगणित: फक्त भरपूर मिती असतील तरच शक्य, कारण प्रत्येक अर्थ-छटेला स्वतःची दिशा हवी. (हे किती खरं, किती अतिशयोक्ती: 1.6 त बघू.)

आता शाप: आपली अंतर्ज्ञान फसते (curse of dimensionality). उच्च-मितींत विचित्र गोष्टी घडतात ज्या आपल्या 3-मिती-सराव्या मेंदूला अशक्य वाटतात: (1) **सगळं सगळ्यापासून दूर होतं:** इतकी जागा की कुठलेही दोन बाण बहुधा लांबच; “जवळचा शेजारी” शोधणं अवघड. (2) **जवळपास सगळे बाण जवळजवळ लंब होतात:** यादृच्छिक दोन बाणांचा dot बहुधा शून्याजवळ. म्हणजे आपलं “जवळ-दूर” चं भान इथे चालत नाही: गणितावर विसंबावं लागतं, डोळ्यांवर नाही. म्हणूनच हे पुस्तक: **उच्च-मितींत डोळे आंधळे, गणित हाच एकमेव चष्मा.**

थेंबूवर आणि पुढे: थेंबूचे 2 आकडे कागदावर दिसतात; GPT चे शेकडो-हजारो आकडे दिसत नाहीत, पण **गणित तेच:** dot product जवळीक मोजतो (1.2), matrix रूपांतर करतो (1.3): 2 मितींत जे, तेच 700 मध्ये. फरक एवढाच की 700 मध्ये **जागा भरपूर** (अर्थ मावतात) पण **डोळे निरुपयोगी** (गणितावर भरवसा). हीच विभाग 1 ची सर्वात मोठी कमाई: **AI च्या मितींना घाबरू नका; त्या फक्त लांब याद्या आहेत, आणि त्यांचं गणित थेंबूइतकं सोपं आहे: फक्त डोळ्यांऐवजी आकड्यांवर विश्वास ठेवा.**

इथे लोक काय चुकीचं समजतात

”शेकडो मिती म्हणजे काहीतरी गूढ, अतिमानवी परिमाण.” नाही: मिती म्हणजे फक्त **यादीतल्या आकड्यांची संख्या**. 700 मिती = 700 आकड्यांची यादी. “चौथी मिती म्हणजे वेळ/जादू” ही विज्ञान-कथेतली कल्पना इथे लागू नाही; इथे मिती = रकाना, बस. दुसरा गैरसमज: “उच्च-मितींत आपली भूमिती चालते.” उलट: चालत नाही, म्हणूनच सावध. डोळ्यांचा अंदाज (“हे जवळ दिसतंय”) उच्च-मितींत फसतो; तिथे फक्त dot product सारखी मापं खरी.

नकाशावर

- 1.1-1.4 vector | dot | matrix | साखळी
 1.5 उच्च मिती: जागा स्फोटक (अर्थ मावतात, दिशांना अर्थ);
 पण डोळे फसतात (curse) -> गणितावर भरवसा; मिती =
 यादीची लांबी, गूढ नाही

सूत्रावर: हा चष्मा सर्वात मोलाचा: उच्च-मितींत **डोळे आंधळे होतात, गणित हाच एकमेव दृष्टिदाता**. AI समजायला गणित “पर्याय” नाही, “एकमेव खिडकी” आहे: कारण तिथलं जग बघता येत नाही, फक्त मोजता येतं.

स्वतः बघा (5 मिनिटं)

एक विचार-प्रयोग: 1 मितीत (रेषेवर) एक टिंब ठेवा; त्याचे “शेजारी” फक्त 2 (डावा-उजवा). 2 मितींत (कागद) शेजारी अनेक (चहूबाजूनी). 3 मितींत (खोली) अजून जास्त. आता कल्पना करा 700 मिती: प्रत्येक टिंबाला अगणित दिशांनी शेजारी, म्हणून प्रचंड जागा, पण प्रत्येक शेजारी **लांब**. ही “भरपूर-जागा-पण-सगळे-दूर” ची विचित्रता उच्च-मितींचं सार आहे.

विचार करा

विभाग 1 संपला. थेंबूला दिशांचं जग कळलं. पण एक गोष्ट अजून अपुरी आहे: “मी 1.5 त ‘राजा - पुरुष + स्त्री = राणी’ बदल ऐकलं: बाणांचं अंकगणित. हे **खरंच** इतकं स्वच्छ चालतं का, की ती एक सुंदर गोष्ट आहे जी प्रत्यक्षात गचडलेली असते? मला हवा तो प्रामाणिक निकाल.”

प्रामाणिक निकाल: अर्थ खरं, अर्थ अतिशयोक्ती: आणि तो वाद स्वतःच AI-गणित कसं समजून घ्यायचं याचा धडा आहे. विभाग 2 चं दार उघडणारा हा प्रश्न पुढच्या भागात: पण आधी थेंबूला एका नव्या जगात नेऊ: जिथे उत्तरं “हो/नाही” नसतात, “किती शक्यता” असतात. शक्यतांचं जग, Part 2.

Chapter 1.6 [SPINE]: राजा-राणी अंकगणित खरं का [दोन्ही बाजू]

थेंबूचा प्रामाणिकपणाचा प्रश्न: “राजा - पुरुष + स्त्री = राणी” हे खरंच चालतं का? हा chapter एका गाजलेल्या निकालाचं प्रामाणिक शव-विच्छेदन आहे: आणि तो स्वतःच “AI-दावे कसे तपासायचे” याचा धडा आहे.

दावा काय होता. 2013 च्या सुमारास (word2vec नावाच्या कामातून) जगाला धक्का बसला: शब्दांचे बाण (embeddings) असे निघाले की **अर्थाचं अंकगणित** चालायचं. बाण-भाषेत: राजाचा बाण घ्या, पुरुषाचा वजा करा, स्त्रीचा जोडा: निकाल राणीच्या बाणाच्या **खूप जवळ**. तसंच “पॅरिस - फ्रान्स + इटली = रोम” (राजधान्या), “चालणे - चालला + धावला = धावणे” (काळ). जणू यंत्राने अर्थाच्या “दिशा” (लिंग-दिशा, देश-दिशा) आपोआप शोधल्या (1.5). हे खरं आहे: आणि सुंदर आहे.

पण आता प्रामाणिक दुसरी बाजू (contested):

- समर्थक बाजू: उदाहरणं खरी आहेत; अर्थाला दिशा असते ही कल्पना खरी आहे; embeddings मध्ये रचना आहे.
- टीकाकार बाजू: प्रत्यक्षात हे इतकं स्वच्छ नाही:
- निकाल बहुधा “जवळ” येतो, “बरोबर” नाही (राणी दुसरी-तिसरी जवळची, पहिली नाही).
 - अभ्यासात दिसलं: उत्तर काढताना “मूळ तीन शब्द वगळा” असा नियम लपवलेला असतो; तो काढला तर अनेकदा उत्तर मूळ शब्दच येतं (फसवणूक नाही, पण जादू कमी).
 - काही नाती छान चालतात (लिंग, राजधानी), बरीच अजिबात चालत नाहीत.
- निकाल: अर्थाला-दिशा ही कल्पना खरी आणि मौल्यवान; पण “स्वच्छ अंकगणित” ही अतिशयोक्ती. उदाहरण खरं, सार्वत्रिक नियम नाही.

यातून खरा धडा (या पुस्तकाचा गाभा): एक सुंदर, गाजलेलं AI-उदाहरण घ्या आणि विचारा: “हे किती वेळा, किती स्वच्छ चालतं? की एक चमकदार केस उचलून सगळीकडे लावलीये?” राजा- राणी हे खरं उदाहरण, पण त्याभोवती जी “यंत्राला अर्थ **कळतो**” ची कविता रचली गेली ती अतिशयोक्त. गणिताचा चष्मा (हे पुस्तक) नेमका इथे उपयोगी: तो तुम्हाला “किती जवळ, किती वेळा, कुठला नियम लपवलाय” हे **मोजायला** लावतो: कवितेवर भुलू देत नाही. Book 2/4 चं तेच सूत्र: “यावर किती विश्वास, आणि का”: इथे गणिताच्या रूपात.

आणि हे leverage आहे (Book 4 शी पूल): जो माणूस “राजा- राणी भारी!” वर थांबतो तो ग्राहक; जो “हे किती स्वच्छ चालतं, मूळ दावा काय, तपासलं कोणी” विचारतो तो papers वाचणारा, आणि तोच top 0.00001 कडे जातो. **AI-गणित शिकण्याचा खरा फायदा नवं बांधणं नाही; दावे तपासता येणं आहे.** कारण AI-जगात कवितेचा (आणि विक्रीचा) पूर आहे, आणि गणित हाच एकमेव गाळणी-चष्मा.

इथे लोक काय चुकीचं समजतात

“गाजलेलं उदाहरण = सिद्ध झालेला सार्वत्रिक नियम.” AI मध्ये सर्वात महाग गैरसमज: एक चमकदार केस (राजा-राणी, किंवा कुठलंही viral demo) घेऊन “यंत्र हे नेहमी करतं” मानणं. प्रत्यक्षात demo हे **निवडलेलं सर्वोत्तम** असतं (Book 4, 5.1 चा “demo = सोपा ढीग”). प्रामाणिक प्रश्न नेहमी: “सरासरी किती वेळा, किती स्वच्छ, आणि अपयशं कुठे?” हा प्रश्न विचारणं म्हणजे गणिताचा चष्मा लावणं.

नकाशावर

- 1.1-1.5 vector | dot | matrix | साखळी | उच्च मिति
- 1.6 राजा-राणी: अर्थाला-दिशा खरी, पण “स्वच्छ अंकगणित”
अतिशयोक्ती; धडा = गाजलेला दावा मोजून तपासा (गणित = गाळणी-चष्मा); हेच papers-वाचनाचं leverage

सूत्रावर: इथे सूत्र पूर्ण वर्तुळ पूर्ण करतं: गणित हा चष्मा फक्त “AI कसं चालतं” दाखवत नाही; तो “AI-दावे किती खरे” हेही **मोजायला** लावतो. जे मोजता येतं ते तपासता येतं: आणि जे तपासता येतं तेच खरं.

स्वतः बघा (5 मिनिटं)

पुढच्या वेळी कुठलंही “AI ने हे भन्नाट केलं!” चं उदाहरण बघाल तेव्हा तीन प्रश्न विचारा: (1) हे किती **वेळा** चालतं (एक demo की हजार वेळा)? (2) “जवळ” की “बरोबर” (जवळपास की नेमकं)? (3) अपयशं कुठे लपवलीयेत? हे तीन प्रश्न म्हणजे गणिताचा चष्मा, सूत्रांशिवाय: आणि तेच तुम्हाला भुलणाऱ्या गर्दीतून वेगळं काढतील.

विचार करा

विभाग 1 खरोखर संपला: दिशांचं जग हातात. थेंबूला बाण, जवळीक, रूपांतर, खोली, मिति, आणि दावे-तपासणी कळली. पण थेंबूचं मूळ काम अजून अपुरं: “मी आजची हवा बघून एक ‘पाऊस-गुण’ काढला (2.0). पण पाऊस **पडेल की नाही** हे हो/नाही नाही ना: ‘किती शक्यता’ असतं. 70% शक्यता म्हणजे काय, आणि गुण-2.0 चं शक्यतेत रूपांतर कसं?”

हाच पुढच्या विभागाचा गाभा: निश्चिततेच्या जगातून **शक्यतांच्या** जगात. गुणाचं शक्यतेत रूपांतर, “70%” चा खरा अर्थ, आणि यंत्राचा आत्मविश्वास कसा मोजायचा: शक्यतांचं जग, Part 2.

BOOK 7, PART 1 चा शेवट

जे तुमच्याकडे आता आहे

vector	आकड्यांची यादी = दिशा (बाण); दिशा=अर्थ, लांबी=तीव्रता; शब्द/चित्र/आवाज सगळं बाणांत
dot product	जोडीने गुणा + बेरीज = जवळिकीचं माप; सारखे-> मोठा, लंब->शून्य, उलटे->उणे; attention चं हृदय
matrix	रूपांतर-यंत्र (अनेक dot एकत्र); बाण आत, फिरवलेला बाण बाहेर; AI चे weights = matrix-आकडे
साखळी	अनेक रूपांतरं = एक मोठं रूपांतर; मधली वाकडी कृती (activation) नसेल तर शंभर थर = एक थर; खोली = सरळ+वाकडं आलटून-पालटून
उच्च मिती	जागा स्फोटक (अर्थ मावतात, दिशांना अर्थ चिकटतात); पण डोळे फसतात (curse) -> गणितावर भरवसा; मिती = यादीची लांबी
राजा-राणी	अर्थाला-दिशा खरी, "स्वच्छ अंकगणित" अतिशयोक्ती; गाजलेला दावा मोजून तपासा (गणित = गाळणी-चष्मा)

स्वतःची परीक्षा (4 प्रश्न, बोलून; उत्तरं खाली)

1. "यंत्राला शब्दाचा अर्थ कसा कळतो" चं गणिती उत्तर?

अर्थ = दिशा; शब्दाला आकड्यांची यादी (बाण) दिली जाते (embedding); जवळच्या दिशा = जवळचे अर्थ. (1.1, 1.5)

2. Attention चं गणिती हृदय एका कृतीत?

dot product: query-बाण आणि key-बाण यांचा जोडीने-गुणा- बेरीज = किती संबंधित. मोठा = लक्ष दे. (1.2)

3. यंत्राचा "थर" म्हणजे गणितात नक्की काय?

matrix (रूपांतर): बाण आत -> फिरवलेला-ताणलेला बाण बाहेर; नंतर वाकडी कृती (activation). weights = matrix-आकडे. (1.3, 1.4)

4. उच्च-मितीत डोळ्यांऐवजी गणितावर का विसंबायचं?

तिथे जागा स्फोटक पण सगळे बाण लांब-लंब होतात (curse); “जवळ दिसतंय” फसतं, फक्त dot सारखी मापं खरी. (1.5)

पुढच्या भागाची चाहूल

थेंबूचा “पाऊस-गुण 2.0” ला “70% शक्यता” मध्ये बदलायचंय. Part 2: शक्यतांचं जग: probability (विश्वासाचं माप), Bayes (पुराव्याने मत बदलणं), entropy (आश्चर्याचं माप), आणि cross-entropy (Book 2 चं loss उघडून). गुणाचं शक्यतेत रूपांतर, “70%” चा खरा अर्थ: सगळं थेंबूसोबत, खऱ्या आकड्यांनी.

BOOK 7, PART 1 चा MINI-GLOSSARY

activation	प्रत्येक थरांनंतरची वाकडी कृती (उदा ReLU) (1.4)
dot product	जोडीने गुणा+बेरीज; जवळिकीचं माप (1.2)
dimension	यादीतल्या आकड्यांची संख्या (मिती) (1.5)
embedding	शब्दाला दिलेला अर्थ-बाण (1.1, 1.5)
matrix	रूपांतर-यंत्र; अनेक dot एकत्र (1.3)
ReLU	"उणे शून्य कर, धन तसंच"; सामान्य activation (1.4)
vector	आकड्यांची यादी = दिशा (बाण) (1.1)
weights	यंत्राचे matrix-आकडे; शिकवणीने जुळतात (1.3)

THE LENS

Book 7, Part 2: शक्यतांचं जग

मागच्या भागाचा शेवट: थेंबूने आजच्या हवेतून “पाऊस-गुण 2.0” काढला. पण पाऊस हो/नाही नसतो: “किती शक्यता” असतो. हा भाग अनिश्चिततेचं गणित शिकवतो: शक्यता म्हणजे काय, “70%” चा खरा अर्थ, पुराव्याने मत कसं बदलावं, आणि Book 2 चं loss नक्की काय: सगळं थेंबूसोबत, खऱ्या आकड्यांनी.

सूत्र (पुन्हा)

गणित म्हणजे आकडेमोड नव्हे; न दिसणारं दाखवणारा चष्मा.
जे मोजता येतं, ते सुधारता येतं.
Part 2 चा भर: अनिश्चितता मोजता येते, म्हणून हाताळता येते.

कपाटावर एक नजर

Book 1-5 (पाया ते रचना) Book 7 The Lens <- Part 2

Part 1 ची उजळणी: 4 प्रश्न (बोलून; उत्तरं खाली)

1. “अर्थ यंत्राला कसा कळतो” चं गणिती उत्तर?

| अर्थ = दिशा; शब्दाला बाण (embedding); जवळच्या दिशा = जवळचे अर्थ. (1.1)

2. Dot product काय मोजतं?

| दोन बाणांची जवळीक (जोडीने गुणा+बेरीज); attention चं हृदय. (1.2)

3. यंत्राचा थर = गणितात?

| matrix (रूपांतर) + वाकडी कृती; weights = matrix-आकडे. (1.3)

4. उच्च-मितींत डोळ्यांवर का विसंबू नये?

तिथे सगळे बाण लांब-लंब होतात (curse); फक्त dot सारखी मापं खरी. (1.5)

या भागात काय

Probability (विश्वासाचं माप), distribution (शक्यतांचा डोंगर), Bayes (पुराव्याने मत हलवणं: doctor-test), entropy (आश्चर्याचं माप), cross-entropy (loss चं खरं रूप), softmax + temperature. सगळं थेंबूच्या पाऊस-अंदाजावर.

विभाग 2: शक्यतांचं जग

Book 2 चं सर्वात मोठं सत्य आठवा: यंत्र हो/नाही देत नाही, ते **probability-यादी** देतं (पुढच्या token ची शक्यता). म्हणजे AI च्या हृदयात निश्चितता नाही, **अनिश्चितता** आहे: आणि तिचं गणित म्हणजे probability. हा विभाग ते शिकवतो: शक्यता म्हणजे विश्वासाचं माप, आणि तो मोजता आला की यंत्राचा आत्मविश्वास, त्याच्या चुका, आणि त्याचं शिकणं: सगळं दिसायला लागतं. **हे तुमच्या शिक्षणात कुठे येईल:** temperature, hallucination, calibration, loss: हे सगळे शब्द इथून जन्मतात.

Chapter 2.1 [SPINE]: Probability:

विश्वासाचं माप

थेंबूला “पाऊस पडेल” हे हो/नाही न सांगता “70% शक्यता” सांगायचंय. पण “70%” म्हणजे नक्की काय? इथे probability चा खरा, खोल अर्थ आहे, आणि तो दोन प्रकारे बघता येतो.

अर्थ 1: वारंवारता (frequency). “पाऊस 70% शक्यता” म्हणजे: “अशी हवा असलेले 100 दिवस घेतले, तर त्यातल्या ~70 दिवशी पाऊस पडला.” भूतकाळातल्या मोजणीतून. फासाची उपमा: फासा टाकल्यावर 6 येण्याची शक्यता $1/6$, म्हणजे “पुष्कळ वेळा टाकलं तर ~सहावा हिस्सा वेळा 6.” हे मोजता-तपासता येतं.

अर्थ 2: विश्वासाची मात्रा (belief). पण “उद्या पाऊस” हा तर एकच दिवस, 100 वेळा घडणार नाही. मग 70% म्हणजे? ”मला किती खात्री आहे” ची मात्रा: 0 = अजिबात नाही, 1 = पूर्ण खात्री, 0.7 = बऱ्यापैकी खात्री पण पूर्ण नाही. Probability हे विश्वासाचं थर्मामीटर आहे: 0 ते 1 च्या पट्टीवर. आणि AI साठी हाच अर्थ मुख्य: यंत्र “पुढचा शब्द ‘पाऊस’ असण्याची probability 0.7” म्हणतं म्हणजे “मला 0.7 इतकी खात्री.”

तीन लोखंडी नियम (probability चे, पाठ करा):

1. प्रत्येक शक्यता 0 आणि 1 च्या दरम्यान (कधीच उणे नाही, कधीच 1 पेक्षा जास्त नाही).
2. सगळ्या शक्यतांची बेरीज = 1 (काहीतरी घडणारच).
पाऊस 0.7 -> पाऊस-नाही 0.3; बेरीज 1.
3. probability 0 म्हणजे अशक्य, 1 म्हणजे निश्चित; मध्ये सगळी अनिश्चितता.

नियम 2 महत्वाचा: थेंबूचं यंत्र “पाऊस, ढगाळ, कोरडं” या तीन शक्यतांना उदा 0.6, 0.3, 0.1 देईल: बेरीज **नेहमी 1**. यंत्र शक्यता “वाटतं”, एकूण 1 चा केक तीन तुकड्यांत.

आणि इथे Book 2 चं मोठं सत्य नव्या प्रकाशात: ChatGPT चं “पुढचा token” म्हणजे नक्की काय? शब्दकोशातल्या प्रत्येक शब्दाला एक probability (बेरीज 1): “the” ला 0.3, “cat” ला 0.05, “पाऊस” ला 0.001... हजारो शब्द, हजारो शक्यता, बेरीज

1. यंत्र एका शब्दाची खात्री देत नाही; अख्ख्या शब्दकोशावर विश्वास वाटून देतं. हेच LLM चं गणिती हृदय: आणि म्हणूनच ते कधीच “नक्की” नसतं, नेहमी “किती शक्यता” असतं. Book 2 चं “यंत्र फासे टाकतं” आता नेमकं दिसतं: शब्दकोशावरच्या probability-यादीतून एक निवडणं.

इथे लोक काय चुकीचं समजतात

”70% म्हणजे यंत्राला बऱ्यापैकी माहीत आहे.” धोकादायक. Probability हे यंत्राच्या **आत्मविश्वासाचं** माप आहे, **बरोबरपणाचं** नाही. यंत्र 0.99 खात्रीने **साफ चुकीचं** सांगू शकतं (Book 2, 5.1: hallucination = ठाम-खोटं). “किती खात्री” आणि “किती बरोबर” या दोन वेगळ्या गोष्टी; त्या जुळतात का हे तपासणं म्हणजे calibration (2.6 च्या पुढे, आणि Book 2, 1.4). आत्मविश्वास = बरोबरपणा हे गृहीत धरणं म्हणजे ठाम-चुकीच्या यंत्रावर विश्वास ठेवणं.

नकाशावर

(दर chapter ला एक ओळ.)

2.1 probability = विश्वासाचं माप (0-1); बेरीज=1; LLM = शब्दकोशावर वाटलेला विश्वास; खात्री म्हणजे बरोबरपणा नव्हे

सूत्रावर: probability हा चष्मा यंत्राची अनिश्चितता **मोजता येण्याजोगी** करतो: “यंत्राला माहीत नाही” ही अस्पष्ट गोष्ट “0.5 probability” या नेमक्या आकड्यात. आणि मोजता आलं की हाताळता येतं: पुढचं सगळं Part 2 यावर.

स्वतः बघा (5 मिनिटं)

हवामान-app उघडा: “पाऊस 40%” दिसेल. आता विचारा: याचा अर्थ (अ) “40% भाग आकाशात पाऊस” नाही; (ब) “अशा दिवशी 100 पैकी ~40 वेळा पाऊस पडतो” हो. आणि लक्षात घ्या: app कधीच “पाऊस: हो” म्हणत नाही, नेहमी टक्केवारी: कारण भविष्य अनिश्चित, आणि प्रामाणिक यंत्र अनिश्चितता लपवत नाही, मोजून दाखवतं.

विचार करा

थेंबूचं यंत्र आता तीन शक्यता देतं: पाऊस 0.6, ढगाळ 0.3, कोरडं 0.1. पण थेंबूला वाटतं: “ही तीन-शक्यतांची यादी म्हणजे यंत्राचं पूर्ण ‘मत’ आहे. या यादीलाच काही आकार आहे का? कधी ती ‘एका शक्यतेवर ठाम’ असते, कधी ‘सगळीकडे पसरलेली गोंधळलेली’: हा फरक कसा बघायचा?”

ती शक्यतांची यादी म्हणजे एक “आकार” आहे: distribution (शक्यतांचा डोंगर). तो कधी एका शिखरावर तीव्र (खात्री), कधी सपाट पसरलेला (गोंधळ). त्या आकाराचं गणित: पुढचा chapter.

Chapter 2.2 [SPINE]: Distribution: शक्यतांचा डोंगर

थेंबूचा प्रश्न: शक्यतांच्या यादीला आकार असतो का? हो: आणि त्या आकाराचं नाव **distribution** (वाटणी). तो आकार यंत्राचं मन उघडून दाखवतो: खात्री की गोंधळ.

Distribution म्हणजे काय. सगळ्या शक्यतांची यादी, एकत्र बघितलेली: एक “आकार.” थेंबूची तीन-शक्यतांची यादी दोन वेगळ्या दिवशी बघा:

दिवस A (खात्रीचा): पाऊस 0.9, ढगाळ 0.08, कोरडं 0.02
दिवस B (गोंधळाचा): पाऊस 0.4, ढगाळ 0.35, कोरडं 0.25

दोन्हींची बेरीज 1 (नियम पाळला). पण **आकार** वेगळा: A मध्ये एक **तीव्र शिखर** (पाऊस-वर सगळं वजन): यंत्र ठाम. B मध्ये **सपाट, पसरलेला** डोंगर (तिन्हींत वाटलेलं): यंत्र गोंधळलेलं. तेच यंत्र, दोन दिवस, दोन मनःस्थिती: आणि distribution चा आकार ती मनःस्थिती **दाखवतो**. शिखर तीव्र = खात्री; डोंगर सपाट = अनिश्चितता.

दोन टोकं (लक्षात ठेवा): (1) **सर्वात तीव्र:** एका शक्यतेला 1, बाकी सगळ्यांना 0: पूर्ण खात्री, शून्य अनिश्चितता (“नक्की पाऊस”). (2) **सर्वात सपाट:** सगळ्यांना **सारखीच** शक्यता (तीन असतील तर प्रत्येकी 0.33): पूर्ण गोंधळ, कमाल अनिश्चितता (“काहीच अंदाज नाही, सगळं सारखं”). खऱ्या यंत्राचं distribution या दोन टोकांच्या मध्ये कुठेतरी: आणि **किती तीव्र की सपाट** हेच त्याचा आत्मविश्वास सांगतं.

हे AI मध्ये कुठे दिसतं: LLM चं प्रत्येक token हे शब्दकोशावरचं distribution (2.1). पुढचा शब्द “स्पष्ट” असेल (“भारताची राजधानी ____” -> “दिल्ली” ला 0.95: तीव्र शिखर) तर distribution तीव्र; “अनेक शक्य” असेल (“मला आवडतं ____” -> हजारो शब्द थोडी-थोडी शक्यता: सपाट) तर distribution पसरलेलं. आणि इथे एक व्यावहारिक सोनं: **distribution चा आकार बघून यंत्र किती “खात्रीशीर” आहे हे कळतं**. सपाट distribution म्हणजे यंत्र गोंधळलंय: तिथे त्याच्या उत्तरावर कमी भरवसा (hallucination चा धोका जास्त). तीव्र शिखर म्हणजे यंत्र ठाम (पण ठाम-चुकीचंही असू शकतं: 2.1 चा इशारा).

इथे लोक काय चुकीचं समजतात

“यंत्र एक उत्तर देतं.” नाही: यंत्र **पूर्ण distribution** काढतं (हजारो शक्यता), मग त्यातून एक निवडतं (2.6 चा softmax/ temperature). तुम्हाला फक्त निवडलेलं दिसतं, पण मागे अरुखा डोंगर असतो. आणि तो डोंगर **फेकून** दिला जातो हे दुखणं: कारण त्या डोंगरात “यंत्र किती गोंधळलेलं होतं” ही अमूल्य

माहिती असते, जी अंतिम उत्तरात दिसत नाही. म्हणून calibration-अभ्यास (Book 2, 1.4) या डोंगराकडे बघतो, उत्तराकडे नाही.

नकाशावर

- 2.1 probability = विश्वासाचं माप; बेरीज=1
- 2.2 distribution = शक्यतांचा आकार; तीव्र शिखर=खात्री, सपाट=गोंधळ; यंत्राचं मन उघडतं

सूत्रावर: distribution हा चष्मा यंत्राचा आत्मविश्वास **दृश्य** करतो: “यंत्र गोंधळलंय” ही भावना “सपाट distribution” या मोजता- येणाऱ्या आकारात. मोजता आलं, म्हणून वापरता आलं (कमी-खात्रीच्या उत्तरांना जास्त तपासा).

स्वतः बघा (5 मिनिटं)

दोन प्रश्न कल्पना करा: “ $2+2 = ?$ ” (उत्तर distribution: “4” ला ~ 1.0 , बाकी ~ 0 : तीव्र शिखर) आणि “एक चांगलं नाव सुचव” (उत्तर: हजारो नावांना थोडी-थोडी शक्यता: सपाट). पहिल्यावर यंत्र ठाम, दुसऱ्यावर मुक्त. तुम्ही AI ला हे दोन प्रश्न विचारून बघा: पहिल्याचं उत्तर नेहमी तेच, दुसऱ्याचं दर वेळी वेगळं: distribution चा आकार वर्तनात दिसतो.

विचार करा

थेंबूचं यंत्र कालपासून शिकतंय, आणि आज सकाळी त्याने अंदाज लावला: “पाऊस 0.6.” पण दुपारी अचानक **नवा पुरावा** आला: आकाशात काळे ढग दाटले. थेंबूला वाटलं: “आता माझा अंदाज बदलायला हवा: 0.6 वरून वर. पण **किती** वर? नव्या पुराव्याने जुनं मत नक्की किती हलवायचं: याचा काही नियम आहे का, की मनाने ठरवायचं?”

नव्या पुराव्याने जुनं मत **किती** हलवायचं याचा एक अचूक, सुंदर नियम आहे: आणि तो जगातल्या सर्व विज्ञान, वैद्यक, आणि यंत्र-शिक्षणाचा पाया आहे. त्याचं नाव Bayes: पुढचा chapter, आणि तो या विभागातला सर्वात शक्तिशाली.

Chapter 2.3 [SPINE]: Bayes: पुराव्याने मत हलवणं

थेंबूचा प्रश्न: नव्या पुराव्याने जुनं मत किती हलवायचं? याचं उत्तर विज्ञानातल्या सर्वात शक्तिशाली कल्पनांपैकी एक आहे. आणि ती समजायला एक धक्कादायक वैद्यकीय उदाहरण घेऊ: जे बहुतेक लोक (आणि डॉक्टरही) चुकतात.

धक्कादायक doctor-test. एक आजार 1000 माणसांत 1 ला असतो (दुर्मिळ). त्याची चाचणी 99% “अचूक” आहे. तुमची चाचणी **positive** आली. तुम्हाला आजार असण्याची खरी शक्यता किती? बहुतेक म्हणतात “99%.” **चुकीचं.** खरं उत्तर ~9% आहे. का, ते आकडे मोजून बघू (हेच Bayes):

1000 माणसं घ्या.
 आजारी: 1 (दुर्मिळता). निरोगी: 999.
 - आजारी 1: चाचणी 99% बरोबर -> ~1 positive (खरा).
 - निरोगी 999: चाचणी 99% बरोबर म्हणजे 1% चुकीची ->
 $999 \times 0.01 = \sim 10$ जणांना चुकून positive (खोटे).
 एकूण positive: 1 खरा + 10 खोटे = 11.
 यातले खरे आजारी: 1 पैकी 11 = ~9%.

म्हणजे positive येऊनही आजार असण्याची शक्यता फक्त ~9%! कारण आजार इतका **दुर्मिळ** होता की चाचणीच्या “छोट्या चुका” (999 पैकी 10) खऱ्या केसपेक्षा जास्त झाल्या. **मूळ दुर्मिळता (1 in 1000) चा विसर पडला की सगळं चुकतं.**

Bayes चा गाभा एका वाक्यात: नवं मत = जुनं मत (मूळ शक्यता) + नवा पुरावा, दोन्ही मिळून. पुरावा जुन्या मताला पूर्ण उलथवत नाही; तो त्याला **हलवतो**, आणि किती हलवायचं हे जुनी शक्यता किती होती यावर ठरतं. जुनं मत “आजार दुर्मिळ” (1/1000) होतं; एका positive ने ते 9% पर्यंत वर नेलं (90 पट वाढ!), पण 99% पर्यंत नाही (कारण दुर्मिळता प्रचंड होती). दुसरी positive चाचणी आली तर आता जुनं मत 9% (पहिल्यापेक्षा जास्त), म्हणून ती अजून वर नेईल. **पुरावा साचत जातो, मत टप्प्याटप्प्याने सरकतं.**

थेंबूवर: थेंबूचं जुनं मत “पाऊस 0.6.” नवा पुरावा “काळे ढग” (जे पावसाच्या दिवशी अनेकदा दिसतात, कोरड्या दिवशी क्वचित). Bayes म्हणतो: 0.6 वर ढगांचा पुरावा जोडून नवं मत काढ: म्हणा 0.85. किती वर? ढग पावसाशी किती जोडलेले यावर. मनाने नाही, **गणिताने**. आणि हेच यंत्र-शिक्षणाचं हृदय: प्रत्येक नवं उदाहरण म्हणजे पुरावा, जो यंत्राचं “मत” (weights) थोडं हलवतो (Part 3 चा gradient descent हा Bayes चा चुलतभाऊ).

हे सर्वत्र आहे: spam-गाळणी (“हा शब्द spam मध्ये किती वेळा येतो” वरून email चं मत), वैद्यकीय निदान, न्यायालयातले पुरावे, आणि AI चा अख्खा अंदाज-खेळ. **Bayes = तर्कशुद्ध मत-बदलाचं गणित:** आणि जो हे शिकतो तो बातम्या, आकडे, दावे: सगळं जास्त शहाणपणाने वाचतो.

इथे लोक काय चुकीचं समजतात

“चाचणी 99% अचूक, positive आलं, म्हणजे 99% आजार.” जगातली सर्वात सामान्य आकडे-चूक (base rate neglect: मूळ-दुर्मिळतेचा विसर). लोक चाचणीच्या अचूकतेकडे बघतात, आजाराच्या दुर्मिळतेकडे नाही. Bayes शिकवतो: **दुर्मिळ गोष्टीचा पुरावा नेहमी संशयाने बघा:** कारण दुर्मिळतेमुळे “खोटे positive” खऱ्यापेक्षा जास्त असू शकतात. हीच चूक AI मध्येही: “यंत्र 99% खात्रीने म्हणालं” पण ती गोष्ट मुळात दुर्मिळ/अशक्य असेल तर खात्रीलाही संशयाने बघा.

नकाशावर

- 2.1 probability = विश्वासाचं माप 2.2 distribution = आकार
2.3 Bayes: नवें मत = जुनं मत + पुरावा; दुर्मिळतेचा विसर =
मोठी चूक (doctor-test 9%); पुरावा हलवतो, उलथवत नाही

सूत्रावर: Bayes हा चष्मा “मत कसं बदलावं” ला **गणित** देतो: भावनेने नाही, पुराव्याच्या वजनाने. आणि यंत्राचं शिकणं हेच: पुरावा-पुरावा, मत सरकत जाणं. तर्कशुद्धता म्हणजे Bayes जगणं.

स्वतः बघा (5 मिनिटं)

एक बातमी आठवा: “X चाचणीत 95% अचूक!” आता विचारा: ज्या गोष्टीची चाचणी आहे ती किती **दुर्मिळ** आहे? दुर्मिळ असेल तर 95% अचूकतेतही बहुतेक positive **खोटे** असू शकतात (doctor- test). ही एक नजर तुम्हाला आरोग्य-जाहिराती, सर्वेक्षणं, आणि AI-दावे: सगळं जास्त शहाणपणाने वाचायला लावेल.

विचार करा

थेंबूला आता एक वेगळाच प्रश्न पडला: “मी शक्यता मोजायला शिकलो, मत बदलायलाही. पण एक गंमत: जेव्हा माझं distribution सपाट असतं (सगळं सारखं, गोंधळ), तेव्हा मला ‘किती गोंधळ आहे’ हे **एका आकड्यात** सांगता येईल का? ‘खात्री’ आणि ‘गोंधळ’ यांच्यातलं अंतर मोजायचं एक माप?”

हो, आणि ते माप AI मधलं सर्वात खोल, सर्वात सुंदर आहे: **entropy**: आश्चर्याचं/गोंधळाचं माप. आणि तेच Book 2 च्या loss चं मूळ आहे. पुढचा chapter.

Chapter 2.4 [SPINE]: Entropy: आश्चर्याचं माप

थेंबूला “गोंधळ” एका आकड्यात हवाय. गणिताचं उत्तर एका सुंदर कल्पनेत आहे: **entropy**: आश्चर्याचं माप. आणि ते समजायला एक खेळ खेळू: विसाव्या प्रश्नांचा.

20 प्रश्नांचा खेळ (entropy चा आत्मा). मी एक गोष्ट मनात धरतो, तुम्ही हो/नाही प्रश्न विचारून ओळखा. जर मी “आठवड्याचा वार” धरला (7 शक्यता), तर तुम्हाला ~3 प्रश्न लागतात (हुशारीने: “पहिल्या सहामांत?” वगैरे, अर्ध-अर्ध कापत). जर मी “वर्षातला दिवस” धरला (365 शक्यता), तर ~9 प्रश्न. **जितक्या जास्त, तितकी अनिश्चितता जास्त, तितके जास्त प्रश्न.** Entropy म्हणजे नेमकं हेच: “ही अनिश्चितता संपवायला सरासरी किती हो/नाही प्रश्न लागतील”: गोंधळाचं मोजमाप, प्रश्नांच्या भाषेत.

थेंबूवर, दोन दिवस:

दिवस A (खात्री): पाऊस 0.9, ढगाळ 0.08, कोरडं 0.02

-> जवळजवळ नक्की पाऊस; ओळखायला ~शून्य प्रश्न;

entropy कमी (~0.5).

दिवस B (गोंधळ): पाऊस 0.4, ढगाळ 0.35, कोरडं 0.25

-> काहीच स्पष्ट नाही; ओळखायला जास्त प्रश्न;

entropy जास्त (~1.5).

(आकडे “bits” मध्ये; नेमकी मोजणी सोडा: दिशा पकडा.) तीव्र distribution (2.2) = कमी entropy = कमी आश्चर्य = ठाम. सपाट distribution = जास्त entropy = जास्त आश्चर्य = गोंधळ. **entropy हा distribution च्या “सपाटपणा”चा एक आकडा.**

“आश्चर्य” का म्हणतो. जी गोष्ट नक्की घडणार (probability

1. ती घडली तर आश्चर्य **शून्य** (“अर्थातच”). जी **दुर्मिळ** (probability कमी) ती घडली तर आश्चर्य **मोठं** (“अरे, हे कसं!”). Entropy = सरासरी आश्चर्य. खात्रीच्या यंत्राला जग “अपेक्षित” (कमी आश्चर्य); गोंधळलेल्या यंत्राला जग सतत “धक्कादायक” (जास्त आश्चर्य). आणि इथे AI चं खोल सत्य: **यंत्र शिकतं म्हणजे जगाचं आश्चर्य कमी करत जातं**: सुरुवातीला सगळं धक्कादायक (काहीच अंदाज नाही, प्रचंड entropy); शिकल्यावर “पुढचा शब्द असाच असणार” (कमी आश्चर्य, कमी entropy). **शिकणं = आश्चर्य कमी करणं.**

हे **compression** शीही जोडलेलं (गंमत): कमी entropy = कमी आश्चर्य = अंदाज सोपा = **कमी जागेत साठवता येतं** (zip files याच तत्वावर). आणि म्हणूनच काही संशोधक म्हणतात “समजणं म्हणजे compression”: जितकं चांगलं समजलं, तितकं कमी आश्चर्य, तितकं आवळता येतं. LLM हे एका अर्थाने

इंटरनेटचं आवळलेलं रूप: कमी entropy मध्ये बसवलेलं जग.

इथे लोक काय चुकीचं समजतात

"Entropy म्हणजे भौतिकशास्त्रातली अस्ताव्यस्तता (गरम-थंड)." तिथूनच शब्द आला, पण माहिती-जगात entropy = **अनिश्चितता/ आश्चर्य**, तापमान नाही. आणि दुसरा गैरसमज: "कमी entropy = चांगलं." नेहमी नाही: यंत्र चुकीच्या गोष्टीवर कमी-entropy (ठाम- खोटं) असू शकतं (2.1 चा hallucination). Entropy फक्त "किती ठाम" मोजतं, "किती बरोबर" नाही. ठाम-आणि-चूक ही सर्वात धोकादायक जोडी.

नकाशावर

2.1-2.3 probability | distribution | Bayes
2.4 entropy = आश्चर्याचं/गोंधळाचं माप (किती हो/नाही प्रश्न लागतील); तीव्र=कमी, सपाट=जास्त; शिकणं = आश्चर्य कमी करणं

सूत्रावर: entropy हा चष्मा "गोंधळ" या अस्पष्ट गोष्टीला **एका आकड्यात** आणतो. आणि तो आकडा शिकण्याची दिशा दाखवतो: आश्चर्य कमी करत जा. जे मोजता येतं (आश्चर्य) ते सुधारता येतं (कमी करत जाणं): सूत्र प्रत्यक्षात.

स्वतः बघा (5 मिनिटं)

20-प्रश्नांचा खेळ खेळा (कुणासोबत, किंवा मनात): एकदा "आठवड्याचा वार" (7 शक्यता), एकदा "जगातलं कुठलंही शहर" (हजारो). दुसऱ्याला किती जास्त प्रश्न लागतात बघा. तो फरक = entropy चा फरक. आणि लक्षात घ्या: प्रत्येक चांगला प्रश्न अनिश्चितता **अर्धी** करतो (अर्धी-अर्धी कापणं: Book 6 चा binary search इथे भेटेल): हुशार प्रश्न = जास्त entropy-कपात प्रति प्रश्न.

विचार करा

थेंबूचं यंत्र आता शिकतंय: आश्चर्य कमी करतंय. पण थेंबूला मूळ प्रश्न आठवला: "यंत्र शिकतं म्हणजे नक्की **कशाकडून** शिकतं? Book 2 म्हणालं 'चूक (loss) मोजून, ती कमी करत.' पण ती 'चूक' नक्की काय? माझा अंदाज (पाऊस 0.6) आणि खरं घडलेलं (पाऊस पडला) यांच्यातलं अंतर एका आकड्यात कसं मोजायचं? आणि त्याचा entropy शी संबंध आहे का?"

आहे, आणि खोल आहे: Book 2 चं loss म्हणजे प्रत्यक्षात **cross-entropy**: entropy चंच जुळं भावंडं, जे "यंत्राचा अंदाज खऱ्यापासून किती दूर" मोजतं. loss चं खरं रूप: पुढचा chapter.

Chapter 2.5 [SPINE]: Cross-Entropy: Loss चं खरं रूप

थेंबूचा प्रश्न: “चूक (loss)” नक्की काय? Book 2 ने loss ला “चुकीचं माप” म्हटलं (2.5); आता त्याचं खरं गणिती रूप उघडू: आणि ते entropy चंच जुळं भावंडं आहे: **cross-entropy**. हे समजलं की यंत्राच्या शिकवणीचं हृदय दिसतं.

कल्पना: खऱ्याला तू किती probability दिलीस? थेंबूने अंदाज लावला (distribution): पाऊस 0.6, ढगाळ 0.3, कोरडं 0.1. मग प्रत्यक्षात **पाऊस पडला**. आता चूक कशी मोजायची? सोपं तत्त्व: **जे खरं घडलं, त्याला यंत्राने किती probability दिली होती?** पाऊस पडला, यंत्राने पावसाला 0.6 दिलं होतं: बऱ्यापैकी, पण पूर्ण नाही. जर यंत्राने 0.95 दिलं असतं तर उत्तम (कमी चूक); 0.1 दिलं असतं तर वाईट (मोठी चूक: खऱ्या गोष्टीला यंत्र म्हणत होतं “अशक्य”).

Cross-entropy loss (गाभा, सूत्राशिवाय): खऱ्या घटनेला यंत्राने दिलेली probability जितकी जास्त, तितकी चूक कमी. आणि नातं उलटं-आणि-तीव्र आहे:

यंत्राने खऱ्याला दिलं	-> loss (चूक)
0.9 (छान)	-> लहान (~0.1)
0.6 (ठीक)	-> मध्यम (~0.5)
0.1 (वाईट)	-> मोठा (~2.3)
0.01 (भयंकर)	-> प्रचंड (~4.6)

लक्षात घ्या: probability जसजशी शून्याकडे, तसतशी loss **स्फोटक** वाढते. का? कारण **“खऱ्या गोष्टीला अशक्य म्हणणं” ही सर्वात मोठी चूक**. यंत्र 0.9 खात्रीने चुकीचं बोललं (आणि खरं वेगळं निघालं) तर loss प्रचंड: शिक्षा मोठी. हेच यंत्राला “ठाम-चूक” पासून परावृत्त करतं (किंवा करायला हवं: hallucination अजून का उरतं हे Book 2, 5.1). Loss = खऱ्याला दिलेल्या खात्रीची उलटी शिक्षा.

Entropy शी नातं (सुंदर): entropy होतं “यंत्राच्या स्वतःच्या अंदाजातलं सरासरी आश्चर्य” (2.4). Cross-entropy आहे “खऱ्या जगाशी ताडून यंत्राला किती आश्चर्य.” जर यंत्राचा अंदाज खऱ्याशी तंतोतंत जुळला तर cross-entropy = entropy (कमीत कमी). जितका अंदाज खऱ्यापासून दूर, तितकी cross-entropy entropy पेक्षा जास्त: आणि तो **जास्तीचा भाग म्हणजे यंत्राची चूक**. म्हणून training म्हणजे: cross-entropy कमी करत नेणं = यंत्राचा अंदाज खऱ्या जगाच्या जवळ नेणं = आश्चर्य कमी करणं (2.4 चा “शिकणं = आश्चर्य कमी करणं” आता नेमकं).

हेच LLM चं संपूर्ण training (Book 2 उघडलं): अब्जावधी वाक्यांत, प्रत्येक शब्दाला यंत्र अंदाज लावतं (पुढचा शब्द काय), खरा शब्द बघतं, आणि **खऱ्या शब्दाला यंत्राने किती probability दिली** यावरून cross-entropy loss. मग ती कमी करायला weights थोडे हलवतात (Part 3). ट्रिलियन वेळा. “यंत्र इंटरनेट वाचून शिकलं” म्हणजे: ट्रिलियन शब्दांवर cross-entropy कमी करत, आपला अंदाज खऱ्या मजकुराच्या जवळ नेत गेलं. Book 2 चं “अंदाज-चूक-सुधार” चक्र आता गणितात: चूक = cross-entropy.

इथे लोक काय चुकीचं समजतात

“Loss म्हणजे यंत्राने किती उत्तरं चुकवली (टक्केवारी).” नाही: loss हे “किती चुकवली” नाही, “**किती खात्रीने** चुकवली/बरोबर केली” मोजतं. यंत्र बरोबर उत्तर देऊनही (जर कमी खात्रीने दिलं तर) थोडी loss घेतं; आणि चुकीचं उत्तर ठाम खात्रीने दिलं तर प्रचंड loss. म्हणून loss हे उत्तरांच्या **खात्रीचं** माप आहे, नुसत्या बरोबर-चूक चं नाही. हेच यंत्राला “नुसतं बरोबर” नाही तर “योग्य आत्मविश्वासाने बरोबर” व्हायला शिकवतं (आदर्शात; प्रत्यक्षात calibration अपुरं: Book 2, 1.4).

नकाशावर

2.1-2.4 probability | distribution | Bayes | entropy
 2.5 cross-entropy = loss चं खरं रूप; खऱ्याला दिलेली
 probability जास्त -> loss कमी; अशक्य-म्हणणं = स्फोटक
 शिक्षा; training = cross-entropy कमी करणं

सूत्रावर: cross-entropy हा चष्मा “यंत्र शिकतं म्हणजे काय” हे पूर्ण उघडतो: खऱ्या जगाशी आपला अंदाज ताडून, अंतर (loss) मोजून, ते कमी करणं. जे मोजता येतं (loss) तेच सुधारता येतं (कमी करत): सूत्र यंत्र-शिक्षणाच्या केंद्रस्थानी.

स्वतः बघा (5 मिनिटं)

एक स्वतःची परीक्षा कल्पना करा जिथे तुम्ही प्रत्येक उत्तराला “किती खात्री” (%) लिहायची. आता cross-entropy चा नियम: बरोबर उत्तराला 90% खात्री दिली आणि बरोबर निघालं -> छान (कमी शिक्षा); पण चुकीच्या उत्तराला 90% खात्री दिली -> मोठी शिक्षा. हा नियम तुम्हाला “खात्री तेवढीच दाखवा जेवढी खरी आहे” शिकवतो: अति-आत्मविश्वासाला शिक्षा. यंत्रालाही तेच शिकवायचा प्रयत्न, cross-entropy ने.

विचार करा

थेंबूला आता एक व्यावहारिक प्रश्न: “माझं यंत्र आतून ‘पाऊस-गुण’ काढतं (Part 1: matrix मधून, उदा 2.0, ढगाळ 1.8, कोरडं 0.5). पण हे ‘गुण’ कुठलेही आकडे असू शकतात (मोठे, उणे). त्यांचं 0-1 च्या, बेरीज-1 च्या **probability** मध्ये रूपांतर कसं? आणि मी ‘किती धीट अंदाज लावायचा’ (नेहमी सर्वात शक्य, की कधी जोखीम) हे कसं ठरवायचं?”

गुणांचं probability मध्ये रूपांतर करणारं एक सुंदर यंत्र आहे: softmax; आणि “किती धीट” ठरवणारी एक कळ: temperature (Book 2 ची तीच!). विभागाचा शेवटचा chapter, दोन्ही एकत्र.

Chapter 2.6 [SPINE]: Softmax आणि Temperature

थेंबूचे दोन प्रश्न: कुठलेही गुण probability मध्ये कसे बदलायचे, आणि “किती धीट” कसं ठरवायचं. दोन्हींची उत्तरं एका सुंदर यंत्रात आणि एका कळीत आहेत: **softmax** आणि **temperature**. हे विभाग 2 आणि Part 1 ला जोडतात.

Softmax: गुणांचं probability मध्ये रूपांतर. थेंबूचे गुण: पाऊस 2.0, ढगाळ 1.8, कोरडं 0.5. हे 0-1, बेरीज-1 मध्ये कसे आणायचे? Softmax ची तीन पावलं (हाताने, ढोबळ):

1. प्रत्येक गुणाचा “स्फोट” (exponential: मोठा गुण जास्त मोठा होतो, फरक ठळक होतात):
पाऊस 2.0 $\rightarrow \sim 7.4$; ढगाळ 1.8 $\rightarrow \sim 6.0$; कोरडं 0.5 $\rightarrow \sim 1.6$
2. बेरीज: $7.4 + 6.0 + 1.6 = 15.0$
3. प्रत्येकाचा हिस्सा (भागा):
पाऊस $7.4/15 = 0.49$; ढगाळ $6.0/15 = 0.40$; कोरडं $1.6/15 = 0.11$

झालं: गुण (2.0, 1.8, 0.5) $\rightarrow$ probability (0.49, 0.40, 0.11), बेरीज 1. **Softmax = कुठलेही आकडे घेऊन probability-वाटणी बनवणारं यंत्र.** आणि पायरी-1 चा “स्फोट” महत्त्वाचा: तो मोठ्या गुणाला **अप्रमाणात** जास्त probability देतो (फरक ठळक करतो): म्हणून “soft-max”: सर्वात मोठ्याला झुकतं, पण बाकीलाही थोडं (पूर्ण max नाही, soft). हेच LLM च्या शेवटच्या पायरीत: शब्दकोशाच्या गुणांचं (logits) probability मध्ये रूपांतर, प्रत्येक token ला.

Temperature: “किती धीट” ची कळ (Book 2 ची तीच). आता जादूची कळ. softmax च्या आधी सगळे गुण एका आकड्याने **भागा**: त्याचं नाव temperature (T).

- T कमी (उदा 0.5): गुण मोठे होतात $\rightarrow$ स्फोट तीव्र $\rightarrow$ सर्वात मोठ्याला अजून जास्त वजन $\rightarrow$ distribution तीव्र (2.2) $\rightarrow$ यंत्र “ठाम”, नेहमी सर्वात शक्य निवडतं. (कंटाळवाणं पण सुरक्षित.)
- T जास्त (उदा 1.5): गुण लहान होतात $\rightarrow$ स्फोट मंद $\rightarrow$ सगळे जवळ येतात $\rightarrow$ distribution सपाट $\rightarrow$ यंत्र “धीट/जुगारी”, कमी-शक्य पर्यायही निवडतं. (सर्जनशील पण जोखमीचं.)
- T = 1: मूळ, जसच्या तसं.

म्हणजे temperature ही **entropy ची कळ** (2.4): कमी T = कमी entropy (ठाम); जास्त T = जास्त entropy (गोंधळ/सर्जनशीलता). Book 2 मध्ये “temperature = निवडीच्या फाशांची मात्रा” म्हटलं होतं; आता नेमकं दिसतं: ती softmax च्या तीव्रतेची कळ, म्हणजे distribution च्या आकाराची कळ.

सगळं जोडून (विभाग 2 चा कळस): एका token चा पूर्ण प्रवास.

1. matrix-थर (Part 1): शब्दाचा बाण -> गुण-यादी (logits), शब्दकोशातल्या प्रत्येक शब्दाला एक गुण.
2. temperature ने भागा: "किती धीट" ठरवा.
3. softmax: गुण -> probability-distribution (बेरीज 1).
4. त्या distribution मधून एक शब्द निवडा (फासे: 2.1).
5. training असेल तर: खऱ्या शब्दाशी ताडून cross-entropy loss (2.5) -> weights हलवा (Part 3).

Part 1 (बाण, matrix) + Part 2 (probability, softmax, loss): एकत्र म्हणजे LLM च्या एका पावलाचं पूर्ण गणित. थेंबूचं यंत्र आणि ChatGPT: हाच प्रवास, फक्त आकार वेगळा.

इथे लोक काय चुकीचं समजतात

"Temperature वाढवली की यंत्र हुशार/सर्जनशील होतं." अर्धसत्य, धोकादायक. Temperature फक्त "किती कमी-शक्य पर्याय निवडायचे" ठरवते: जास्त T = जास्त विविधता, पण जास्त चुका/बरळणही (कमी-शक्य म्हणजे अनेकदा चुकीचं). "सर्जनशीलता" आणि "बरळण" दोन्ही जास्त-T चीच फळ: फरक फक्त तुम्हाला कोणतं हवं. तथ्यांच्या कामाला कमी T (ठाम, अचूक), कल्पक लेखनाला जास्त T (विविध). कळ हुशारीची नाही, जोखमीची आहे.

नकाशावर

- 2.1-2.5 probability | distribution | Bayes | entropy | cross-entropy
- 2.6 softmax = गुण -> probability (स्फोट+भागा); temperature = धीटपणाची/entropy ची कळ (कमी=ठाम, जास्त=जुगारी); पूर्ण token-प्रवास: बाण->गुण->softmax->निवड->loss

सूत्रावर: softmax+temperature हा चष्मा "यंत्र किती धीट/ठाम" ही कळ तुमच्या हातात देतो: entropy ची कळ फिरवता येते. आणि पूर्ण Part 1-2 मिळून यंत्राचं एक पाऊल आता संपूर्ण गणित आहे: कुठेही जादू उरली नाही.

स्वतः बघा (5 मिनिटं)

अनेक AI-साधनांत “temperature” किंवा “creativity” ची कळ असते. असेल तर: तोच प्रश्न दोन T ला विचारा (कमी आणि जास्त). कमी T: उत्तर दर वेळी जवळपास तेच, सुरक्षित. जास्त T: दर वेळी वेगळं, कधी छान कधी विचित्र. तुम्ही entropy ची कळ प्रत्यक्ष फिरवताय: distribution तीव्र-सपाट करताय.

विचार करा

विभाग 2 संपला. थेंबूला अनिश्चिततेचं पूर्ण गणित कळलं: शक्यता, आकार, पुरावा, आश्चर्य, चूक, धीटपणा. पण एक मोठा प्रश्न उरला, आणि तो सर्वात महत्वाचा: “मला ‘चूक (loss)’ मोजता येते, हे कळलं. पण Book 2 म्हणालं ‘चूक कमी करायला weights **हलवतात**.’ कुठल्या दिशेने, किती हलवायचे: हे यंत्राला कसं कळतं? लाखो weights आहेत; प्रत्येकाला किती ढकलायचं?”

हाच पुढच्या विभागाचा गाभा, आणि पूर्ण यंत्र-शिक्षणाचं हृदय: **उतार** (gradient). प्रत्येक weight ला “तू loss वर किती परिणाम करतोस, आणि कमी करायला कुठे सरकावं” हे सांगणारं गणित. उताराचं जग, Part 3.

BOOK 7, PART 2 चा शेवट

जे तुमच्याकडे आता आहे

probability	विश्वासाचं माप (0-1); बेरीज=1; LLM = शब्दकोशावर वाटलेला विश्वास; खात्री म्हणजे बरोबरपणा नव्हे
distribution	शक्यतांचा आकार; तीव्र शिखर=खात्री, सपाट=गोंधळ; यंत्राचं मन उघडतं
Bayes	नवं मत = जुनं मत + पुरावा; दुर्मिळतेचा विसर = मोठी चूक (doctor-test 9%); पुरावा हलवतो, उलथवत नाही
entropy	आश्चर्याचं/गोंधळाचं माप; तीव्र=कमी, सपाट=जास्त; शिकणं = आश्चर्य कमी करणं
cross-entropy	loss चं खरं रूप; खऱ्याला दिलेली probability जास्त -> loss कमी; अशक्य-म्हणणं = स्फोटक शिक्षा
softmax+temp	गुण -> probability (स्फोट+भागा); temperature = धीटपणाची/entropy ची कळ; पूर्ण token-प्रवास

स्वतःची परीक्षा (4 प्रश्न, बोलून; उत्तरं खाली)

1. LLM “एक उत्तर” देतं का, गणितात नक्की काय होतं?

नाही: शब्दकोशावर पूर्ण probability-distribution काढतं (बेरीज 1), मग softmax+temperature ने निवडतं. मागे अख्खा डोंगर. (2.1, 2.2, 2.6)

2. चाचणी 99% अचूक, positive आलं: आजार 99%? आणि खरा धडा?

नाही, ~9% (आजार दुर्मिळ तर खोटे-positive जास्त: Bayes). धडा: दुर्मिळतेचा विसर = मोठी चूक; पुरावा जुन्या मताला हलवतो, उलथवत नाही. (2.3)

3. Loss (cross-entropy) नक्की काय मोजतं, आणि सर्वात मोठी शिक्षा कधी?

खऱ्या घटनेला यंत्राने किती probability दिली (जास्त=कमी loss); “खऱ्याला अशक्य म्हणणं” (probability ~0) = स्फोटक शिक्षा. उत्तरांच्या खात्रीचं माप, नुसत्या बरोबर-चूक चं नाही. (2.5)

4. Temperature काय करते, आणि “सर्जनशीलता” चा सापळा?

distribution तीव्र (कमी T, ठाम) की सपाट (जास्त T, धीट) ठरवते = entropy ची कळ. सापळा: जास्त T = विविधता आणि बरळणं दोन्ही; कळ हुशारीची नाही, जोखमीची. (2.6)

पुढच्या भागाची चाहल

थेंबूचा शेवटचा प्रश्न: loss कमी करायला weights **कुठल्या दिशेने, किती** हलवायचे? Part 3: उताराचं जग: derivative (बदलाचा दर), gradient (धुक्यातला डोंगर उतरणं), chain rule (चूक मागे वाटणं), आणि थेंबूवर **पूर्ण backpropagation हाताने, आकड्यांनिशी**. पूर्ण यंत्र-शिक्षणाचं हृदय.

BOOK 7, PART 2 चा MINI-GLOSSARY

Bayes	नवं मत = जुनं मत + पुरावा (2.3)
base rate	मूळ दुर्मिळता; हिचा विसर = मोठी चूक (2.3)
calibration	खात्री आणि बरोबरपणा जुळतात का (2.1)
cross-entropy	loss चं खरं रूप; खऱ्याला दिलेल्या खात्रीची शिक्षा (2.5)
distribution	शक्यतांचा आकार (तीव्र/सपाट) (2.2)
entropy	आश्चर्याचं/गोंधळाचं माप (2.4)
logits	softmax च्या आधीचे कच्चे गुण (2.6)
probability	विश्वासाचं माप (0-1); बेरीज=1 (2.1)
softmax	गुण -> probability-वाटणी (2.6)
temperature	धीटपणाची/entropy ची कळ (2.6)

THE LENS

Book 7, Part 3: उताराचं जग

मागच्या भागाचा शेवट: थेंबूला चूक (loss) मोजता येते, पण प्रश्न उरला: ती कमी करायला weights कुठल्या दिशेने, किती हलवायचे? हा भाग त्याचं उत्तर: आणि तेच पूर्ण यंत्र-शिक्षणाचं हृदय आहे.

Derivative (बदलाचा दर), gradient (उतार), chain rule (चूक मागे वाटणं), आणि सर्वात महत्वाचं: थेंबूवर पूर्ण **backpropagation**, हाताने, **खऱ्या आकड्यांनी**. हा भाग संपला की “यंत्र शिकतं” हे वाक्य तुमच्यासाठी कायमचं उघडं होईल.

सूत्र (पुन्हा)

गणित म्हणजे आकडेमोड नव्हे; न दिसणारं दाखवणारा चष्मा.

जे मोजता येतं, ते सुधारता येतं.

Part 3 चा भर: चूक कुठे-किती हे मोजता आलं की सुधारणा आपोआप होते. हेच शिकणं.

Part 2 ची उजळणी: 3 प्रश्न (बोलून; उत्तरं खाली)

1. Loss (cross-entropy) नक्की काय मोजतं?

खऱ्या घटनेला यंत्राने किती probability दिली (जास्त=कमी loss); “अशक्य म्हणणं” = स्फोटक शिक्षा. (2.5)

2. Softmax काय करतं?

कुठलेही गुण -> probability-वाटणी (स्फोट + भागा), बेरीज 1. (2.6)

3. Temperature ची कळ?

distribution तीव्र (ठाम) की सपाट (धीट) = entropy ची कळ. (2.6)

या भागात काय

Derivative (एका आकड्याचा दुसऱ्यावर परिणाम), gradient (सगळ्या weights ची उतार-दिशा), chain rule (चूक थरांमागे वाटणं), थेंबूवर पूर्ण एक शिकवणी-पाऊल हाताने, learning rate (पावलाचा आकार), आणि “हे का चालतं” चं प्रामाणिक गूढ. सगळं आकड्यांनी.

विभाग 3: उताराचं जग

Book 2 चं शिकणं आठवा: अंदाज -> चूक -> उतार -> केसभर पाऊल -> पुन्हा (2.6). त्यातला “उतार” हा या विभागाचा गाभा आहे. यंत्राकडे लाखो-अब्जावधी weights; loss कमी करायला प्रत्येकाला किती, कुठे ढकलायचं हे “उतार” ठरवतो. आणि आश्चर्य हे की हा उतार काढणारं गणित (derivative, gradient, chain rule) आश्चर्यकारक साधं आहे: थेंबूवर हाताने करता येईल इतकं. हे तुमच्या शिक्षणात कुठे येईल: “training”, “fine-tuning”, “gradient descent”, “backprop”: हे सगळे शब्द इथून जन्मतात; हा विभाग समजला की “यंत्राला शिकवणं” ही जादू न राहता अंकगणित होतं.

Chapter 3.1 [SPINE]: Derivative: बदलाचा दर

उतार समजायला आधी एक साधी कल्पना: **derivative** (बदलाचा दर). आणि ती इतकी रोजची आहे की तुम्ही ती वापरता, फक्त नाव माहीत नाही.

Derivative म्हणजे काय. एका आकड्याला थोडं ढकललं, तर दुसरा आकडा **किती** बदलतो? गाडीचा वेग म्हणजे derivative: “वेळ थोडा पुढे गेला, तर अंतर किती वाढलं.” थेंबूवर: “weight थोडं वाढवलं, तर loss किती बदलली?” हाच प्रश्न, आणि त्याचं उत्तर = derivative. एका ओळीत: **derivative = परिणामाचा दर = “इथे थोडं हललं तर तिथे किती हलतं.”**

आकड्यांनी बघू (थेंबूचं सोपं रूप). समजा थेंबूचा loss हा एका weight w वर असा अवलंबून आहे: $\text{loss} = (w - 3)^2$. म्हणजे $w = 3$ ला loss शून्य (सर्वोत्तम), आणि w जसजसा 3 पासून दूर, तसतशी loss वाढते (एक खोरं, तळाशी $w=3$). आता derivative विचारतो: “ $w = 5$ ला उभं राहून थोडं हललं तर loss कुठे जाईल?”

$$\begin{aligned} w = 5: \quad \text{loss} &= (5-3)^2 = 4 \\ w = 5.1: \text{loss} &= (5.1-3)^2 = 2.1^2 = 4.41 \quad (\text{वाढली!}) \\ w = 4.9: \text{loss} &= (4.9-3)^2 = 1.9^2 = 3.61 \quad (\text{घटली!}) \end{aligned}$$

म्हणजे $w = 5$ ला: w **वाढवलं** तर loss वाढते; w **घटवलं** तर loss घटते. Derivative हा दर आणि दिशा दोन्ही सांगतो: इथे तो **धन** (positive) आहे (“ w वाढला की loss वाढते”), आणि आकार सांगतो किती वेगात. आणि इथे शिकण्याची गुरुकिल्ली: **loss कमी करायची तर derivative च्या उलट दिशेला जा.** derivative धन (w वाढला की loss वाढते) $\rightarrow$ म्हणून w **कमी** करा (उताराच्या खाली, $w=3$ कडे). हेच “उतार उतरणं.”

डोंगराची उपमा (Book 2 चा धुका). $\text{loss} =$ एक डोंगराळ भूभाग, उंची = चूक. तुम्ही एका जागी ($w = 5$) उभे, तळ (कमीत कमी loss) शोधायचाय, पण धुक्यामुळे पूर्ण नकाशा दिसत नाही. Derivative म्हणजे: **तुमच्या पायाखालचा उतार:** “इथे जमीन कुठल्या दिशेला झुकलीये, किती तीव्र.” उतार कळला की एक पाऊल **खाली** टाका (loss कमी होईल त्या दिशेला). पुन्हा उतार बघा, पुन्हा पाऊल. हळूहळू तळाकडे. Derivative = पायाखालच्या उताराचं मोजमाप: पूर्ण नकाशा नाही, पण पुढचं एक पाऊल पुरेसं.

इथे लोक काय चुकीचं समजतात

”Derivative म्हणजे किचकट calculus, सूत्रं.” मूळ कल्पना साधी: “इथे थोडं हललं तर तिथे किती हलतं.” तुम्ही ती रोज वापरता (वेग = अंतराचा derivative, प्रवेग = वेगाचा). AI मध्ये लागणारं derivative फक्त काही मूठभर नियमांचं (कोणतं फार महत्वाचं नाही; कल्पना महत्वाची). आणि दुसरा गैरसमज: “derivative म्हणजे उत्तर.” नाही: derivative म्हणजे दिशा (पुढचं पाऊल कुठे), उत्तर नाही: उत्तर मिळतं अनेक पावलं टाकून (3.4).

नकाशावर

(दर chapter ला एक ओळ.)

3.1 derivative = बदलाचा दर (“इथे हललं तर तिथे किती”);
पायाखालचा उतार; loss कमी करायला उलट दिशेला जा

सूत्रावर: derivative हा चष्मा “सुधारायचं तर कुठे सरकावं” हे **मोजून** दाखवतो: अंदाजाने नाही, दराने. जे मोजता येतं (उतार) त्या दिशेने सुधारता येतं (खाली पाऊल): हेच शिकण्याचं यांत्रिक हृदय.

स्वतः बघा (5 मिनिटं)

डोंगरउतारावर चेंडू सोडला तर तो **सर्वात तीव्र उताराच्या** दिशेने घरंगळतो, तळाकडे. का? कारण गुरुत्व त्याला “derivative च्या उलट” ढकलतं. यंत्राचं शिकणं तेच: loss-डोंगरावर weight-चेंडू उताराने खाली. निसर्ग हेच गणित वापरतो; आपण फक्त त्याला आकड्यांत मांडलं.

विचार करा

थेंबूला एकच weight असेल तर उतार सोपा (एका दिशेला खाली). पण थेंबूला **दोन** weights आहेत (आर्द्रता आणि ढगांचे), आणि खऱ्या यंत्राला अब्जावधी. “एका weight चा उतार कळला; पण लाखो weights एकाच वेळी, प्रत्येकाचा loss वर वेगळा परिणाम: सगळ्यांचे उतार एकत्र कसे काढायचे, आणि कुठल्या दिशेला सगळ्यांनी मिळून जायचं?”

सगळ्या weights चे उतार एकत्र म्हणजे एक “उतार-बाण” (Part 1 चा vector!): तो सगळ्यात तीव्र-उताराची दिशा दाखवतो. त्याचं नाव gradient. पुढचा chapter.

Chapter 3.2 [SPINE]: Gradient: धुक्यातला डोंगर उतरण

थेंबूचा प्रश्न: लाखो weights चे उतार एकत्र कसे? उत्तर Part 1 शी जोडतं: सगळ्या weights चे derivatives मिळून एक **बाण** (vector) होतो, आणि त्याचं नाव **gradient**. हा विभागाचा मध्यवर्ती शब्द आहे.

Gradient म्हणजे काय. एका weight चा derivative = त्या एका दिशेतला उतार (3.1). पण अनेक weights म्हणजे अनेक दिशा (थेंबूला 2: आर्द्रता-अक्ष, ढग-अक्ष). प्रत्येक अक्षाचा वेगळा उतार काढा, त्यांची यादी बनवा: **तोच gradient बाण**. आणि त्याचा सुंदर गुणधर्म: **gradient बाण नेहमी सर्वात तीव्र चढाच्या दिशेला दाखवतो**. म्हणजे “इथून सर्वात वेगात वर (loss वाढेल) कुठे?” मग loss कमी करायला? **gradient च्या बरोबर उलट** जा: सर्वात तीव्र उताराची दिशा. याला **gradient descent** (उतार-उतरण) म्हणतात: पूर्ण यंत्र-शिक्षणाचं इंजिन.

धुक्यातल्या डोंगराची पूर्ण उपमा (Book 2, 2.6 आता नेमकी). तुम्ही धुक्यात डोंगरावर, तळ शोधायचाय (कमीत कमी loss). पूर्ण नकाशा दिसत नाही. काय करता? (1) पायाखाली चाचपून बघता: **कुठली दिशा सर्वात तीव्र खाली** (gradient चं उलट). (2) त्या दिशेला **एक पाऊल** (छोटं, कारण धुकं). (3) नव्या जागी पुन्हा चाचपा, पुन्हा पाऊल. हळूहळू तळाकडे. हेच gradient descent: **उतार बघ -> उलट दिशेला पाऊल -> पुन्हा**, हजारो- लाखो वेळा. यंत्र “शिकतं” म्हणजे नक्की हेच करतं: loss-डोंगरावर weights-चेंडू धुक्यात, पावलापावलाने तळाकडे.

थेंबूवर आकड्यांनी (दोन weights). थेंबूचा loss दोन weights w_1 , w_2 वर. एका जागी gradient काढला, म्हणा तो बाण (+4, -2) निघाला. अर्थ: “ w_1 वाढवला तर loss जोरात वाढेल (+4); w_2 वाढवला तर loss घटेल (-2).” loss कमी करायला **उलट** जा: w_1 **कमी** करा, w_2 **वाढवा**, आणि प्रमाणात (4 चा उतार मोठा म्हणून w_1 जास्त हलवा). एक पाऊल:

```
gradient = (+4, -2)    (सर्वात तीव्र चढाची दिशा)
उलट दिशा = (-4, +2)   (सर्वात तीव्र उताराची: इकडे जा)
w1: 5 -> 5 - (थोडं)x4  (कमी करा, जास्त)
w2: 3 -> 3 + (थोडं)x2  (वाढवा, कमी)
```

नवे weights loss किंचित कमी करतात. पुन्हा gradient, पुन्हा पाऊल. हेच शिकणं, फक्त 2 ऐवजी अब्जावधी weights आणि ट्रिलियन पावलं.

आणि इथे GPU का लागतो ते नेमकं दिसतं (Book 2 चा कारखाना): अब्जावधी weights चा gradient एका पावलात काढणं म्हणजे अब्जावधी derivatives, अब्जावधी गुणा-बेरीज (Part 1 चे dot products, matrices). आणि हे ट्रिलियन पावलं. म्हणून हजारो GPU, महिनोन्महिने (Book 4, 1.1 चं training-bill: आता कळलं कशाचं). “training” म्हणजे: प्रचंड gradient descent, धुक्यातल्या अवाढव्य डोंगरावर.

इथे लोक काय चुकीचं समजतात

“Gradient descent यंत्राला ‘सर्वोत्तम उत्तर’ शोधून देतो.” नाही: तो फक्त **जवळचा खोलगट भाग** शोधतो (local minimum), जगातला सर्वात खोल नाही. धुक्यात तुम्ही एका दरीत उतराल, पण शेजारी अजून खोल दरी असू शकते: तुम्हाला दिसत नाही. आश्चर्य हे की अब्जावधी-मितींच्या डोंगरावर हे बहुधा **पुरेसं चांगलं** निघतं (का, ते 3.6 चं गूढ). पण “सर्वोत्तम सापडतं” ही चूक: gradient descent “चांगलं-पुरेसं” शोधतो, “परिपूर्ण” नाही.

नकाशावर

- 3.1 derivative = एका दिशेतला उतार
- 3.2 gradient = सगळ्या weights चे उतार एकत्र (बाण); सर्वात तीव्र चढाची दिशा -> उलट जा (gradient descent); धुक्यात पावलापावलाने तळाकडे = शिकणं

सूत्रावर: gradient हा चष्मा “अब्जावधी weights एकत्र कसे सुधारायचे” या अशक्य वाटणाऱ्या प्रश्नाला एका बाणात आणतो: सर्वात तीव्र उताराची दिशा. जे मोजता येतं (gradient) त्या दिशेने सगळे weights एकदम सुधारतात: हेच शिकण्याचं इंजिन.

स्वतः बघा (5 मिनिटं)

डोळे मिटून, एका उतारावर उभं असल्याची कल्पना करा. पायाखाली जाणवतं: डावा पाय थोडा खाली, उजवा थोडा वर -> म्हणजे उतार डावीकडे-खाली. तुम्ही सहज डावीकडे पाऊल टाकाल (तळाकडे). तुमचा पाय हा gradient-sensor आहे; तुमचं पाऊल gradient descent. यंत्र हेच करतं, फक्त अब्जावधी “पायांनी” (weights) एकाच वेळी.

विचार करा

थेंबूचं यंत्र आता एका थराचं समजलं. पण खरं यंत्र **अनेक थरांचं** (Part 1, 1.4: साखळी). शेवटच्या थरात loss दिसते; पण **पहिल्या** थरातल्या weight ने त्या loss वर किती परिणाम केला हे कसं काढायचं? “पहिला थर -> दुसरा -> ... -> शेवटचा -> loss: इतक्या लांब साखळीत, सुरुवातीच्या एका weight चा शेवटच्या loss वरचा उतार कसा मोजायचा?”

हाच deep learning चा सर्वात हुशार भाग, आणि तो एका साध्या गुणाकार-नियमाने सुटतो: चूक थरामागून थर, मागे वाटत जाणं. त्याचं नाव chain rule / backpropagation: पुढचा chapter, विभागाचा गाभा.

Chapter 3.3 [SPINE]: Chain Rule: चूक मागे वाटणं

थेंबूचा प्रश्न: लांब साखळीत सुरुवातीच्या weight चा शेवटच्या loss वरचा उतार कसा? उत्तर deep learning चा सर्वात हुशार, सर्वात सुंदर भाग आहे: **chain rule** (साखळी-नियम), ज्याला कृतीत **backpropagation** (चूक मागे-वाटणं) म्हणतात.

कल्पना: परिणामांची साखळी. एक साखळी: पाऊस कमी -> धरणात पाणी कमी -> वीज कमी -> कारखाना बंद -> मजूर बेकार. आता प्रश्न: “पाऊस 10% कमी झाला तर मजुरीवर किती परिणाम?” उत्तर: **प्रत्येक दुव्याचा दर गुणा.** पाऊस->पाणी चा दर x पाणी-> वीज चा दर x वीज->कारखाना x कारखाना->मजुरी. दरांचा गुणाकार = टोकापासून टोकाचा परिणाम. **हाच chain rule: साखळीतल्या प्रत्येक पायरीचा दर (derivative) गुणा, म्हणजे सुरुवातीचा शेवटावरचा परिणाम मिळतो.**

यंत्रात: loss मागे वाटणं. थेंबूचं यंत्र: पहिला थर -> दुसरा -> शेवटचा -> loss. पहिल्या थरातल्या weight चा loss वरचा उतार हवाय. Chain rule: **शेवटापासून सुरुवातीकडे, प्रत्येक थराचा दर गुणत मागे या.** म्हणून याला “back-propagation”: loss ची “जबाबदारी” शेवटच्या थरापासून मागे, प्रत्येक थराला त्याच्या वाट्याची, वाटत जाणं. जणू loss म्हणते “ही चूक झाली; प्रत्येक थराचा यात किती हात?": आणि उत्तर मागे-मागे, गुणाकाराने, प्रत्येक weight पर्यंत पोहोचतं.

दोन पावलं (हेच पूर्ण training चं यंत्र):

1. पुढे (forward): माहिती आत -> थर-थर -> अंदाज -> loss.
(थेंबू: हवा -> गुण -> probability -> चूक)
2. मागे (backward): loss -> chain rule ने प्रत्येक थराचा दर गुणत मागे -> प्रत्येक weight चा उतार (gradient).
मग gradient descent ने सगळे weights एक पाऊल सुधार (3.2).

पुढे-मागे, पुढे-मागे: ट्रिलियन वेळा. हेच “यंत्र शिकतं.” **Forward ने अंदाज, backward ने दोष-वाटप, मग सुधारणा.** आणि सौंदर्य: कितीही खोल यंत्र (शंभर थर) असो, chain rule प्रत्येक weight पर्यंत नेमका उतार पोहोचवतो: फक्त दर गुणत मागे या. Deep learning शक्य झालं कारण हा एक साधा गुणाकार-नियम अब्जावधी weights ना एका पावलात सुधारू देतो.

एक सूक्ष्म धोका (कळून घ्या, नाव पुरे): दर गुणत-गुणत मागे जाताना, जर दर सतत **छोटे** ($0.1 \times 0.1 \times 0.1 \dots$) असतील तर गुणाकार जवळजवळ **शून्य** होतो: सुरुवातीच्या थरांपर्यंत उतार पोहोचतच नाही (ते शिकतच नाहीत): याला “vanishing gradient” म्हणतात. उलट दर मोठे तर गुणाकार **स्फोटक** (exploding). खूप-खोल यंत्रं शिकवायला हे मोठे अडथळे होते; आणि transformer ची काही रचना

(residual connections वगैरे) नेमकी हे टाळायला: म्हणजे Book 2 चा transformer अंशतः या गणिती अडचणीवरचा उपाय आहे. (खोलात जायची गरज नाही; एवढं कळलं की papers मधला हा शब्द ओळखीचा होईल.)

इथे लोक काय चुकीचं समजतात

”Backpropagation म्हणजे यंत्र ‘मागे विचार करतं’ किंवा ‘आठवतं’.” नाही: हे विचार-आठवण नाही, **शुद्ध गुणाकार**. loss पासून मागे, प्रत्येक थराचा दर गुणत, प्रत्येक weight चा उतार काढणं: यांत्रिक, भावनाशून्य अंकगणित. “यंत्र स्वतःच्या चुकांतून शिकतं” ही कविता; “loss चा gradient chain rule ने प्रत्येक weight ला वाटला जातो आणि weights एक पाऊल सरकतात” हे गणित. Backprop ला बुद्धी नाही, फक्त गुणाकार आहे.

नकाशावर

3.1 derivative = उतार 3.2 gradient = उतार-बाण, उलट जा
3.3 chain rule/backprop: प्रत्येक थराचा दर गुणत loss मागे
वाटणं; forward (अंदाज) + backward (दोष-वाटप) = शिकणं;
vanishing/exploding = खोलीचा अडथळा

सूत्रावर: chain rule हा चष्मा “खोल यंत्र कसं शिकतं” या गूढाला एका गुणाकार-नियमात आणतो: चूक मागे वाटा, प्रत्येक weight ला त्याचा वाटा. जे मोजता येतं (प्रत्येकाचा दोष) ते सुधारता येतं (प्रत्येकाला एक पाऊल): deep learning चं संपूर्ण रहस्य एका गुणाकारात.

स्वतः बघा (5 मिनिटं)

एक साखळी-हिशेब करा: एका दुकानाचा नफा 10% वाढला, दुकानाचा मालक कंपनीचा 20% भागधारक, कंपनीचा नफा शहराच्या करात 5% योगदान. “दुकान-नफा वाढ शहराच्या करावर किती?”: दर गुणा (0.10 x 0.20 x 0.05 = 0.001, म्हणजे किरकोळ). तुम्ही आत्ता chain rule केलात: साखळीतले दर गुणून टोकाचा परिणाम. यंत्र loss साठी हेच करतं, फक्त लाखो दुव्यांचं.

विचार करा

थेंबूला आता सगळे तुकडे कळले: अंदाज (Part 1), चूक (Part 2), उतार, gradient, backprop. पण थेंबू म्हणतो: “तुकडे कळले, पण मला **एकदा, संपूर्ण, आकड्यांनी** करून बघायचंय: माझी खरी हवा घ्या, अंदाज काढा, चूक मोजा, आणि एक weight प्रत्यक्ष सुधारा: सुरुवातीपासून शेवटपर्यंत, काहीही न

वगळता. तरच ‘यंत्र शिकतं’ हे माझ्या हाडात मुरेल.”

हीच पुढच्या chapter ची विनंती, आणि विभागाचा कळस: थेंबूवर पूर्ण एक शिकवणी-पाऊल, हाताने, खऱ्या आकड्यांनी, एकही पायरी न वगळता. यंत्र-शिक्षण डोळ्यांसमोर घडताना बघू.

Chapter 3.4 [SPINE]: थेंबूला हाताने शिकवू: पूर्ण एक पाऊल

हा पूर्ण पुस्तकातला सर्वात महत्वाचा chapter. इथे आपण थेंबूला **प्रत्यक्ष, हाताने, एका शिकवणी-पावलातून** नेऊ: एकही पायरी न वगळता, खऱ्या आकड्यांनी. हे एकदा डोळ्यांनी घडताना बघितलं की “यंत्र शिकतं” हे वाक्य कायमचं उघडं होईल. कागद-पेन घ्या; सोबत करा.

थेंबूची रचना (सर्वात सोपी). थेंबू एका ओळीचं यंत्र:

$$\text{अंदाज } p = w_1 \times \text{आर्द्रता} + w_2 \times \text{ढग} + b$$

w_1, w_2 = आर्द्रता आणि ढगांना दिलेली महत्त्वं (weights); b = एक स्थिर सरकवण (bias). आजची माहिती: आर्द्रता = 0.8, ढग = 0.6. सुरुवातीचे (कच्चे, न-शिकलेले) weights: $w_1 = 1.0, w_2 = 1.0, b = 0$. खरं घडलं: **पूर्ण पाऊस, म्हणजे लक्ष्य $y = 1$.**

पायरी 1: पुढे (forward): अंदाज काढा.

$$\begin{aligned} p &= 1.0 \times 0.8 + 1.0 \times 0.6 + 0 \\ &= 0.8 + 0.6 \\ &= 1.4 \end{aligned}$$

थेंबूचा अंदाज 1.4. पण खरं लक्ष्य 1. म्हणजे थेंबू **अति-आत्मविश्वासाने** जास्त बोलला (1 हवं होतं, 1.4 दिलं).

पायरी 2: चूक (loss) मोजा. सोप्या $\text{loss} = (\text{अंदाज} - \text{खरं})^2$:

$$\text{loss} = (p - y)^2 = (1.4 - 1)^2 = 0.4^2 = 0.16$$

चूक 0.16. आता ती कमी करायची.

पायरी 3: मागे (backward): प्रत्येक weight चा उतार (chain rule, 3.3). प्रश्न: प्रत्येक weight थोडा बदलला तर loss किती बदलेल?

आधी loss चा अंदाजावरचा दर:

$$dLoss/dp = 2 \times (p - y) = 2 \times (1.4 - 1) = 2 \times 0.4 = 0.8$$

आता अंदाजाचा प्रत्येक weight वरचा दर ($p = w_1 \times 0.8 + w_2 \times 0.6 + b$):

$$dp/dw_1 = \text{आर्द्रता} = 0.8$$

$$dp/dw_2 = \text{ढग} = 0.6$$

$$dp/db = 1$$

chain rule ने गुणा (दर मागे वाटा):

$$w_1 \text{ चा उतार} = 0.8 \times 0.8 = 0.64$$

$$w_2 \text{ चा उतार} = 0.8 \times 0.6 = 0.48$$

$$b \text{ चा उतार} = 0.8 \times 1 = 0.80$$

तिन्ही उतार **धन** (positive): अर्थ “हा weight वाढवला तर loss वाढेल.” म्हणून तिन्ही weights **कमी** करायचे (उलट दिशा: 3.2). आणि लक्षात घ्या: w_1 चा उतार (0.64) w_2 पेक्षा (0.48) मोठा, कारण आर्द्रता (0.8) ढगांपेक्षा (0.6) जास्त होती: **जो input मोठा, त्याचा weight जास्त जबाबदार, म्हणून जास्त सुधारणा**. गणित आपोआप न्याय करतं.

पायरी 4: सुधारा (gradient descent). प्रत्येक weight मधून “पावलाचा-आकार (learning rate) x उतार” वजा करा. पाऊल-आकार 0.1 घेऊ:

$$w_1: 1.0 - 0.1 \times 0.64 = 1.0 - 0.064 = 0.936$$

$$w_2: 1.0 - 0.1 \times 0.48 = 1.0 - 0.048 = 0.952$$

$$b: 0 - 0.1 \times 0.80 = 0 - 0.080 = -0.080$$

पायरी 5: तपासा: चूक कमी झाली का? नव्या weights ने पुन्हा अंदाज:

$$p = 0.936 \times 0.8 + 0.952 \times 0.6 + (-0.08)$$

$$= 0.7488 + 0.5712 - 0.08$$

$$= 1.24$$

$$\text{नवी loss} = (1.24 - 1)^2 = 0.24^2 = 0.0576$$

बघा: चूक 0.16 वरून 0.0576 वर घसरली! एका पावलात. थेंबू 1.4 वरून 1.24 कडे, म्हणजे खऱ्या 1 च्या **जवळ** आला. हे पुन्हा-पुन्हा (पायरी 1-5) केलं तर थेंबू हळूहळू 1 वर स्थिरावेल: **तो शिकला**. आणि हेच, नेमकं हेच, ChatGPT ट्रिलियन वेळा करतं: फक्त 3 weights ऐवजी अब्जावधी, आणि आर्द्रता-ढग ऐवजी शब्दांचे बाण. **तुम्ही आत्ता, हाताने, यंत्र-शिक्षण केलंत.**

इथे लोक काय चुकीचं समजतात

“यंत्र-शिक्षण म्हणजे काहीतरी गूढ, अतिमानवी.” तुम्ही ते आत्ता कागदावर केलंत: गुणा, बेरीज, वजा. पाच पायऱ्या. गूढ काहीच नाही: फक्त अब्जावधी weights आणि ट्रिलियन पावलं, म्हणून GPU आणि महिने (Book 4, 1.1). “यंत्र जादूने शिकतं” ही कविता संपली; “forward-loss-backward-update, पुन्हा” हे अंकगणित उरलं. आणि हीच सर्वात मोठी मुक्ती: **AI मध्ये कुठेही जादू नाही, फक्त आकडे: आणि आकडे तुम्हाला समजतात.**

नकाशावर

3.1-3.3 derivative | gradient | chain rule
 3.4 थेंबू हाताने: forward (अंदाज 1.4) -> loss (0.16) ->
 backward (उतार गुणा) -> update (weights कमी) -> नवी
 loss 0.0576; हेच ChatGPT, फक्त अब्जावधी पट

सूत्रावर: हा chapter पूर्ण सूत्राचं मूर्त रूप आहे: चूक **मोजली** (0.16), उतार **मोजला**, म्हणून **सुधारता आली** (0.0576). जे मोजता येतं ते सुधारता येतं: यंत्र-शिक्षण म्हणजे या एका वाक्याची ट्रिलियन-पट पुनरावृत्ती.

स्वतः बघा (5 मिनिटं)

वरचं पूर्ण उदाहरण स्वतः कागदावर, हाताने, पुन्हा करा: पण वेगळ्या सुरुवातीच्या weights ने (उदा $w_1 = 0.5$, $w_2 = 0.5$, $b = 0$). पाच पायऱ्या चालवा आणि बघा: loss कमी होते का? (होईल.) एकदा हाताने केलंत की “training” हा शब्द तुमच्यासाठी कायमचा अंकगणित होईल, जादू नाही: आणि तीच या पुस्तकाची सर्वात मोठी कमाई.

विचार करा

थेंबू शिकला. पण एक गोष्ट खटकली: “मी पाऊल-आकार 0.1 घेतला. जर 0.01 (खूप छोटं) घेतलं असतं तर? किंवा 2 (खूप मोठं)? हे ‘0.1’ कुठून आलं, आणि ते चुकीचं निवडलं तर काय होतं? आणि धुक्यातल्या डोंगरावर मी ‘खऱ्या’ तळाऐवजी एका छोट्या खड्ड्यात अडकलो तर?”

पाऊल-आकार (learning rate) हा यंत्र-शिक्षणातला सर्वात नाजूक निर्णय आहे: खूप छोटं = कासवगती; खूप मोठं = तळ ओलांडून उडी. आणि खड्ड्यात-अडकणं हे खरं दुखणं. दोन्ही: पुढचा chapter.

Chapter 3.5 [SPINE]: पाऊल-आकार आणि अडकणं

थेंबूचे दोन प्रश्न: पाऊल-आकार 0.1 कुठून, आणि खड्ड्यात अडकलं तर? हे यंत्र-शिक्षणातले सर्वात व्यावहारिक, सर्वात नाजूक मुद्दे आहेत.

पाऊल-आकार (learning rate): सर्वात नाजूक कळ. gradient descent मध्ये उतार-दिशा ठरली (3.2); पण किती मोठं पाऊल टाकायचं ते learning rate ठरवते (थेंबूचा 0.1). धुक्यातल्या डोंगराची उपमा:

खूप छोटं (0.001): चिमुकली पावलं; तळ गाठायला अनंत काळ (कासवगती). training महिने-वर्ष रेंगाळतं, पैसा जळतो.
 खूप मोठं (2.0): अवाढव्य उड्या; तळ ओलांडून पलीकडच्या चढावर, मग परत ओलांडून: उड्या मारत भरकटतं, कधीच स्थिरावत नाही (किंवा loss स्फोटक वाढते).
 योग्य (0.1 आसपास): नीट उतरत, वाजवी वेगात तळाकडे.

आणि गंमत: **योग्य learning rate कामागणिक, यंत्रागणिक वेगळा**; तो शोधायला प्रयोग लागतात (म्हणून तो “hyperparameter”: यंत्र स्वतः शिकत नाही, माणूस/प्रयोग ठरवतो). आधुनिक पद्धती learning rate **चालता-चालता बदलतात** (सुरुवातीला मोठा: वेगात उतरा; शेवटी छोटा: तळाशी नाजूक): याला “schedule” म्हणतात. पण गाभा तोच: **पाऊल खूप छोटं = वाया वेळ; खूप मोठं = भरकटणं; मधलं सोनं.** आयुष्यातही तेच: सुधारणा खूप हळू = कंटाळा; खूप आक्रमक = अस्थिरता.

अडकणं: खऱ्या तळाऐवजी छोटा खड्डा (local minimum). धुक्यात उतरताना तुम्ही एका छोट्या खड्ड्यात याल: सगळीकडे वर दिसतं (उतार शून्य), म्हणून “तळ आला” वाटतं: पण शेजारी अजून खोल दरी असते, दिसत नाही. यंत्रही असंच “पुरेसं-चांगल्या” जागी थांबू शकतं, “सर्वोत्तम” नाही (3.2 चा इशारा). हे टाळायला युक्त्या: (1) **थोडा गोंधळ (randomness)**: प्रत्येक पावलाला पूर्ण data ऐवजी **तुकडा** वापरणं (mini-batch): यामुळे उतारात थोडा “थरथराट” येतो, जो छोट्या खड्ड्यातून बाहेर ढकलतो: गंमत अशी की **थोडा गोंधळ शिकण्याला मदत करतो**. (2) **गती (momentum)**: घरंगळत्या चेंडूला गती असते: तो छोट्या खड्ड्यावरून **पुढे** जातो (जडत्वाने), खऱ्या खोल दरीत जाऊन थांबतो.

आणि इथे आश्चर्याची गोष्ट (पुढच्या chapter चं बीज): अब्जावधी-मितींच्या डोंगरावर, “छोट्या खड्ड्यात अडकणं” ही अपेक्षेपेक्षा **खूप कमी** समस्या ठरते: बहुतेक “सपाट” जागा सगळ्या दिशांनी खड्डे नसतात (काही दिशांनी खाली जाता येतं). का हे नीट कुणालाच माहीत नाही: पण प्रत्यक्षात gradient descent हे “पुरेसं-चांगलं” आश्चर्यकारकपणे विश्वासाने शोधतं. हे “का चालतं” हे गूढ पुढच्या chapter चा विषय.

इथे लोक काय चुकीचं समजतात

”मोठा learning rate = वेगात शिकेल.” उलट अनेकदा: खूप मोठा = तळ ओलांडून भरकटणं, loss वाढणं, training कोसळणं. वेग learning rate वाढवून येत नाही, योग्य learning rate ने येतो. आणि दुसरा गैरसमज: “randomness म्हणजे चूक/गोंधळ, तो टाळावा.” इथे उलट: थोडा नियंत्रित गोंधळ (mini-batch, momentum) यंत्राला छोट्या खड्ड्यांतून सोडवतो: **कधीकधी थोडी अनिश्चितता हीच सुटकेची वाट.** (आयुष्यातही: सगळं-ठरलेलं मार्ग कधी स्थानिक- खड्ड्यात अडकवतो; थोडा प्रयोग बाहेर काढतो.)

नकाशावर

3.1-3.4 derivative | gradient | chain rule | थेंबू हाताने
 3.5 learning rate = पावलाचा आकार (छोटं=कासव, मोठं=भरकटणं, मधलं सोनं; hyperparameter); अडकणं (local minimum) -> थोडा गोंधळ (mini-batch) + गती (momentum) सोडवतात

सूत्रावर: learning rate हा चष्मा दाखवतो की सुधारणेचा वेग हाही एक नाजूक सौदा आहे (Book 5 चा आत्मा इथे!): खूप हळू वाया, खूप वेगात अस्थिर. आणि “मोजून सुधारणं” ला योग्य पाऊल- आकार लागतो: नाहीतर मोजमाप असूनही सुधारणा फसते.

स्वतः बघा (5 मिनिटं)

कुठलीही सवय सुधारण्याचा विचार करा (व्यायाम, अभ्यास). खूप छोटं पाऊल (रोज 1 मिनिट) = प्रगती नगण्य, कंटाळा. खूप मोठं (रोज 5 तास एकदम) = दुसऱ्या दिवशी सोडून देणं (भरकटणं). योग्य पाऊल (रोज 30 मिनिटं, वाढवत) = टिकाऊ प्रगती. Learning rate चं तत्त्व तुमच्या स्वतःच्या सुधारणेलाही लागू: आणि 90-दिवस- roadmap (The Climb) चा वेगही याच तर्काने ठरवा.

विचार करा

थेंबूला सगळं यंत्र कळलं: अंदाज, चूक, उतार, पाऊल. पण एक खोल अस्वस्थता उरली: “हे सगळं चालतं, मी हाताने बघितलं. पण का चालतं? अब्जावधी weights, धुक्यातला अवाढव्य डोंगर, आणि तरी यंत्र काहीतरी उपयोगी शिकतं: नुसतं आकडे जुळवत, कुणी ‘अर्थ’ न शिकवता. हे इतकं साधं गणित इतकं गुंतागुंतीचं वर्तन कसं घडवतं? कुणाला तरी नक्की माहीत असेल ना?”

प्रामाणिक उत्तर तुम्हाला हादरवेल: **नीट कुणालाच माहीत नाही.** जगातले सर्वात मोठे मेंदू अजून “हे का इतकं चांगलं चालतं” यावर भांडतात. आणि तेच न-कळणं हा विभागाचा सर्वात प्रामाणिक, सर्वात मुक्त करणारा धडा आहे. शेवटचा chapter.

Chapter 3.6 [DEPTH]: हे का चालतं: प्रामाणिक गूढ [दोन्ही बाजू]

थेंबूचा प्रश्न: हे साधं गणित इतकं गुंतागुंतीचं वर्तन का घडवतं? आणि उत्तर तुम्हाला हादरवेल आणि मुक्तही करेल: **नीट कुणालाच माहीत नाही**. हा chapter त्या प्रामाणिक गूढाचा, आणि तो पूर्ण पुस्तकातला सर्वात मोकळा श्वास आहे. [DEPTH]: थोडं तत्त्वज्ञान, पण महत्त्वाचं.

गूढ काय आहे. आपण शिकलो: gradient descent धुक्यात पावलापावलाने तळ शोधतं. पण गणिती तर्काने अनेक गोष्टी **चालायला नकोत**:

- अब्जावधी-मितींचा डोंगर म्हणजे अगणित खड्डे: यंत्र एखाद्या वाईट खड्ड्यात अडकायला हवं (3.5). पण अडकत नाही. का?
- यंत्राकडे इतके weights की ते training-data नुसतं **घोकून** (पाठ करून) टाकायला हवं, नव्या गोष्टींवर फसायला हवं (overfitting). पण अनेकदा ते नव्यावरही चांगलं चालतं (generalization). का?
- "मोठं यंत्र = जास्त घोकंपट्टी = वाईट" ही जुनी सांख्यिकी-अपेक्षा; प्रत्यक्षात मोठं यंत्र **जास्त चांगलं** चालतं (Book 4 चे scaling laws). हे जुन्या सिद्धांताच्या **उलट**.

म्हणजे AI **प्रत्यक्षात चालतं**, पण **का इतकं चांगलं चालतं** याचा पूर्ण, समाधानकारक सिद्धांत जगाकडे नाही. Deep learning हे विज्ञानापेक्षा **किमया** (alchemy) जास्त आहे: प्रयोगाने काय चालतं ते माहीत, पण का ते अर्धवट.

दोन बाजू (हा जिवंत वाद):

"सिद्धांत मागे आहे" बाजू: आपल्याकडे भक्कम गणिती स्पष्टीकरण नाही; बरंचसं "हे करून बघितलं, चाललं" (प्रयोग > सिद्धांत). काही संशोधक याला अस्वस्थ होतात: "आपण न-समजलेलं यंत्र जगात सोडतोय."

"अंशतः समजतंय" बाजू: काही तुकडे कळलेत (उच्च-मितीत खड्डे कमी अडकवणारे; थोडा गोंधळ (3.5) मदत करतो; साधेपणाकडे झुकाव). पूर्ण चित्र नाही, पण धुकं विरतंय.

निकाल: AI हे "बांधता येतं पण पूर्ण समजत नाही" या विचित्र जागी आहे: आणि तेच त्याला रोमांचक आणि थोडं भीतीदायक करतं.

हे तुमच्यासाठी मुक्त करणारं का (सर्वात मोठा धडा): जर जगातल्या सर्वात मोठ्या मेंदूंनाही “हे का चालतं” पूर्ण माहीत नसेल, तर तुम्हाला “सगळं समजायलाच हवं” हा दबाव नाही. या क्षेत्रात कुणीच “पूर्ण जाणकार” नाही; सगळे शिकत, प्रयोग करत, आश्चर्य करत पुढे जातायत. म्हणजे तुम्ही “उशिरा आलात, सगळं आधीच माहीत आहे” ही भीती खोटी: सीमारेषेवर सगळेच नवखे आहेत. आणि दुसरा धडा (Book 4 शी पूल): जिथे सिद्धांत अपुरा, तिथे प्रयोग आणि मोजमाप (evals!) हेच सत्याचं साधन: म्हणून जो नीट मोजतो-तपासतो तो, सिद्धांत नसतानाही, पुढे जातो.

आणि सूत्राचं सर्वात खोल रूप: आपण “मोजता येतं ते सुधारता येतं” म्हणालो. Deep learning हे त्याचं टोक आहे: आपल्याला “का” पूर्ण कळत नाही, पण “किती चूक” मोजता येते, म्हणून सुधारता येते. समजून नाही, मोजून प्रगती. हे विचित्र वाटतं, पण मानवजातीने अनेक गोष्टी आधी वापरल्या, मग समजल्या (आग, औषध, वीज). AI तिथेच आहे: वापरात पुढे, समजुतीत मागे. आणि त्या दरीत उभं राहायला भीती नको, नम्रता हवी: तीच खरी वैज्ञानिक वृत्ती.

इथे लोक काय चुकीचं समजतात

“तज्ज्ञांना AI पूर्ण समजतं, फक्त मला नाही.” खोटं, आणि म्हणून घातक (न्यूनगंड देणारं). प्रत्यक्षात frontier वर सगळे अंधारात चाचपडतायत: papers “आम्हाला आश्चर्य वाटलं की...” ने भरलेली असतात. आणि उलट गैरसमज: “समजत नाही म्हणजे सगळं थोटांड.” तेही खोटं: चालतं हे मोजता येतं (benchmarks, प्रत्यक्ष वापर). खरं मधे: चालतं (सिद्ध), पण का पूर्ण नाही (प्रामाणिक). ही नम्र, अचूक भूमिका: आणि तीच तुम्हाला भुलवणाऱ्या दोन्ही टोकांपासून (अति-भक्ती, अति-तुच्छता) वाचवते.

नकाशावर

3.1-3.5 derivative...learning rate

3.6 “का चालतं”: पूर्ण सिद्धांत नाही (किमया > विज्ञान);
सीमेवर सगळे नवखे (मुक्त करणारं); समजून नाही, मोजून
प्रगती; नम्रता = खरी वृत्ती

सूत्रावर: इथे सूत्र त्याच्या सर्वात धाडसी रूपात: पूर्ण न समजताही, मोजता आलं तर सुधारता येतं. Deep learning हे याचा जिवंत पुरावा: आणि म्हणूनच मोजण्याची (evals, गणित) कला समजण्याच्या कलेइतकीच, कधी जास्त, मौल्यवान.

स्वतः बघा (5 मिनिटं)

एखादी गोष्ट आठवा जी तुम्ही **वापरता** पण पूर्ण **समजत** नाही (वीज कशी वाहते, औषध कसं काम करतं, पचन). तरी तुम्ही ती वापरता, आणि “किती चाललं” मोजता (दिवा लागला, ताप उतरला). AI तिथेच आहे. “पूर्ण समजल्याशिवाय वापरू नये” हा दबाव झुगारा: मानवजात नेहमी वापर-आणि-समज यांच्या दरीत जगत आलीये, आणि पुढे गेलीये: मोजत, तपासत, नम्रपणे.

विचार करा

विभाग 3 संपला: उताराचं जग, यंत्र-शिक्षणाचं हृदय, हातात. थेंबूला अंदाज, चूक, उतार, शिकणं, आणि “का चालतं” चं गूढही कळलं. पण एक शेवटचा प्रवास उरला: “मी थेंबूवर सगळं शिकलो: 2 आकडे, 3 weights. पण खरं ChatGPT चं हृदय **attention** आहे (Book 2). ते नक्की या गणितात कसं बसतं? माझे dot products, matrices, softmax: ते सगळं attention मध्ये एकत्र येतं का? मला ते **आकड्यांनी**, पायरी-पायरीने बघायचंय.”

हाच शेवटच्या विभागाचा कळस: थेंबूचं सगळं गणित घेऊन **attention आणि transformer आकड्यांनी, पायरी-पायरीने** उलगडणं. Part 1-2-3 सगळं एकत्र येऊन ChatGPT चं हृदय उघडं होईल. परत AI कडे, Part 4.

BOOK 7, PART 3 चा शेवट

जे तुमच्याकडे आता आहे

derivative	बदलाचा दर ("इथे हललं तर तिथे किती"); पायाखालचा उतार; loss कमी करायला उलट दिशेला जा
gradient	सगळ्या weights चे उतार एकत्र (बाण); सर्वात तीव्र चढ -> उलट जा (gradient descent); धुक्यात पावलापावलाने
chain rule	प्रत्येक थराचा दर गुणत loss मागे वाटणं (backprop); forward (अंदाज) + backward (दोष-वाटप) = शिकणं
थेंबू हाताने	forward 1.4 -> loss 0.16 -> उतार गुणा -> weights कमी -> नवी loss 0.0576; हेच ChatGPT, अब्जावधी पट
learning rate	पावलाचा आकार (छोटं=कासव, मोठं=भरकटणं); अडकणं -> थोडा गोंधळ + गती सोडवतात
का चालतं	पूर्ण सिद्धांत नाही (किमया); सीमेवर सगळे नवखे; समजून नाही, मोजून प्रगती; नम्रता = वृत्ती

स्वतःची परीक्षा (4 प्रश्न, बोलून; उत्तरं खाली)

1. "यंत्र शिकतं" चं पूर्ण गणित पाच पायऱ्यांत?

forward (अंदाज) -> loss (चूक मोजा) -> backward (chain rule ने प्रत्येक weight चा उतार) -> update (उताराच्या उलट, learning rate ने) -> पुन्हा. loss घसरते. (3.4)

2. Gradient बाण काय दाखवतो, आणि आपण काय करतो?

सर्वात तीव्र **चढाची** दिशा; loss कमी करायला त्याच्या **उलट** पाऊल (gradient descent). (3.2)

3. Backpropagation म्हणजे "यंत्र मागे विचार करतं" का?

नाही: शुद्ध गुणाकार: प्रत्येक थराचा दर गुणत loss मागे, प्रत्येक weight ला त्याचा दोष-वाटा. बुद्धी नाही, अंकगणित. (3.3)

4. "AI का चालतं" चं प्रामाणिक उत्तर, आणि त्याचा धडा?

पूर्ण कुणालाच माहीत नाही (किमया > विज्ञान); म्हणून सीमेवर सगळे नवखे (मुक्त करणारं), आणि जिथे सिद्धांत अपुरा तिथे मोजमाप (evals) हेच सत्य. (3.6)

पुढच्या भागाची चाहल

थेंबूचं सगळं गणित (बाण, dot, matrix, probability, softmax, gradient) आता attention मध्ये एकत्र येईल. Part 4: परत AI कडे: attention आकड्यांनी पायरी-पायरी, एक transformer-मजला हाताने, scaling laws चं गणित, आणि एक खरा paper उलगडून वाचणं. ChatGPT चं हृदय, पूर्ण उघडं.

BOOK 7, PART 3 चा MINI-GLOSSARY

backpropagation	chain rule ने loss मागे वाटणं (3.3)
chain rule	साखळीतल्या दरांचा गुणाकार (3.3)
derivative	बदलाचा दर; एका दिशेतला उतार (3.1)
gradient	सगळ्या weights च्या उतारांचा बाण (3.2)
gradient descent	उताराच्या उलट पावलं टाकत तळ शोधणं (3.2)
learning rate	पावलाचा आकार (hyperparameter) (3.5)
local minimum	खरा तळ नसलेला छोटा खड्डा (3.5)
mini-batch	data चा तुकडा वापरून पाऊल; थोडा गोंधळ (3.5)
momentum	घरंगळत्या चेंडूची गती; खड्ड्यातून सोडवते (3.5)
overfitting	training घोकणं, नव्यावर फसणं (3.6)

THE LENS

Book 7, Part 4: परत AI कडे

मागच्या भागाचा शेवट: थेंबूचं सगळं गणित हातात: बाण, dot, matrix (Part 1), probability, softmax, loss (Part 2), gradient, backprop (Part 3). आता ते सगळं एकत्र येऊन ChatGPT चं हृदय उघडेल: **attention** आकड्यांनी पायरी-पायरी, एक transformer- मजला हाताने, scaling laws चं गणित, आणि एक खरा paper उलगडून वाचणं. हा भाग म्हणजे पूर्ण पुस्तकाचा कळस: जिथे थेंबू ChatGPT होतो.

सूत्र (शेवटच्या भागासाठी)

गणित म्हणजे आकडेमोड नव्हे; न दिसणारं दाखवणारा चष्मा.
जे मोजता येतं, ते सुधारता येतं.
Part 4 चा भर: सगळे तुकडे एकत्र = AI चं हृदय, आकड्यांत.

Part 3 ची उजळणी: 3 प्रश्न (बोलून; उत्तरं खाली)

1. “यंत्र शिकतं” चं गणित पाच पायऱ्यांत?

forward -> loss -> backward (chain rule) -> update (उलट उतार, learning rate) -> पुन्हा.
(3.4)

2. Gradient काय दाखवतो?

सर्वात तीव्र चढाची दिशा; loss कमी करायला उलट जा. (3.2)

3. “AI का चालतं” चं प्रामाणिक उत्तर?

पूर्ण कुणालाच माहीत नाही; सीमेवर सगळे नवखे; मोजून प्रगती. (3.6)

या भागात काय

Attention (query-key-value) आकड्यांनी हाताने, softmax-scaling का लागतं, एक पूर्ण transformer-मजला, scaling laws चं log-log गणित, एक खरा AI-paper वाचण्याची कला, आणि अंतिम परीक्षा + सूत्र-पत्र. थेंबूचं गणित ChatGPT होताना बघू.

विभाग 4: परत AI कडे

आता वर्तुळ पूर्ण करू. Book 2 ने attention उपमेने दिलं (बाजार, मागणी-पाटी-माल); या पुस्तकाने त्याखालचं गणित तुकड्यातुकड्याने दिलं. या विभागात ते सगळे तुकडे एकत्र येतील: dot product + softmax + weighted sum = attention, आकड्यांनी. मग transformer, scaling, आणि papers वाचणं. **हे तुमच्या शिक्षणात कुठे येईल:** हा विभाग संपला की तुम्ही Book 2 चं “उपमा-AI” आणि खरं “गणित- AI” यांना जोडाल, आणि सर्वात महत्वाचं: **AI-paper स्वतः उघडून वाचायची भीती कायमची जाईल.** थेंबूपासून सुरू झालेला प्रवास इथे ChatGPT च्या हृदयात पोहोचतो.

Chapter 4.1 [SPINE]: Attention

आकड्यांनी: पायरी-पायरी

हा chapter म्हणजे पूर्ण पुस्तकाचा कळस: **attention, आकड्यांनी, हाताने**. Book 2 ने उपमा दिली (query = मागणी, key = पाटी, value = माल); आता ती उपमा **आकड्यांत** बघू. कागद-पेन घ्या.

रचना: तीन शब्द, प्रत्येकाला तीन बाण. एक छोटं वाक्य: “पाऊस आज पडेल.” attention चं काम: प्रत्येक शब्दाने इतर शब्दांकडे **किती लक्ष द्यायचं** ठरवून, त्यानुसार माहिती मिसळणं. प्रत्येक शब्दाला तीन बाण (हे matrices ने बनतात, Part 1; इथे तयार धरू):

शब्द	query (q)	key (k)	value (v)
पाऊस	-	(1, 0)	(2, 0)
आज	-	(0, 1)	(0, 2)
पडेल	(1, 0)	(0.5, 0.5)	(1, 1)

query = “मला काय शोधायचं”; key = “माझ्याकडे काय आहे”; value = “मी काय माहिती देईन.” आपण **”पडेल” या शब्दाचं attention** काढू: तो इतर शब्दांकडे किती लक्ष देतो?

पायरी 1: जुळणी-गुण (query · प्रत्येक key): dot product (1.2).

$$\begin{aligned}
 \text{पडेल} \cdot \text{पाऊस} &= (1,0) \cdot (1,0) = 1 \times 1 + 0 \times 0 = 1.0 && (\text{जुळतं!}) \\
 \text{पडेल} \cdot \text{आज} &= (1,0) \cdot (0,1) = 1 \times 0 + 0 \times 1 = 0.0 && (\text{जुळत नाही}) \\
 \text{पडेल} \cdot \text{पडेल} &= (1,0) \cdot (0.5,0.5) = 1 \times 0.5 + 0 \times 0.5 = 0.5 && (\text{थोडं})
 \end{aligned}$$

”पडेल” ची मागणी (1,0) “पाऊस” च्या पाटीशी (1,0) सर्वात जुळते. गुण: 1.0, 0.0, 0.5.

पायरी 2: गुणांचं लक्ष-वाटप (softmax, 2.6). हे गुण probability मध्ये (बेरीज 1):

$$\begin{aligned}
 \text{स्फोट: } e^1 &= 2.72, \quad e^0 = 1.0, \quad e^{0.5} = 1.65 \\
 \text{बेरीज: } 2.72 + 1.0 + 1.65 &= 5.37 \\
 \text{लक्ष: पाऊस } 2.72/5.37 &= 0.51, \quad \text{आज } 1.0/5.37 = 0.19, \quad \text{पडेल } 1.65/5.37 = 0.31
 \end{aligned}$$

म्हणजे “पडेल” आपलं **51% लक्ष “पाऊस” कडे**, 19% “आज” कडे, 31% स्वतःकडे देतो. हेच “attention weights”: कुणाकडे किती बघायचं.

पायरी 3: माहिती मिसळण (लक्ष x value यांची बेरीज). आता प्रत्येक शब्दाचा value-बाण त्याच्या लक्ष-वाट्याने घ्या, बेरीज करा:

$$\begin{aligned} \text{output} &= 0.51 \times (2,0) + 0.19 \times (0,2) + 0.31 \times (1,1) \\ &= (1.02, 0) + (0, 0.38) + (0.31, 0.31) \\ &= (1.33, 0.69) \end{aligned}$$

झालं. “पडेल” चा नवा बाण = **(1.33, 0.69)**: मुख्यतः “पाऊस” च्या माहितीने (2,0) रंगलेला, कारण तिकडे सर्वात जास्त लक्ष. **हेच attention**: प्रत्येक शब्दाने इतरांकडे लक्ष-वाटून, त्यांची माहिती स्वतःत मिसळणं. “पडेल” ला आता “पाऊस” चा संदर्भ कळला: वाक्याचा अर्थ त्याच्या बाणात उतरला.

हेच ChatGPT करतं, फक्त: 3 शब्द ऐवजी हजारो, 2-आकड्यांचे बाण ऐवजी शेकडो-आकड्यांचे, आणि एका “लक्ष-नजरे” ऐवजी अनेक समांतर (multi-head: प्रत्येक नजर वेगळं नातं बघते: कोण-कुणाशी व्याकरण, कोण-कुणाशी अर्थ). पण **कृती तीच जी तुम्ही आता केलीत**: dot (जुळणी) -> softmax (लक्ष) -> weighted sum (मिसळण). Book 2 चा “मागणी-पाटी-माल बाजार” आता तीन ओळींचं अंकगणित आहे. Attention चं गूढ संपलं.

इथे लोक काय चुकीचं समजतात

”Attention म्हणजे यंत्र ‘लक्ष देतं’, म्हणजे त्याला जाणीव/समज आहे.” नाही: “लक्ष” हा फक्त softmax-चा वाटप-आकडा आहे (0.51, 0.19, 0.31). यंत्र “बघत” नाही, “जाणत” नाही; ते dot products चे गुण softmax मधून probability करतं आणि values ची भारित बेरीज घेतं. “attention” हे काव्यात्मक नाव आहे, यांत्रिक कृतीला. जाणीव तिथे नाही, फक्त जुळणी-वाटप-मिसळण आहे. (हा भेद Book 2 च्या “यंत्राला समज आहे का” वादाचा गाभा.)

नकाशावर

(दर chapter ला एक ओळ.)

4.1 attention आकड्यांनी: dot (जुळणी-गुण) -> softmax (लक्ष-वाटप) -> weighted sum (value मिसळण); “पडेल” 51% “पाऊस” कडे; हेच ChatGPT, अब्जावधी पट

सूत्रावर: attention हा सर्वात मोठा चष्मा-क्षण: Book 2 चं सर्वात गूढ यंत्र आता तीन ओळींचं अंकगणित. न दिसणारं (यंत्र शब्दांचा संदर्भ कसा जोडतं) पूर्ण आकड्यांत दिसलं. जादू कायमची संपली; समज उरली.

स्वतः बघा (5 मिनिटं)

वरचं attention स्वतः, हाताने करा: पण “पाऊस” या शब्दाचं (त्याचा query असेल समजा (0,1)). कुठल्या शब्दाकडे तो सर्वात जास्त लक्ष देईल? (key (0,1) असलेल्या “आज” कडे.) एकदा हाताने केलंत की attention चा “बाजार” तुमच्या बोटान्त उतरेल: आणि कुठलाही transformer-paper वाचताना हे चित्र डोळ्यांसमोर येईल.

विचार करा

थेंबूने attention काढलं, पण एक बारकावा दिसला: “मी गुण (1.0, 0.0, 0.5) थेट softmax मध्ये टाकले. पण Book 2 आणि papers मध्ये ‘गुणांना आधी भागतात’ असं काहीतरी असतं (scaled dot-product). का भागायचं? गुण जसेच्या तसे का चालत नाहीत?”

सूक्ष्म पण महत्त्वाचा प्रश्न: बाण मोठे (शेकडो आकडे) झाले की dot-गुणही मोठे होतात, आणि मोठे गुण softmax ला **अति-तीव्र** करतात (एकावर सगळं लक्ष, बाकी शून्य: शिकणं बिघडतं). तो का आणि उपाय: पुढचा chapter.

Chapter 4.2 [DEPTH]: Softmax-Scaling का लागत

थेंबूचा प्रश्न: attention मध्ये गुण आधी का भागतात? हा छोटा पण सुंदर मुद्दा आहे, आणि तो “papers मधले विचित्र भागाकार” समजायला किल्ली आहे. [DEPTH]: बारीक, पण एका खऱ्या नमुन्याचं स्पष्टीकरण.

समस्या: मोठे बाण = मोठे गुण = अति-तीव्र softmax. 4.1 मध्ये बाण छोटे (2 आकडे) होते, गुण छोटे (1.0, 0.5). पण खऱ्या यंत्रात बाण शेकडो आकड्यांचे. dot product म्हणजे शेकडो गुणाकारांची बेरीज (1.2): जितके जास्त आकडे, तितकी बेरीज **मोठी** होते. गुण 1-2 ऐवजी 20-50 होतात. आणि मोठे गुण softmax मध्ये घातले तर?

छोटे गुण (1, 0, 0.5): softmax $\rightarrow$ (0.51, 0.19, 0.31): मऊ वाटप
मोठे गुण (10, 0, 5): softmax $\rightarrow$ (0.99, 0.00, 0.01): अति-तीव्र!

मोठे गुण softmax ला **टोकाला** नेतात: जवळजवळ सगळं लक्ष एकावर, बाकीला शून्य (distribution अति-तीव्र, entropy जवळजवळ शून्य: 2.4). हे वाईट का? दोन कारणे: (1) यंत्र फक्त एकाच शब्दाकडे बघतं, बाकीचा संदर्भ गमावतं (मऊ मिसळण हवं). (2) आणि गंभीर: शिकवणीत **gradient जवळजवळ शून्य** होतो (vanishing: 3.3): कारण अति-तीव्र softmax चा उतार सपाट, म्हणून weights हलतच नाहीत, यंत्र शिकत नाही.

उपाय: गुणांना बाणाच्या-आकाराच्या मुळाने भागा. transformer चा नियम: dot-गुणांना **root(d)** ने भागा (d = बाणातल्या आकड्यांची संख्या). बाण 64 आकड्यांचा तर $\text{root}(64) = 8$ ने भागा; 100 आकड्यांचा तर 10 ने. का हे नेमकं? गणिती कारण: बाण मोठे झाले की dot-गुण साधारण $\text{root}(d)$ पटीने वाढतात; म्हणून $\text{root}(d)$ ने भागलं की गुण पुन्हा “वाजवी” आकारात येतात (1-2 च्या आसपास), softmax मऊ राहतो, शिकणं सुरळीत. एका ओळीत: **scaling म्हणजे बाण कितीही मोठे असोत, attention चे गुण वाजवी ठेवणं, म्हणजे softmax मऊ आणि शिकणं जिवंत.**

हे शिकण्याचा खरा फायदा (papers-वाचन): transformer च्या मूळ paper चं नावच “scaled dot-product attention” आहे. आता तुम्हाला “scaled” का ते नेमकं कळलं: तो $\text{root}(d)$ चा भागाकार, आणि तो का लागतो. papers मध्ये असे शेकडो “छोटे तांत्रिक तपशील” असतात जे भीतीदायक दिसतात पण **प्रत्येकामागे असंच एक साधं व्यावहारिक कारण** असतं (“हे न केलं तर हे बिघडतं”). गणिताचा चष्मा तुम्हाला ते कारण शोधायला शिकवतो: आणि मग paper भीतीदायक न राहता “समस्या-उपाय” ची यादी होतं.

इथे लोक काय चुकीचं समजतात

"Paper मधली प्रत्येक सूत्र-सजावट म्हणजे खोल, दुर्बोध गणित." बहुतेकदा उलट: प्रत्येक तपशीलामागे एक साधं, व्यावहारिक "नाहीतर हे बिघडतं" असतं (इथे: नाहीतर softmax तीव्र, शिकणं मरतं). papers अवघड दिसतात कारण संक्षिप्त भाषा आणि प्रतीक; पण आत बहुधा तुम्हाला समजणारी अभियांत्रिकी-कारणं. "हे प्रतीक का आहे" विचारत गेलं की paper उलगडतं. भीती प्रतीकांची असते, कल्पनांची नाही.

नकाशावर

- 4.1 attention आकड्यांनी: dot $\rightarrow$ softmax $\rightarrow$ weighted sum
- 4.2 scaling: मोठे बाण $\rightarrow$ मोठे गुण $\rightarrow$ अति-तीव्र softmax (शिकणं मरतं); उपाय $\sqrt{d}$ ने भागा $\rightarrow$ गुण वाजवी, softmax मऊ; papers चे तपशील = "नाहीतर हे बिघडतं"

सूत्रावर: scaling हा छोटा चष्मा मोठा धडा देतो: AI मधला प्रत्येक तांत्रिक तपशील एका मोजता-येणाऱ्या समस्येचा उपाय आहे. जे बिघडतं ते मोजता आलं (तीव्र softmax, मेलेला gradient), म्हणून उपाय (भागाकार) सापडला: सूत्र papers च्या तळाशीही.

स्वतः बघा (5 मिनिटं)

दोन softmax हाताने: गुण (2, 1, 0) आणि तेच 10-पट (20, 10, 0). पहिल्याचा softmax मऊ (तिन्हीना थोडं); दुसऱ्याचा जवळजवळ (1, 0, 0). बघा: गुण मोठे केले की softmax टोकाला जातो. हेच scaling टाळतं. आकड्यांचा "आकार" softmax च्या मऊपणावर किती परिणाम करतो, ते डोळ्यांनी दिसेल.

विचार करा

थेंबूला attention चा एक "मजला" कळला. पण Book 2 म्हणालं transformer-मजल्यात attention आणि आणखी काही (एकांत- खोली, वाकडी कृती) असतं, आणि असे शेकडो मजले. "एक पूर्ण मजला नक्की काय-काय करतो, आणि तो एका बाणावर पायरी-पायरी कसा चालतो? मला अख्खा मजला, आकड्यांनी, बघायचाय."

हाच पुढचा chapter, आणि थेंबूचा ChatGPT होण्याचा क्षण: एक पूर्ण transformer-मजला, सगळे तुकडे जोडून, एका बाणावर पायरी-पायरी. Part 1-4 चं सगळं एका चित्रात.

Chapter 4.3 [SPINE]: एक Transformer-मजला, पूर्ण

थेंबूचा ChatGPT होण्याचा क्षण. एक पूर्ण transformer-मजला, सगळे तुकडे जोडून, एका बाणावर पायरी-पायरी. Book 2 चा “बाजार + एकांत-खोली” आता आकड्यांच्या प्रवाहात.

मजल्याचे चार अवयव (एका शब्द-बाणावर): एक शब्द-बाण आत येतो; मजला त्याला चार पायऱ्यांतून नेतो, नवा (जास्त-समजलेला) बाण बाहेर.

पायरी 1: ATTENTION (बाजार): शब्द इतर शब्दांकडे लक्ष-वाटून त्यांची माहिती मिसळतो (4.1). “पडेल” $\rightarrow$ (1.33, 0.69), “पाऊस” चा संदर्भ आत आला. आउटपुट: संदर्भ-रंगलेला बाण.

पायरी 2: जोडणी (residual): मूळ बाण + attention-आउटपुट (बेरीज). का? म्हणजे मूळ माहिती हरवत नाही (attention ने फक्त “भर” घातली, मूळ पुसलं नाही); आणि हेच खोल यंत्रात gradient जिवंत ठेवतं (3.3 चा vanishing टाळतो). “जुनं ठेवून नवं जोडा.”

पायरी 3: एकांत-खोली (feed-forward): आता प्रत्येक शब्द एकटा, एका छोट्या 2-थरी यंत्रातून (matrix $\rightarrow$ वाकडी कृती ReLU $\rightarrow$ matrix: Part 1, 1.3-1.4). इथे शब्द बाजारात मिळालेली माहिती “पचवतो”, स्वतःपुरता विचार करतो. + पुन्हा जोडणी.

पायरी 4: ताळमेळ (normalization): बाणातले आकडे खूप मोठे/लहान होऊ नयेत म्हणून त्यांना “वाजवी” पट्ट्यात आणणं (scaling चा भाऊ, 4.2): पुढच्या मजल्याला स्वच्छ बाण मिळो.

आत बाण, बाहेर बाण: **पण बाहेरचा बाण “जास्त समजलेला”** (संदर्भ मिसळलेला + पचवलेला + नीटनेटका). आणि मग तोच बाण **पुढच्या मजल्यात**, तिथे पुन्हा चार पायऱ्या, आणि पुढच्या... GPT मध्ये असे **शेकडो मजले**. प्रत्येक मजला बाणाला थोडं जास्त अर्थ देतो: पहिले मजले व्याकरण-सारखं उथळ, वरचे मजले खोल अर्थ-तर्क. शेवटी शेवटच्या बाणातून पुढच्या token ची probability (softmax, 2.6). हेच ChatGPT चं एक पाऊल, पूर्ण.

थेंबू ते ChatGPT (पूर्ण प्रवास एका दृष्टिक्षेपात):

थेंबू: 2 आकडे -> 3 weights -> 1 अंदाज (एक ओळ)
 मजला: बाण -> attention + जोडणी + एकांत + ताळमेळ -> बाण
 ChatGPT: शब्द -> बाण (embedding) -> शेकडो मजले ->
 शेवटचा बाण -> softmax -> पुढचा token -> पुन्हा

तुकडे तेच जे थेंबूचे: बाण (Part 1), dot-matrix (Part 1), softmax-probability (Part 2), आणि हे सगळं शिकलं gradient descent-backprop ने (Part 3). **कुठेही नवीन जादू नाही; फक्त थेंबूचे तुकडे, अब्जावधी पट, शेकडो मजले उंच.** जो थेंबू समजला तो ChatGPT समजला: फरक आकाराचा, तत्वाचा नाही. हीच पूर्ण पुस्तकाची सर्वात मोठी कमाई: **AI ही थेंबूची मोठी आवृत्ती आहे, वेगळं जग नाही.**

इथे लोक काय चुकीचं समजतात

“शेकडो मजले म्हणजे यंत्र शेकडो पट ‘जास्त हुशार/जागरूक’.” मजले जास्त = जास्त **टप्प्याटप्प्याने अर्थ-शुद्धीकरण**, जागरूकता नाही. प्रत्येक मजला तेच चार यांत्रिक अवयव चालवतो; “समज” कुठल्याही एका मजल्यात नाही, ती अनेक साध्या रूपांतरांच्या साखळीतून **उगवते** (emergence: Book 2, 3.9). “मजला विचार करतो” ही उपमा; “मजला बाणावर चार गणिती कृती करतो” हे सत्य. आणि हेच का इतकं चांगलं चालतं: पूर्ण कुणालाच माहीत नाही (3.6): नम्रता कायम.

नकाशावर

4.1-4.2 attention आकड्यांनी | scaling
 4.3 transformer-मजला: attention (बाजार) + जोडणी (residual) + एकांत (feed-forward) + ताळमेळ (norm); शेकडो मजले;
 थेंबू ते ChatGPT: तेच तुकडे, अब्जावधी पट

सूत्रावर: हा chapter पूर्ण चष्मा-प्रवासाचा कळस: ChatGPT चं हृदय आता थेंबूच्या तुकड्यांचं बनलेलं दिसतं. सर्वात गुंतागुंतीचं यंत्र सर्वात साध्या कृतींची उंच रचना आहे: आणि ती रचना तुम्ही आता वाचू शकता.

स्वतः बघा (5 मिनिटं)

Book 2 चा transformer-chapter (3.8) परत उघडा आणि आता प्रत्येक उपमेखाली गणित बघा: “बाजार” = attention (dot+softmax+ मिसळण), “एकांत-खोली” = feed-forward (matrix+ReLU), “मजले x30-100” = शेकडो अशा रचना. उपमा आणि गणित जोडले जातील: आणि तेच खरं समजणं:

दोन्ही डोळ्यांनी एकच गोष्ट बघणं.

विचार करा

थेंबू ChatGPT झाला. पण एक मोठा प्रश्न उरला: “मजले, आकडे, सगळं कळलं. पण Book 4 म्हणालं ‘मोठं यंत्र = जास्त हुशार’ (scaling laws), आणि ते एका **सरळ रेषेवर** चालतं म्हणे. यंत्र मोठं केलं की हुशारी अंदाजपत्रे वाढते: हे कसं? आणि ‘सरळ रेषा’ म्हणजे नक्की कशाची रेषा?”

Scaling laws हे AI मधलं सर्वात आश्चर्यकारक गणित आहे: आकार वाढवला की चूक **अंदाजपत्रे** घटते, आणि ती एका विशिष्ट आलेखावर सरळ रेषा येते. ते गणित, आणि त्याचा अर्थ: पुढचा chapter.

Chapter 4.4 [SPINE]: Scaling Laws: सरळ रेषेचं गणित

थेंबूचा प्रश्न: यंत्र मोठं केलं की हुशारी अंदाजपत्रे वाढते: हे कसं, आणि “सरळ रेषा” कशाची? Scaling laws हे AI मधलं सर्वात आश्चर्यकारक, आणि व्यावहारिकदृष्ट्या सर्वात महत्वाचं गणित आहे (Book 4 चा अख्खा उद्योग यावर उभा).

निरीक्षण: आकार वाढवा, चूक अंदाजपत्रे घटते. संशोधकांना आढळलं: यंत्र मोठं करा (जास्त weights), data वाढवा, compute वाढवा: आणि loss (चूक, 2.5) **गुळगुळीत, अंदाजपत्रे घटते.** इतकी अंदाजपत्रे की छोट्या यंत्रांवरून **मोठ्या यंत्राची चूक आधीच भाकीत** करता येते (म्हणून labs अब्जावधी खर्चण्याआधी छोट्या प्रयोगांतून “हे मोठं यंत्र किती चांगलं होईल” ठरवतात). हे विलक्षण: गुंतागुंतीचं वर्तन, पण त्याची चूक एका साध्या नियमाने पडते.

”सरळ रेषा” कशाची: log-log आलेख. साध्या आलेखावर (आकार विरुद्ध चूक) रेषा वाकडी येते. पण **दोन्ही अक्ष “log” मध्ये** घेतले (म्हणजे 1, 10, 100, 1000 समान अंतरावर: गुणाकाराचे टप्पे, बेरजेचे नाही) तर ती वाकडी रेषा **सरळ** होते. याचा अर्थ: **आकार 10 पट केला की चूक ठराविक टक्क्याने घटते; पुन्हा 10 पट, पुन्हा तेवढीच टक्केवारी.** हा “power law” (घात-नियम): निसर्गात सर्वत्र (भूकंपांचे आकार, शहरांची लोकसंख्या, संपत्तीचं वाटप). AI ची चूकही याच कुळात: गुणाकाराच्या टप्प्यांत गुळगुळीत घट.

पण इथे कठोर सत्य (आणि आशा): रेषा सरळ, पण **खाली झुकती:** प्रत्येक 10-पट सुधारणा **आधीच्याइतकीच टक्केवारी** देते, म्हणजे **निरपेक्ष सुधारणा घटत जाते** (returns diminish). 100 वरून 1000 (10x) ने जेवढी सुधारणा, 1000 वरून 10000 (पुन्हा 10x, पण 9000 चा प्रचंड खर्च!) ने तेवढीच टक्केवारी: म्हणजे पुढची प्रत्येक सुधारणा **प्रचंड महाग.** म्हणूनच Book 4 (2.7) चा “scaling वळलं”: नुसतं मोठं करत राहणं परवडेनासं झालं, म्हणून खर्च नव्या जागी (post-training, विचार-वेळ) वळला. Scaling मेलं नाही; **घात-नियमाची किंमत असह्य झाली, म्हणून वाट बदलली.**

हे तुमच्यासाठी का महत्वाचं: (1) scaling laws समजले की “पुढचं यंत्र किती चांगलं” या चर्चा तुम्ही आकड्यांनी वाचता, hype ने नाही. (2) “AI अनंत वाढेल” (घात-नियम विसरून) आणि “AI थांबलं” (एका सपाटीकडे बघून) दोन्ही अतिरेक ओळखता: खरं मधे, घातनियमाच्या झुकत्या रेषेवर. (3) आणि सर्वात खोल: **एका साध्या रेषेने अब्जावधींचे निर्णय ठरतात** (labs किती खर्चायचं ठरवतात): गणिताचा चष्मा किती शक्तिशाली, याचं हे टोक.

इथे लोक काय चुकीचं समजतात

"Scaling laws म्हणजे यंत्र मोठं केलं की अनंत हुशार होईल." घात-नियमाची झुकती रेषा हेच नाकारते: सुधारणा घटत जाते, आणि खर्च स्फोटक वाढतो. आणि उलट गैरसमज: "एका सुधारणेचा वेग मंदावला = scaling मेलं." नाही: रेषा अजून सरळ (सुधारणा सुरू), फक्त निरपेक्ष घट लहान आणि खर्च मोठा. दोन्ही टोकं (अनंत-आशा, संपूर्ण-निराशा) घातनियम न समजल्याने येतात. रेषा वाचता आली की दोन्ही भ्रम विरतात.

नकाशावर

4.1-4.3 attention | scaling(softmax) | transformer-मजला
 4.4 scaling laws: आकार 10x -> चूक ठराविक % घट (घात-नियम);
 log-log आलेखावर सरळ-झुकती रेषा; सुधारणा घटती, खर्च
 स्फोटक -> "scaling वळलं"; रेषा वाचा, hype नको

सूत्रावर: scaling laws हा सर्वात भव्य चष्मा: AI च्या भवितव्याचा अंदाज एका सरळ रेषेत मोजता येतो. जे मोजता येतं (चूकीचा कल) त्यावर अब्जावधींचे निर्णय ठरतात: गणित इथे भविष्यवाणीचं साधन होतं.

स्वतः बघा (5 मिनिटं)

एक घात-नियम रोजचा: तुमच्या अभ्यासात/कौशल्यात पहिले 10 तास मोठी झेप देतात; पुढचे 10 कमी; पुढचे 10 अजून कमी (diminishing returns). पण थांबत नाही: प्रत्येक "दुप्पट मेहनत" ठराविक सुधारणा देतच राहते, फक्त लहान. AI ची चूकही असंच वागते. तुमच्या 90-दिवस-प्रवासालाही (The Climb) हेच लागू: सुरुवात झपाट्याने, नंतर संध-पण-सतत.

विचार करा

थेंबू ChatGPT झाला, scaling ही कळलं. आता थेंबूला आत्मविश्वास आला: "मला बाण, dot, matrix, probability, gradient, attention, transformer, scaling: सगळं आकड्यांनी कळलं. आता मला एक खरा AI-paper उघडून वाचायचाय: बघायचंय की खरंच ही भीती संपली का, की फक्त थेंबूपुरतं समजलं. एक खरा paper समोर आला तर मी काय करू?"

हाच शेवटच्या-आधीचा chapter, आणि पूर्ण पुस्तकाची खरी परीक्षा: एक खरा AI-paper कसा उघडायचा, कुठून वाचायचा, कशाला घाबरायचं नाही. papers वाचण्याची कला: पुढचा chapter.

Chapter 4.5 [SPINE]: Paper वाचण्याची कला

पूर्ण पुस्तकाची खरी परीक्षा: एक खरा AI-paper उघडून वाचणं. कारण top 0.00001 ची सीमारेषा नेमकी हीच: papers स्वतः वाचता येणं. आणि हे chapter सांगतं की ती भीती **रचनेची** आहे, बुद्धीची नाही: आणि रचना शिकता येते.

आधी दिलासा: papers तुमच्यासाठीच लिहिलेली नाहीत. AI-papers तज्ज्ञांनी तज्ज्ञांसाठी, संक्षिप्त, प्रतीकांनी भरून लिहिलेली असतात: वाचकाला घाबरवायला नाही, पण **तसाच परिणाम** होतो. म्हणून पहिला नियम: **paper “समजलं नाही” म्हणजे तुम्ही कमी नाही; paper दुर्बोध भाषेत आहे.** आणि दुसरा: **पहिल्यांदा 100% समजायचं नसतंच**; अनुभवी संशोधकही paper 3-4 वेळा, वाढत्या खोलीने वाचतात.

वाचनाचा क्रम (छापून ठेवा): बाहेरून आत. paper पहिल्या ओळीपासून शेवटपर्यंत वाचू नका (तिथेच लोक बुडतात). ऐवजी थरांनी:

- थर 1 (5 मिनिटं): फक्त शीर्षक + सारांश (abstract) + निष्कर्ष (conclusion) + आकृत्यांचे कॅप्शन. प्रश्न: "हे कुठलं दुखणं सोडवतात, आणि निकाल काय?" (Book 1-4 चं जुनं सूत्र!)
- थर 2 (15 मिनिटं): प्रस्तावना (intro) + प्रत्येक विभागाचं पहिलं वाक्य. प्रश्न: "त्यांची मुख्य कल्पना काय, आधीच्यापेक्षा वेगळं काय?"
- थर 3 (खोल, गरज असेल तर): पद्धत (method) + आकडे नीट. इथे गणित येतं: आणि आता तुमच्याकडे चष्मा आहे: dot, softmax, gradient, attention: बहुतेक प्रतीक ओळखीची.

बहुतेक papers साठी थर 1-2 पुरतात ("हे काय, का, किती चांगलं"). थर 3 फक्त जे तुम्ही खरंच वापरणार/खोदणार त्यासाठी. **90% मूल्य पहिल्या 20 मिनिटांत**; उरलेलं 10% साठी तास.

प्रतीकांना घाबरू नका (सर्वात मोठा अडथळा). paper मधली भीतीदायक सूत्रं बहुधा तुम्हाला **आता माहीत असलेल्या** गोष्टीच: " $\text{softmax}(\text{QK}^T / \text{root}(d)) V$ " हे भयंकर दिसतं, पण तुम्ही ते आता वाचू शकता: Q,K,V = query-key-value बाण (4.1); QK^T = query-key चे dot products (जुळणी-गुण); $/\text{root}(d)$ = scaling (4.2); softmax = लक्ष-वाटप (2.6); V = values ची भारित बेरीज. **अख्खं attention एका ओळीत, आणि प्रत्येक तुकडा तुम्हाला माहीत.** हीच पूर्ण पुस्तकाची कमाई: प्रतीक बघून घाबरण्याऐवजी "हा कुठला ओळखीचा तुकडा" विचारणं. एक अनोळखी प्रतीक आलं तर थांबा, शोधा, तो एक तुकडा समजून घ्या: paper तुकड्यांचं बनलेलं आहे, अभेद्य भिंत नाही.

आणि सर्वात मोठा गुपित (Book 4 शी पूल): AI आता paper वाचायला मदत करतं. अडलेलं प्रतीक/परिच्छेद AI ला विचारा “हे सोप्या भाषेत समजाव”: पण **आंधळेपणाने नाही:** तुमच्या चष्म्याने त्याचं उत्तर **तपासा** (Book 4 चं evals-भान). AI + तुमचा गणिती पाया = papers ची भीती कायमची संपते. जो हे जोडतो (पाया + AI-मदत + तपासणी) तो कुठलंही नवं संशोधन, आठवड्याच्या आत, वाचू-समजू शकतो: आणि तेच top 0.00001 चं खरं रहस्य: **नवं ज्ञान स्वतः पचवण्याची यंत्रणा.**

इथे लोक काय चुकीचं समजतात

“Papers फक्त PhD-वाल्यांसाठी; मी वाचूच शकत नाही.” खोटं, आणि आत्म-पराभवी. papers दुर्बोध भाषेत आहेत, दुर्बोध **कल्पनांचं** नाहीत (बहुतेकदा): आणि भाषेचा अडथळा थर-वाचन + चष्मा + AI-मदत ने ओलांडता येतो. आणि उलट: “मी एक paper वाचलं, सगळं समजलं, आता मी तज्ज्ञ.” एक paper = एक तुकडा; खरी समज अनेक papers, प्रयोग, वेळ यांतून. नम्रता दोन्ही बाजूंनी: “वाचू शकतो” (आत्मविश्वास) आणि “सगळं कळलं नाही” (प्रामाणिकपणा): दोन्ही एकत्र.

नकाशावर

4.1-4.4 attention | scaling | transformer | scaling laws
 4.5 paper वाचन: बाहेरून-आत (abstract->intro->method); 90%
 मूल्य 20 मिनिटांत; प्रतीक = ओळखीचे तुकडे; AI-मदत +
 तपासणी = भीती संपली; हेच top-thinker चं रहस्य

सूत्रावर: paper-वाचन हा सर्वात व्यावहारिक चष्मा-क्षण: गणित शिकण्याचा खरा फायदा नवं बांधणं नाही, **जगातलं नवं ज्ञान स्वतः वाचता येणं.** आणि जे स्वतः वाचता-तपासता येतं, त्यावर कुणाच्या “सांगण्यावर” विसंबावं लागत नाही: तीच खरी बौद्धिक स्वातंत्र्य.

स्वतः बघा (5 मिनिटं)

“Attention Is All You Need” (transformer चा मूळ paper, 2017: जगातलं सर्वाधिक-cited AI-paper) चा फक्त abstract शोधून वाचा (एक परिच्छेद). बघा: किती शब्द तुम्हाला आता ओळखीचे (attention, encoder, translation)? दोन वर्षांपूर्वी ते चिनी वाटलं असतं; आता अर्थ वाचता येतं. हीच प्रगती: आणि थर-1 वाचन इतकंच.

विचार करा

पूर्ण पुस्तक संपत आलय. थेंबू ChatGPT झाला, आणि थेंबूचा मालक (तुम्ही) papers वाचू शकतो. शेवटचा प्रश्न, जो सगळं एका परीक्षेत बांधेल: “मी हे सगळं शिकलो: दिशा, शक्यता, उतार, attention. पण हे खरंच **मुरलं** का, की वाचून गेलं? आणि याचा मला **खरा** उपयोग काय: नुसतं ‘समजलं’ चं समाधान, की काहीतरी जास्त?”

तेच अंतिम परीक्षा ठरवेल: आणि उत्तर तुम्हाला माहीत आहे, फक्त शब्दांत यायचंय. गणिताचा चष्मा तुम्हाला “समजणाऱ्यां” कडून “तपासणाऱ्यां” कडे, आणि “ऐकणाऱ्यां” कडून “वाचणाऱ्यां” कडे नेतो: आणि तिथेच खरं leverage आहे. अंतिम परीक्षा, पुढे.

Chapter 4.6 [SPINE]: अंतिम परीक्षा

नियम आधीसारखेच: पुस्तक न उघडता, **बोलून** उत्तर द्या; गाभा खाली. हेतू गुण नाही: **गणिताचा चष्मा मुरला का** हे बघणं.

भाग अ: गणित मुरलं का (5 प्रश्न)

1. “यंत्राला शब्दाचा अर्थ कसा कळतो” चं पूर्ण गणिती उत्तर?

अर्थ = दिशा; शब्दाला आकड्यांचा बाण (embedding); जवळच्या दिशा = जवळचे अर्थ; जवळीक = dot product ने मोजतात. (1.1, 1.2, 1.5)

2. “यंत्र शिकतं” पाच पायऱ्यांत, आणि “चूक” नक्की काय?

forward (अंदाज) -> loss (cross-entropy: खऱ्याला दिलेली probability) -> backward (chain rule ने प्रत्येक weight चा उतार) -> update (उलट उतार, learning rate) -> पुन्हा. (2.5, 3.3, 3.4)

3. Attention तीन कृतींत?

dot (query-key जुळणी-गुण) -> softmax (लक्ष-वाटप) -> weighted sum (values ची भारित मिसळण). (4.1)

4. “AI मोठं केलं की हुशार” चं गणित, आणि दोन्ही टोकांचे भ्रम?

scaling laws: आकार 10x -> चूक ठराविक % घट (घात-नियम, log-log सरळ-झुकती रेषा); सुधारणा घटती + खर्च स्फोटक. भ्रम: “अनंत वाढ” आणि “पूर्ण थांबलं” दोन्ही रेषा न वाचल्याने. (4.4)

5. “AI का चालतं” चं प्रामाणिक उत्तर?

पूर्ण कुणालाच माहीत नाही (किमया > विज्ञान); सीमेवर सगळे नवखे; समजून नाही, मोजून प्रगती. (3.6)

भाग ब: थेंबू ते ChatGPT, आणि leverage (5 प्रश्न)

6. softmax मध्ये गुण आधी का भागतात (scaling)?

मोठे बाण -> मोठे dot-गुण -> अति-तीव्र softmax -> gradient मरतो, शिकणं थांबतं; root(d) ने भागून गुण वाजवी, softmax मऊ. (4.2)

7. transformer-मजल्याचे चार अवयव?

attention (बाजार: संदर्भ मिसळणं) + जोडणी (residual: जुनं ठेवून नवं) + एकांत (feed-forward: पचवणं) + ताळमेळ (norm). शेकडो मजले. (4.3)

8. थेंबू आणि ChatGPT यांत तत्वाचा फरक आहे का?

नाही: तेच तुकडे (बाण, dot, matrix, softmax, gradient), फक्त 3 weights ऐवजी अब्जावधी, शेकडो मजले उंच. फरक आकाराचा, तत्वाचा नाही. (4.3)

9. भीतीदायक सूत्र (उदा $\text{softmax}(QK^T/\text{root}(d))V$) समोर आलं तर?

तुकड्यांत फोडा: Q,K,V=बाण, QK^T =dot-जुळणी, $/\text{root}(d)$ =scaling, softmax=लक्ष, V=भारित बेरीज = attention. प्रत्येक तुकडा ओळखीचा; प्रतीकाला घाबरू नका, तुकडा शोधा. (4.5)

10. गणित शिकण्याचा खरा उपयोग काय (नुसतं “समजलं” पलीकडे)?

papers/दावे स्वतः वाचता-तपासता येणं: कुणाच्या सांगण्यावर विसंबावं लागत नाही. “समजणाऱ्या” कडून “तपासणाऱ्या” कडे, “ऐकणाऱ्या” कडून “वाचणाऱ्या” कडे: तेच leverage (Book 4, 9.2). (4.5, 1.6)

आणि आता खरी अंतिम परीक्षा: वरचे दहा नाही, खालचा एक, ज्याचं उत्तर पुस्तकात नाही, फक्त तुमच्याकडे आहे.

पुस्तकाच्या सुरुवातीला (front matter) एक भीती होती: “गणित म्हणजे सूत्र-घोकंपट्टी, माझ्या आवाक्याबाहेर.” आता, थेंबूला हाताने शिकवल्यावर, attention आकड्यांनी काढल्यावर, तो कागद पुन्हा बघा. भीती कुठे गेली? बहुधा तिची जागा एका शांत आत्मविश्वासाने घेतली:

”AI मध्ये कुठेही जादू नाही. फक्त आकडे: बाण, गुणाकार, बेरीज, उतार. आणि आकडे मला समजतात. म्हणून AI मला समजतं: उपमेने नाही, गणिताने. आणि जे मला गणिताने समजतं, त्यावर मी कुणाच्या ‘सांगण्यावर’ विसंबत नाही: मी स्वतः तपासतो. हीच माझी उरलेली, न-नकलता-येणारी ताकद.”

थेंबूपासून ChatGPT पर्यंतचा प्रवास हेच शिकवतो: सर्वात गुंतागुंतीचं यंत्रही सर्वात साध्या कृतींची उंच रचना आहे, आणि त्या साध्या कृती तुम्हाला येतात. जादू संपली; चष्मा उरला.

शेवटचं “स्वतः बघा” (आयुष्यभराचं)

आजपासून, कुठलंही AI-सूत्र, कुठलाही “यंत्र हे करतं” चा दावा, कुठलाही paper: तीन प्रश्न विचारा: ”याखालचं गणित कुठलं, आणि ते मला माहीत असलेल्या तुकड्यांचं बनलंय का?” (Part 1-3), ”हा दावा किती वेळा, किती स्वच्छ चालतो: मोजलंय का?” (1.6), आणि ”हे मी स्वतः वाचून-तपासू शकतो, की फक्त ऐकतोय?” (4.5). हे तीन प्रश्न तुम्हाला AI-गर्दीतल्या कवितेतून आणि विक्रीतून कायमचे वेगळे काढतील: कारण तुमच्याकडे चष्मा आहे, आणि चष्मा असलेला माणूस भुलत नाही: तो बघतो.

सूत्र-पत्र: सगळं गणित एका पानावर (भिंतीवर लावा)

(थेंबूचा ChatGPT होण्याचा पूर्ण नकाशा, एका पानात.)

दिशांचं जग (Part 1):

vector	आकड्यांची यादी = दिशा (बाण); अर्थ = दिशा
dot product	जोडीने गुणा + बेरीज = जवळीकीचं माप सारखे->मोठा, लंब->शून्य, उलटे->उणे
matrix	रूपांतर-यंत्र (अनेक dot); बाण आत, फिरवलेला बाण बाहेर weights = matrix-आकडे
साखळी+खोली	रूपांतर + वाकडी कृती (ReLU), वारंवार = खोली
उच्च मिति	जागा स्फोटक (अर्थ मावतात); डोळे फसतात, गणित खरं

शक्यतांचं जग (Part 2):

probability	विश्वासाचं माप (0-1); बेरीज=1; खात्री-बरोबर वेगळे
distribution	शक्यतांचा आकार; तीव्र=खात्री, सपाट=गोंधळ
Bayes	नवं मत = जुनं मत + पुरावा; दुर्मिळतेचा विसर = चूक
entropy	आश्चर्याचं माप; शिकणं = आश्चर्य कमी करणं
cross-entropy loss	= खऱ्याला दिलेल्या खात्रीची शिक्षा
softmax+temp	गुण -> probability (स्फोट+भागा); temp = धीटपणा-कळ

उताराचं जग (Part 3):

derivative	बदलाचा दर; पायाखालचा उतार
gradient	सगळ्या weights चे उतार (बाण); उलट जा = शिकणं
chain rule	दर गुणत loss मागे वाटणं (backprop)
थेंबू-पाऊल	forward(अंदाज) -> loss -> backward(उतार) -> update(उलट, learning rate) -> पुन्हा
का चालतं	पूर्ण कुणालाच माहीत नाही; मोजून प्रगती

परत AI कडे (Part 4):

attention dot(जुळणी) -> softmax(लक्ष) -> weighted sum(मिसळण)
 scaling root(d) ने भागा: softmax मऊ, शिकणं जिवंत
 transformer attention + जोडणी + एकांत + ताळमेळ; शेकडो मजले
 scaling laws आकार 10x -> चूक % घट (घात-नियम, log-log रेषा)
 paper-वाचन बाहेरून-आत; प्रतीक = ओळखीचे तुकडे; AI-मदत+तपास

थेंबू ते ChatGPT (एका ओळीत):

शब्द -> बाण(embedding) -> [attention+एकांत] x शेकडो मजले
 -> शेवटचा बाण -> softmax -> पुढचा token -> पुन्हा
 शिकलं: gradient descent + backprop, ट्रिलियन पावलं.
 तेच थेंबूचे तुकडे, अब्जावधी पट. जादू नाही, आकडे.

तीन आयुष्यभराचे प्रश्न:

1. याखालचं गणित कुठलं, माझ्या तुकड्यांचं बनलंय का? (Part 1-3)
2. हा दावा किती वेळा, किती स्वच्छ चालतो: मोजलंय का? (1.6)
3. हे मी स्वतः वाचून-तपासू शकतो, की फक्त ऐकतोय? (4.5)

सूत्र: गणित म्हणजे न दिसणारं दाखवणारा चष्मा.
 जे मोजता येतं ते सुधारता येतं; ते तपासताही येतं.

पुस्तक संपलं. थेंबू ChatGPT झाला, आणि तुमच्या हातात चष्मा आला. आता कुठलंही AI-यंत्र बघाल तेव्हा जादू दिसणार नाही: बाण, गुणाकार, उतार दिसतील. आणि जादू न दिसणारा माणूस भुलत नाही: तो बांधतो, तपासतो, आणि पुढे जातो.

Book 6 (Computer च्या आत) या मालिकेचा पाया पूर्ण करेल: यंत्र **कसं मोजतं-वेगवान होतं** याचं गणित. पण तो वेगळा चष्मा; हा इथे संपतो. सुरू करा.