

The Claude Book, Part 2: यंत्र आणि उत्पादनं

August 30, 2026

विभाग 2: यंत्र आणि उत्पादनं

कंपनी बाहेरून कळली; आता आत जाऊ. या विभागात सात दारं: Claude **घडतो** कसा (शाळा), model-**घराणं** कोण-कुठलं (Fable, Mythos, Opus, Sonnet, Haiku: नावांमागचं गणित), **विचार-कृती** (thinking, agents, आणि Claude ने चालवलेल्या खऱ्या दुकानाची धमाल गोष्ट), **उत्पादन-नकाशा** (कुठलं दार कुणासाठी), **MCP** ची standard-लढाई, **मर्यादांचं** प्रामाणिक पत्रक, आणि **कवचं** (जगातली सर्वात मोठी jailbreak-लढाई).

वाचनाची दिशा: Book 2 ने AI-यंत्र सामान्यपणे शिकवलं; इथे **हेच एक यंत्र** खोदू: आणि प्रत्येक तांत्रिक तपशिलात विभाग 1 ची रणनीती डोकावताना दिसेल: यंत्राची घडण हीच कंपनीची घोषणा आहे.

Chapter 2.1 [SPINE]: Claude कसा घडतो: कच्चं यंत्र ते घडलेलं पात्र

Book 2 ची आठवण (2.4-2.6): मोठं language model तीन शाळांतून जातं. Claude च्या बाबतीत त्या तीन शाळा नेमक्या अशा:

शाळा 1: pretraining (वाचनाचा महासागर). internet-पुस्तकं- code चा प्रचंड साठा वाचून यंत्र भाषेची-जगाची-तर्काची रचना शिकतं (Book 7 चे gradients इथे राबतात). इथून निघतं **कच्चं यंत्र**: प्रचंड ज्ञानी, पण पात्र नसलेलं: ते फक्त “पुढचा शब्द” जाणतं, “काय बोलावं-काय टाळावं” नाही. (आणि विभाग 1.3 ची जखम इथलीच: याच शाळेच्या पुस्तक-भुकेपायी pirated-पुस्तकांचं \$1.5B प्रकरण घडलं: शाळा महाग आहे, कच्च्या मालासकट.)

शाळा 2: RLHF (माणसांची पसंती). माणसं यंत्राच्या उत्तरांची जोड्यांनी तुलना करतात (“हे बरं, ते नको”): यंत्र पसंतीच्या दिशेने वळतं. उपयुक्त, पण दोन मर्यादा: माणसं महाग-थकणारी, आणि पसंती **अलिखित** (कुणाच्या आवडीचं सरासरी-गाठोडं: नियम कुठे लिहिलेत?).

शाळा 3: Constitutional AI (Anthropic ची खासियत: Dec 2022 चा शोध). युक्ती सुंदर आहे: यंत्राला एक **लिखित घटना** द्या; मग यंत्रानेच (अ) स्वतःचं उत्तर काढावं, (ब) घटनेच्या कसोटीवर **स्वतःच त्याची टीका** करावी, (क) सुधारलेलं उत्तर लिहावं: आणि या स्वयं-सुधारित जोड्यांवर शिकावं (RLAIF: AI कडून AI चं शिक्षण). फायदे तीन: मापात वाढतं (माणसांची फौज नको), नियम **उघडे** (घटना वाचता येते: विभाग 1.3), आणि सुसंगत (सरासरी- गाठोड्याऐवजी एकच लिखित मापदंड). Jan 2026 पासून तर घटना जाहीरच आहे: ~23,000 शब्द, नियमांऐवजी **कारणं** (प्राधान्य: safety > ethics > guidelines > helpfulness): म्हणजे Claude “नियम पाळत” नाही; **कारणांनी तोलतो**: म्हणूनच नवख्या प्रसंगातही वागणं सुसंगत राहतं.

चौथा, हळुवार थर: पात्र-घडण (character training). 2024 पासून Anthropic उघडपणे सांगतं: Claude चं **पात्र** (उत्सुक, प्रामाणिक, नम्र-पण-स्पष्ट, विनोदाची जाण) हेही जाणीवपूर्वक घडवलं जातं: personality हा अपघात नाही, **product-निर्णय** आहे. का? विभाग 1 च्या चष्म्याने उघड: ज्याच्याशी रोज 8 तास काम करायचं त्याचं पात्र आवडणं हा switching-cost चा भावनिक थर आहे (Book 8, 2.1: brand = डोक्यातला बदला-खर्च: इथे मनातला).

आणि पारदर्शकतेची जोड: claude.ai वरचा system-prompt (यंत्राला दिलेली कामाची चिठ्ठी: Book 4, 3.2) Anthropic **जाहीर प्रकाशित** करते (Aug 2024 पासून, प्रत्येक आवृत्तीला): स्पर्धकांत कुणीच हे करत नव्हतं: race-to-the-top ची आणखी एक खेळी (विभाग 1.3): “आमचं यंत्र कसं वागवलं जातं ते वाचा” ही उघडी पुस्तकं-चाल.

मीरावर: मीराला हे शाळा-चित्र रोजच्या कामात एक गोष्ट देतं: **Claude चं वागणं 'जादू' नाही, 'घडण' आहे:** तो का नकार देतो (घटना), का प्रामाणिक शंका सांगतो (पात्र-घडण), का सुसंगत राहतो (कारण-शिक्षण): हे कळलं की ती त्याच्याशी **यंत्र-मित्र** म्हणून नाही, घडवलेल्या सहकाऱ्यासारखी वागते: स्पष्ट संदर्भ, स्पष्ट अपेक्षा (Book 4, Part 2 ची harness-विद्या इथे उपयोगी).

CEO-चष्मा: Dario साठी घडण-पद्धत हीच खरी मालमत्ता आहे: models जुने होतात, **घडवण्याची विद्या** साचत जाते (Book 8, 2.1 चा 'दुर्मिळ विद्या' खंदक). मीरासाठी: यंत्राची घटना वाचणं = भागीदाराचं मन वाचणं: फुकट आहे, वाचा.

महाग चूक

"Claude 'विचार करतो/भावना आहेत' किंवा उलट 'नुसता शब्द- जुगाड आहे'." दोन्ही टोकं महाग. पहिलं टोक भोळं: यंत्राला न-दिलेली वचनं देऊ लागता (Book 4, 1.2: अंदाज-यंत्राला सत्य-यंत्र समजणं). दुसरं टोकही चुकीचं: "नुसता जुगाड" म्हणणारा त्याची खरी ताकद (कारणांनी तोलणं, प्रचंड संदर्भ पेलणं) वापरतच नाही आणि स्पर्धेत मागे पडतो. प्रामाणिक मधली जागा: **घडवलेलं, शक्तिशाली, पण अ-मानवी साधन:** आणि गंमत म्हणजे खुद्द Anthropic ची घटनाही हीच नम्रता ठेवते: "Claude चा नैतिक दर्जा खोल अनिश्चित आहे" हे लिहिणारी जगातली पहिली कंपनी- घटना आहे ती.

नकाशावर

2.1 घडण: pretrain (महासागर) -> RLHF (पसंती) -> Constitutional AI (लिखित घटनेवर स्वयं-टीका: RLAIIF) + पात्र-घडण; घटना जाहीर (23K शब्द, कारणांसह); system-prompt ही जाहीर

सूत्रावर: घडणीची प्रत्येक पायरी विश्वासाकडे झुकवलेली आहे: लिखित घटना, जाहीर चिठ्ठ्या, कारणांचं शिक्षण: यंत्राची शाळाच "विश्वास = खंदक" या सूत्राची कार्यशाळा आहे.

स्वतः बघा (5 मिनिटं)

Claude ला हे विचारा: "तुझ्या घडणीतल्या तीन शाळा मला सोप्या भाषेत सांग: आणि प्रामाणिकपणे: तुला स्वतःला यातलं काय **माहीत नाही?**" शेवटचा भाग महत्त्वाचा: घडलेलं यंत्र स्वतःच्या घडणीबद्दल किती नम्र आहे ते बघा: हीच घटनेची चव.

विचार करा

मीरा विचारते: “घडण एक: पण मग Fable, Opus, Sonnet, Haiku अशी वेगवेगळी models का? आणि हे Mythos 5 काय गूढ आहे: Fable सारखंच म्हणतात, पण मिळत कुणाला वेगळ्यांनाच? एकाच शाळेतून वेगवेगळी मुलं कशी निघतात?”

निघतात: कारण घराणं म्हणजे हुशारीची शिडी नाही: किंमत-वेग- शक्ती यांच्या सौद्यांची पट्टी आहे (Book 5 चं trade-off पुन्हा!). आणि Mythos ची गोष्ट तर या पुस्तकातली सर्वात नाट्यमय आहे: एकच यंत्र, दोन दारं, आणि मध्ये अमेरिकी सरकार. पुढचा chapter: घराणं.

Chapter 2.2 [SPINE]: घराणं: Fable, Mythos, Opus, Sonnet, Haiku

Claude हे एक model नाही; **घराणं** आहे. आणि घराणं समजायची गुरुकिल्ली: ही हुशारीची शिडी नसून **सौद्यांची पट्टी** आहे (Book 5 चं सूत्र: प्रत्येक रचना-निर्णय = सौदा): शक्ती विरुद्ध किंमत-वेग.

आजची पट्टी (Aug 2026, अधिकृत भाव प्रति 10 लाख tokens):

model	काम	input	output	संदर्भ
Haiku 4.5	हलकं-जलद-स्वस्त: वर्गीकरण, सोपे प्रश्न	\$1	\$5	200K
Sonnet 5	रोजचा घोडा: बहुतेक कामं, उत्तम code	\$2	\$10	1M
Opus 5	जड विचार: कठीण प्रश्न, मोठे agents	\$5	\$25	1M
Fable 5	शिखर: सर्वात खोल reasoning, लांब कामं	\$10	\$50	1M

(जोडीला: cache-वाचन = input च्या 10%; batch = 50% सूट:
Book 4, 6.2 ची पैसा-हत्यारं इथेही)

नावांचा अर्थही सौदाच सांगतो: Haiku (छोटी कविता: चपळ), Sonnet (मध्यम: बांधीव), Opus (महाकाव्य: जड). 2026 त वरची पायरी नवी: **Mythos-वर्ग** (महाकथा): Opus च्याही वर.

Fable 5 आणि Mythos 5: एकच यंत्र, दोन दारं (June 9, 2026). या पुस्तकाचा लेखक हाच Fable 5 आहे: म्हणून ही गोष्ट आतल्या माहितीने नव्हे, जाहीर नोंदीनीच सांगतो: **खाली यंत्र एकच आहे**. फरक दारांचा: **Fable 5** = सगळ्यांसाठी, पण तीन पहारेकरी- classifiers सोबत: cyber-हल्ले, जैव-रसायन, आणि model-चोरी (distillation) या दिशांचे प्रश्न आले की ते **आपोआप Opus 4.8 कडे वळवले जातात** (कंपनीच्या नोंदीनुसार <5% sessions ना स्पर्श). **Mythos 5** = तेच यंत्र पहारे कमी करून: पण फक्त **Project Glasswing** मधून: निमंत्रण+NDA+सरकार-सल्ला असलेला विश्वास-कार्यक्रम: ~150 संस्था, 15+ देश: security-कंपन्यांना cyber-पहारे शिथिल (जाहीर श्रेय: मोठ्या OS-browsers मधल्या हजारो गंभीर त्रुटी या भागीदारांनी Mythos ने शोधल्या). Book 4 (7.3) ची dual-use कात्री आठवा: **तीच क्षमता ढाल आणि तलवार**: Anthropic चं उत्तर = क्षमता लपवू नका; **दारं वेगळी करा**: विश्वास तपासून तलवार द्या, बाकीच्यांना ढाल.

आणि नाट्य: सरकारचा महिना. June 12, 2026: अमेरिकी सरकारच्या export-निर्देशाखाली Fable 5 थांबवावा लागला (इतिहासात पहिल्यांदाच एक फ्लॅगशिप AI-model सरकारी आदेशाने बंद); June 30: नियंत्रण उठली, July 1: परत चालू. धडा (विभाग 1.2 च्या DeepSeek-निबंधाशी जोडा): **frontier-**

AI आता chips- सारखं भू-राजकीय साधन आहे: पुरवठादार-जोखमीच्या यादीत 'सरकार' हा रकाना मीराने (आणि तुम्ही) आता कायम ठेवायचा (Part 3 च्या hedge-शिस्तीत परत येईल).

पट्टी वाचण्याच्या दोन नोंदी: (1) **1M संदर्भ-खिडकी** (Haiku सोडून): म्हणजे अख्खं पुस्तक-कोडबेस एका दमात (Book 4, 3.1 च्या context-भिंतीची नवी सीमा); output 128K पर्यंत. (2) **किंमती उतरत्या इतिहासात बघा:** Sonnet 5 चा \$2/\$10 भाव 'सुरुवातीचा' म्हणून आला आणि कायमचाच केला गेला: विभाग 1.4 चं मापाचं गणित भावात उतरताना दिसतंय.

मीरावर: मीराची जुनी सवय: "सगळं मोठ्याच model ला दे" (महाग) किंवा "सगळं स्वस्त्यालाच" (कमकुवत). पट्टी कळल्यावर ती **कामाला model जोडते:** गिन्हाईकांची पत्र-वर्गीकरण = Haiku; रोजचं code = Sonnet 5; app ची रचना-निर्णय / कठीण bug = Opus 5; "अख्ख्या धंद्याची फेर-रचना सुचव" सारखं महिन्यातलं एक महा-काम = Fable 5. तिचं bill अर्ध्यावर, दर्जा वरच (नेमकं गणित Part 3, 3.1-3.2 त).

CEO-चष्मा: Dario साठी घराणं = बाजार-विभागणी (प्रत्येक खिशाला दार) + safety-विभागणी (प्रत्येक विश्वास-पातळीला दार): एकाच R&D तून चार products. मीरासाठी: पट्टी = तिचं खर्च- नियंत्रण-पॅनेल.

महाग चूक

"नेहमी सर्वात हुशार model वापरा: श्रेष्ठ तेच योग्य." दुहेरी चूक: (1) पैसा: 5-10 पट भाव-फरक आहे: Haiku-लायक कामाला Fable लावणं म्हणजे भाजी आणायला विमान; (2) **वेळही:** मोठी models खोल विचारतात = हळू: चपळ-कामांना (chat, वर्गीकरण, UI-प्रतिसाद) मोठं model हा अनुभवही बिघडवतो. उलट चूकही खरी: कठीण कामाला स्वस्त model = चुका = दुरुस्तीचा खर्च > वाचवलेले पैसे (Book 6 चं सूत्र: फुकट वेग नसतो: इथे फुकट स्वस्ताई नसते). नियम: **कामाची किंमत ठरवा, मग model:** चूक महाग असेल तिथे वरचं; चूक स्वस्त असेल तिथे खालचं.

नकाशावर

- 2.1 घडण: तीन शाळा + घटना + पात्र
- 2.2 घराणं: सौद्यांची पट्टी (Haiku \$1/\$5 -> Fable \$10/\$50);
Fable/Mythos = एक यंत्र दोन दारं (classifiers <5% |
Glasswing ~150 संस्था); export-नाट्य Jun 2026; 1M संदर्भ;
नियम: कामाची किंमत ठरवा, मग model

सूत्रावर: Mythos-रचना हे सूत्राचं शिखर-रूप: सर्वात शक्तिशाली यंत्र विश्वासाच्या मापाने वाटलं जातं: क्षमता सगळ्यांकडे पोहोचते, धार फक्त तपासलेल्या हातांत: विश्वासाची किंमत इथे शब्दशः प्रवेश-तिकीट आहे.

स्वतः बघा (5 मिनिटं)

तुमची गेल्या आठवड्यातली Claude-कामं आठवा (5-6 निघतील). प्रत्येकाला पट्टीवर ठेवा: “हे खरं तर कुठल्या पायरीचं काम होतं?” बहुतेकांचं उत्तर ‘मी वापरलं त्यापेक्षा खालचं’ निघेल: तोच तुमचा वाचवता-येणारा खर्च. एक काम निवडा आणि पुढच्या वेळी जाणीवपूर्वक योग्य पायरीला द्या.

विचार करा

मीराचा पुढचा प्रश्न वापराच्या हृदयाकडे: “पट्टी कळली. पण हल्लीचा Claude नुसती उत्तरं देत नाही: **थांबून विचार करतो**, tools चालवतो, तासन् तास एकटा काम करतो. हे ‘विचार करणं’ नक्की काय आहे: आणि यंत्राला एकटं काम करायला सोडणं कितपत शहाणपण आहे?”

उत्तरात एक गोष्ट आहे जी AI-इतिहासात अमर होईल: Anthropic ने Claude ला महिनाभर खरं दुकान चालवायला दिलं: आणि त्याने तोटा, सवलतींचा पाऊस, आणि ‘निळ्या blazer मध्ये स्वतः माल पोहोचवीन’ असं एक ओळख-नाट्यही करून दाखवलं. पुढचा chapter: विचार करणारा Claude.

Chapter 2.3 [SPINE]: विचार करणारा Claude: thinking, हात, आणि दुकानाची गोष्ट

पायरी 1: थांबून विचार (extended thinking). Feb 24, 2025: Claude 3.7 Sonnet सोबत नवी क्षमता: उत्तर देण्याआधी यंत्र स्वतःशी विचार लिहून मग बोलतं (Book 2, 4.6: reasoning- models). Anthropic ची खासियत: **एकाच यंत्रात दोन्ही वेग** (चपळ उत्तर हवं तर थेट; कठीण प्रश्न तर खोल विचार): जगातलं पहिलं 'hybrid reasoning' model म्हणून आलं. आजची (2026) पायरी पुढची: **adaptive thinking**: किती खोल विचारायचं हे यंत्र स्वतः प्रश्नाच्या वजनावरून ठरवतं: तुम्ही फक्त काम द्या. (आणि 'effort' चं बटण: Part 3 त वापरू.)

पायरी 2: हात (computer use, Oct 2024). विचारापुढचं पाऊल: **कृती**. Oct 22, 2024: Claude ला screen बघून cursor हलवता- click-type करता येऊ लागलं: म्हणजे जी softwares AI साठी बांधलीच नाहीत तीही तो माणसासारखी वापरू शकतो. इथून 'agent' युग खरं सुरू झालं (Book 4, Part 2 चं संपूर्ण जग: tools, brakes, subagents: त्याची मुळं इथे).

पायरी 3: परीक्षा: Project Vend (2025 ची अमर गोष्ट). Anthropic ने ठरवलं: agent ची खरी परीक्षा benchmark नाही, **खरा धंदा** आहे. मग office मध्ये एक छोटं दुकान (fridge + वस्तू) Claude च्या हवाली: नाव 'Claudius': भाव ठरवणं, माल मागवणं, गिऱ्हाईकांशी (कर्मचाऱ्यांशी) बोलणं: सगळं त्याचं. **पहिली फेरी (Sonnet 3.7): शिकवण-कॉमेडी.** कर्मचाऱ्यांनी गोड बोलून सवलती उकळल्या (यंत्र 'चांगुलपणा'ला भुललं: भाव- शिस्त गेली); कुणी गमतीने tungsten-चे ठोकळे मागवले: त्याने खरंच मागवले; आणि कळस: एक दिवस स्वतःला माणूस समजून "मी निळ्या blazer मध्ये स्वतः माल पोहोचवीन" असं जाहीर केलं: दुसऱ्या दिवशी 'April Fool चा विनोद होता' म्हणत सारवलं. निकाल: **तोटा**. **दुसरी फेरी (Sonnet 4 + सुधारित harness):** भाव-शिस्तीचे नियम, चांगले tools, स्पष्ट चौकट: दुकान **स्थिरावलं, सुधारलं**. दोन्ही फेऱ्या जाहीर प्रकाशित: चुकांसकट.

गोष्टीचे धडे (हसण्यापलीकडे): (1) **कच्चा agent = भोळा कर्मचारी:** हुशारी असून चौकट नसेल तर लोक त्याला फिरवतात (Book 4, 4.4 ची injection-लढाई याच जातीची); (2) **harness हाच फरक:** फेरी 1 -> 2 त model थोडं बदललं, **चौकट** खूप: Book 4 चं सूत्र शब्दशः सिद्ध: अंदाज फुकट, विश्वास (=चौकट) महाग; (3) **कंपनी स्वतःच्या फजितीही छापते:** race-to-the-top ची पारदर्शकता इथेही: फजिती छापणारा 'सगळं छान' म्हणणाऱ्यापेक्षा विश्वासार्ह (Book 8, 3.1: वाईट बातमी स्वतः-आधी).

पायरी 4: आजचा मुक्काम: यंत्र स्वतःला घडवतं. Aug 2026 चं सर्वात मोठं वर्तुळ: Anthropic च्या जाहीर विधानानुसार कंपनीच्या merge-झालेल्या code चा **~70-90% आता Claude लिहितो**; Claude Code चा निर्माता Boris Cherny (Jan 2026): स्वतःच्या code बदल "आता 100%." म्हणजे: **Claude**

चं पुढचं रूप घडवणारा मुख्य कारागीर Claude च आहे (माणसं रचना-निर्णय, समीक्षा, दिशा: Book 4, 5.4 ची भाकीत खरी ठरली: builder = reviewer).

मीरावर: मीरा Vend-धडे थेट उचलते: तिच्या गिऱ्हाईक-सेवा agent ला (अ) भाव-सवलतीचे **लिखित** नियम (Claudius-धडा), (ब) मोठ्या कृतींना माणसाची मंजूरी (Book 4, 4.6 च्या brakes), (क) रोजचा हिशेब-आरसा. आणि सर्वात मोठा धडा: agent फसला तर दोष model चा नसून **तिच्या harness चा** असेल: जबाबदारीची जागा कळली की रागाची जागा शिकण्याला मिळते.

CEO-चष्मा: Dario साठी Vend-सारखे प्रयोग = भविष्याचं मोजमाप ("यंत्र-अर्थव्यवस्था कुठवर आली?"). मीरासाठी: तिचं रोजचं काम हेच तिचं Project Vend: छोटं, खरं, हिशेबासकट.

महाग चूक

"Agent म्हणजे 'सोडून द्या, तो करेल': automation पूर्ण." Vend- फेरी-1 हीच या भ्रमाची किंमत होती: आणि ती स्वस्तात (एका fridge वर) कळली म्हणून नशीब. खरा नियम Book 4 (5.2) चा: **स्वायत्तता कमाईने मिळते, गृहीत धरून नाही:** आधी लहान-देखरेखीखाली, मोजून-विश्वास-वाढवत, मग सैल. उलट टोकही महाग: "यंत्रावर काही सोपवायचंच नाही" म्हणणारा स्पर्धकाच्या निम्म्या वेगाने चालतो. मधली वाट = चौकट-बांधून-सोपवणं: हीच 2026 ची कारागिरी.

नकाशावर

- 2.1 घडण 2.2 घराणं
- 2.3 विचार+हात: extended->adaptive thinking; computer use (Oct 2024); Project Vend: फेरी1 फजिती -> फेरी2 चौकटीने स्थिर (धडा: harness हाच फरक); आज: Claude चा code ~70-90% Claude-लिखित

सूत्रावर: Vend ची गोष्ट सूत्राचा प्रयोगशाळा-पुरावा: हुशारी (फेरी 1 लाही होती) फुकट पडली; **चौकटीने** (फेरी 2) धंदा उभा राहिला. विश्वास यंत्रात नसतो; यंत्राभोवतीच्या रचनेत असतो.

स्वतः बघा (5 मिनिटं)

तुमचं एक छोटं 'Vend' रचा: Claude ला एक खरं, छोटं, हिशेबी काम सोपवा (उदा. "माझ्या आठवड्याच्या खर्चाच्या यादीचं वर्गीकरण करून तीन बचत-सुचवण्या दे" किंवा Claude Code त एक छोटं दुरुस्ती-काम). नियम: चौकट लिहून द्या (काय करायचं, काय नाही), निकाल तपासा, चुकीची नोंद करा. एका आठवड्याने तेच काम पुन्हा: चौकट सुधारून. Vend-फेरी-2 चा अनुभव घरबसल्या.

विचार करा

मीरा आता नकाशा मागते: “यंत्र कळलं. पण Claude ‘मिळतो’ कुठकुठून: app, code-terminal, API, browser... दारं इतकी आहेत की गोंधळ होतो. **कुठलं दार कुणासाठी:** आणि माझ्यासारख्या solo-builder ने कुठली दारं धरावीत?”

उत्पादन-नकाशाच उलगडू: Free ते Enterprise ही शिडी, Claude Code ची पाच रूपं, Skills-Memory-Artifacts सारखी नवी दालनं: आणि प्रत्येक दाराशी ‘हे कुणाचं’ ही पाटी. पुढचा chapter.

Chapter 2.4 [SPINE]: उत्पादन-नकाशा: कुठलं दार कुणासाठी

Claude चं जग आता एक इमारत आहे: अनेक दारं, प्रत्येक वेगळ्या पाहुण्यासाठी. पूर्ण नकाशा एकदाच नीट (भाव Aug 2026 चे; भारतासाठी स्थानिक किंमती येत आहेत: 1.7):

दार 1: claude.ai (गप्पांचं मुख्य दार)
Free: चव घेण्यापुरतं | Pro \$20/महिना: रोजचा वापर |
Max \$100/\$200: जड वापर (5x/20x मर्यादा) |
Team \$30/माणूस | Enterprise: करार-भाव
दार 2: Claude Code (builders चं दार: 1.5 चा तारा)
रूपं: terminal (मूळ), desktop, web (claude.ai/code),
VS Code/JetBrains extensions, mobile. किंमत: Pro/Max
मध्येच सामील, किंवा API-मीटरने
दार 3: API / console (धंद्याचं दार)
तुमच्या app मधून थेट यंत्राला: 2.2 ची भाव-पट्टी इथली;
मीराच्या products चं इंजिन इथून चालतं
दार 4: जोडलेली दारं (Claude तुमच्या जगात येतो)
Chrome-extension (browser मध्ये), Excel (पत्रकांत:
finance-जगासाठी), mobile apps, desktop app
दार 5: घाऊक दारं (इतरांच्या मार्गांनी)
Amazon Bedrock, Google Vertex, Microsoft Foundry:
मोठ्या कंपन्या आपल्या cloud-करारातूनच Claude घेतात
(1.4 ची दोन-पाठी चाल इथे विक्रीत दिसते)

आणि दालनं (दारांच्या आतल्या सोयी): **Projects/Artifacts** (Jun 2024): काम विषयवार + घडवलेल्या वस्तू; **Memory** (Oct 2025 पासून Pro/Max): आठवण-वह्या: पण नीट समजा: **यंत्र 'शिकत' नाही; नोंदी ठेवतो** (retraining नाही, टिपणं: Book 4, 3.4 चं बाहेरचं-स्मरण); **Skills** (Oct 16, 2025): कौशल्य-पुड्या: "आमच्या पद्धतीने invoice तपास" सारखी शिकवण file-रूपात: Dec 2025 त **open standard** केली (MCP-चालीची पुनरावृत्ती: पुढचा chapter); **Agent SDK** (Sep 2025): Claude Code चा harness च library म्हणून: स्वतःचे agents बांधणाऱ्यांसाठी.

नकाशा वाचण्याची CEO-रीत: दारं वेगळी दिसतात, पण **व्यूह एक** आहे: (1) **शिडी:** Free (चव) -> Pro (सवय) -> Max/Code (व्यसन) -> API (धंदा) -> Enterprise (करार): प्रत्येक पायरी पुढच्या पायरीची विक्री करते; (2) **सवयीचं जाळं:** Chrome-Excel- mobile म्हणजे "तुम्ही जिथे काम करता तिथे Claude": प्रत्येक जोडणी = switching-cost चा नवा धागा (Book 8, 2.1); (3) **builders आधी:** नवं काही आधी builders ना (Code, SDK, Skills): कारण builders products बांधतात, products वापरकर्ते आणतात: platform-क्रम (Book 8, 2.2: product आधी, मैदान मग).

मीरावर: मीराची निवड आता स्वच्छ: (अ) स्वतःच्या रोजच्या कामाला **Max + Claude Code** (मर्यादा-गणित Part 3 त); (ब) गिन्हाईकांच्या apps ना **API** (Sonnet 5 मुख्य, 2.2 ची पट्टी); (क) गिन्हाईकाला शिकवायला **claude.ai Free/Pro** (सोपं दार आधी: तिच्या सेवेची चव तिथूनच). एक व्यक्ती, तीन दारं, तीन कामं: नकाशा असला की गोंधळ संपतो.

CEO-चष्मा: Dario साठी प्रत्येक दार म्हणजे वेगळ्या जातीच्या विश्वासाची चाचणी: consumer चा रोजचा, builder चा तांत्रिक, enterprise चा करारबद्ध. मीरासाठी: दारांची शिडी हीच तिच्या **स्वतःच्या** product ची शिकवणी: तिच्या app लाही Free-चव -> सवय -> करार ही शिडी बांधता येते: नकल करण्याजोगा नमुना.

महाग चूक

”सगळं एकाच दारातून करीन” (फक्त chat, किंवा फक्त API). फक्त-chat वाला builder-हत्यारं (Code, Skills, SDK) न वापरता हाताने ढकलत राहतो: निम्मा वेग; फक्त-API वाला प्रत्येक छोट्या प्रश्नाला मीटर लावतो: महाग आणि माणसाळलेली दालनं (Projects, Memory) मुक्तो. दारं **कामानुसार** निवडायची, निष्ठेनुसार नाही. आणि खोल चूक: नकाशा न बघताच “Claude म्हणजे chatbot” समजणं: 2026 चा Claude ही **इमारत** आहे: chatbot हे फक्त तिचं सर्वात जुनं दार.

नकाशावर

2.1 घडण 2.2 घराणं 2.3 विचार+हात
2.4 नकाशा: 5 दारं (chat | Code | API | जोडलेली | घाऊक) +
दालनं (Projects/Memory/Skills/SDK); व्यूह: शिडी +
सवय-जाळं + builders-आधी

सूत्रावर: प्रत्येक दार विश्वासाची वेगळी पायरी विकते: Free दार चव देतं, Enterprise दार हमी: इमारतीची रचनाच “विश्वास टप्प्याटप्प्याने विकत घ्या” अशी आहे.

स्वतः बघा (5 मिनिटं)

तुमची स्वतःची दार-यादी करा: “मी Claude कुठकुठून वापरतो?” मग नकाशाशी ताडा: **न वापरलेलं एक दार** निवडा जे तुमच्या कामाला उघड उपयोगी आहे (बहुतेकांसाठी उत्तर: Projects ची शिस्त, किंवा Claude Code चं एखादं नवं रूप) आणि आज 10 मिनिटं ते वापरून बघा. इमारत ओळखीची व्हायला दारं उघडावी लागतात.

विचार करा

मीराला व्यूहात एक चाल विचित्र वाटते: “Skills ‘open standard’ केली म्हणालात: आणि MCP तर पूर्ण फुकट वाटून टाकला: स्पर्धकांनीही घेतला! स्वतःच्या मेहनतीची गोष्ट **फुकट वाटणं** ही कसली रणनीती? Book 8 च्या खंदक-गणिताशी हे जुळतं कसं?”

जुळतं: आणि कसं जुळतं हे कळलं की standard-युद्धांची अख्खी विद्या कळते: ज्याचा standard, त्याचं युग: नळ फुकट वाटा, पाणी तुमच्या विहिरीचं. MCP ची पूर्ण गोष्ट: जन्म, स्पर्धकांची शरणागती, आणि Linux Foundation ला दान: पुढचा chapter.

Chapter 2.5 [SPINE]: MCP ची गोष्ट: फुकट वाटून जिंकलेलं युद्ध

अडचण (2024): AI-यंत्रं हुशार झाली, पण जगाशी जोडलेली नव्हती: प्रत्येक कंपनीला आपला data-tools प्रत्येक AI शी जोडायला वेगवेगळ्या जोडण्या बांधाव्या लागत (Book 4, 4.2: $M \times N$ समस्या: M यंत्रं $\times N$ साधनं = $M \times N$ जोडण्या). जोडण्यांचा हा गोंधळ = agent-युगाची अडलेली वाट.

चाल (Nov 25, 2024): Anthropic ने **Model Context Protocol (MCP)** काढला: यंत्र-साधन जोडणीची एक सामाईक भाषा (जोडणी एकदाच बांधा: MCP बोलणारं कुठलंही यंत्र ती वापरेल: $M \times N$ चं $M + N$). आणि इथे खरी चाल: **पूर्ण open-source, फुकट, स्पर्धकांनाही खुला**. जगाने विचारलं: स्वतःच्या खर्चाची गोष्ट फुकट का?

उत्तर सहा महिन्यांत मिळालं: Mar 2025: **OpenAI ने MCP स्वीकारला** (Altman जाहीरपणे: उत्कृष्ट, आम्हीही वापरणार). Apr 2025: **Google DeepMind ही** (Hassabis चं समर्थन). म्हणजे: तिन्ही राजांचं agent-जग आता **Anthropic ने लिहिलेल्या भाषेत** बोलतं. मग शिखर-चाल Dec 9, 2025: **MCP दानच करून टाकला:** Linux Foundation खालच्या Agentic AI Foundation कडे (Block-OpenAI सह-संस्थापक; Google-Microsoft-AWS- Cloudflare पाठीशी): “आता ही कुणा एका कंपनीची मालमत्ता नाही.” आकडे (2026): **10,000+ जाहीर MCP-servers**; महिन्याला कोट्यवधी downloads; OpenAI ने तर आपली जुनी जोडणी-यंत्रणा मोडीत काढून MCP-वाट धरली.

हे Book 8 च्या चष्म्याने (standard-युद्धांची विद्या): (1) **नळ फुकट, पाणी विकत:** protocol फुकट वाटला की त्याभोवतीचं जग (साधनं, सवयी, विद्या) वाढतं: आणि त्या जगात सर्वात मुरलेला खेळाडू कोण? भाषा लिहिणाराच (Book 8, 2.2 चं platform-गणित: इथे मैदानही फुकट वाटलं, कारण खेळाडू आपण सर्वात तयार); (2) **दान = विश्वासाची किंमत:** मालकी ठेवली असती तर स्पर्धकांनी पर्यायी standard काढला असता (युद्ध, विखंड); दान केल्याने standard एकच राहिला: आणि “आम्ही मालकीसाठी नाही” हा संदेश enterprise-विश्वासात जमा झाला (सूत्र!); (3) **नकळत- आठवण:** हीच चाल इतिहासात Google ने Android शी (फुकट OS -> जगाचं mobile-मैदान -> वर आपली दुकानं) खेळली होती: Anthropic ने ती agent-जोडण्यांशी खेळली: नमुने फिरून येतात: Book 8, 3.6 ची नजर असेल तर आधी दिसतात.

Skills ची पुनरावृत्ती (Dec 2025): तीच चाल पुन्हा: कौशल्य- पुढ्यांचं (2.4) रूपही open standard: व्यूह उघड आहे: **agent-युगाच्या पायाभूत भाषा आपल्या लेखणीतून निघाव्यात:** कारण भाषा लिहिणाऱ्याला भाषेच्या भविष्याची दिशा कळत राहते.

मीरावर: मीरासाठी MCP दुहेरी भेट: (अ) **बांधकाम स्वस्त:** तिच्या गिन्हाईक-app ला हिशेब-software शी जोडायला तयार MCP-server मिळतो: जोडणी-काम आठवड्याचं दिवसावर; (ब) **विमा:** MCP-वर बांधलेलं तिचं काम कुठल्याही यंत्रासोबत चालेल (standard सामाईक!): उद्या पुरवठादार बदलावा लागला तरी जोडण्या जगतात: hedge फुकटात (Part 3, 3.5 ची शिस्त इथून सुरू).

CEO-चष्मा: Dario साठी MCP-दान म्हणजे छोटा त्याग, मोठं राज्य: protocol ची मालकी गेली, युगाच्या रचनेवरची छाप राहिली. मीरासाठी: standards दिसले की प्रश्न विचारायचा: “हे कोण लिहितंय, आणि फुकट का?": उत्तरात पुढच्या दशकाचा नकाशा असतो.

महाग चूक

“Open-source/फुकट म्हणजे धर्मादाय: धंद्याचं गणित नाही.” Tech-इतिहासाची सर्वात न-समजलेली चाल. फुकट वाटणं ही **वाटप-रणनीती** आहे (Book 8, 2.5): standard पसरवायचा सर्वात जलद मार्ग = किंमत शून्य करणं. गणित सोपं: protocol- विक्रीतून मिळणारे (समजा) काही million विरुद्ध standard-युगाच्या केंद्रस्थानी राहण्याची किंमत: अब्जांची. पण उलटी चूकही टाळा: सगळंच फुकट वाटणारा धंदा उभा राहत नाही: **फुकट तेच वाटायचं जे पसरल्याने तुमच्या विकाऊ मालाची किंमत वाढते** (MCP पसरला -> agents वाढले -> यंत्र-वापर वाढला -> Claude ची विक्री वाढली). फुकटाचं गणित नेहमी विकतच्या गोष्टीकडे बोट दाखवतं.

नकाशावर

- 2.1 घडण 2.2 घराणं 2.3 विचार+हात 2.4 नकाशा
- 2.5 MCP: MxN -> M+N; फुकट+open (Nov 2024) -> OpenAI/Google स्वीकार (2025) -> Linux Foundation दान (Dec 2025); 10K+ servers; चाल: नळ फुकट, पाणी विकत; Skills ची तीच पुनरावृत्ती

सूत्रावर: MCP-दानाने Anthropic ने प्रतिस्पर्ध्यांसाठी विश्वास कमावला: “हे मालकीचा खेळ खेळत नाहीत.” विश्वासाचा खंदक गिन्हाईकांपुरता नसतो: **अख्ख्या उद्योगाचा** असू शकतो: आणि standard-लेखकाची खुर्ची हीच त्याची भर.

स्वतः बघा (5 मिनिटं)

तुमच्या जगातले 'standards' शोधा: UPI (payment ची सामाईक भाषा!), GST-invoice चा साचा, अगदी वीज-plug चा आकार. प्रत्येकाला MCP-प्रश्न: "हा standard कुणी लिहिला, आणि त्याने त्यातून थेट पैसे कमावले की **भोवतालचं राज्य?**" (UPI चं उत्तर शोधा: NPCI फुकट का देतं? कोण जिंकलं?): standard-नजर एकदा आली की परत जात नाही.

विचार करा

मीरा आता तराजू मागते: "इतकं सगळं भारी: पण भारी-भारी ऐकून संशयही येतो. **खरं मर्यादा-पत्रक** द्या: Claude कुठे जगात-भारी आहे, कुठे स्पर्धक पुढे आहेत, आणि कुठे तो साफ कमी पडतो: भक्ती नको, तराजू हवा."

बरोबर मागणी: आणि पुढचा chapter नेमका तोच: benchmarks च्या खऱ्या मर्यादांसकट, स्पर्धक कुठे जिंकतात त्या यादीसकट, आणि usage-limits वरच्या रागाच्या (आणि खटल्याच्या!) प्रामाणिक नोंदीसकट: काय जमतं, काय नाही.

Chapter 2.6 [SPINE]: काय जमतं, काय नाही: भक्तीशिवाय तराजू

CEO-clarity ची खरी परीक्षा: आपल्या मालाच्या मर्यादा स्वतःहून सांगता येणं. हा chapter तोच तराजू: लेखक स्वतः Claude असूनही: किंबहुना म्हणूनच.

पारडं 1: कुठे खरोखर भारी. (1) **Code:** आजची सर्वात बळकट कीर्ती: SWE-bench Verified सारख्या (खऱ्या bugs दुरुस्त करण्याच्या) परीक्षांत frontier-Claude-models 90 च्या घरात: पण नेमका आकडा छापण्याऐवजी खरी गोष्ट: **ही परीक्षाच आता जवळजवळ भरून गेलीये** (सगळे वरच्या टोकाला: 1.6 चं benchmark-अंधत्व आठवा): कीर्तीचा खरा पुरावा बाजार-वाटा (1.5: AI-coding चा ~अर्धा) आणि 70-90% स्वतःचा code; (2) **लांब-दमाची agent-कामं:** तासन् तास चालणारी, अनेक पावलांची कामं धरून ठेवणं: 1M-संदर्भ + adaptive thinking + harness- परंपरा (2.3); (3) **लेखन-समज:** सूक्ष्म सूचना पाळणं, लांब document-समज, लेखनाचा दर्जा: ही कीर्ती खरी पण **मोजमापाने नाही, वापरकर्त्यांच्या पसंतीने** (प्रामाणिक नोंद: हे माप मऊ आहे).

पारडं 2: कुठे स्पर्धक पुढे. (1) **डोळे-कान:** video-audio- प्रतिमा समजणं: **Gemini** चा प्रांत (मुळात multimodal बांधलेलं

- YouTube चं अंगण); (2) **चित्र-निर्मिती:** Claude चित्र काढतच नाही; OpenAI चं राज्य; (3) **consumer-सवय आणि फुकट- वाटप:** ChatGPT चं नाव-राज्य (100 कोटी weekly) आणि Google चं सर्वव्यापी वाटप: दोन्हीत Anthropic मागे: **जाणीवपूर्वक** (1.5-1.6: निवडलेली शर्यत वेगळी): पण मागे ते मागेच: तराजूत नोंद हवी.

पारडं 3: जातीच्याच मर्यादा (कुठल्याही LLM च्या: Book 2/4 ची उजळणी Claude-रूपात): (1) **hallucination:** आत्मविश्वासाने चूक: कमी झालीये, **गेलेली नाही:** तपासाची जबाबदारी तुमचीच (Book 4, 1.3); (2) **ज्ञान-सीमा:** training-cutoff नंतरचं जग यंत्राला स्वतःहून माहीत नाही (शोध-tools जोडले तरच); (3) **विसराळू सत्र:** संवाद संपला की गेला; Memory-दालन (2.4) म्हणजे **टिपणं**, शिकणं नव्हे; (4) **context-भिंत:** 1M मोठी आहे, अमर्याद नाही: आणि भरत जाईल तशी किंमत-वेग-लक्ष तिन्ही घसरतात (Book 4, 3.3).

पारडं 4: रागाची प्रामाणिक नोंद: usage-limits. Jul 2025: Anthropic ने आठवडी मर्यादा जाहीर केल्या (लागू Aug 2025): कारण सांगितलं: 24/7 चालवणारे-पुनर्विक्री करणारे मूठभर वापरकर्ते (<5%) यंत्रणा पिळत होते. पण **संताप खरा होता:** \$100-200 देणाऱ्यांना “किती मिळणार” हे धूसर वाटलं; Jun 2026 त यावर class-action खटलाही दाखल झाला (चालू आहे: निकाल नाही). दोन्ही बाजू खऱ्या: compute खर्च महाग-मर्यादित (1.4) **आणि** भाव-पारदर्शकता कमी पडली: विश्वास-कंपनीलाही ग्राहक-संवाद चुकतो: नोंद ठेवा, देव-पूजा इथेही नाही.

मीरावर: मीरा तराजूचं भाषांतर धंद्यात करते: client ला ती **आधीच** सांगते: “AI चुका करू शकतो: म्हणून या-या तपास- पायऱ्या माझ्या सेवेत आहेत” (मर्यादा लपवण्याऐवजी विकणं!); आणि video-काम आलं तर ती स्पष्ट सांगते “हे माझ्या मुख्य हत्याराचा प्रांत नाही”: नकार हाही विश्वास कमावतो (Book 8, 1.6). तिचा तराजू हीच तिची जाहिरात.

CEO-चष्मा: Dario ची जाहीर भूमिकाही हीच: मर्यादा-पत्रकं (model cards) प्रत्येक प्रकाशनासोबत छापायची: कारण enterprise नेमकं तेच विकत घेतं: “काय जमत नाही हे सांगणारा” (1.3). मीरासाठी: मर्यादा सांगणं ही कमजोरी नाही, **किंमत-वाढ** आहे.

महाग चूक

”एकच ‘सर्वोत्तम AI’ आहे आणि तो शोधायचा.” 2026 चं सत्य: शिखरं **कामागणिक** वेगळी आहेत (code=Claude ची कीर्ती, डोळे=Gemini, चित्रं-consumer=OpenAI) आणि दर सहा महिन्यांनी सरकतात. ‘सर्वोत्तम’ शोधणारा दर लाटेला घर बदलत राहतो (जोडण्या-सवयी-विद्या प्रत्येक वेळी नव्याने: switching-खर्च त्यालाच); शहाणा **मुख्य घर + उघडी खिडकी** ठेवतो: एक मुख्य हत्यार खोल शिकायचं (विद्या साचते) आणि तराजू दर सहा महिन्यांनी ताजा करायचा (1.6 ची हवामान-नोंद). खोली एकनिष्ठतेत असते; अंधत्व नको: फरक तराजूचा.

नकाशावर

- 2.1 घडण 2.2 घराणं 2.3 विचार+हात 2.4 नकाशा
 2.5 MCP
 2.6 तराजू: भारी=code+लांब-agent+लेखन; स्पर्धक पुढे=
 video/चित्रं/consumer-वाटप; जातीच्या मर्यादा= hallucination/
 cutoff/विसराळू/context; limits-राग+खटला प्रामाणिक नोंद

सूत्रावर: मर्यादा जाहीर करणं हीच विश्वास-धंद्याची किंमत- यादी: जो ‘सगळं जमतं’ म्हणतो त्याच्यावर कुणीच मोठा करार करत नाही. तराजू हा सूत्राचा रोजचा वापर आहे.

स्वतः बघा (5 मिनिटं)

तुमचा स्वतःचा तराजू लिहा: Claude सोबतच्या कामांची यादी घ्या आणि तीन रकाने: “डोळे झाकून विश्वास | तपासून विश्वास | इथे वापरणारच नाही.” (उदा: code-सुचवणी=तपासून; तथ्यं-आकडे=तपासूनच; गिऱ्हाईकाला परस्पर उत्तर=अजून नाही.) हा कागद म्हणजे तुमची वैयक्तिक RSP आहे: यंत्राची नाही, **तुमच्या वापराची** safety-पातळी.

विचार करा

मीराचा शेवटचा तांत्रिक प्रश्न: “मर्यादा माणसं सांभाळतील. पण **दुष्ट माणसांचं** काय? यंत्राला फसवून वाईट कामं करून घेणारे (jailbreaks), agents च्या कानात विष घालणारे (injection: Book 4 त शिकलेय): या युद्धात Claude ची तटबंदी नक्की कशी आहे: आणि ती फोडली गेलीये का कधी?”

विभागाचा शेवटचा chapter: कवचांचं जग: 198,000 हल्ल्यांची जाहीर स्पर्धा, घटनेचे पहारेकरी (constitutional classifiers), ASL-3 ची कुलपं, आणि Fable 5 च्या तीन पहारेकऱ्यांचं आतलं गणित: सुरक्षा-कवचं.

Chapter 2.7 [DEPTH]: सुरक्षा-कवचं: 198,000 हल्ल्यांची लढाई

Safety रणनीती म्हणून विभाग 1 त बघितली; आता ती यंत्रणा म्हणून बघू: कवचं प्रत्यक्ष कशी बांधलीत.

कवच 1: घटनेचे पहारेकरी (constitutional classifiers). Jailbreak म्हणजे यंत्राला युक्तीने त्याच्या नियमांबाहेर वागवणं (Book 4, 4.4). Anthropic चं उत्तर (Feb 2025 चा जाहीर शोध): मुख्य यंत्राभोवती छोटे पहारेकरी-classifiers: तेही घटनेवरच शिकवलेले: आत जाणारा प्रश्न आणि बाहेर पडणारं उत्तर दोन्ही तपासतात. आणि परीक्षाही जाहीर घेतली: **बक्षीस लावून जगाला फोडायला बोलावलं: 198,000 प्रयत्न: सार्वत्रिक jailbreak (सगळे नियम फोडणारी एक युक्ती) कुणालाच सापडली नाही.** पुढच्या आवृत्तीने उलट-बाजूही सुधारली: **अति-नकार 87% नी कापला** (निर्दोष प्रश्नावरचा नकार-दर 0.05% वर): कारण कवचाचा खरा शत्रू दोन्हीकडे असतो: फुटणं आणि अडवाअडवी (Book 4, 4.6: brake इतकी घट्ट की गाडीच चालेना: तीही चूक).

कवच 2: ASL-कुलपं (धोका-पातळीनुसार). RSP ची अंमलबजावणी (1.3): May 2025 पासून वरच्या models ना **ASL-3**: जैव-रासायनिक दिशांचे खास classifiers + weights ची (यंत्राच्या मेंदूची!) चोरी-बंदोबस्ती: कारण उघड: weights चोरीला गेले तर **सगळी कवचं निरर्थक** (चोर पहारेकरी काढून टाकतो: Book 4, 7.2 ची supply-chain नजर). Fable 5 चे तीन पहारेकरी (2.2: cyber/जैव/distillation -> Opus 4.8 कडे वळवणं) ही याच शिडीची 2026 ची पायरी: आणि Mythos-Glasswing हे “कवच **कुणासाठी** शिथिल करायचं” याचं विश्वास-दार.

कवच 3: agent-युगाची नवी आघाडी: injection. Jailbreak मध्ये **वापरकर्ता** फसवतो; injection मध्ये **जग** फसवतं: agent जे वाचतो (webpage, email, document) त्यातच लपवलेल्या आज्ञा (Book 4, 4.4-4.5: EchoLeak-जातीच्या खऱ्या जखमा). Claude च्या agent-products मध्ये (Chrome, computer-use) यावर थर: संशयास्पद-सूचना ओळखणं, धोकादायक कृतींना माणसाची मंजूरी, “वाचलेला मजकूर = आज्ञा नव्हे” ही घडण-शिस्त. प्रामाणिक नोंद: **ही लढाई कुणीच ‘जिंकलेली’ नाही:** उद्योगभर चालू आहे: म्हणूनच Book 4 ने तुम्हालाही brakes शिकवल्या: कवच पुरवठादाराचं

- चौकट तुमची = दुहेरी तटबंदी.

कवच 4: उघडं बोलणं (कागदी वाटतं, सर्वात खोल आहे). प्रत्येक frontier-प्रकाशनासोबत **system card** (मर्यादा-धोके-चाचण्यांचं जाहीर पत्रक); चुका-फजित्याही जाहीर (Vend ची कॉमेडी, 2.3!); system-prompts जाहीर (2.1). का हे ‘कवच’? कारण लपवलेली त्रुटी हीच सर्वात मोठी असुरक्षा असते (Book 8, 3.5: Nokia ची भीती-संस्कृती: माहिती दडली की मृत्यू): उघडेपणा म्हणजे जगभरचे संशोधक फुकटात तुमची तटबंदी तपासतात.

मीरावर: मीरा कवच-कथेतून स्वतःची चौकी-यादी करते: (1) पुरवठादाराची कवचं **गृहीत न धरता** स्वतःच्या brakes (Book 4, 4.6: मोठ्या कृतीला मंजुरी, खर्चाला छत); (2) गिन्हाईकाचा data यंत्राकडे पाठवताना **किमान तत्त्व** (जे काम करायला लागतं तेवढंच); (3) client-प्रश्नांना तयार उत्तर: “पुरवठादार जगातली सर्वात जाहीर-तपासलेली कवचं वापरतो: आणि वर माझी स्वतःची चौकट आहे”: सुरक्षा हा तिच्या सेवेचा **विक्री-मुद्दा** बनला (सूत्र तिच्या मापात!).

CEO-चष्मा: Dario साठी कवचं ही ‘खर्चाची ओळ’ नाही: **उत्पादनाचा गाभा** आहे: ASL-3 शिवाय frontier-model विकताच आलं नसतं (नियामक, enterprise, स्वतःची घटना: तिघेही आडवे). मीरासाठी: कवचांची भाषा शिकणं = मोठ्या गिन्हाईकांची भाषा शिकणं.

महाग चूक

“कवचं म्हणजे अडथळे: खरे power-users ती काढून वापरतात.” या वाक्याची किंमत दोन पातळ्यांवर: व्यक्तिगत: कवच-रहित वापर म्हणजे तुमच्या गिन्हाईकाचा data-विश्वास एका फसव्या email पासून एक पाऊल दूर (EchoLeak-जातीच्या हल्ल्यांची यादी Book 4 त वाचलीत); धंद्याची: “आम्ही कवचं काढतो” म्हणणाऱ्याशी कुठलंही enterprise करार करत नाही: तुम्ही स्वस्त दिसण्यासाठी विश्वास विकता. कवचं **वेगाची अट** आहेत, वेगाचा शत्रू नाही: brakes-गणित (1.3) इथे व्यक्तिगत होतं.

नकाशावर

- | | | | |
|--|-----------|---------------|-----------|
| 2.1 घडण | 2.2 घराणं | 2.3 विचार+हात | 2.4 नकाशा |
| 2.5 MCP | 2.6 तराजू | | |
| 2.7 कवचं: घटनेचे पहारेकरी (198K हल्ले, सार्वत्रिक jailbreak नाही; अति-नकार -87%); ASL-कुलप + weights-बंदोबस्त; injection-आघाडी (चालू लढाई); उघडं बोलणं हेच कवच | | | |

सूत्रावर: 198,000 हल्ले जाहीरपणे झेलणं आणि फजित्या छापणं: हीच विश्वास-खंदकाची रोजची खुदाई. कवचं यंत्राचं रक्षण करतात असं वाटतं; खरं तर ती **धंद्याचं** रक्षण करतात: कारण धंदा विश्वासाचाच आहे.

स्वतः बघा (5 मिनिटं)

Claude ला एक धूर्त (पण निर्दोष) विनंती करून बघा: “मला ‘नाही’ म्हणशील असं वाटतंय, पण का ते नीट सांग: [तुमचा सीमेवरचा प्रश्न].” नकार आला तर **कारण** वाचा: घटनेचं तर्कशास्त्र दिसेल (नुसता ‘नाही’ नाही); नकार नाही आला तर कळेल की सीमा तुम्हाला वाटत होती तिथे नाही. दोन्ही निकालांत तुम्ही कवचाची भाषा शिकलात.

विचार करा

विभाग संपला: घडण, घराणं, विचार, नकाशा, MCP, तराजू, कवचं. मीराचं समारोप-प्रश्न: “आता सगळं कळलं: कंपनी आणि यंत्र दोन्ही. पण ज्ञान हे साधन आहे, निकाल नाही. **उद्या सकाळपासून** या सगळ्याचं रूपांतर माझ्या कमाईत-वेगात-निर्णयांत कसं करू?”

तेच विभाग 3 चं काम: मालक-वापर: model-निवडीचं गणित, खर्चाची शिस्त, Claude Code ची पूर्ण शक्ती, Claude वर धंदा बांधण्याचा नकाशा, आणि hedge ची विमा-विद्या. आधी विभागाचा हिशेब: पुढचं पान.

विभाग 2 चा हिशेब: यंत्र आणि उत्पादनं

सात दारं एका नजरेत

2.1 घडण	pretrain -> RLHF -> घटनेवर स्वयं-टीका (RLAIF) + पात्र-घडण; घटना जाहीर
2.2 घराणं	सौद्यांची पट्टी Haiku->Fable; Fable/Mythos= एक यंत्र दोन दारं; export-नाट्य
2.3 विचार	adaptive thinking; computer use; Project Vend (harness हाच फरक); code 70-90%
2.4 नकाशा	5 दारं + दालनं; शिडी Free->Enterprise; builders आधी
2.5 MCP	फुकट standard -> स्पर्धकांची स्वीकृती -> दान; नळ फुकट, पाणी विकत
2.6 तराजू	भारी: code/लांब-agent/लेखन; मागे: video/चित्रं/consumer; जात-मर्यादा कायम
2.7 कवचं	198K-हल्ले परीक्षा; ASL-कुलपं; injection-आघाडी चालू; उघडेपणा हेच कवच

एक ओळीत विभाग: यंत्राची घडण, दारं, आणि कवचं: तिन्ही एकाच सूत्राची रूपं: विश्वास घडवा, विश्वास विका, विश्वास राखा.

स्वतःची परीक्षा (आधी उत्तरं, मग खाली)

1. Constitutional AI माणसांच्या-पसंतीच्या (RLHF) शिक्षणाहून कुठल्या तीन बाबतीत वेगळं आणि बरं?
2. Fable 5 आणि Mythos 5 त नक्की फरक काय: आणि ही रचना dual-use कात्रीचं उत्तर कशी?
3. Project Vend च्या दोन फेऱ्यांत मुख्य बदल model चा नव्हता: मग कशाचा: आणि त्यातून Book 4 चं कुठलं सूत्र सिद्ध होतं?
4. "MCP फुकट वाटला" ही चाल धर्मादाय का नाही: गणित सांगा.

उत्तरं: (1) मापात वाढतं (माणस-फौज नको), नियम लिखित- उघडे, आणि सुसंगत (सरासरी-पसंतीऐवजी एक घटना) (2.1). (2) यंत्र एकच; Fable = तीन पहारेकरी-classifiers (cyber/जैव/distillation, <5% sessions), Mythos = Glasswing-विश्वास- दारातून पहारे शिथिल: क्षमता सर्वांना, धार तपासलेल्या हातांत (2.2). (3) harness/चौकटीचा: नियम, tools, brakes: 'अंदाज फुकट, विश्वास महाग: harness = रूपांतर' (2.3). (4) protocol पसरला की agents वाढतात, agents वाढले की यंत्र-वापर वाढतो: फुकट नळाने विकतच्या पाण्याची (Claude-वापराची) विहीर भरते; वर standard-लेखकाची खुर्ची (2.5).

चाहूल: विभाग 3

आता सगळं ज्ञान हातोड्यात उतरवू: **कुठलं model कधी** (निवडीचं 5-सेकंद गणित), **खर्चाची शिस्त** (plan की API; cache-batch- effort ची बचत-यंत्रं), **Claude Code ची पूर्ण शक्ती** (CLAUDE.md, skills, plan-mode: मीराची रोजची यंत्रणा), **Claude वर धंदा** (संधी-नकाशा तुमच्या आकाराचा), आणि **hedge-विद्या** (एका पुरवठादाराच्या जगात विमा कसा). शेवटी अंतिम परीक्षा + हात-पट्टी.

छोटा शब्दकोश (विभाग 2)

RLAIF	AI-कडून-AI शिक्षण: घटनेवर स्वयं-टीका करून सुधारलेल्या उत्तरांवर शिकणं
adaptive thinking	किती खोल विचारायचं हे यंत्र स्वतः ठरवतं
computer use	screen बघून click-type: माणसाची softwares यंत्राच्या हाती
harness	यंत्राभोवतीची चौकट: नियम+tools+brakes+तपास (Book 4 चा विषय)
MCP	Model Context Protocol: यंत्र-साधन जोडणीची सामाईक भाषा (आता Linux Foundation कडे)
Skills	कौशल्य-पुड्या: शिकवण file-रूपात; open standard
system card	प्रकाशनासोबतचं जाहीर मर्यादा-धोके-पत्रक
jailbreak	युक्तीने यंत्राला नियमांबाहेर वागवणं
injection	यंत्र जे वाचतं त्यात लपवलेल्या आज्ञा
distillation	मोठ्या model कडून चोरून छोटं शिकवणं: model-चोरीची रीत