

The Paper, Part 1: पेपर आधीचं जग आणि पेपरची गोष्ट

August 30, 2026

THE PAPER

Book 10, Part 1: पेपरआधीचं जग आणि पेपरची गोष्ट

हे पुस्तक कुणासाठी: जगात असे मोजके दस्तावेज असतात ज्यांनी इतिहास दुभंगला: त्यांच्या आधीचं जग वेगळं, नंतरचं वेगळं. "Attention Is All You Need" (2017) हा त्यातला एक: **15 पानांचा पेपर ज्याने ChatGPT-Claude-Gemini या सगळ्यांचा सांगाडा जन्माला घातला.** तुम्ही Book 2 त कल्पना शिकलात, Book 7 त गणित: आता **उगम- दस्तावेज स्वतः:** पूर्ण, समीकरणागणिक, हाताच्या आकड्यांनी: वाचून संपल्यावर मूळ पेपर तुम्हाला परका राहणार नाही.

या पुस्तकाचं एकमेव सूत्र

रांग मोडा: प्रत्येक शब्दाला सगळ्यांकडे एकदम बघू द्या.
"कोण कुणाला किती लागू?" या एका प्रश्नाचं गणित = लक्ष.
आणि तेवढंच पुरेसं आहे: ना रांग, ना खिडकी.

पेपरचं शीर्षक हीच घोषणा आहे: लक्ष (attention) ही **जोड-सोय नाही; ती एकटीच पुरते:** बाकी सगळं (तेव्हाचं पवित्र RNN-यंत्र!) फेकून द्या. 2017 त हे उद्घट वाटलं; आज हे जगाचं वास्तव आहे.

एक वाक्य, एक प्रवास: या पुस्तकाची रीत

पुस्तकभर एकच काम करू: **"मांजर चटईवर बसली"** चं **"the cat sat on the mat"** होणं (पेपरचं स्वतःचं कामही भाषांतरच होतं!). हे वाक्य प्रत्येक chapter मध्ये यंत्राच्या एका-एका अवयवातून जाईल: आणि प्रत्येक अवयवाचं गणित आपण **छोट्या खऱ्या आकड्यांनी हाताने** करू (Book 7 च्या थेंबू-शैलीत). पेपर 'वाचणं' आणि पेपर 'चालवून बघणं' यांतला फरक हाच.

तीन भागांचा नकाशा: तुम्ही इथे आहात

- PART 1 पेपरआधीचं जग + पेपरची गोष्ट <- तुम्ही इथे
रांगेचं दुखणं, लक्षाचा जन्म, 8 लेखक, abstract
- PART 2 पेपरच्या आत: प्रत्येक समीकरण हाताने
Q-K-V, $\sqrt{d}$ चं गूढ, 8 डोकी, मुखवटा, sin-cos,
सांधे, शिकवण-निकाल
- PART 3 पेपरनंतरचं जग
GPT-BERT वंशावळ, काय टिकलं-बदललं, लेखकांचं
पुढे, मूळ पेपर सोबत-नकाशाने

कपाटावर एक नजर

- | | | | |
|--------|-----------------|---------|--|
| Book 1 | The Machine | Book 2 | The Thinking Machine |
| Book 3 | The Land Game | Book 4 | The Harness |
| Book 5 | The Blueprint | Book 6 | The Engine Room |
| Book 7 | The Lens | Book 8 | The Owner's Mind |
| Book 9 | The Claude Book | Book 10 | The Paper <- हे:
उगम-दस्तावेजाचा
पूर्ण उलगडा |

नाती स्पष्ट: Book 2 (4.2-4.3) ने attention ची **कल्पना** दिली; Book 7 (Part 4) ने त्याचं **गणित** हाताने केलं; हे पुस्तक त्या दोन्हींच्या मुळाशी जाऊन **पेपरच** पूर्ण करतं: तिथून पुढे तुम्ही कुठलाही AI-पेपर स्वबळावर वाचू शकाल (Book 7, 4.5 चं वचन इथे पूर्ण होतं).

एक इशारा, सुरुवातीलाच

पेपरचे सगळे आकडे-तपशील मूळ दस्तावेजातून आणि बाहेरून तपासलेले आहेत; लेखकांच्या-जन्मकथेच्या दंतकथा (ज्या भरपूर आहेत!) जिथे अपुष्ट तिथे तसंच म्हटलंय. आणि नेहमीची शिस्त: देव-पूजा नाही: पेपरमधल्या **अपूर्ण जागाही** दाखवू (लेखकांनाही तेव्हा माहीत नव्हतं की हे इतकं मोठं होईल: तो प्रामाणिकपणा हीच गोष्टीची चव).

विभाग 1: पेपरआधीचं जग आणि पेपरची गोष्ट

कुठलाही क्रांतिकारी दस्तावेज समजायचा तर आधी तो ज्या तुरुंगातून सुटका करतो तो तुरुंग समजावा लागतो. 2017 पूर्वी भाषा-AI एका रांगेत कैद होतं: शब्द एकामागोमाग एक वाचायचे: आणि त्या रांगेची तीन दुखणी जगातल्या सर्वात हुशार प्रयोगशाळांना अडवून बसली होती.

या विभागात चार दारं: **रांगेचं जग** (RNN/LSTM: दुखण्यांसकट), **लक्षाचा जन्म** (2014 ची पहिली ठिणगी: रांगेला जोडलेलं लक्ष), **पेपरची गोष्ट** (आठ माणसं, एक उन्हाळा, एक उद्धट शीर्षक), आणि **पेपर बाहेरून** (abstract चा शब्दागणिक उलगडा + पुढच्या प्रवासाचा नकाशा). विभाग संपेल तेव्हा पेपरचं पहिलं पान तुम्ही मूळ इंग्रजीत वाचून समजू शकाल.

Chapter 1.1 [SPINE]: रांगेचं जग: RNN/LSTM आणि तीन दुखणी

2017 पूर्वी यंत्राला वाक्य वाचायची एकच मान्य रीत होती: **रांगेने**. RNN (recurrent neural network: Book 2, 3.6 ची आठवण): यंत्र शब्द एकामागोमाग घेतं आणि एक **आठवण-गाठोडं** (hidden state) पुढे-पुढे सरकवत नेतं: प्रत्येक नव्या शब्दाने गाठोडं बदलतं.

उपमा: निरोप्याची साखळी. “मांजर चटईवर बसली” हे वाक्य गावाबाहेर पोहोचवायचंय. रीत अशी: पहिला निरोप्या “मांजर” ऐकतो, आपल्या डोक्यात ठेवून दुसऱ्याला **सारांश** सांगतो; दुसरा त्यात “चटईवर” मिसळून तिसऱ्याला; तिसरा “बसली” मिसळून चौथ्याला. शेवटच्या निरोप्याकडे अख्ख्या वाक्याचं **एकच घुसळलेलं गाठोडं** असतं: त्यातून त्याने भाषांतर करायचं.

दुखणं 1: लांबचं विसरणं. साखळी लांबली (50-100 शब्दांचं वाक्य) की सुरुवातीचे शब्द गाठोड्यात **विरत** जातात: 40 व्या शब्दापर्यंत “मांजर” चा वास फिका. गणिती नाव: vanishing gradients (Book 7, 3.3 चं chain-rule: 40 पायऱ्यांतून मागे जाताना गुणाकारांत संदेश शून्याकडे). LSTM (1997 ची सुधारणा: गाठोड्याला ‘लक्षात-ठेव/विसर’ अशी दारं) ने हे **सौम्य** केलं, **संपवलं नाही**: लांब पल्ल्याची नाती (वाक्याच्या सुरुवातीचा ‘तो’ आणि शेवटचं ‘गेला’ यांची जोडी) अजूनही धूसरच.

दुखणं 2: रांग म्हणजे वेळ. शब्द 7 वाचायच्या आधी शब्द 6 पूर्ण व्हावाच लागतो (त्याचं गाठोडं लागतं!): म्हणजे **समांतर काम अशक्य**. आणि नेमकं याच काळात hardware-जग उलट्या दिशेला गेलं होतं: GPU म्हणजे हजारो हात **एकाच वेळी** काम करणारं यंत्र (Book 6, 3.4). RNN त्या हजार हातांना रांगेत उभं करून एका-एका शब्दाची वाट बघायला लावायचा: विकत घेतलेली समांतर-शक्ती वाया. मोठा data, मोठी models: सगळं **रांगेच्या वेगाने** रखडलेलं.

दुखणं 3: गाठोड्याची चिंचोळी मान. अख्ख्या वाक्याचा अर्थ **एका ठरावीक-आकाराच्या** गाठोड्यात कोंबायचा (seq2seq रचना, 2014: वाचक-RNN ने गाठोडं बांधायचं, लेखक-RNN ने त्यातून भाषांतर काढायचं). 10 शब्दांना ठीक; 60 शब्दांचा परिच्छेद त्याच गाठोड्यात? पाण्याचा टँकर स्ट्रॉ मधून: माहिती **मानेतच** अडते.

आणि तरी हेच राज्य होतं. 2016 ला Google Translate ची मोठी झेप (GNMT) याच LSTM-तंत्रावर: जगातल्या सर्वोत्तम टीमा रांगेची दुखणी **औषधांनी** सांभाळत होत्या (दारं, युक्त्या, थरांवर थर): कुणी विचारत नव्हतं की **रांगच का हवी?** (Book 8, 1.1 आठवा: ‘असंच असतं’ चा वास: first-principles चा प्रश्न विचारायची वेळ भरली होती.)

एका वाक्यावर: आपलं “मांजर चटईवर बसली” रांगेच्या जगात असं जगायचं: ‘मांजर’ -> गाठोडं-1 -> +‘चटईवर’ -> गाठोडं-2 -> +‘बसली’ -> गाठोडं-3 -> त्या एकट्या गाठोड्यातून ‘the cat sat on the mat’ उपसायचं. तीन शब्दांना जमतं; तीस शब्दांना जीव घुसमटतो. **हे वाक्य आता पुस्तकभर आपल्यासोबत राहील: पुढच्या प्रत्येक chapter मध्ये त्याची सुटका टप्प्याटप्प्याने बघू.**

महाग चूक

”RNN ‘चुकीचं’ होतं आणि लेखकांनी ‘बरोबर’ शोधलं.” इतिहास असा साधा नसतो: RNN हा **त्या काळच्या hardware-data-मापाला योग्य सौदा** होता (Book 5 चं सूत्र: रचना-निर्णय = सौदा!): छोट्या data-युगात रांगेची शिस्त उपयोगीही होती. बदललं काय: **मैदान** (GPU-समांतरता स्वस्त, data महापूर): आणि जुन्या सौद्याच्या अटी शिळ्या झाल्या. धडा तांत्रिक कमी, मालकी-नजरेचा जास्त (Book 8, 2.4 चा Grove!): **तुमचं आजचं ‘योग्य’ तंत्र कुठल्या अटींवर उभं आहे, आणि त्या अटी कोण हलवतंय?**

नकाशावर

- 1.1 रांगेचं जग: RNN/LSTM = निरोप्यांची साखळी; तीन दुखणी:
लांबचं विसरण (vanishing) | समांतर-बंदी (GPU वाया) |
गाठोड्याची चिंचोळी मान (seq2seq)

सूत्रावर: सूत्र म्हणतं “रांग मोडा”: हा chapter सांगतो रांग **का** मोडायची होती: तिन्ही दुखणी रांगेच्याच पोटची. पुढे प्रश्न उरतो: रांगेशिवाय शब्दांचा **क्रम** कसा सांभाळायचा? (उत्तर 2.6 पर्यंत राखून ठेवा: पेपरची सर्वात नाजूक युक्ती तीच.)

स्वतः बघा (5 मिनिटं)

स्वतःवर प्रयोग: कुणाला तरी 25-30 शब्दांचं लांब वाक्य **एकदाच** वाचून दाखवा आणि लगेच भाषांतर/सारांश मागा: सुरुवातीचा भाग हमखास गळेल (माणसाचं गाठोडंही चिंचोळं!). मग तेच वाक्य **लिहून समोर** ठेवा: आता सगळं जमतं: कारण नजर **कुठल्याही शब्दाकडे केव्हाही** परत जाऊ शकते. हा दुसरा अनुभव म्हणजेच: attention. पेपरने यंत्राला नेमकी हीच सोय दिली.

विचार करा

रांगेची दुखणी 2015-16 लाच जगजाहीर होती. मग प्रश्न: क्रांतीच्या **आधीची पायरी** काय होती? म्हणजे: कुणीतरी रांग पूर्ण मोडण्याआधी रांगेला **कुबडी** लावून बघितली असणार: ती कुबडी कुठली, कुणी लावली, आणि तिनेच पुढच्या क्रांतीचा दरवाजा कसा दाखवला?

बरोबर ओळखलंत: लक्ष (attention) ही कल्पना 2017 ची नाही: 2014 चीच: पण **रांगेला जोडलेली मदतनीस** म्हणून. Bahdanau नावाच्या एका विद्यार्थ्याची ती युक्ती, आणि तिच्यातून निघालेला उद्धट प्रश्न: 'मदतनीसच इतकी हुशार, तर मालक कशाला?': पुढचा chapter: लक्षाचा जन्म.

Chapter 1.2 [SPINE]: लक्षाचा जन्म: 2014 ची ठिणगी

क्रांत्या शून्यातून येत नाहीत; **कुबड्यांमधून** येतात. Attention ची कुबडी 2017 च्या तीन वर्ष आधी लागली होती.

Sep 2014: Bahdanau-Cho-Bengio चा पेपर. Dzmitry Bahdanau (तेव्हा विद्यार्थी!) आणि सहकाऱ्यांनी seq2seq च्या चिंचोळ्या मानेवर (1.1 चं दुखणं-3) थेट घाव घातला. त्यांची युक्ती: **लेखक-RNN ला एकाच गाठोड्यावर जगायला लावू नका; त्याला प्रत्येक शब्द लिहिताना मूळ वाक्यातल्या सगळ्या शब्दांकडे मागे वळून बघू द्या: आणि 'आत्ता कुणाकडे किती बघायचं' हे त्याचं त्यालाच शिकू द्या.** हेच पहिलं attention: भाषांतर करताना 'the cat' लिहिण्याच्या क्षणी यंत्राची नजर आपोआप 'मांजर' वर: 'sat' लिहिताना 'बसली' वर: **जिवंत, वळणारी नजर:** गोठवलेल्या गाठोड्याऐवजी.

गणिताची पहिली चव (हाताने, पुढच्या भागाची तालीम): नजर 'वळते' म्हणजे नक्की काय? **वजनांची वाटणी.** 'sat' लिहिण्याच्या क्षणी यंत्र मूळ तीन शब्दांना गुण देतं (जुळणीचे: कसे ते Part 2 त): समजा मांजर=1.0, चटईवर=0.5, बसली=3.0. softmax (Book 7, 2.6) ने गुणांची **टक्केवारी:** 0.11, 0.07, 0.82. मग या टक्क्यांनी तिन्ही शब्दांच्या अर्थ-बाणांची (vectors) **भारित सरासरी:** म्हणजे 'sat' च्या क्षणीचं संदर्भ-गाठोडं 82% 'बसली' चं. **नजर = टक्केवारी. इतकंच.** पुढच्या क्षणी ('on' लिहिताना) टक्केवारी नवी: 'चटईवर' कडे झुकलेली. चिंचोळी मान गेली: प्रत्येक क्षणाला ताजं, त्या-क्षणापुरतं गाठोडं.

निकाल आणि मर्यादा. भाषांतर सुधारलं (लांब वाक्यांवर खासच); 2015 त Luong च्या पेपरने रीती आणखी घासल्या; 2016 च्या Google-Translate-झेपेतही (GNMT) attention-कुबडी होतीच. पण लक्षात घ्या रचना: **मालक अजून RNN च होता:** रांग कायम (दुखणं-2 जिवंत: समांतर-बंदी!), विसरणं सौम्य-पण-हजर, attention फक्त वाचक-लेखक यांना जोडणारा **पूल.** कुबडीने चालणं सुधारलं; रांगेचा तुरंग शाबूत.

आणि मग तो प्रश्न. अशा क्षणी इतिहास वळतो जेव्हा कुणीतरी मदतनीसाकडे बघून विचारतं: **"कामातलं खरं शहाणपण हिच्यातच दिसतंय: मग मालक (RNN) हवाच कशाला?"** first-principles चा शुद्ध क्षण (Book 8, 1.1): 'attention ही RNN ची सोय' हे **मत** होतं; 'शब्दा-शब्दांची जुळणी मोजता येते' हे **मूळ** होतं. मत सोलून फेकलं की उरतो प्रश्न: लक्ष **एकटं** पुरेल का: वाचकातही, लेखकातही, पुलावरही: सगळीकडे फक्त लक्ष? या प्रश्नाचं 15-पानी उत्तर म्हणजे आपला पेपर: आणि त्याचं शीर्षक हा प्रश्नच आहे, उत्तरासकट: **Attention Is All You Need.**

महाग चूक

”क्रांतिकारी कल्पना ‘नवीन’ असते.” Attention 2014 ला जन्मली, 2015-16 त सर्वत्र वापरात होती: **2017 चा पेपर एकही मूलभूत नवी संकल्पना आणत नाही!** त्याची क्रांती **वजा-करण्यात** आहे: सगळे RNN काढून फक्त attention ठेवणं: हे धाडस कल्पनेचं नाही, **विश्वासाचं** (कुबडी मालक होऊ शकते हा विश्वास). इतिहासात हे परत-परत दिसतं: क्रांती बहुधा नव्या तुकड्यात नसते; **जुन्या तुकड्यांच्या उद्धट फेर-मांडणीत** असते (Book 8, 1.1: मुळांची फेर-जुळणी). ‘माझ्याकडे नवं काही नाही’ म्हणून थांबलेल्यांनी हे लक्षात ठेवावं: फेर-मांडणीचं धाडस हीच अनेकदा खरी नवता.

नकाशावर

- 1.1 रांगेचं जग: तीन दुखणी
- 1.2 लक्षाचा जन्म: Bahdanau 2014: लेखकाला मूळ वाक्यभर वळणारी नजर (नजर = softmax-टक्केवारी x भारित सरासरी); पण मालक RNN च; मग प्रश्न: ‘मदतनीसच हुशार, तर मालक कशाला?’

सूत्रावर: “कोण कुणाला किती लागू?” हे सूत्रातलं गणित 2014 लाच जगात आलं: 2017 ने फक्त (फक्त!) ‘तेवढंच पुरेसं आहे’ हे सिद्ध केलं. सूत्राचा पूर्वार्ध Bahdanau चा, उत्तरार्ध पेपरचा.

स्वतः बघा (5 मिनिटं)

तुम्ही स्वतः भाषांतर करताना तुमची नजर बघा: कुठलंही इंग्रजी वाक्य घ्या आणि मराठीत लिहिताना **प्रत्येक मराठी शब्दाच्या क्षणी तुमची नजर इंग्रजीत कुठे आहे** ते टिपा. नजर उड्या मारते (क्रमाने जात नाही!), आणि प्रत्येक क्षणी 1-2 शब्दांवर जड असते: तुम्ही आत्ता स्वतःमधलं attention पकडलंत: softmax-टक्केवारीसकट (जड नजर = मोठं वजन).

विचार करा

प्रश्न विचारला गेला: “लक्ष एकटं पुरेल का?” पण प्रश्न विचारणं आणि 15 पानांत जगाला पटवणं यात अंतर आहे. कुणी विचारला हा प्रश्न? कुठे? आणि आठ नावं पेपरवर आहेत: **आठ जणांनी मिळून एक पेपर कसा घडतो: कुणी काय केलं?**

पुढचा chapter गोष्टीचा: Google च्या इमारतीतले आठ जण, एका boardवरचं वाक्य, तीन महिन्यांची शर्यत, Beatles च्या गाण्यातून आलेलं शीर्षक, आणि ‘योगदान सर्वांचं सारखं: क्रम चिठ्ठ्या टाकून’ ही पेपरवरची अनोखी तळटीप: पेपरची जन्मकथा.

Chapter 1.3 [SPINE]: पेपरची गोष्ट: आठ माणसं, एक शर्यत, एक उद्धट शीर्षक

जागा: Google, 2017. आठ जण: Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan Gomez, Lukasz Kaiser, Illia Polosukhin. कुणी वरिष्ठ संशोधक, कुणी नुकतेच आलेले: आणि **Aidan Gomez तर Toronto चा शिकाऊ (intern)** होता: पेपरवर त्याचं नाव विद्यापीठाच्या पत्त्यासकट आहे! Polosukhin पेपर छापला जाईपर्यंत Google सोडूनही गेला होता (तळटीप: 'काम Google त असताना केलं'). म्हणजे: इतिहास घडवणारा गट 'निवडलेल्या ताऱ्यांचा' नव्हता: **कल्पनेभोवती जमलेल्या उत्सुकांचा** होता.

कल्पनेचा प्रवाह. 'रांगेशिवाय, फक्त लक्षाने' ही दिशा आतल्या वर्तुळात Jakob Uszkoreit जोरात मांडत होता (self-attention वरचं त्याचं काम 2017 आधीचं): गंमत म्हणजे त्याचे वडील (प्रसिद्ध भाषा-वैज्ञानिक) यालाही साशंक होते! Vaswani-Shazeer-Parmar आणि बाकीचे जुळत गेले; Shazeer (जुना-मुरलेला engineer) ने यंत्रणा घडवण्यात मोठा वाटा उचलला. मग **NIPS 2017 (आजचं NeurIPS) च्या deadline ची शर्यत: May 19, 2017:** शेवटचे आठवडे रात्र-दिवस: प्रयोग, तक्ते, लिखाण: आणि deadline च्या 'दोन रात्री आधी' Llion Jones ने शीर्षक सुचवलं: Beatles च्या "All You Need Is Love" वरून: **"Attention Is All You Need."** (यंत्राचं नाव 'Transformer' Uszkoreit चं: कारण साधं: त्याला शब्दाचा नाद आवडला!) Jun 12, 2017 ला arXiv वर जगासमोर.

पेपरवरची अनोखी तळटीप. पहिल्याच पानावर: **"Equal contribution. Listing order is random."** (योगदान सर्वांचं सारखं; नावांचा क्रम चिठ्ठीने). शैक्षणिक जगात नाव-क्रम ही युद्धभूमी असते (पहिलं नाव = श्रेय); या आठांनी ती लढाईच रद्द केली. Book 8 (3.3) ची संस्कृती-नजर: **हा छोटा निर्णय गटाच्या आतल्या विश्वासाचं मोठं मोजमाप आहे:** आणि योगायोग नव्हे की अशाच गटातून बिनधास्त 'सगळं RNN फेकून द्या' निघू शकलं (भीतीच्या संस्कृतीत कुणी हे बोललंही नसतं: Nokia आठवा).

निकालाची झलक (तपशील 2.8 त): भाषांतर-स्पर्धेच्या (WMT 2014) दोन्ही मैदानांत नवा विक्रम: आणि **आधीच्या विजेत्यांच्या अंशात्मक खर्चात** (8 GPU वर साडेतीन दिवस: तेव्हाचे विजेते आठवडे जळायचे). पण 2017 त जग 'बरं, छान पेपर' म्हणालं: क्रांती **ओळखली** गेली नव्हती: ती पुढच्या पाच वर्षांत उलगडत गेली (Part 3). आज: **2 लाखांवर citations: या शतकातल्या सर्वात-उल्लेखलेल्या पेपरांच्या पहिल्या दहांत** (गंमत: पहिला नंबर अजूनही ResNet चा: Book 2 च्या जगालाही नमस्कार).

आणि गोष्टीचा काटा (Book 8, 3.5 ची पुनरावृत्ती): हा पेपर Google चा. पण त्याचं सोनं केलं OpenAI ने (GPT-मालिका: 3.1). आणि आठही लेखक **Google सोडून गेले** (शेवटचा Llion Jones, 2023): कुणी स्वतःच्या कंपनी काढल्या, कुणी स्पर्धकांकडे (आजचे पत्ते: 3.3 त: त्यात Anthropic ही आहे!). Kodak-प्रश्न पुन्हा: **शोध घरात, फायदा दारात:** का होतं हे: Part 3 त खोदू.

महाग चूक

”असे पेपर ‘प्रतिभेच्या झटक्यात’ जन्मतात.” गोष्ट उलटी शिकवते: (1) कल्पना **जुनीच** होती (1.2: attention 2014 चं; self-attention वरही आधी काम); (2) गट **खुल्या दाराचा** होता (intern सकट; श्रेय-लढाई रद्द); (3) झटका नव्हे, **deadline-शर्यत** होती: प्रयोग- तक्ते-घासणं. म्हणजे कृती-सूत्र असं: जुन्या कल्पना + मोकळा गट + सक्तीची मुदत = क्रांतीची शक्यता. ‘प्रतिभेची वाट बघणं’ ही सर्वात महाग वाट: **रचना बांधता येते, झटका नाही.**

नकाशावर

- 1.1 रांगेचं जग: तीन दुखणी
- 1.2 लक्षाचा जन्म: Bahdanau 2014 + उद्धट प्रश्न
- 1.3 पेपरची गोष्ट: 8 लेखक (intern सकट), equal-contribution-चिठ्ठी, deadline-शर्यत, Beatles-शीर्षक, 'Transformer' = नादासाठी; आज 200K+ citations; सगळे Google सोडून गेले

सूत्रावर: शीर्षकाचा उद्धटपणा ('तेवढंच पुरेसं!') हा गटाच्या आतल्या मोकळेपणाचं फळ होता: विश्वासाच्या खोलीतच धाडसी वाक्यं जन्मतात: सूत्र यंत्राचं आहे, पण गोष्ट माणसांची.

स्वतः बघा (5 मिनिटं)

पेपरचं पहिलं पान उघडा: नावं वाचा, तळटीपा वाचा (Gomez ची Toronto-टीप, Polosukhin ची 'काम-तेव्हाचं' टीप, equal-contribution- ओळ). मग स्वतःला: तुमच्या कामाच्या जगात 'श्रेयाची चिठ्ठी-वाटणी' चालेल का: आणि न चालण्याने कुठली धाडसी वाक्यं बोलली जात नाहीयेत? (उत्तर अस्वस्थ करेल: तीच किंमत.)

विचार करा

गोष्ट झाली; आता दस्तावेज. पेपरचं पहिलं पान म्हणजे **abstract**: आठ ओळींत अख्खा दावा. पण संशोधन-पेपरची भाषा दाट असते: प्रत्येक शब्द वजनाने भरलेला. ती आठ-ओळी नक्की काय **दावा** करतात: आणि 'दावा' विरुद्ध 'पुरावा' ही पेपरची रचना कशी वाचायची?

पुढचा chapter: abstract चा शब्दागणिक उलगडा + पेपरच्या सात विभागांचा नकाशा + निकालाचे दोन आकडे जे पाठ करण्याजोगे आहेत: 28.4 आणि 3.5 दिवस. विभागाचा शेवट.

Chapter 1.4 [SPINE]: पेपर बाहेरून: abstract चा उलगडा आणि विभाग-नकाशा

संशोधन-पेपर वाचायची पहिली विद्या (Book 7, 4.5 ची उजळणी): **पेपर = दावा + पुरावा**. Abstract म्हणजे दाव्याचं आठ-ओळी रूप. आपल्या पेपरचा abstract वाक्या-वाक्याने मराठीत सोलू (मूळ इंग्रजी सोबत ठेवून वाचा: शब्द जुळवत):

ओळ 1-2 (जुनं जग): "प्रचलित sequence-यंत्रं गुंतागुंतीच्या recurrent/convolutional जाळ्यांवर उभी आहेत: encoder-decoder रचनेत." -> आपला 1.1: रांगेचं जग.
ओळ 3 (कुबडी): "सर्वोत्तम यंत्रं attention ने encoder-decoder जोडतात." -> आपला 1.2: Bahdanau ची कुबडी.
ओळ 4 (दावा!): "आम्ही Transformer ही नवी, साधी रचना मांडतो: फक्त attention वर; recurrence आणि convolutions पूर्ण वगळून." -> 'साधी' (simple) हा शब्द मुद्दाम आहे: अभिमानाचा: गुंतागुंत कापली हीच प्रगती.
ओळ 5-7 (पुरावा-झलक): "दोन भाषांतर-स्पर्धात सरस: EN-DE 28.4 BLEU (जुन्या विक्रमाहून 2+ ने वर, ensembles सकट); EN-FR 41.8: 8 GPU वर 3.5 दिवसांत: साहित्यातल्या सर्वोत्तम यंत्रांच्या खर्चाच्या अंशात." -> दावा दुहेरी: भारी आणि स्वस्त.
ओळ 8 (सामान्यीकरण): "इंग्रजी वाक्य-विश्लेषणावरही चालतं: रचना general आहे." -> भविष्याची चाहूल: फक्त भाषांतर नाही: (केवढी खरी ठरली हे Part 3!)

दोन आकडे पाठ करा: 28.4 (EN-DE BLEU: भाषांतर-गुणवत्तेचं प्रमाण-माप: जुना विक्रम ~26: उडी मोठी) आणि **3.5 दिवस x 8 GPU** (मोठ्या model ची पूर्ण शिकवण: तेव्हाच्या विजेत्यांना आठवडे-महिने). हे दोन आकडे म्हणजे पेपरचा अख्खा दावा: **वर गुणवत्ता, खाली खर्च**: आणि खर्च का कोसळला? रांग गेली म्हणून (1.1 चं दुखणं-2): समांतर GPU-हात पूर्ण कामाला: रचनेचा शोध हा **अर्थशास्त्राचाही** शोध होता (Book 8, 1.4: याच स्वस्ताईने पुढे scaling परवडलं: आजच्या राक्षसांची वाट इथून).

पेपरचा विभाग-नकाशा (7 विभाग, आपले पत्ते):

पेपर-विभाग	आपल्या पुस्तकात
1 Introduction (जुनं जग, दावा)	Part 1 (झालं!)
2 Background (आधीचे प्रयत्न)	1.2 + 2.8 ची complexity-चर्चा
3 Model Architecture (मुख्य!)	2.1-2.7 (पुढचे सात chapters)
4 Why Self-Attention (तुलना-तक्ता)	2.8
5 Training (शिकवण-तपशील)	2.8
6 Results (निकाल + ablations)	2.8
7 Conclusion (भविष्य-दिशा)	Part 3

म्हणजे पेपरचा गाभा **विभाग 3** आहे (साडेतीन पानं, 5 समीकरणं, 2 आकृत्या): आणि आपला अख्खा विभाग 2 त्याचीच सावकाश, हाताच्या-आकड्यांची आवृत्ती. पेपर 15 पानी का, तर: दावा 1 पान, यंत्र 4 पानं, पुरावा-संदर्भ 10: **चांगल्या दाव्याला पुराव्याचं वजन लागतं** (Book 8, 1.7: लिहून-सिद्ध-करण्याची संस्कृती).

महाग चूक

"Abstract वाचला = पेपर कळला." Abstract हा **जाहिरात-दावा** आहे (प्रामाणिक, पण दावाच): 'काय' सांगतो, 'कस-का' नाही. Abstract-वाचनावर मतं बनवणारे (आणि हल्ली शीर्षक-वाचनावर!) गोंधळ पसरवतात: 'attention is all you need' चा शब्दशः अर्थ घेऊन 'बाकी काही लागतच नाही' म्हणणारे विसरतात की पेपरच्या यंत्रात FFN-सांधे-embeddings सगळं आहे (2.7 त बघू: शीर्षक 'रांग-खिडकी लागत नाही' म्हणतं, 'फक्त attention पुरतं' नाही!). शिस्त: **abstract = नकाशाची खूण; प्रवास = आतले विभाग.**

नकाशावर

- 1.1 रांगेचं जग 1.2 लक्षाचा जन्म 1.3 पेपरची गोष्ट
- 1.4 पेपर बाहेरून: abstract = दावा (साधी रचना, फक्त लक्ष;
28.4 BLEU; 3.5 दिवस x 8 GPU); 7-विभाग नकाशा; गाभा =
विभाग 3; शीर्षकाचा नेमका अर्थ: 'रांग-खिडकी नको'

सूत्रावर: abstract चं 'simple' हे विशेषण सूत्राचाच अभिमान आहे: एक प्रश्न ("कोण कुणाला किती लागू?") गुंतागुंतीच्या रांगांची जागा घेतो: साधेपण ही ताकद.

स्वतः बघा (5 मिनिटं)

आता मूळ abstract **इंग्रजीत** वाचा (पेपरचं पान 1): वरच्या मराठी उलगड्याशी ओळ-ओळ जुळवत. न अडता वाचता आला? मग हा विभाग सफल: तुम्ही जगातल्या सर्वात प्रभावी वैज्ञानिक दस्तावेजाचं पहिलं पान **मुळातून** वाचलंत. अडलेले शब्द लिहून ठेवा: विभाग 2 संपेपर्यंत प्रत्येकाचं घर लागलेलं असेल.

विचार करा

विभाग संपला. दावा हातात: “रांगेशिवाय, फक्त लक्षाने: भारी आणि स्वस्त.” आता आतली सफर: पण दाराशीच पहिला प्रश्न अडतो: ‘लक्ष’ या शब्दाचं यंत्र-रूप. 1.2 त टक्केवारी बघितली: पण टक्केवारीआधी **गुण** लागतात: ‘बसली’ ला ‘मांजर’ किती लागू हे यंत्र **कशाने** मोजतं? शब्दांची ‘जुळणी’ मोजणारं गणित नक्की कुठलं?

उत्तर पेपरच्या हृदयात: प्रत्येक शब्दाला तीन रूपं द्यायची: प्रश्न (Query), पत्ता (Key), ऐवज (Value): आणि जुळणी = प्रश्न-पत्त्याचा dot product (Book 7, 1.2 ची सावली परतली!). विभाग 2: ग्रंथालयात भेटू.

विभाग 1 चा हिशोब

चार दारं एका नजरेत

- 1.1 रांगेचं जग RNN/LSTM = निरोप्यांची साखळी; दुखणी: विसरण | समांतर-बंदी | चिंचोळी मान
- 1.2 लक्षाचा जन्म Bahdanau 2014: वळणारी नजर = softmax-टक्केवारी; पण मालक RNN च; उद्धट प्रश्न
- 1.3 पेपरची गोष्ट 8 लेखक, चिठ्ठी-श्रेय, deadline-शर्यत, Beatles-शीर्षक; 200K+ citations
- 1.4 पेपर बाहेरून abstract = दावा; 28.4 BLEU + 3.5 दिवस; 7-विभाग नकाशा; गाभा = विभाग 3

स्वतःची परीक्षा (आधी उत्तरं, मग खाली)

1. रांगेची तीन दुखणी सांगा: आणि त्यातलं कुठलं दुखणं थेट 'पैशाचं' होतं?
2. Bahdanau च्या attention मध्ये आणि 2017 च्या दाव्यात नेमका फरक काय?
3. "Attention Is All You Need" या शीर्षकाचा नेमका (आणि चुकीचा-लोकप्रिय) अर्थ काय?
4. 28.4 आणि 3.5 हे दोन आकडे कशाचे: आणि दुसरा आकडा पहिल्याइतकाच क्रांतिकारी का?

उत्तरं: (1) लांबचं विसरणं, समांतर-बंदी, चिंचोळी मान; समांतर-बंदी = GPU-गुंतवणूक वाया = थेट पैसा (1.1). (2) Bahdanau: लक्ष ही RNN-मालकाची मदतनीस; 2017: मालकच काढून टाकला: लक्ष एकटं (1.2). (3) नेमका: recurrence आणि convolution लागत नाहीत; चुकीचा-लोकप्रिय: 'attention शिवाय काहीच लागत नाही' (यंत्रात FFN-सांधेही आहेत!) (1.4). (4) EN-DE BLEU 28.4 (गुणवत्ता-विक्रम) आणि 8 GPU x 3.5 दिवस (खर्च-कोसळ): स्वस्त शिकवण = मोठं scaling परवडणं = आजचे राक्षस: दुसरा आकडा भविष्य घडवणारा (1.4).

चाहूल: विभाग 2

आता पेपरचा गाभा: ग्रंथालयाची उपमा घेऊन Q-K-V; आपल्या तीन शब्दांवर पूर्ण हाताचं गणित; $\sqrt{d}$ चं गूढ; आठ डोकी; मुखवटा; sin-cos ची क्रम-जादू; आणि सांधे. पेन तयार ठेवा.

छोटा शब्दकोश (विभाग 1)

RNN/LSTM	रांगेने वाचणारं यंत्र / त्याची दारांवाली सुधारणा
hidden state	निरोप्याचं आठवण-गाठोडं
vanishing gradient	मागे जाताना शिकवण-संदेश विरणं
seq2seq	वाचक-गाठोडं-लेखक ही 2014 ची रचना
attention	'कोण कुणाला किती लागू' ची शिकता-येणारी टक्केवारी-नजर
BLEU	भाषांतर-गुणवत्तेचं प्रमाण-माप (जास्त = चांगलं)
abstract	पेपरच्या दाव्याचं आठ-ओळी रूप
Transformer	पेपरने मांडलेलं रांग-विरहित यंत्र (नाव: Uszkoreit ला नाद आवडला म्हणून!)