

The Paper, Part 2: पेपरच्या आत, प्रत्येक समीकरण हाताने

August 30, 2026

विभाग 2: पेपरच्या आत: प्रत्येक समीकरण हाताने

आता मुख्य काम: पेपरचं यंत्र (Transformer) **अवयवागणिक उघडू**: आणि प्रत्येक अवयवाचं गणित छोट्या खऱ्या आकड्यांनी हाताने करू. शिस्त Book 7 चीच: कुठलंही चिन्ह आधी मराठी वाक्य म्हणून, मगच गणित म्हणून.

आठ दारं: **सांगाडा** (6+6 मजल्यांची इमारत), **Q-K-V** (पेपरचं हृदय: हाताने), $\sqrt{d}$ चं गूढ (एका भागाकाराची अख्खी गोष्ट), **8 डोकी** (multi-head), **तीन जागी लक्ष + मुखवटा**, **sin-cos ची जादू** (रांगेशिवाय क्रम), **सांधे** (FFN, residual, LayerNorm), आणि **शिकवण-निकाल** (यंत्र शिकवलं कसं, जिंकलं किती). आपलं वाक्य ("मांजर चटईवर बसली") प्रत्येक दारातून जाईल.

एक धीराचा शब्द: हा विभाग पुस्तकातला सर्वात दाट आहे: पण प्रत्येक पायरी मागच्यावर उभी आहे आणि कुठेही उडी नाही. पेन घ्या: हाताने केलेलं गणित विसरत नाही.

Chapter 2.1 [SPINE]: सांगाडा: 6+6 मजल्यांची इमारत

पेपरच्या पान-3 वरची प्रसिद्ध आकृती (Figure 1) शब्दांत उभी करू. Transformer ची इमारत दोन मनोऱ्यांची आहे:

वाचक-मनोरा (encoder): 6 सारखे मजले, एकावर एक
काम: मूळ वाक्य ("मांजर चटईवर बसली") पूर्ण समजून
प्रत्येक शब्दाचं समृद्ध अर्थ-रूप बनवणं
लेखक-मनोरा (decoder): 6 सारखे मजले
काम: भाषांतर एक-एक शब्द घडवणं ("the" -> "cat" ->
"sat"...), प्रत्येक शब्दाच्या क्षणी वाचक-मनोऱ्याकडे
बघत (cross-attention: 2.5)

प्रत्येक वाचक-मजल्यात दोनच खोल्या: (1) **लक्ष-खोली** (self-attention): शब्द एकमेकांकडे बघून आपापले अर्थ ताजे करतात (पुढचे 4 chapters हिच्याच); (2) **विचार-खोली** (feed-forward: 2.7): प्रत्येक शब्द **एकटा** बसून आपल्या ताज्या अर्थावर प्रक्रिया करतो. लेखक-मजल्यात तिसरी खोली जास्त: **वाचक-मनोऱ्याकडे बघण्याची खिडकी** (cross-attention). आणि प्रत्येक खोलीभोवती दोन सुरक्षा-सोयी: उडी-रस्ता (residual) आणि तराजू (LayerNorm): 2.7 त.

आकड्यांची ओळख (पेपरचा base-साचा): प्रत्येक शब्द इमारतीत **512 आकड्यांचा बाण** ($d_{\text{model}}=512$: Book 7, 1.1 चे vectors) म्हणून फिरतो. मजले $N=6$. हे आकडे 'पवित्र' नाहीत: लेखकांनी प्रयोगाने ठरवलेले सौदे आहेत (मोठा साचा: 1024: महाग-भारी: 2.8). **आणि सर्वात महत्वाचं वाक्य: इमारतीत RNN कुठेच नाही.** कुठल्याही मजल्यावर 'रांग' नाही: लक्ष-खोलीत सगळे शब्द **एकाच वेळी** एकमेकांकडे बघतात, विचार-खोलीत सगळे **एकाच वेळी** एकटे विचार करतात: 1.1 चं दुखणं-2 (समांतर-बंदी) मुळापासून गेलं: GPU चे हजार हात आता खरंच हजार हात.

एका वाक्यावर (इमारत-फेरी): "मांजर चटईवर बसली": तीन शब्द -> तीन 512-बाण इमारतीच्या तळमजल्यावर एकदम शिरतात (अधिक क्रमाची खूण: 2.6 ची sin-cos-मुद्रा: तूर्त 'लावलीये' इतकंच). मजला 1: लक्ष-खोलीत तिघे एकमेकांकडे बघतात ('बसली' ला कळतं की कर्ता 'मांजर' आहे), विचार-खोलीत प्रत्येक स्वतःला घासतो. तेच $\times 6$. वर पोहोचतात तीन **पिकलेले** बाण: प्रत्येकात आता स्वतःसोबत वाक्य-संदर्भही मुरलेला. मग लेखक-मनोरा 'the' पासून सुरुवात करून या पिकलेल्या बाणांकडे बघत-बघत इंग्रजी घडवतो. तपशील पुढे; **इमारतीचा नकाशा हा असा.**

महाग चूक

”6 मजले म्हणजे 6 वेगवेगळी कामं करणारे विभाग असतील.” नाही: सहाही मजले **रचनेने सारखे** (वजनं वेगळी शिकतात): हीच पेपरची सौंदर्य-चाल: एक साधा block, फक्त **पुनरावृत्ती**. खोली येते थरांच्या साचण्यातून (खालचे मजले जवळचे-साधे संबंध टिपतात, वरचे लांबचे-गुंतागुंतीचे: हे शिकण्यातून घडतं, रचनेतून नाही). Book 5 (1.16) ची आठवण: उत्तम रचना ‘हुशार गुंतागुंत’ नसते; **साध्या तुकड्याची शिस्तबद्ध पुनरावृत्ती** असते: आजचे 100-थरांचे राक्षसही (Claude सकट) हाच block थरावर थर रचून बांधलेत.

नकाशावर

2.1 सांगाडा: वाचक 6 + लेखक 6 सारखे मजले; मजला = लक्ष-
खोली + विचार-खोली (+लेखकात खिडकी); शब्द = 512-बाण;
RNN शून्य: सगळं समांतर

सूत्रावर: “ना रांग, ना खिडकी” ची पहिली प्रत्यक्ष भेट: इमारतीत रांगच बांधलेली नाही. उरलेला विभाग एकाच प्रश्नाचा तपशील: लक्ष-खोलीत नक्की घडतं काय?

स्वतः बघा (5 मिनिटं)

मूळ पेपर उघडा (arxiv.org/abs/1706.03762: फुकट) आणि **फक्त Figure 1** बघा (पान 3). या chapter नंतर त्यातलं प्रत्येक खोकं ओळखीचं वाटलं पाहिजे: डावा मनोरा, उजवा मनोरा, Multi-Head Attention चे ठोकळे, Feed Forward, Add & Norm च्या पट्ट्या. न कळलेली खोकी लिहून ठेवा: विभाग संपेपर्यंत प्रत्येकाचं दार उघडणार आहे: ही यादी तुमची प्रगती-पट्टी.

विचार करा

लक्ष-खोलीत “शब्द एकमेकांकडे बघतात” म्हणालो. पण ‘बघणं’ यंत्रात कसं उतरवायचं? 1.2 त टक्केवारी बघितली: पण ती टक्केवारी **कुठून** येते? दोन शब्दांची ‘जुळणी किती’ हे ठरवायला यंत्राकडे नक्की कुठलं गणित आहे: आणि प्रत्येक शब्द ‘बघणारा’, ‘दाखवणारा’ आणि ‘देणारा’ अशा तीन भूमिका एकदम कसा निभावतो?

आलं पेपरचं हृदय: Query, Key, Value: प्रश्न, पत्ता, ऐवज: ग्रंथालयाची उपमा आणि पूर्ण हाताचं गणित: आपल्या तीन शब्दांवर, खऱ्या आकड्यांनी. पुढचा chapter या पुस्तकातला सर्वात महत्त्वाचा आहे.

Chapter 2.2 [SPINE]: Q-K-V: पेपरचं हृदय, हाताच्या आकड्यांनी

ग्रंथालयाची उपमा (एकदा पक्की करा: पुस्तकभर पुरेल). तुम्ही ग्रंथालयात जाता. तुमच्या हातात **प्रश्न-चिठ्ठी** (Query): “स्वयंपाकाची पुस्तकं हवीत.” प्रत्येक कप्यावर **पत्ता-पाटी** (Key): “इतिहास”, “स्वयंपाक”, “प्रवास”. आणि कप्याच्या आत **ऐवज** (Value): प्रत्यक्ष पुस्तकं. रीत: तुमची चिठ्ठी प्रत्येक पाटीशी **जुळवायची** (जुळणी जास्त = त्या कप्याकडे लक्ष जास्त), आणि जुळणीच्या प्रमाणात ऐवज गोळा करायचा. Attention म्हणजे नेमकं हेच: फक्त इथे **प्रत्येक शब्द एकाच वेळी वाचक आणि कप्या** असतो: त्याची स्वतःची चिठ्ठी (Q), स्वतःची पाटी (K), स्वतःचा ऐवज (V).

तीन रूपं येतात कुठून? प्रत्येक शब्दाच्या अर्थ-बाणाला (embedding: Book 2, 3.2) तीन **शिकलेली रूपांतर-यंत्रं** (matrices W_Q, W_K, W_V : Book 7, 1.3!) लावली की तीन रूपं निघतात. उदाहरणादाखल ‘मांजर’ चा (सोपेपणासाठी) 4-आकडी बाण आणि 4×2 चं W_Q घेऊ: बाण $[1, 0, 1, 0]$ $\times W_Q =$ चिठ्ठी $[1.0, 0.8]$ (Book 7, 1.4 चा गुणाकार). **हे गुणाकार यंत्र शिकतं:** ‘चिठ्ठी कशी लिहावी’ हीच त्याची विद्या. पुढच्या गणितासाठी तिन्ही शब्दांची तयार रूपं (2-आकडी: हाताला पेलतील अशी):

शब्द	चिठ्ठी Q	पाटी K	ऐवज V
मांजर	$[0.9, 0.2]$	$[1.0, 0.8]$	$[2, 0]$
चटईवर	$[0.3, 0.5]$	$[0.2, 0.4]$	$[0, 2]$
बसली	$[1.0, 1.0]$	$[0.6, 0.6]$	$[1, 1]$

आता पेपरचं समीकरण-1, पायरी-पायरीने. ‘बसली’ या शब्दाला वाक्य समजायचंय (कर्ता कोण? कुठे?). त्याची चिठ्ठी $Q=[1,1]$ प्रत्येक पाटीशी जुळवू: जुळणीचं गणित = **dot product** (Book 7, 1.2: सावली-गुणाकार: दिशा जुळल्या तर मोठा):

पायरी 1: गुण (scores)
 बसली-मांजर: $1 \times 1.0 + 1 \times 0.8 = 1.8$ <- सर्वात जुळलं!
 बसली-चटईवर: $1 \times 0.2 + 1 \times 0.4 = 0.6$
 बसली-बसली: $1 \times 0.6 + 1 \times 0.6 = 1.2$
 पायरी 2: $\sqrt{d_k}$ ने भागा ($d_k=2$, $\sqrt{2} = 1.41$: का ते 2.3 त!)
 $1.8/1.41=1.28$ $0.6/1.41=0.43$ $1.2/1.41=0.85$
 पायरी 3: softmax (Book 7, 2.6: गुणांची टक्केवारी)
 $e^{1.28}=3.60$ $e^{0.43}=1.54$ $e^{0.85}=2.34$ (बेरीज 7.48)
 टक्के: 0.48, 0.21, 0.31
 पायरी 4: टक्क्यांनी ऐवजांची भारित बेरीज
 $0.48 \times [2, 0] + 0.21 \times [0, 2] + 0.31 \times [1, 1]$
 $= [0.96+0+0.31, 0+0.42+0.31] = [1.27, 0.73]$

झालं! 'बसली' चं नवं रूप [1.27, 0.73]: त्यात 48% 'मांजर' मुरलंय (कर्ता सापडला!), 21% जागा, 31% स्वतः. **हेच पेपरचं हृदय-समीकरण:** $\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d_k})V$: आपण आता ते हाताने चालवलं. आणि सगळ्यात सुंदर: हेच गणित तिन्ही शब्दांसाठी **एकाच वेळी** होतं (प्रत्येकाची स्वतःची चिठ्ठी: तीन प्रश्न, एकदम): Q, K, V हे तक्ते (matrices) बनवून एकच मोठा गुणाकार: GPU चं आवडतं जेवण (1.1 चं दुखणं-2 इथेच मरतं).

हे 'समज' का आहे (नुसती बेरीज का नाही)? कारण टक्केवारी शिकलेली आहे: W_Q-W_K अशी घडतात की व्याकरणाला जे जुळायला हवं (क्रियापद-कर्ता, सर्वनाम-नाम) त्यांच्या चिठ्ठ्या-पाट्या जुळतात. 'ती बसली' मधल्या 'ती' ची चिठ्ठी 'मांजर' च्या पाटीशी जुळणं: **संदर्भ-समज म्हणजे हीच जुळणी** (Book 2, 4.3 चं 'ambiguity-निवारण' आता समीकरणात दिसलं).

महाग चूक

"Q, K, V ही तीन वेगळी क्लिष्ट यंत्रं आहेत." उलट: तिन्ही **एकाच बाणाची तीन रूपं** आहेत: तीन साधे गुणाकार: आणि संपूर्ण attention म्हणजे फक्त चार पायऱ्या: गुणाकार, भागाकार, टक्केवारी, भारित-बेरीज: **शाळेचं गणित**. पेपरची दहशत वाटते ती चिन्हांमुळे ($QK^T/\sqrt{d_k}$!); चिन्हं सोलली की आत चौथीची आकडेमोड. हा धडा सगळ्या AI-पेपरांचा: **दहशत notation ची असते, गणिताची नसते** (Book 7 चं पूर्ण सूत्र: चष्मा लावा, डोंगर सपाट).

नकाशावर

- 2.1 सांगाडा: 6+6, समांतर
- 2.2 Q-K-V: चिठ्ठी-पाटी-ऐवज; 4 पायऱ्या: dot-गुण -> $\sqrt{d_k}$ -भाग -> softmax-टक्के -> भारित-बेरीज; 'बसली' = 48% मांजर; सगळं एकाच matrix-गुणाकारात, एकदम

सूत्रावर: "कोण कुणाला किती लागू?" या सूत्र-प्रश्नाचं उत्तर आता नेमकं आहे: **चिठ्ठी x पाटी**. बाकी सगळं पुस्तक या चार पायऱ्यांभोवतीचे मजले आहेत.

स्वतः बघा (5 मिनिटं)

वरचं गणित **स्वतःच्या हाताने** परत करा: पण आता 'चटईवर' साठी ($Q=[0.3, 0.5]$): तिन्ही गुण, भागाकार, softmax (e^x साठी phone-calculator), भारित बेरीज. उत्तर तपासायला Claude ला विचारा. दहा मिनिटांत तुम्ही जगातलं सर्वात प्रभावी समीकरण दोनदा हाताने चालवलेलं असेल: आता ते तुमचं आहे.

—

विचार करा

पायरी 2 गूढ राहिली: $\sqrt{d_k}$ ने भागलं: का? 1.41 ने भागण्याने असं काय घडतं? आणि पेपरचे लेखक इतक्या बारीक गोष्टीला शीर्षक-समीकरणात जागा का देतात: 'scaled' dot-product हे नावच त्यांनी भागाकारावरून ठेवलंय!

कारण भागाकार नसेल तर मोठ्या d_k ला यंत्र शिकणं थोडं त्रुटि: softmax 'गोठतो'. एका भागाकाराची अख्खी गोष्ट: छोटी, सुंदर, आणि 'बारकाव्यांत देव असतो' ची पाठ्यपुस्तकी साक्ष: पुढचा chapter.

Chapter 2.3 [DEPTH]: $\sqrt{d_k}$ चं गूढ: एका भागाकाराची गोष्ट

पेपरमधली सर्वात छोटी युक्ती, सर्वात मोठा धडा. लेखकांनी आपल्या attention ला नाव दिलं ”**scaled dot-product attention**”: म्हणजे नावातच भागाकार. का?

अडचण: आकड्यांची सूज. 2.2 त आपली चिठ्ठी-पाटी 2-आकडी होती: गुण 1.8 पर्यंत आले. पण खऱ्या यंत्रात $d_k=64$: चिठ्ठी-पाटीचा dot product म्हणजे **64 गुणाकारांची बेरीज**. सोपं सत्य: जितकी लांब बेरीज, तितका निकाल मोठा होत जातो (पेपरची नेमकी भाषा: प्रत्येक घटक स्वतंत्र, सरासरी 0, पसरण 1 धरली तर बेरजेची पसरण d_k होते: म्हणजे ‘सूज’ सरासरीने $\sqrt{d_k}$ पट: Book 7, 2.2 ची पसरण-भाषा). $d_k=64$ ला गुण सहज 8-10 पट फुगतात.

फुगले तर काय बिघडतं? softmax गोठतो. हाताने बघू. 2.2 चे गुण (1.8, 0.6, 1.2) **दहा पट** फुगले असते: (18, 6, 12):

```
softmax(1.8, 0.6, 1.2) = 0.53, 0.16, 0.31 <- मऊ वाटणी
softmax(18, 6, 12)    = 0.9975, 0.00001, 0.0025
                        <- जवळजवळ 1, 0, 0: दगड!
```

(गणित: e^{18} हे e^{12} च्या ~400 पट: बाकीचे चिरडले जातात.) याला म्हणतात softmax **saturate** होणं: टक्केवारीची ‘वाटणी’ जाऊन ‘विजेता-सगळं-घेतो’ दगड बनतो. आणि खरा घात पुढे: **शिकणं थांबतं**. Book 7 (3.2-3.3) आठवा: यंत्र शिकतं gradients नी: ‘वजन जरा हलवलं तर निकाल किती हलतो’ या उतारावरून. दगड-झालेल्या softmax मध्ये वजनं हलवली तरी टक्केवारी हलत नाही (0.9975 चं फार तर 0.9976): **उतार जवळजवळ शून्य: शिकवण-संदेश मागे पोहोचतच नाही** (vanishing gradient चं भूत परत: यावेळी रांगेमुळे नाही, सुजेमुळे!).

उपाय: सुजेच्या मापाने भागा. सूज $\sqrt{d_k}$ पट येते: मग $\sqrt{d_k}$ नेच भागा: गुण परत माणसाळलेल्या पट्ट्यात, softmax मऊ, gradients जिवंत. $d_k=64$ ला भाग 8 ने; आपल्या $d_k=2$ ला 1.41 ने (2.2 ची पायरी-2). बस: इतकीच गोष्ट. **पण ही ओळ नसती तर?** मोठ्या d_k चं शिक्षण अडखळतं: पेपरने हे ओळखून आधीच बांधून टाकलं: नाहीतर ‘Transformer चालत नाही’ म्हणून कल्पनाच मेली असती कदाचित: **क्रांत्या कधीकधी एका भागाकारावर तरतात**.

एका वाक्यावर: आपल्या तीन शब्दांचं गणित 2.2 त आधीच scaled होतं: (1.28, 0.43, 0.85) -> (0.48, 0.21, 0.31): बघा किती **मऊ** वाटणी आहे: ‘बसली’ मुख्यत: मांजराकडे बघतो पण जागेचाही 21% कान ठेवतो: भाषेला हेच हवं (अर्थ अनेक धाग्यांनी येतो). दगड-वाटणी (1, 0, 0) असती तर ‘चटईवर’ चा धागाच तुटला असता.

महाग चूक

”असले बारकावे ‘engineering-तपशील’: मुख्य कल्पना महत्वाची.” पेपर-वाचनातली सर्वात पसरलेली उर्मट चूक. सत्य: **मुख्य कल्पना फुकट असते; ती चालवणारे बारकावे महाग** (Book 4 चं सूत्र पुन्हा वेगळ्या रूपात!). Transformer च्या यशात $\sqrt{d_k}$, warmup (2.8), residual (2.7) असे ‘बारकावे’च प्राण आहेत: यातला एक काढा, यंत्र शिकेनासं होतं. म्हणून पेपर वाचताना शिस्त: **समीकरणातल्या प्रत्येक चिन्हाला ‘हे नसतं तर?’ विचारा**: उत्तर ‘काही बिघडत नाही’ असं क्वचितच निघतं: आणि निघालं नाही की तुम्हाला यंत्राची खरी समज आली.

नकाशावर

- 2.1 सांगाडा 2.2 Q-K-V: 4 पायऱ्या
- 2.3 $\sqrt{d_k}$: लांब बेरीज = $\sqrt{d_k}$ -पट सूज $\rightarrow$ softmax दगड $\rightarrow$ gradients मरतात $\rightarrow$ शिकणं थांबतं; उपाय: सुजेच्या मापाने भाग; मऊ वाटणी हीच भाषेची गरज

सूत्रावर: “कोण कुणाला किती लागू” ची वाटणी **मऊ** राहणं हीच सूत्राची अट आहे: दगड-वाटणी म्हणजे लक्षच नाही, हट्ट. $\sqrt{d_k}$ हा त्या मऊपणाचा रखवालदार.

स्वतः बघा (5 मिनिटं)

Calculator वर स्वतः अनुभवा: softmax(2, 1) काढा ($e^2=7.39$, $e^1=2.72$: टक्के 0.73/0.27: मऊ). आता दोन्ही 5-पट करा: softmax(10, 5): ($e^{10}=22026$, $e^5=148$: टक्के 0.993/0.007: दगड!). आकडे तेच ‘प्रमाणात’: पण फुगले की वाटणी मेली. आता 10, 5 ला $\sqrt{\cdot}$ -युक्तीने परत खाली आणा: हेच पेपरचं काम.

विचार करा

2.2 चं गणित एकाच ‘नजरे’चं होतं: ‘बसली’ ने एक चिठ्ठी लिहिली, एक वाटणी मिळाली. पण भाषेत एकाच शब्दाला **अनेक** प्रश्न असतात: ‘बसली’ ला कर्ताही हवा (मांजर) **आणि** जागाही हवी (चटईवर) **आणि** काळही: एकाच वाटणीत हे सगळं कोंबलं तर सगळं धूसर होईल. यंत्राला **अनेक स्वतंत्र नजरा** एकदम देता येतील का?

हेच पेपरचं दुसरं रत्न: Multi-Head Attention: आठ डोकी, प्रत्येकाची स्वतःची चिट्ठी-पाटी-ऐवज-यंत्रं, प्रत्येकाची स्वतंत्र वाटणी: आणि मग आठांची एकत्र गुंफण. आपल्या वाक्यावर दोन डोकी हाताने चालवू: पुढचा chapter.

Chapter 2.4 [SPINE]: Multi-Head: आठ डोकी, आठ नजरा

कल्पना एका ओळीत: एक attention = एक नजर = एक जुळणी-प्रकार. भाषेला अनेक जुळणी-प्रकार लागतात (कर्ता-क्रियापद, जागा-क्रियापद, विशेषण-नाम, सर्वनाम-मालक...). मग **एकाच मोठ्या नजरेऐवजी आठ छोट्या स्वतंत्र नजरा** चालवा आणि निकाल गुंफा: हेच multi-head attention.

हाताने: दोन डोकी आपल्या वाक्यावर. प्रत्येक डोक्याला स्वतःची W_Q - W_K - W_V यंत्रं (म्हणजे स्वतःच्या चिठ्या-पाट्या!). 'बसली' साठी:

डोकं 1 (2.2 चंच: 'कर्ता-शोधक' निघालं):
 गुण-> softmax: मांजर 0.48, चटईवर 0.21, बसली 0.31
 निकाल-1 = [1.27, 0.73] <- मांजर-रंगाचं
 डोकं 2 (नवी यंत्रं: वेगळ्या चिठ्या-पाट्या):
 Q' (बसली)=[1,0]; K' (मांजर)=[0.2,1], K' (चटईवर)=[1.4,0],
 K' (बसली)=[0.5,0.5]
 गुण: 0.2, 1.4, 0.5 -> /1.41 -> 0.14, 0.99, 0.35
 softmax: e: 1.15, 2.69, 1.42 (बेरीज 5.26)
 -> मांजर 0.22, चटईवर 0.51, बसली 0.27!
 V' ने भरित बेरीज -> निकाल-2 <- चटई-रंगाचं

बघा काय घडलं: **तेच वाक्य, तोच शब्द, दोन वेगळ्या वाटण्या:** डोकं-1 कर्त्याकडे (मांजर 48%), डोकं-2 जागेकडे (चटईवर 51%): कुणीही त्यांना 'तू कर्ता बघ, तू जागा बघ' शिकवलेलं नाही: वेगवेगळ्या सुरुवाती-वजनांतून **आपोआप वेगळ्या भूमिका** घेतात (शिक्षणाची गंमत: कामाची वाटणी स्वयंभू). खऱ्या यंत्रांत डोक्यांच्या भूमिका अभ्यासकांनी नंतर उघडून बघितल्यात: कुणी व्याकरण-डोकं, कुणी शेजार-डोकं, कुणी दुर्मिळ-शब्द-डोकं (Book 9, 1.2 ची interpretability इथलीच).

गुंफण (पेपरचं गणित): आठ डोक्यांचे निकाल **शेजारी जोडायचे** (concat) आणि एका शेवटच्या यंत्राने (W_O) मिसळायचे. पेपरची हुशार काटकसर: $d_{\text{model}}=512$ चे 8 भाग: **प्रत्येक डोकं फक्त $d_k=64$ आकड्यांत** काम करतं ($512/8=64$): आठही मिळून खर्च जवळजवळ एका मोठ्या नजरेइतकाच: **आठ नजरा जवळजवळ फुकटात** (Book 5 ची नजर: सौदा ओळखा: विविधता घेतली, किंमत नाही वाढवली). 8×64 जोडून परत 512: इमारतीचा बाण-आकार कायम (2.1): मजल्यावर मजला चढवायला हेच लागतं.

पेपरचा पुरावा (Table 3 ची झलक: पूर्ण 2.8 त): लेखकांनी डोकी बदलून बघितली: **1 डोकं: 0.9 BLEU ने वाईट** (एक नजर पुरत नाही: सिद्ध!); 8-16: गोड जागा; **32: परत किंचित घसरण** (खूप डोकी = प्रत्येकाला खूपच अरुंद d_k : नजराच अधू). 'जास्त ते चांगलं' नव्हे: **वाटणीचा सौदा** आहे: विविधता

विरुद्ध प्रत्येक नजरेची खोली.

एका वाक्यावर: 'बसली' आता मजल्यातून बाहेर पडताना त्याच्या 512-बाणात आठ धागे विणलेले: कर्ता-धागा, जागा-धागा, काळ-धागा... पुढच्या मजल्यावर याच समृद्ध बाणावर पुन्हा आठ नजरा: **थरांगणिक समज दाटत जाते** (2.1 चं 'पिकणं' हेच).

महाग चूक

"आठ डोकी म्हणजे यंत्र आठ पट हुशार/महाग." दोन्ही चूक: काटकसरीची रचना बघितलीच (512 चे 8 तुकडे: खर्च ~तोच); आणि हुशारीही 'बेरजेने' येत नाही, **विविधतेने** येते: आठ सारखी डोकी असती तर एकाइतकीच अक्कल (Table 3 चा 32-डोक्यांचा धडाही तोच: संख्या नव्हे, प्रत्येक नजरेची धड-खोली). हा नियम यंत्राबाहेरही ओळखीचा आहे: समितीत आठ **सारखे** विचार = एक विचार; आठ **स्वतंत्र** नजरा = खरी समिती (Book 8, 1.7 चा disagree-लिहून-नोंदवा त्याच जातीचा). विविधता ही रचून आणावी लागते: यंत्रात वेगळ्या W-यंत्रांनी, समितीत वेगळ्या पार्श्वभूमींनी.

नकाशावर

2.1 सांगाडा 2.2 Q-K-V 2.3 $\sqrt{d_k}$
 2.4 multi-head: 8 स्वतंत्र नजरा (स्वतःची W-यंत्रं) -> स्वयंभू
 भूमिका-वाटणी (कर्ता-डोकं, जागा-डोकं) -> concat + W_0;
 512/8=64: विविधता जवळजवळ फुकट; 1 डोकं -0.9 BLEU,
 32 ही घसरण

सूत्रावर: सूत्राचा प्रश्न आता अनेकवचनी झाला: "कोण कुणाला **कुठल्या नात्याने** किती लागू?": प्रत्येक नात्याला स्वतःची नजर. लक्ष पुरेसं आहे: पण **अनेक-अंगी** लक्ष.

स्वतः बघा (5 मिनिटं)

डोकं-2 चं गणित हाताने पूर्ण करा: $V'(\text{मांजर})=[0,1]$, $V'(\text{चटईवर})=[2,1]$, $V'(\text{बसली})=[1,0]$ घेऊन भारित बेरीज काढा (टक्के: 0.22, 0.51, 0.27). मग concat चा अनुभव: निकाल-1 [1.27, 0.73] आणि तुमचा निकाल-2 शेजारी लिहा: ही चार-आकडी ओळ म्हणजेच 'बसली' चं दोन-डोकी रूप. (उत्तर-ताळा: निकाल-2 = [1.29, 0.73]: जुळलं?)

विचार करा

आतापर्यंतचं सगळं लक्ष **आपापसातलं** होतं (वाचक-मनोऱ्यातलं self-attention: मराठी शब्द मराठी शब्दांकडे). पण यंत्राचं काम भाषांतर आहे: लेखक-मनोऱ्याला **दोन** गरजा: इंग्रजी घडवताना मागे लिहिलेल्या इंग्रजीकडे बघणं, **आणि** मूळ मराठीकडे बघणं. आणि तिसरी अडचण: शिकताना यंत्राला उत्तर आधीच दिसलं तर नक्कल करेल: **भविष्य लपवायचं कसं?**

पुढचा chapter: लक्षाच्या तीन जागा (self, masked-self, cross): आणि 'मुखवटा' (mask): भविष्यावर $-\infty$ चा पडदा टाकण्याची पेपरची युक्ती: जिच्यामुळेच आजचे GPT-Claude एक-एक शब्द 'भाकीत' करत लिहितात.

Chapter 2.5 [SPINE]: लक्षाच्या तीन जागा आणि मुखवटा

एकच attention-यंत्र (2.2 च्या चार पायऱ्या) इमारतीत **तीन वेगळ्या जागी, तीन वेगळ्या भूमिकांत** बसवलंय: फरक फक्त **चिठ्या कुणाच्या, पाट्या-ऐवज कुणाचे** इतकाच:

जागा 1: वाचक-मनोऱ्यातलं आपापसातलं लक्ष (encoder self-attn)

Q, K, V तिन्ही मराठी शब्दांचेच: सगळे सगळ्यांकडे बघतात (मागचे-पुढचे दोन्ही: वाचकाला पूर्ण वाक्य दिसण्यात गैर काहीच नाही). हेच आपण 2.2-2.4 त केलं.

जागा 2: लेखक-मनोऱ्यातलं मुखवटा-लक्ष (masked self-attn)

Q, K, V इंग्रजी (आतापर्यंत लिहिलेल्या) शब्दांचे: पण प्रत्येक शब्द फक्त मागच्यांकडेच बघू शकतो: भविष्यावर मुखवटा (खाली).

जागा 3: खिडकी (cross-attention: encoder-decoder attn)

चिठ्या इंग्रजीच्या; पाट्या-ऐवज मराठीचे! लेखक विचारतो, वाचक पुरवतो: 1.2 चं Bahdanau-लक्ष याच जागेचा पूर्वज.

मुखवटा का लागतो (शिक्षणाची गोम). यंत्र शिकतं कसं: त्याला मराठी वाक्य + तयार इंग्रजी भाषांतर देतात आणि म्हणतात “प्रत्येक जागी पुढचा इंग्रजी शब्द ओळख” (Book 2, 2.2 चं next-word शिक्षण). पण घोटाळा: “the cat ____” ओळखायचंय आणि लेखक- मनोऱ्याच्या हातात पूर्ण “the cat sat on the mat” आहे: लक्ष- खोलीत ‘sat’ **दिसतोच** आहे! न लपवता शिकवलं तर यंत्र ‘ओळखणं’ नाही, **‘नक्कल करणं’** शिकतं (उत्तर बघून पेपर सोडवणारा विद्यार्थी: परीक्षेत शून्य). उपाय: **भविष्याच्या गुणांवर -∞ (उणे-अनंत) लिहा:** softmax मध्ये $e^{(-\infty)} = 0$: भविष्याची टक्केवारी आपोआप शून्य: दिसतच नाही.

हाताने (मुखवटा चालवून): लेखक ‘sat’ च्या जागेवर आहे; गुण निघाले (the: 0.5, cat: 1.4, sat: 2.0, on: 1.1...):

मुखवट्याआधी:	0.5	1.4	2.0	1.1	
मुखवट्यानंतर:	0.5	1.4	-∞	-∞	<- स्वतःसकट पुढचं बंद*
softmax:	0.29	0.71	0	0	

(*‘sat’ ओळखायच्या क्षणी ‘sat’ स्वतः आणि पुढचं झाकलेलं: मागचे ‘the’, ‘cat’ तेवढे खुले: आणि यंत्र cat कडे 71% लक्ष देऊन ‘मांजराने पुढे काय केलं असेल’ या दिशेने भाकीत बांधतं.) हा मुखवटा म्हणजे फक्त **गुण-तक्त्यावरचा त्रिकोणी पडदा:** एक ओळ code, पण त्याच्याविना अख्खं शिक्षण फसवं. **आणि**

इतिहास: GPT-मालिका म्हणजे या जागा-2 चाच (मुखवटा-लक्षाचा) एकटा मनोरा (3.2 त पूर्ण):
आज तुम्ही Claude शी बोलता तेव्हा प्रत्येक शब्द असाच, मुखवट्यामागून, एक-एक जन्मतो.

खिडकीत (जागा 3) आपलं वाक्य: 'sat' घडवण्याच्या क्षणी लेखकाची चिठ्ठी खिडकीतून मराठी पाट्यांना भिडते: गुण: मांजर 0.9, चटईवर 0.7, **बसली 2.1:** softmax: 0.17, 0.14, 0.69: लक्ष 'बसली' वर: आणि 'बसली' चा ऐवज (कृती-भूत-एकवचन- स्त्रीलिंग सगळं मुरलेला: वाचक-मनोऱ्याचे 6 मजले आठवा!) उचलून 'sat' उमटतो. 1.2 त हेच 'नजर वळणं' अंधुक बघितलं होतं; आता त्याचं पूर्ण यंत्र-रूप हातात आहे.

महाग चूक

"तीन attention म्हणजे तीन वेगळी तंत्रं शिकायची." पेपर-वाचकांची नेहमीची धास्ती: प्रत्यक्षात **यंत्र एकच** (चार पायऱ्या), बदलतं फक्त 'कोण विचारतो, कोण पुरवतो' हे plumbing: चिठ्ठ्या इकडून, पाट्या तिकडून. हा नमुना सार्वत्रिक आहे: चांगल्या रचना **एकच तुकडा वेगवेगळ्या जोडण्यांत** वापरतात (Book 5, 2.16 ची नजर: रचना वाचताना 'नवा ठोकळा' आणि 'जुना ठोकळा नव्या जागी' वेगळे ओळखा: 90% वेळा दुसरंच असतं: दहशत निम्मी होते).

नकाशावर

2.1 सांगाडा 2.2 Q-K-V 2.3 $\sqrt{d_k}$ 2.4 multi-head
2.5 तीन जागा: वाचक-आपापसात (सगळं खुलं) | लेखक-मुखवटा
(भविष्यावर $-\infty \rightarrow \text{softmax } 0$: नक्कल-बंदी) | खिडकी (Q इंग्रजी, K-V मराठी); GPT = एकटा मुखवटा-मनोरा

सूत्रावर: "ना रांग" म्हणणाऱ्या यंत्रात लेखनाचा **क्रम** मुखवट्याने परततो: पण बघा फरक: रांग **सक्ती** होती (वाचनही रांगेत); मुखवटा **निवड** आहे (फक्त लेखनापुरता, वाचन समांतरच). क्रम हवा तिथेच, नको तिथे नाही: हीच रचनेची प्रगल्भता.

स्वतः बघा (5 मिनिटं)

मुखवट्याचा त्रिकोण कागदावर काढा: 4 शब्दांच्या वाक्यासाठी 4x4 चौकट: ओळी = 'कोण बघतोय', रकाने = 'कुणाकडे': प्रत्येक घरात खुलं/बंद लिहा (ओळ 1: फक्त घर-1 खुलं; ओळ 4: चारही). हा **खालचा-त्रिकोण** (lower-triangular) आकार डोळ्यांसमोर पक्का करा: LLM-जगातल्या प्रत्येक चर्चेत 'causal mask' या नावाने हाच भेटत राहील.

विचार करा

एक विचित्र गोष्ट अजून अनुत्तरित: 2.2 च्या गणितात 'मांजर चटईवर बसली' आणि 'बसली चटईवर मांजर' यांत **फरकच नाही!** dot products शब्द-जोड्यांचे: क्रमाचा उल्लेखच कुठे नाही. रांग काढली आणि क्रमही गेला: पण भाषेत क्रम म्हणजे अर्थ ('मांजराने उंदीर खाल्ला' विरुद्ध 'उंदराने मांजर खाल्ला!'). रांगेशिवाय क्रम यंत्रात **घालायचा** कसा?

पेपरचं तिसरं रत्न, आणि सर्वात काव्यमय: प्रत्येक शब्दाला त्याच्या जागेची 'सुगंधी मुद्रा' लावायची: sin-cos लहरींची: जलद-घड्याळ + संथ-घड्याळ. positional encoding: हाताच्या आकड्यांसकट: पुढचा chapter.

Chapter 2.6 [SPINE]: जागेची मुद्रा: sin-cos ची घड्याळ-जादू

अडचण नेमकी: attention चं गणित क्रम-आंधळं आहे: शब्दांचा गढा बघतं, रांग नाही. रांगेचं यंत्र (RNN) फेकलं तेव्हा क्रमाची फुकट-सोयही गेली. आता क्रम **माहिती म्हणून** परत घालायचा: प्रत्येक शब्दाच्या बाणात 'मी जागा क्रमांक अमुक' ही खूण मिसळायची.

पहिली कल्पना (आणि तिचं दुखणं): जागा-क्रमांकच मिसळा: 1, 2, 3... दुखणं: 100-शब्दी वाक्यात '100' हा आकडा बाणांतल्या 0.5-1.2 च्या नाजूक आकड्यांना **चिरडेल**; आणि यंत्राने 40 जागांवर शिकलं तर जागा-41 त्याला परकी. लागते अशी खूण जी (अ) मर्यादित पट्ट्यात राहते (कधीच फुगत नाही), (ब) प्रत्येक जागेला वेगळी, (क) आणि 'दोन जागांतलं अंतर' गणिताला सहज दिसेल अशी.

पेपरचं उत्तर: घड्याळांची रांग. भिंतीवर अनेक घड्याळं: पहिलं **जलद** (दर शब्दाला काटा खूप फिरतो), दुसरं हळू, तिसरं आणखी हळू... शेवटचं **अति-संथ** (हजार शब्दांत जरा हलतं). प्रत्येक जागेची खूण = **त्या क्षणी सगळ्या घड्याळांच्या काट्यांची स्थिती**. जलद घड्याळ शेजारच्या जागा वेगळ्या करतं (जागा 5 वि. 6: जलद काटा खूप वेगळा); संथ घड्याळ लांबचा पत्ता देतं (वाक्याच्या सुरुवातीला की शेवटी). आणि काटे **गोल फिरतात**: स्थिती नेहमी -1 ते +1 च्या पट्ट्यात: कधीच फुगत नाही (अट अ पूर्ण). काट्याची स्थिती गणितात = sin आणि cos: म्हणून सूत्र:

```
PE(जागा, 2i)   = sin(जागा / 10000^(2i/d_model))
PE(जागा, 2i+1) = cos(जागा / 10000^(2i/d_model))
(i = घड्याळ-क्रमांक: i वाढेल तसं घड्याळ 10000-च्या
घातांनी संथ; प्रत्येक घड्याळ बाणाचे दोन आकडे भरतं:
sin-कोन आणि cos-कोन: काट्याची पूर्ण स्थिती)
```

हाताने (d_model=4: दोन घड्याळं: जलद x1, संथ x1/100):

जागा 0 (मांजर):	[sin 0,	cos 0,	sin 0,	cos 0	]
	= [0,	1,	0,	1	]
जागा 1 (चटईवर):	[sin 1,	cos 1,	sin 0.01,	cos 0.01]	
	= [0.84,	0.54,	0.010,	1.000	]
जागा 2 (बसली):	[sin 2,	cos 2,	sin 0.02,	cos 0.02]	
	= [0.91,	-0.42,	0.020,	1.000	]

बघा: पहिले दोन आकडे (जलद घड्याळ) जागोजागी झपाट्याने बदलतात; शेवटचे दोन (संथ) रांगत सरकतात. ही चार-आकडी मुद्रा शब्दाच्या अर्थ-बाणात **मिसळायची** (बेरीज): 'चटईवर' चा बाण = चटईवरचा-अर्थ + जागा-1-ची-मुद्रा. आता 'मांजर चटईवर बसली' आणि 'बसली चटईवर मांजर' चे बाण **वेगळे**: क्रम परतला: रांगेशिवाय.

आणि अट (क) ची जादू: $\sin\text{-}\cos$ ची शाळेतली ओळख आठवा: कोन k ने पुढे सरकवणं हे **फिरवण्याचं** (rotation) साधं गणित आहे: म्हणजे 'जागा $p+k$ ची मुद्रा' ही 'जागा p च्या मुद्रे'चं ठरावीक वळण: '**k अंतरावरचा शब्द**' ही कल्पना यंत्राला एका सोप्या रूपांतराने शिकता येते: पेपरने घड्याळं निवडली ती नेमकी यासाठी. (लेखकांनी 'शिकलेल्या मुद्रा' पण तपासल्या: निकाल जवळजवळ सारखा: Table 3: पण $\sin\text{-}\cos$ ला शिकवावं लागत नाही आणि न-बघितलेल्या लांबीलाही चालतं: म्हणून तेच ठेवलं. गंमत: पुढच्या युगाने हीच कल्पना आणखी घासून RoPE बनवली: 3.2 त.)

महाग चूक

" $\sin\text{-}\cos$ ही 'जादूची' निवड: असंच काहीतरी गूढ." उलट प्रवास खरा: **गरजा आधी लिहिल्या** (फुगू नये, प्रत्येक जागा वेगळी, अंतर गणिती-सोपं, कुठल्याही लांबीला चालावं), मग त्या गरजा पूर्ण करणारं **सर्वात साधं** गणित शोधलं: त्रिकोणमिती. पेपर- वाचनाची खोल शिस्त इथे शिका: विचित्र-दिसणाऱ्या प्रत्येक निवडीमागे गरजांची यादी असते: **निवड पाठ करू नका; यादी शोधा** (Book 8, 1.1: मुळं). यादी सापडली की निवड 'जादू' न राहता 'अपरिहार्य' वाटू लागते: तीच समजेची खूण.

नकाशावर

2.1-2.5 सांगाडा | Q-K-V | $\sqrt{d_k}$ | multi-head | तीन जागा+मुखवटा
 2.6 जागेची मुद्रा: घड्याळांची रांग (जलद->संथ); $\sin\text{-}\cos$ = काट्यांची स्थिती: फुगत नाही, प्रत्येक जागा वेगळी, अंतर = फिरवणं; मुद्रा अर्थ-बाणात मिसळा; learned आणि $\sin\text{-}\cos$ जवळजवळ सारखे

सूत्रावर: "रांग मोडा" चं शेवटचं देणं फेडलं: रांग मोडूनही क्रम शाबूत: कारण क्रम आता **रचनेची सक्ती** नाही, **बाणांतली माहिती** आहे: आणि माहितीवर लक्षाचं गणित चालतंच.

स्वतः बघा (5 मिनिटं)

Calculator (radian mode!) घेऊन जागा 3 ('बसली' नंतर चौथा शब्द असता तर) ची मुद्रा काढा: $[\sin 3, \cos 3, \sin 0.03, \cos 0.03]$. मग वरच्या तक्त्याखाली लिहा आणि नमुना बघा: जलद-जोडी उड्या मारतेय, संध-जोडी रांगतेय. (ताळा: $[0.14, -0.99, 0.030, 1.000]$.) चार जागांची चार-आकडी मुद्रा-सारणी तुम्ही हाताने बांधलीत.

विचार करा

लक्ष-खोली आता पूर्ण कळली. पण मजल्यात दुसरी खोलीही होती (2.1): 'विचार-खोली' (feed-forward): आणि खोल्यांभोवती 'उडी-रस्ता' आणि 'तराजू'. लक्षच सगळं करतं तर या **बिन-लक्षाच्या** भागांचं काम काय: आणि ते नसते तर काय बिघडलं असतं?

पुढचा chapter: यंत्राचे सांधे: FFN (गोळा केलेल्याचं पचन), residual (ResNet कडून घेतलेला उडी-रस्ता: तोच ResNet जो citations मध्ये आपल्या पेपरच्याही वर आहे!), आणि LayerNorm (थरांचा तराजू): 6 मजले कोसळू न देणारी त्रयी.

Chapter 2.7 [SPINE]: सांधे: FFN, उडी-रस्ता, तराजू

शीर्षक 'attention is all you need' म्हणतं: पण यंत्रात लक्षाइतकेच महत्त्वाचे तीन बिन-लक्षाचे भाग आहेत (1.4 ची शीर्षक-तंबी आठवा). तिघांची कामं नेमकी:

भाग 1: विचार-खोली (Feed-Forward Network). लक्ष-खोलीचं काम **गोळा करणं** आहे (इतरांकडून घेणं: 'बसली' त मांजर-चटई मुरली); पण गोळा केलेल्याचं **पचन** कोण करणार? FFN: प्रत्येक शब्द **एकटा** बसून स्वतःच्या बाणावर प्रक्रिया करतो: सूत्र: $FFN(x) = \text{ReLU}(x \cdot W1) \cdot W2$ ($\text{ReLU} = \text{Book 7, 3.5}$ चा 'उणे-कापा' दरवाजा). आकड्यांची गंमत: 512 $\rightarrow$ **2048** $\rightarrow$ 512: बाण आधी **चौपट रुंद** पसरवायचा, तिथे प्रक्रिया, परत आवळायचा: अरुंद बोळात न मावणारे विचार रुंद मैदानात मांडून परत बांधणं. आणि 'प्रत्येक शब्द एकटा' = पुन्हा **पूर्ण समांतर**. (आजचं ज्ञान: यंत्राची 'आठवण-साठवण' मुख्यतः याच FFN-थरांत राहते: लक्ष = वाहतूक, FFN = गोदाम: parameters चा 2/3 वाटा FFN कडेच!)

भाग 2: उडी-रस्ता (residual connection). प्रत्येक खोलीभोवती एक बगल-रस्ता: खोलीचा निकाल = **खोलीत घडलेलं + मूळ आल्याबरोबरचं** ($x + \text{खोली}(x)$: बेरीज). कशाला? 6 मजले (आणि आजचे 100!) चढताना दोन संकटं: माहिती विरणं आणि शिकवण-संदेश (gradients) मरणं (1.1 चं भूत उभ्या दिशेने!). उडी-रस्त्याने मूळ माहिती आणि gradient दोन्हींना **थेट महामार्ग**: प्रत्येक खोलीने 'सगळं नव्याने घडवण्याऐवजी' फक्त **सुधारणा** (residual = उरलेलं) शिकायची. ही कल्पना पेपरने ResNet (2015) कडून घेतली: तोच ResNet जो आजही citation-यादीत आपल्या पेपरच्या **वर** आहे (1.3): इतिहासाची विनम्र गाठ: क्रांतीही खांद्यांवर उभी असते.

भाग 3: तराजू (LayerNorm). प्रत्येक खोलीनंतर बाणाचे आकडे **तोलून-मापून** ठेवायचे (सरासरी 0, पसरण 1 च्या घरात: Book 7, 2.2 ची भाषा). कशाला? थरामागून थर जाताना आकडे फुगत/आटत जातात (2.3 चा softmax-दगड आठवा: तीच जात): तराजू दर मजल्यावर सगळं माणसाळलेल्या पट्ट्यात आणतो: **शिडीची प्रत्येक पायरी सारख्या उंचीची**: म्हणून 6 काय, 100 मजलेही चढता येतात. पेपरची रचना: प्रत्येक खोलीला "Add & Norm" ची जोड (Figure 1 मधल्या त्या पट्ट्या!): आधी उडी-बेरीज (Add), मग तराजू (Norm).

एका वाक्यावर (मजल्याची पूर्ण फेरी, आता सगळं जोडून): 'बसली' चा बाण मजल्यात शिरतो $\rightarrow$ **लक्ष-खोली** (8 डोकी: मांजर-चटई मुरते) $\rightarrow$ **Add & Norm** (मूळ + नवं, तोललेलं) $\rightarrow$ **विचार-खोली** (एकट्याने पचन, 512 $\rightarrow$ 2048 $\rightarrow$ 512) $\rightarrow$ **Add & Norm** $\rightarrow$ पुढचा मजला. x6. आता पेपरची Figure 1 पूर्ण वाचता येते: प्रत्येक ठोकळा, प्रत्येक बाण, प्रत्येक पट्टी: **ओळखीची**.

महाग चूक

”शीर्षक म्हणतं लक्ष पुरेसं: मग FFN-सांधे ‘दुय्यम’.” प्रयोगांनी उलट सिद्ध केलंय: FFN काढा: यंत्र अधू (साठवण गेली); residual काढा: खोल यंत्र **शिकतच नाही** (gradients मरतात); Norm काढा: शिक्षण अस्थिर-स्फोटक. शीर्षक जाहिरात-वाक्य आहे (‘रांग- खिडकी नको’ इतकाच दावा: 1.4); **यंत्र चालतं ते चौकडीने: लक्ष + पचन + महामार्ग + तराजू**. धडा पुन्हा तोच (2.3): नायक एकटा जिंकत नाही; सांधे-संगत नसेल तर नायक पडतो. रचना वाचताना ‘गाजणाऱ्या भागा’इतकंच ‘गाजत-नसलेल्या आधारां’कडे बघा: तिथेच बहुधा खरी प्राण-यंत्रणा असते.

नकाशावर

2.1-2.6 सांगाडा | Q-K-V | $\sqrt{d_k}$ | multi-head | तीन जागा | मुद्रा
 2.7 सांधे: FFN = एकट्याचं पचन (512->2048->512; साठवणीचं गोदाम) | residual = उडी-महामार्ग (ResNet कडून; फक्त सुधारणा शिका) | LayerNorm = दर मजल्यावर तराजू;
 जोडी: Add & Norm

सूत्रावर: सूत्र म्हणतं लक्ष पुरेसं: आता नेमकेपणा आला: लक्ष पुरेसं आहे **संदर्भ-जुळणीला**; यंत्र उभं राहायला पचन-महामार्ग- तराजू लागतातच. सूत्रं धारदार असतात; यंत्रं पूर्ण असावी लागतात.

स्वतः बघा (5 मिनिटं)

उडी-रस्त्याचा अनुभव कागदावर: $x=[1, 2]$ घ्या; समजा खोलीने गोंधळ केला: खोली(x)=[-0.9, -1.8] (जवळजवळ सगळं पुसलं). उडी-रस्त्याविना निकाल = [-0.9, -1.8] (माहिती गेली!); उडी- रस्त्याने $x + \text{खोली}(x) = [0.1, 0.2]$ (आटली, पण **जिवंत**: पुढचा मजला सावरू शकतो). आता 6 मजल्यांची कल्पना करा: विना-उडी एक वॉर्ट मजला = सर्वनाश; उडीसकट = सुधारण्याजोगी चूक. हाच फरक 100-मजली राक्षसांना शक्य करतो.

विचार करा

यंत्र पूर्ण उभं राहिलं! पण अजून ते **कोरं** आहे: W_Q, W_K, W_V , FFN ची वजनं: सगळी सुरुवातीला यादृच्छिक (random). पेपरने हे कोट्यवधी आकडे **शिकवले** कसे: कुठला data, कुठली रीत, कुठल्या युक्त्या: आणि शेवटी 28.4 चा विक्रम नक्की कसा मोजला?

विभागाचा शेवटचा chapter: शिकवण आणि निकाल: BPE चे शब्द-तुकडे, Adam ची warmup-चाल (आधी हळू, मग जोरात, मग उतरत!), label smoothing चा 'अति-खात्री-विरोधी' डोस, आणि पेपरचे तक्ते: निकालांचे, ablations चे, आणि complexity चा: पेपर-वाचनाची अंतिम फेरी.

Chapter 2.8 [SPINE]: शिकवण आणि निकाल: पेपरचे तक्ते बोलतात

यंत्र उभं; आता शाळा. पेपरचे विभाग 5-6 (Training, Results) चार गोष्टी सांगतात:

गोष्ट 1: शब्दांचे तुकडे (BPE). यंत्राला अख्खे शब्द दिले तर शब्दकोश अवाढव्य आणि नवा शब्द आला की पंचाईत. पेपरची रीत: **byte-pair encoding**: वारंवार येणाऱ्या अक्षर-जोड्या जोडत-जोडत ~37,000 तुकड्यांचा (EN-DE, दोन्ही भाषांना **एकच**) संच (Book 2, 2.3 चे tokens: त्यांचा जन्म-विधी हा). ‘बसली’ कदाचित ‘बस’+‘ली’: नवे-दुर्मिळ शब्दही जुन्या तुकड्यांतून वाचता येतात.

गोष्ट 2: Adam ची warmup-चाल. शिकवण Adam ने (Book 7, 3.5 चा उतार-शोधक, सुधारित). पण पेपरची खास युक्ती **शिकण्याच्या वेगाची (learning rate) चाल**: पहिली 4,000 पावलं वेग **चढत** (warmup), मग हळूहळू **उतरत** ($1/\sqrt{\text{step}}$). का? सुरुवातीला वजनं यादृच्छिक: पहिल्याच क्षणी मोठ्या उड्या = गोंधळात उड्या (Book 7, 3.5 चा दरीत-उडी-धडा): म्हणून आधी चाचपडत, आत्मविश्वास आला की जोरात, शेवटी बारीक-घासत. (आजही प्रत्येक LLM याच चालीचा वंशज वापरतो: ‘warmup’ शब्द दिसला की आता तुम्हाला यंत्र दिसेल.)

गोष्ट 3: label smoothing: अति-खात्रीचं औषध. शिकवताना ‘बरोबर उत्तराला 100% दे’ ऐवजी **90% दे, उरलेले 10% इतरांत वाटा** (0.1 चा डोस). विचित्र वाटतं: मुद्दाम ‘चूक’ शिकवायचं? पेपरची प्रामाणिक नोंद: याने यंत्राची आकडेवारी-खात्री (perplexity) ‘बिघडते’ पण **भाषांतर-गुणवत्ता (BLEU) सुधारते**: कारण 100%- खात्रीचं यंत्र दगडी होतं (2.3 चा softmax-दगड शिक्षणातही!); जरा-नम्र यंत्र पर्याय खुले ठेवतं. (Book 8 च्या भाषेत: यंत्रालाही ‘मी चुकू शकतो’ ची जागा ठेवली की निर्णय सुधारतात!)

गोष्ट 4: निकाल आणि दोन अमर तक्ते.

यंत्र	EN-DE BLEU	EN-FR BLEU	शिकवण-खर्च
आधीचे विजेते	~26 (ensembles!)	~41	प्रचंड
base (65M)	27.3	38.1	12 तास x 8 GPU
big (213M)	28.4	41.8	3.5 दिवस x 8 GPU

एकट्या यंत्राने ensembles (अनेक यंत्रांच्या फौजा!) हरवल्या: अंशात्मक खर्चात. (बारकावे: big चा dropout EN-DE ला 0.3; लेखन-वेळी v1 त EN-FR 41.0 होतं, अंतिम आवृत्तीत 41.8; भाकीत-वेळी beam search रुंदी 4: Book 4, 2.2 च्या sampling- जगाचा पूर्वज.) **Ablation-तक्ता (Table 3): ‘काय काढलं तर काय बिघडतं’**: 1 डोकं: -0.9 BLEU; 32 डोकी: किंचित घसरण (2.4); d_k खूप आटवला: घसरण (जुळणी-गणिताला जागा लागते); मोठं यंत्र: चढ; dropout काढला: घसरण; sin-cos

ऐवजी शिकलेल्या मुद्रा: **जवळजवळ सारखं** (2.6). ablation = विज्ञानाची खरी शिस्त: दावा नुसता 'चाललं' नाही; '**कशामुळे चाललं**' सुट्टं करून सिद्ध (Book 7, 4.5: पेपर तोलताना ablations आधी बघा!).

आणि Table 1: complexity चा तक्ता (पेपरचा 'का' विभाग): प्रति-थर काम: self-attention $O(n^2 \cdot d)$ विरुद्ध recurrent $O(n \cdot d^2)$ (n = वाक्य-लांबी, d = बाण-रुंदी: Book 6, 1.1 ची Big-O भाषा!). $n < d$ असेपर्यंत (सामान्य वाक्य: $n \sim 50$, $d = 512$) लक्ष स्वस्तही! आणि दोन निर्णायक रकाने: क्रमिक-पावलं: $O(1)$ विरुद्ध $O(n)$ (समांतर-स्वातंत्र्य: 1.1 चं दुखणं-2 अंकात) आणि माहितीचा लांबचा रस्ता: $O(1)$ विरुद्ध $O(n)$ (कुठलाही शब्द कुठल्याही शब्दाला एका उडीत: दुखणं-1 अंकात). पेपरचा पूर्ण दावा या एका तक्त्यात मावतो. (आणि भविष्याची कुजबुज: n^2 हेच पुढच्या युगाचं दुखणं बनणार: लांब context ला लक्ष महाग: Book 4, 3.1 ची context-भित इथे जन्मली: 3.2 त परतू.)

महाग चूक

"निकाल-तक्ता = विजयाचा पुरावा: बाकी तपशील सजावट." उलटं: **निकाल जुने होतात (28.4 केव्हाच मागे पडलं!); पद्धत अमर राहते.** आजचा वाचक पेपरातून काय उचलतो: BPE (आजही), warmup (आजही), label smoothing (आजही), ablation-शिस्त (आजही), complexity-विचार (आजही: n^2 ची लढाई चालूच!). Benchmark- आकडे विरुद्ध पद्धत-विद्या हा फरक Book 9 (1.6) त कंपन्यांना लावला; इथे पेपरांना: **पेपर वाचा तो आकड्यांसाठी नव्हे, पद्धतींसाठी:** आकडे बातमी आहेत, पद्धती संपत्ती.

नकाशावर

2.1-2.7 सांगाडा | Q-K-V | $\sqrt{d_k}$ | multi-head | जागा+मुखवटा | मुद्रा | सांधे

2.8 शिकवण: BPE-तुकडे, Adam+warmup-4000 (चढ मग उतार), label smoothing 0.1 (नम्रतेचा डोस); निकाल: 28.4/41.8, ensembles हरले, 3.5 दिवस; Table 3 ablations; Table 1: $O(n^2 d)$ वि $O(nd^2)$, क्रमिक $O(1)$, रस्ता $O(1)$; n^2 = उद्याचं दुखणं

सूत्रावर: complexity-तक्ता हे सूत्राचं गणिती प्रमाणपत्र: 'रांग मोडा' चा फायदा $O(n) \rightarrow O(1)$ या दोन रकान्यांत सिद्ध. सूत्र घोषणा होती; तक्ता हिशेब आहे.

स्वतः बघा (5 मिनिटं)

आता मूळ पेपरची **Table 2** (निकाल) आणि **Table 3** (ablations) उघडून बघा: प्रत्येक ओळ ओळखीची वाटते का तपासा: (E) ओळीत sin-cos वि. learned दिसेल, (A) ओळीत डोकी-प्रयोग. जिथे अडाल तिथे या पुस्तकाचं पान-क्रमांक आठवा: नकाशाच आहे. हा अनुभव नोंदवा: **दोन आठवड्यांपूर्वी हा तक्ता तुम्हाला चिनी वाटला असता.**

विचार करा

पेपर संपला: यंत्र उभं, शिकलेलं, विक्रमी. पण 2017 ची ही भाषांतर-गोष्ट आजच्या ChatGPT-Claude पर्यंत पोहोचली **कशी?** मधल्या पाच वर्षांत नक्की काय घडलं: आणि पेपरच्या रचनेतलं आज काय जिवंत आहे, काय बदललं?

विभाग 3: स्फोटाची गोष्ट: GPT चा 'अर्धा-Transformer' जुगार, BERT चा उलटा अर्धा, scaling ची शर्यत, आणि आठ लेखकांचं (चकित करणारं) पुढचं आयुष्य: मूळ पेपर ते तुमच्या खिशातलं Claude-app हा पूर्ण पूल.

विभाग 2 चा हिशोब: यंत्र पूर्ण

आठ दारं एका नजरेत

- 2.1 सांगाडा 6+6 सारखे मजले; मजला = लक्ष + पचन;
RNN शून्य, सगळं समांतर
- 2.2 Q-K-V चिठ्ठी-पाटी-ऐवज; 4 पायऱ्या; 'बसली' =
48% मांजर (हाताने!)
- 2.3 $\sqrt{d_k}$ सूज $\rightarrow$ softmax-दगड $\rightarrow$ शिकणं थांबतं;
सुजेच्या मापाने भाग
- 2.4 multi-head 8 स्वतंत्र नजरा जवळजवळ फुकट (512/8);
1 डोकं -0.9 BLEU
- 2.5 तीन जागा वाचक-खुलं | लेखक-मुखवटा ($-\infty$) | खिडकी;
GPT = एकटा मुखवटा-मनोरा
- 2.6 मुद्रा घड्याळांची रांग: sin-cos; अंतर = फिरवणं
- 2.7 सांधे FFN-पचन (2/3 साठवण!) | residual-महामार्ग |
LayerNorm-तराजू
- 2.8 शाळा BPE, warmup, label smoothing; 28.4/41.8;
ablations; $O(1)$ रस्ता; n^2 ची कुजबुज

स्वतःची परीक्षा (आधी उत्तरं, मग खाली)

1. Attention च्या चार पायऱ्या क्रमाने सांगा: आणि 'जुळणी' नेमकी कशाकशाची होते?
2. $\sqrt{d_k}$ ने न भागल्यास शिकणं का थांबतं: साखळी सांगा.
3. मुखवटा ($-\infty$) नसता तर शिक्षणात नेमकी कुठली फसवणूक झाली असती?
4. sin-cos मुद्रेच्या 'गरजांची यादी' सांगा (निवड नव्हे, यादी!).
5. पेपरच्या complexity-तक्यातले दोन $O(1)$ कशाचे: आणि ते 1.1 च्या कुठल्या दुखण्यांची उत्तरं आहेत?

उत्तरं: (1) dot-गुण $\rightarrow \sqrt{d_k}$ -भाग $\rightarrow$ softmax-टक्के $\rightarrow$ ऐवजांची भारित बेरीज; जुळणी चिठ्ठी(Q) x पाटी(K) ची (2.2). (2) लांब बेरीज फुगते $\rightarrow$ softmax दगड $\rightarrow$ वजन हलवूनही टक्केवारी हलत नाही $\rightarrow$ gradient शून्य $\rightarrow$ शिकणं बंद (2.3). (3) पुढचा शब्द ओळखताना तो दिसतोच: यंत्र भाकीत नव्हे नक्कल शिकतं: परीक्षेत (खऱ्या वापरात) शून्य (2.5). (4) फुगू नये, प्रत्येक जागा वेगळी, अंतर गणिती-सोपं, कुठल्याही लांबीला चालावं (2.6). (5) क्रमिक-पावलं $O(1)$ = समांतर- स्वातंत्र्य (दुखणं-2) आणि लांबचा माहिती-रस्ता $O(1)$ = विसरण्यावर घाव (दुखणं-1) (2.8).

चाहूल: विभाग 3

यंत्र समजलं; आता त्याचं **साम्राज्य**: पेपरचा मनोरा कुणी अर्धा कापला आणि का (GPT/BERT); scaling-शर्यतीने भाषांतर-यंत्राचं जग-यंत्र कसं केलं; मूळ रचनेतलं आज काय टिकलं-काय बदललं (आणि n^2 च्या लढाईचं पुढे काय); आठ लेखकांची चकित करणारी पुढची आयुष्यं; आणि शेवटी: मूळ पेपर सोबत-नकाशाने स्वतः वाचण्याची अंतिम फेरी.

छोटा शब्दकोश (विभाग 2)

Q / K / V	चिठ्ठी (काय शोधतोय) / पाटी (माझ्याकडे काय) / ऐवज (प्रत्यक्ष माल)
scaled dot-product	गुणांची $\sqrt{d_k}$ ने भागलेली जुळणी
softmax saturation	गुण फुगून टक्केवारीचा दगड होणं
multi-head	अनेक स्वतंत्र चिठ्ठी-पाटी-संच: अनेक नजरा
causal mask	भविष्यावर $-\infty$ चा त्रिकोणी पडदा
cross-attention	लेखकाची चिठ्ठी, वाचकाच्या पाट्या-ऐवज
positional encoding	जागेची sin-cos घड्याळ-मुद्रा
FFN	प्रत्येक शब्दाचं एकट्याचं पचन ($512 \rightarrow 2048 \rightarrow 512$)
residual	खोलीभोवतीचा उडी-महामार्ग ($x + \text{खोली}(x)$)
LayerNorm	दर मजल्यावरचा आकडे-तराजू
BPE	वारंवारतेने बांधलेले शब्द-तुकडे
warmup	शिकण्याच्या वेगाची चढ-मग-उतार चाल
label smoothing	100% ऐवजी 90%: अति-खात्रीचं औषध
ablation	एक-एक भाग काढून 'कशामुळे चालतं' सिद्ध करणं