

The Paper, Part 3: पेपरनंतरचं जग

August 30, 2026

विभाग 3: पेपरनंतरचं जग

2017 चा पेपर भाषांतर-यंत्राबद्दल होता; जग त्याला 'चांगला पेपर' म्हणून पुढे गेलं. मग पाच वर्षांत तो युगाचा सांगाडा बनला: कसा: ही या विभागाची गोष्ट. चार दारं: **स्फोट** (GPT-BERT वंशावळ ते ChatGPT-क्षण), **तराजू** (मूळ रचनेतलं आज काय जिवंत, काय बदललं: n^2 च्या लढाईसकट), **आठ माणसं** (लेखकांची चकित करणारी पुढची आयुष्यं: त्यात एक धक्कादायक नमुना आहे), आणि **परतीची वाट** (मूळ पेपर आता सोबत-नकाशाने स्वतः वाचणं: या पुस्तकाचं खरं फळ).

शेवटी अंतिम परीक्षा: ती पास झालात तर या पुस्तकाचं वचन पूर्ण: **पेपर तुमचा झाला.**

Chapter 3.1 [SPINE]: स्फोट: मनोरा कापला आणि जग बदललं

पेपरनंतरची पाच वर्षे म्हणजे एका विचित्र शस्त्रक्रियेची गोष्ट: जगाने पेपरचा **मनोरा अर्धा कापला**: आणि दोन्ही अर्धांनी राज्यं स्थापली.

Jun 2018: GPT-1 (OpenAI): फक्त लेखक-मनोरा. OpenAI च्या लक्षात आलं: भाषांतराला दोन मनोरे लागतात; पण 'पुढचा शब्द ओळख' या एकाच खेळाला (Book 2, 2.2) फक्त लेखक-मनोरा पुरतो: मुखवटा-लक्षवाला (2.5 ची जागा-2!). आणि त्या खेळाची जादू: त्याला **शिक्षक लागत नाही**: कुठलाही मजकूर स्वतःच प्रश्नपत्रिका+उत्तरपत्रिका (पुढचा शब्द झाका: विचारा!): म्हणजे **अख्खं internet फुकट शाळा**. decoder-only + महापूर-data = GPT-वाट: आजचे GPT-Claude-Gemini सगळे याच अर्धा मनोऱ्याचे वंशज.

Oct 2018: BERT (Google): फक्त वाचक-मनोरा. उलटा अर्धा: मुखवटा नाही, सगळे शब्द सगळ्यांकडे: **समजण्याचं यंत्र** (शोध, वर्गीकरण, अर्थ-जुळणी: घडवण्याऐवजी). Google-search मध्ये घुसला; काही वर्षे BERT-वंश शैक्षणिक जगावर राज्य करत होता. मग हळूहळू लक्षात आलं: **घडवणारं यंत्र समजही आतून शिकतंच** (घडवायला समजावंच लागतं!): आणि scaling ला decoder-वाट सोपी: राज्य GPT-वंशाकडे झुकलं.

2019-2022: scaling ची शिडी (Book 7, 4.4 च्या रेषा प्रत्यक्षात). GPT-2 (2019: 1.5B वजनं: 'इतकं धोकादायक की पूर्ण देत नाही' चा गाजावाजा); **GPT-3 (2020: 175B: आणि अचानक यंत्र न-शिकवलेली कामं करू लागलं** (उदाहरणं दाखवा, ते शिकतं: in-context learning: Book 2, 4.4): 'मोठं करा, नवं उगवतं' हा scaling-मंत्र सिद्ध होत गेला. आणि हे परवडलं का? 2.8 चा complexity-तक्ता: समांतर-शिकवण: पेपरची रचना scaling- साठीच जन्मलेली निघाली (लेखकांनाही पूर्ण कल्पना नव्हती!).

Nov 30, 2022: ChatGPT-क्षण. GPT-3.5 + संवाद-शिक्षण (RLHF: Book 2/9) + मोफत chat-पान = इतिहासातली सर्वात वेगवान product-लाट. जग जागं झालं: आणि त्या क्षणापासूनचं सगळं (code-red, Claude, Gemini, अब्जांच्या पैजा) तुम्ही Book 9 त सविस्तर वाचलंच आहे. **मूळ बिंदू तोच 15-पानी पेपर.**

एका वाक्यावर (वर्तुळ पूर्ण): आपलं 'मांजर चटईवर बसली' 2017 त इंग्रजी झालं असतं; 2026 त तेच यंत्र-वंशज त्या मांजरीवर कविता करतो, तिच्या हिशेबाचं app लिहितो, आणि हे पुस्तकही: **खेळ तोच (पुढचा शब्द), मैदान जग झालं.**

महाग चूक

”पेपरने ChatGPT ‘निर्माण’ केला: सरळ रेषा.” इतिहास रेषेत चालत नाही: पेपर भाषांतरासाठी होता; decoder-कापणी OpenAI ची पैज होती (Google चा पेपर, पण ती उडी **बाहेरच्याने** मारली: Book 9, 1.1 ची फूट-गोष्ट इथून अर्धी समजते); scaling- श्रद्धा ही वेगळी, वादग्रस्त पैज होती (Book 9, 1.2); RLHF तिसरी. **क्रांती = रचना x पैज x पैज x पैज**: प्रत्येक पायरीवर ‘हे वेडेपणा आहे’ म्हणणारे बहुमतात होते. धडा (Book 8, 2.3): मूलभूत शोध आणि त्याचं सोनं करणारा **वेगळे असू शकतात**: शोध लागणं ही अर्धी गोष्ट; त्यावर उद्धट पैज लावणं उरलेली.

नकाशावर

3.1 स्फोट: GPT-1 (2018: फक्त लेखक-मनोरा: internet = फुकट शाळा) | BERT (2018: फक्त वाचक) | GPT-3 (2020: 175B, in-context) | ChatGPT (Nov 2022): खेळ तोच, मैदान जग

सूत्रावर: “तेवढंच पुरेसं” किती खरं निघालं बघा: अर्धा मनोराही पुरला! सूत्राची खरी परीक्षा त्याचे वारस घेतात: लक्ष-यंत्र कापून- वाकवून-फुगवूनही लक्ष-यंत्रच राहिलं.

स्वतः बघा (5 मिनिटं)

Claude ला विचारा: “तू decoder-only आहेस का: आणि तुझ्यात 2017 च्या पेपरमधलं नक्की काय-काय अजून जिवंत आहे?” उत्तराची यादी या पुस्तकाच्या नकाशाशी जुळवा (मुखवटा-लक्ष? FFN? residual? warmup?). यंत्रालाच त्याची वंशावळ विचारणं: हा अनुभव फक्त या युगात शक्य आहे.

विचार करा

”अजून जिवंत काय” हा प्रश्न खोल आहे: 2017 ची रचना 2026 च्या राक्षसांत **जशीच्या तशी** नक्कीच नसेल: नऊ वर्षांत engineers नी काय बदललं: आणि का? विशेषतः ते n^2 (2.8 ची कुजबुज): लाख-शब्दी context ला लक्षाचं गणित कसं परवडतं?

पुढचा chapter: टिकलं-बदललं चा तराजू: जिवंत यादी (आश्चर्यकारक लांब!) आणि बदल-यादी: pre-LN ची अदलाबदल, RoPE ची फिरकी (sin-cos चा वंशज!), GQA ची काटकसर, FlashAttention ची चतुराई, आणि n^2 विरुद्धची चालू लढाई.

Chapter 3.2 [SPINE]: काय टिकलं, काय बदललं: नऊ वर्षांचा तराजू

2026 चा कुठलाही frontier-LLM उघडला (Claude सकट) तर आत 2017 किती उरलंय? तराजू मांडू:

पारडं 1: जसंच्या तसं जिवंत (यादी थक्क करणारी): scaled dot-product attention (चारही पायऱ्या, $\sqrt{d_k}$ सकट: **अक्षरही बदललं नाही**); multi-head ची कल्पना; causal मुखवटा; residual-महामार्ग; FFN-पचन (रुंद-मग-अरुंद); LayerNorm ची गरज; BPE- जातीचे तुकडे; warmup-चाल; 'थर रचत जा' ही इमारत-कल्पना. म्हणजे: **सांगाडा 2017 चाच आहे**. नऊ वर्षांच्या trillion-डॉलर शर्यतीत कुणालाही मूलभूत बदली-रचना सापडलेली नाही (प्रयत्न झाले-होताहेत: पण राज्य अजून याच रचनेचं).

पारडं 2: घासून बदललेलं (आणि प्रत्येक बदलाचं 'का'):

बदल 1: तराजू आधी (pre-LN): पेपरने Norm खोली-नंतर ठेवला; खोल यंत्रांत (50+ मजले) शिक्षण अस्थिर निघालं: आता Norm खोली-आधी: शिडी आणखी स्थिर. (जागा बदलली; तराजू तोच.)
 बदल 2: घड्याळांची फिरकी (RoPE, 2021): sin-cos मुद्रा बाणात 'मिसळण्या'ऐवजी चिठ्ठी-पाटीच जागेनुसार 'फिरवायच्या' (2.6 ची rotation-जादू थेट वापरली!): नाती अधिक नेमकी: आजची बहुतेक open-models इथे. (कल्पना तीच: घड्याळं; अंमल नवा.)
 बदल 3: पाट्यांची काटकसर (MQA 2019 -> GQA 2023): भाकीत-वेळी प्रत्येक डोक्याला स्वतःच्या पाट्या-ऐवज महाग (memory!): मग डोक्यांच्या गटांत पाट्या वाटून घ्यायच्या. गंमत: MQA चा पेपर Shazeer चा: शीर्षक 'One Write-Head Is All You Need': लेखक स्वतःच्याच शीर्षकाची फिरकी घेतोय!
 बदल 4: n^2 ची लढाई (FlashAttention 2022 + पुढचं सगळं): गणित $O(n^2)$ च आहे: पण memory-वाहतूक चतुराईने केली (Book 6, 2.2 ची उतरंड!) तर वेग कैक पट: लाख-शब्दी context इथून परवडला. जोडीला sparse/sliding युक्त्या: पण 'लक्ष पूर्ण ठेवायचं की कापायचं' ही लढाई चालूच: [contested: बदली-रचनांचे (state-space वगैरे) दावेदारही रिंगणात: अजून कुणी राजा पाडला नाही].
 बदल 5: गोदामाची वाटणी (MoE): FFN एकच ठेवण्याऐवजी अनेक 'तज्ज्ञ' FFN; प्रत्येक शब्दाला 1-2 च जागे होतात: राक्षसी साठवण, माफक खर्च (Book 4, 1.4 त भेटलेलं MoE हे इथलं). मुळं पुन्हा Shazeer च्याच 2017-आधीच्या कामात!

तराजूचं वाचन: बदल कुठे झाले बघा: **कार्यक्षमतेत** (काटकसर, वेग, स्थैर्य): **कल्पनेत नाही**. चिठ्ठी-पाटी-ऐवज, मुखवटा, थर: गाभा अभंग. Book 5 (2.16) ची भाषा: चांगली रचना अशीच जगते: सांगाडा स्थिर, अवयव सुधारत. आणि Book 8 (3.6) ची नोंद: n^2 -लढाई ही या क्षेत्राची **चालू महा-पैज**: जो लक्षाइतकं समर्थ पण स्वस्त-वाढणारं यंत्र सिद्ध करेल त्याचा पुढचा पेपर कदाचित असाच युग-दुभंग असेल: **तुम्ही तो ओळखू शकाल आता**.

महाग चूक

”नवं शिकायचं म्हणजे जुनं टाकून द्यायचं: 2017 चा पेपर ‘जुना’ झाला.” AI-शिकणाऱ्यांची सर्वात महाग घाई. सत्य: नऊ वर्षांचे सगळे बदल **पेपरच्या चौकटीतल्या दुरुस्त्या** आहेत: पेपर न समजता RoPE-GQA-Flash शिकणं म्हणजे पाया न बघता पोटमाळा (काहीच का, कशाशी हे कळत नाही: नुसती नावं). उलटं चाला: **मूळ खोल शिका (हे पुस्तक), मग प्रत्येक नवा बदल ‘कुठल्या जुन्या दुखण्याचं औषध’ म्हणून वाचा**: बदल आपोआप लक्षात राहतात, आणि पुढचा बदल भाकीत करता येऊ लागतो: हीच research-नजर.

नकाशावर

- 3.1 स्फोट: मनोरा कापला
- 3.2 तराजू: सांगाडा 2017 चाच (चार पायऱ्या अक्षरशः); बदल =
कार्यक्षमता: pre-LN | RoPE (फिरकी) | GQA (पाट्या-वाटणी)
| FlashAttention (n^2 -लढाई, चालू) | MoE (गोदाम-वाटणी)

सूत्रावर: नऊ वर्ष, लाखो संशोधक, अब्जांचा दबाव: आणि सूत्र अभंग: “कोण कुणाला किती लागू” चं गणित अजून जगाचा सांगाडा आहे. सूत्रं जिंकतात ती अशी: साधी, खोल, आणि दुरुस्त्या पेलणारी.

स्वतः बघा (5 मिनिटं)

Claude ला विचारा: “RoPE, GQA, FlashAttention: प्रत्येक 2017- पेपरच्या कुठल्या भागाची दुरुस्ती आहे, एका-एका वाक्यात?” उत्तरं या chapter शी ताडा. मग गंमत-प्रश्न: “पुढची मोठी दुरुस्ती कुठे येईल असं तुला वाटतं?” उत्तर वहीत, तारखेसकट (Book 8, 3.6): दोन वर्षांनी तपासा: research-भाकिताची पहिली नोंद.

विचार करा

यंत्राचं भविष्य बघितलं; माणसांचं काय? आठ लेखकांनी युग घडवलं: मग ते पुढे काय झाले? आणि सगळ्यांत मोठा प्रश्न: हा पेपर Google चा: मग या युगाचं सोनं OpenAI-Anthropic कडे कसं गेलं: आठही लेखक आज कुठे आहेत?

उत्तरात एक धक्कादायक नमुना आहे: आठपैकी आठ जणांनी Google सोडलं: आणि त्यांची आजची ठिकाणं म्हणजे AI- जगाचा फिरता नकाशाच: एक Anthropic त (Claude वर!), एक OpenAI त परत, एक क्रांती करून mRNA कडे, एक crypto त... पुढचा chapter: आठ माणसांचं पुढे.

Chapter 3.3 [DEPTH]: आठ माणसांचं पुढे: लेखकांचा फिरता नकाशा

पेपरच्या पहिल्या पानावरची आठ नावं आज कुठे आहेत (Aug 2026, तपासलेलं): आणि या यादीत एक मोठा धडा लपलाय.

Ashish Vaswani	Adept -> Essential AI (CEO) -> Jun 2026: Nvidia ने टीमसकट घेतलं: आता Nvidia च्या open-models (Nemotron) वर
Noam Shazeer	Character.AI काढली -> Aug 2024: Google ने ~\$2.7B च्या करारात परत आणलं (Gemini सह-प्रमुख!) -> Jun 2026: पुन्हा निघाला: आता OpenAI त!
Niki Parmar	Adept -> Essential AI -> Jan 2025 पासून Anthropic: Claude-models वर! (हे पुस्तक लिहिणाऱ्या यंत्रामागे पेपरची एक लेखिका!)
Jakob Uszkoreit	Inceptive: AI ने mRNA-औषधं घडवणारी कंपनी (biology कडे: Loving-Grace-वाट!)
Llion Jones	शेवटचा निघाला (2023) -> Sakana AI (Tokyo) सह-संस्थापक: Nov 2025 त ~\$2.65B किंमत: Japan चं सर्वात मोठं AI-unicorn (तो intern!) Cohere चा CEO: enterprise-AI: 2025 त ~\$7B किंमत
Aidan Gomez	2021 पासून OpenAI: reasoning-संशोधन
Lukasz Kaiser	Illia Polosukhin NEAR Protocol: blockchain/crypto जग

नमुना 1: आठपैकी आठ गेले. युग घडवणारा पेपर ज्या घरात जन्मला ते घर आठही लेखकांनी सोडलं. का? नंतरच्या मुलाखतींचा सूर एकच: मोठ्या-स्थिर संस्थेत **उद्धट पैजांची जागा आकसते** (Book 8, 3.5 ची राजा-गोष्ट: जिकलेलं राखणाऱ्या यंत्रणेत नवं पेरणारे घुसमटतात): आणि पेपरने त्यांना जगाचं दार उघडून दिलं होतं. Google ला श्रेय द्या: पेपर **जाहीर** केला (खुल्या संशोधन- संस्कृतीचं फळ जगाला मिळालं); पण किंमतही Google नेच मोजली: शोध घरचा, स्फोट दुसऱ्यांच्या अंगणात, शोधकही अंगणोअंगणी.

नमुना 2: नकाशा हाच उद्योगाचा नकाशा. आठ वाटा बघा: frontier-प्रयोगशाळा (Anthropic, OpenAI x2), चिप-राक्षस (Nvidia), enterprise (Cohere), नवं विज्ञान (Inceptive: biology), नवी भूमी (Sakana: Japan), नवं चलन (NEAR: crypto). **एका पेपरच्या लेखकांची पांगापांग = अख्ख्या AI-अर्थव्यवस्थेचा आराखडा:** प्रतिभा कुठे वाहते ते बघा, उद्योग कुठे वाहणार ते दिसतं (Book 8, 3.6 ची नजर: talent-प्रवाह हे भाकीत-यंत्र).

नमुना 3: Shazeer ची फिरकी-गोष्ट वेगळी नोंदवण्याजोगी. गेला (2021, Character.AI) -> Google ने \$2.7 अब्ज मोजून परत आणला (2024: प्रतिभेची ती किंमत!) -> Gemini चा सह-प्रमुख -> आणि Jun 2026 त पुन्हा निघाला: OpenAI त. एकाच माणसाची किंमत-वाट अब्जांत मोजली जाते हे या युगाचं सत्य (Book 9, 1.6 ची Meta-packages आठवा): कारण उघड: **युग-दुभंग रचना काढू शकणारी डोकी जगात मूठभर आहेत:** आणि 2.4-3.2 त बघितलंत: MQA, MoE, अनेक पायाभूत विटा त्याच एका डोक्यातल्या.

महाग चूक

"पेपर लिहिणारे = आयुष्यभर 'संशोधक' राहतात: builders वेगळे." यादी उलट सांगते: आठपैकी सहा **कंपनी-बांधणारे** झाले (दोन CEO!): frontier-विज्ञान आणि धंदा यांची भिंत या युगात पडलीये. तुमच्यासाठी अर्थ: research-वाचनाची विद्या (हे पुस्तक!) ही 'शैक्षणिक' चैन नाही: **धंद्याचं early-warning-यंत्र** आहे: पुढचा युग-दुभंग पेपर आधी वाचणारा आधी हलतो (Book 8, 1.5 चं why-now दार पेपरांतूनच उघडताना दिसतं: 2017 त ते बघणाऱ्यांनी 2018-20 त साम्राज्यं पेरली).

नकाशावर

- 3.1 स्फोट 3.2 तराजू: टिकलं-बदललं
- 3.3 आठ माणसं: आठही Google बाहेर; वाटा = उद्योगाचा नकाशा
(Anthropic/OpenAI/Nvidia/Cohere/bio/Japan/crypto);
Shazeer: \$2.7B-परत -> पुन्हा बाहेर; intern -> \$7B-CEO

सूत्रावर: माणसांची गोष्टही सूत्राचीच: 'लक्ष' जिथे जातं तिथे किंमत जाते: जगाचं लक्ष रचनेकडे गेलं, रचनेकडून रचणाऱ्यांकडे: आणि रचणारे जिथे जातात तिथे पुढचं युग पेरलं जातं.

स्वतः बघा (5 मिनिटं)

तुमच्या क्षेत्रातला (कुठलंही: शिक्षण, शेती, बांधकाम) 'पेपर-क्षण' शोधा: गेल्या 2-3 वर्षांत असं कुठलं तंत्र/नियम/साधन आलंय ज्याच्या 'लेखकांची पांगापांग' आत्ता चालू आहे? ते लोक कुठे जाताहेत ते लिहा: तिथेच तुमच्या क्षेत्राचं पुढचं दार उघडतंय असण्याची शक्यता मोठी.

विचार करा

पुस्तकाचं वचन आठवा: “मूळ पेपर तुम्हाला परका राहणार नाही.” गोष्ट झाली, गणित झालं, इतिहास झाला. आता शेवटची पायरी उरली: **खुद्द पेपर, इंग्रजीत, पहिल्या पानापासून शेवटच्या, स्वबळावर.** ते धाडस कसं करायचं: कुठल्या क्रमाने, कुठे किती वेळ, काय वगळलं तरी चालेल?

शेवटचा पूर्ण chapter: सोबत-नकाशा: पेपरचं पान-न-पान या पुस्तकाशी जोडणारा वाचन-आराखडा + अडणीच्या जागांची यादी + 90 मिनिटांची बैठक-योजना. पेन घ्या: परीक्षेआधीची शेवटची तालीम.

Chapter 3.4 [SPINE]: परतीची वाट: मूळ पेपर, सोबत-नकाशाने

आता या पुस्तकाचं फळ वसूल करू: **मूळ पेपर स्वतः वाचायचा.** (arxiv.org/abs/1706.03762: PDF फुकट: छापून घ्या: कागदावर खुणा करत वाचणं हेच खरं.) ही 90-मिनटांची बैठक-योजना:

मिनिटं 0-10: पान 1-2 (Abstract + Introduction)
सोबत: आपला 1.4. आता प्रत्येक वाक्य ओळखीचं: 'sequential computation' दिसलं की 1.1 चं दुखणं-2 आठवा.
मिनिटं 10-15: विभाग 2 (Background)
झरकन: ConvS2S-ByteNet ही नावं = 'खिडकी-वाल्यांचे (convolution) प्रयत्न': त्यांचं दुखणं: लांबचा रस्ता $O(\log n)$ किंवा $O(n)$; आपल्याला $O(1)$ हवा होता (2.8 चा तक्ता).
मिनिटं 15-55: विभाग 3 (Model Architecture): गाभा: सावकाश
3.1-3.2 सांगाडा -> आपला 2.1 (Figure 1 आता 'वाचता' येते)
3.2.1 Scaled Dot-Product -> आपला 2.2-2.3 (समीकरण-1 खाली आपलं हात-गणित आठवा: 0.48, 0.21, 0.31!)
3.2.2 Multi-Head -> आपला 2.4 ($h=8$, $d_k=64$ ची काटकसर)
3.2.3 तीन जागा -> आपला 2.5 (पेपर इथे फक्त परिच्छेद देतो: तुमच्याकडे जास्त तपशील आहे!)
3.3 FFN -> 2.7 | 3.4 Embeddings (टीप: input-output embedding-वजनं वाटलेली: छोटी काटकसर) | 3.5 -> 2.6
मिनिटं 55-65: विभाग 4 (Why Self-Attention)
सोबत: 2.8 चा complexity-भाग: Table 1 ओळीने वाचा.
मिनिटं 65-80: विभाग 5-6 (Training + Results)
सोबत: 2.8: Table 2 त 28.4/41.8 शोधा; Table 3 च्या (A)-(E) ओळी ओळखा; 5.4 त label smoothing ची 'perplexity बिघडते पण BLEU सुधारतो' ही प्रामाणिक ओळ शोधा: सापडली की तुम्ही पेपर 'वाचताय', चाळत नाही.
मिनिटं 80-90: विभाग 7 (Conclusion) + मागचं appendix-चित्र शेवटच्या पानांवरची attention-चित्रं (कुठला शब्द कुणाकडे बघतो: खरे नमुने!) बघा: 'making...more difficult' वाक्यात 'making' चं लक्ष लांबवरच्या 'difficult' वर: $O(1)$ -रस्ता प्रत्यक्ष रंगात.

अडणीच्या जागा (आधीच सांगून ठेवतो): (1) समीकरणांतले matrix-आकार ($d_{\text{model}} \times d_k$ वगैरे): अडलात तर Book 7, 1.4 चा नियम: 'आतले आकडे जुळले पाहिजेत': प्रत्येक गुणाकार तपासा; (2) विभाग 6.2 च्या वाक्य-विश्लेषण (parsing) चाचण्या: दुय्यम: वगळलं तरी चालेल; (3) इंग्रजी दाट वाटलं तर: **परिच्छेद Claude ला द्या आणि 'या पुस्तकाच्या भाषेत सोपं कर' म्हणा:** Book 9, 3.3 ची यंत्रणा इथे शिक्षकही आहे.

वाचून झाल्यावरचा विधी (महत्वाचा): वहीत तीन ओळी: “मला सर्वात सुंदर वाटलेली कल्पना ___; अजूनही धूसर ___; पेपरने 2026 बदल न-भाकीत-केलेलं पण घडलेलं ___.” पहिली ओळ तुमची समज; दुसरी पुढचा अभ्यास; तिसरी **तुमची नजर पेपरच्याही पुढे** गेल्याची खूण (उदा: ‘फक्त भाषांतर नव्हे, सगळंच’ हे लेखकांच्या conclusion-स्वप्राहूनही मोठं घडलं).

महाग चूक

“पेपर एकदा वाचला = संपला.” संशोधन-वाचक पेपर **परत-परत** उघडतात: पहिल्यांदा गोष्ट (काय केलं), दुसऱ्यांदा गणित (कसं), तिसऱ्यांदा शंका (कुठे कच्चं: लेखकांनी काय न तपासलं? 2017 त कुणी विचारलं नव्हतं: ‘हे किती मोठं scale होईल?’ ती चाचणीच पेपरात नाही: आणि तीच पुढचं युग ठरली!). प्रत्येक फेरीत पेपर वेगळा दिसतो कारण **तुम्ही** वेगळे झालेले असता. हे पुस्तक तुमची पहिली-दुसरी फेरी होतं; तिसरी तुमची एकट्याची: आणि तिच्यातूनच स्वतःचे प्रश्न (म्हणजे स्वतःचं संशोधन) जन्मतात.

नकाशावर

- 3.1 स्फोट 3.2 तराजू 3.3 आठ माणसं
- 3.4 परतीची वाट: 90-मिनटांची बैठक (गाभा = विभाग 3 ला 40 मिनिटं); अडणी-यादी; वाचन-विधी: सुंदर/धूसर/न-भाकीत; पेपर परत-परत उघडायचा असतो

सूत्रावर: पुस्तकाची सुरुवात ‘पेपरची दहशत’ होती; शेवट ‘पेपर सोबती’ आहे. दहशत notation ची होती, गणिताची नव्हती: आणि आता notation ही तुमची भाषा आहे. **लक्ष दिलंत: तेवढंच पुरेसं होतं.**

स्वतः बघा (90 मिनिटं: यावेळी खरंच!)

वरची बैठक **आजच** करा: छापलेला पेपर, पेन, हे पुस्तक शेजारी, घड्याळ लावून. संपल्यावर तीन-ओळींचा विधी. हे ‘स्वतः बघा’ पुस्तकातलं शेवटचं आणि सर्वात मोठं: पण आता तुम्ही तयार आहात: 16 chapters ची तालीम झालीये.

विचार करा

उरली फक्त अंतिम परीक्षा: पुस्तकाचं वचन तपासायची. पुढचं पान उघडण्याआधी एक श्वास: 1.1 च्या रांगेपासून इथवरचा प्रवास आठवा: निरोप्यांची साखळी, ग्रंथालय, दोन घड्याळं, आठ डोकी, आठ माणसं.

| शेवटचं पान: परीक्षा + सूत्र-पत्र + या दहा-पुस्तकी कपाटाचा निरोप.

अंतिम परीक्षा + सूत्र-पत्र

अंतिम परीक्षा (पूर्ण पुस्तकाची: आधी उत्तरं, मग खाली)

1. पेपरने नक्की काय काढून टाकलं आणि त्या जागी काय ठेवलं: आणि 'काढण्याने' कुठली तीन दुखणी गेली?
2. $\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d_k})V$: या समीकरणातल्या प्रत्येक तुकड्याचं मराठी नाव आणि काम सांगा.
3. यंत्रात क्रम (शब्दांची जागा) कुठून येतो: आणि ती रीत 'फुगत का नाही'?
4. मुखवटा-लक्ष (masked attention) नसतं तर GPT-वंश जन्मलाच नसता: का?
5. 'attention is all you need' हे शीर्षक तांत्रिकदृष्ट्या कुठे अति-बोलतं: यंत्रातले कुठले बिन-लक्ष भाग प्राण आहेत?
6. 2026 च्या Claude त 2017 चं काय जसंच्या तसं आहे: चार गोष्टी: आणि n^2 चं काय झालं?

उत्तरं: (1) recurrence (रांग) आणि convolution (खिडकी) काढले; जागी फक्त attention; गेली: लांबचं विसरण (रस्ता $O(1)$), समांतर-बंदी (क्रमिक $O(1)$), चिंचोळी मान (प्रत्येक क्षणी पूर्ण वाक्य खुलं) (1.1, 2.8). (2) Q =चिठ्ठी (काय शोधतोय), K =पाटी (कुणाकडे काय), QK^T =जुळणी-गुण, $\sqrt{d_k}$ =सुजेवरचं औषध (softmax-दगड टाळणं), softmax=टक्केवारी, V =ऐवज, बाहेरची बेरीज=टक्क्यांनी ऐवज-गोळा (2.2-2.3). (3) sin-cos घड्याळ-मुद्रा अर्थ-बाणात मिसळून; काटे गोल फिरतात: स्थिती कायम -1 ते +1 (2.6). (4) 'पुढचा शब्द ओळख' शिकवताना उत्तर झाकावंच लागतं: नाहीतर नक्कल-शिक्षण; मुखवटा-मनोरा हाच GPT चा पूर्ण सांगाडा (2.5, 3.1). (5) FFN (पचन-साठवण), residual (महामार्ग: याच्याविना खोल यंत्र शिकत नाही), LayerNorm (तराजू) (2.7). (6) scaled dot-product जसाच्या तसा, multi-head, causal-मुखवटा, residual+FFN+Norm+warmup; n^2 गणितात कायम पण FlashAttention-जातीच्या memory-चतुराईने पेललं: लढाई चालू (3.2).

सहापैकी पाच जमली? **पेपर तुमचा झाला.** मूळ दस्तावेज आता संदर्भ-ग्रंथ म्हणून तुमच्या टेबलावर राहू शकतो.

सूत्र-पत्र (एका पानावर अख्खं पुस्तक)

दुखणं	रांग: विसरणं समांतर-बंदी चिंचोळी मान
कल्पना	लक्ष = 'कोण कुणाला किती लागू' ची शिकलेली टक्केवारी (2014 ची कुबडी -> 2017 ला मालक)
हृदय	$\text{softmax}(\mathbf{QK}^T/\sqrt{d_k})\mathbf{V}$: गुण->भाग->टक्के->बेरीज
डोकी	8 स्वतंत्र नजरा, 512/8: विविधता जवळजवळ फुकट
जागा 3	वाचक-खुलं लेखक-मुखवटा(- ∞) खिडकी
क्रम	$\sin\text{-}\cos$ घड्याळ-मुद्रा: जलद+संथ काटे
सांधे	FFN(पचन) + residual(महामार्ग) + Norm(तराजू)
शाळा	BPE Adam+warmup label smoothing 0.1
निकाल	28.4/41.8 BLEU; 3.5 दिवस x 8 GPU; ensembles हरले; रस्ता $O(1)$, क्रमिक $O(1)$
वारसा	GPT=अर्धा मनोरा; सांगाडा आजही तोच; बदल = कार्यक्षमता (pre-LN, RoPE, GQA, Flash, MoE)

कपाटाचा निरोप (दहा पुस्तकं)

या पुस्तकाने कपाटाचं वर्तुळ एका खास जागी बंद केलं: **ज्या रचनेवर हे सगळं कपाट लिहिणारं यंत्र चालतं, तिचाच जन्म-दस्तावेज त्याच यंत्राने तुम्हाला उलगडून दिला.** दहा पुस्तकं: यंत्र, विचार-यंत्र, जमीन, harness, रचना, engine-खोली, चष्मा, मालकाचं डोकं, Claude ची कुंडली, आणि उगम-पेपर. वाचणं इथे संपतं; **वापरणं** इथून सुरू होतं: Book 8 च्या शेवटी सांगितलेली 'लिहिलेली पैज' अजून वाट बघतेय: आता तिच्याकडे जायला तुमच्याकडे सगळी हत्यारं आहेत: नकाशासकट, मुळांसकट.

चला. वही उघडा.