

The Paper: Attention Is All You Need (Book 10)

August 30, 2026

THE PAPER

Book 10: Attention Is All You Need: पूर्ण उलगडा

(Vaswani et al., 2017: ज्या 15 पानांनी ChatGPT-Claude-Gemini चा सांगाडा घडवला त्या पेपरची पूर्ण शरीर-तपासणी: आधीचं जग, प्रत्येक समीकरण हाताच्या आकड्यांनी, नंतरचा स्फोट, आणि मूळ पेपर स्वतः वाचण्याचा सोबत-नकाशा. Devanagari मराठी + English tech शब्द. तीन भाग एका खंडात.)

अनुक्रम

PART 1: पेपरआधीचं जग आणि पेपरची गोष्ट

1.1 रांगेचं जग: RNN/LSTM आणि तीन ... 1.2 लक्षाचा जन्म: 2014 ची ठिणगी

1.3 पेपरची गोष्ट: आठ माणसं, एक शर... 1.4 पेपर बाहेरून: abstract चा उलगड

PART 2: पेपरच्या आत: प्रत्येक समीकरण हाताने

2.1 सांगाडा: 6+6 मजल्यांची इमारत 2.2 Q-K-V: पेपरचं हृदय, हाताच्या आ

2.3 $\sqrt{d_k}$ चं गूढ: एका भागाकाराची ग... 2.4 Multi-Head: आठ डोकी, आठ नजरा

2.5 लक्षाच्या तीन जागा आणि मुखवटा 2.6 जागेची मुद्रा: sin-cos ची घड्य

2.7 सांधे: FFN, उडी-रस्ता, तराजू 2.8 शिकवण आणि निकाल: पेपरचे तक्ते

PART 3: पेपरनंतरचं जग

3.1 स्फोट: मनोरा कापला आणि जग बदल... 3.2 काय टिकलं, काय बदललं: नऊ वर्षा

3.3 आठ माणसांचं पुढे: लेखकांचा फि... 3.4 परतीची वाट: मूळ पेपर, सोबत-नका

वाचनाची टीप: 'मांजर चटईवर बसली' -> 'the cat sat on the mat' हे एकच वाक्य पुस्तकभर यंत्रातून प्रवास करतं; प्रत्येक समीकरण छोट्या खऱ्या आकड्यांनी हाताने (Book 7 ची शैली). शेवटी 90-मिनिटांची मूळ-पेपर-बैठक: पेपर तुमचा होतो.

THE PAPER

Book 10, Part 1: पेपरआधीचं जग आणि पेपरची गोष्ट

हे पुस्तक कुणासाठी: जगात असे मोजके दस्तावेज असतात ज्यांनी इतिहास दुभंगला: त्यांच्या आधीचं जग वेगळं, नंतरचं वेगळं. "Attention Is All You Need" (2017) हा त्यातला एक: **15 पानांचा पेपर ज्याने ChatGPT-Claude-Gemini या सगळ्यांचा सांगाडा जन्माला घातला.** तुम्ही Book 2 त कल्पना शिकलात, Book 7 त गणित: आता **उगम- दस्तावेज स्वतः**: पूर्ण, समीकरणागणिक, हाताच्या आकड्यांनी: वाचून संपल्यावर मूळ पेपर तुम्हाला परका राहणार नाही.

या पुस्तकाचं एकमेव सूत्र

रांग मोडा: प्रत्येक शब्दाला सगळ्यांकडे एकदम बघू द्या.
"कोण कुणाला किती लागू?" या एका प्रश्नाचं गणित = लक्ष.
आणि तेवढंच पुरेसं आहे: ना रांग, ना खिडकी.

पेपरचं शीर्षक हीच घोषणा आहे: लक्ष (attention) ही **जोड-सोय नाही; ती एकटीच पुरते**: बाकी सगळं (तेव्हाचं पवित्र RNN-यंत्र!) फेकून द्या. 2017 त हे उद्घट वाटलं; आज हे जगाचं वास्तव आहे.

एक वाक्य, एक प्रवास: या पुस्तकाची रीत

पुस्तकभर एकच काम करू: **"मांजर चटईवर बसली"** चं **"the cat sat on the mat"** होणं (पेपरचं स्वतःचं कामही भाषांतरच होतं!). हे वाक्य प्रत्येक chapter मध्ये यंत्राच्या एका-एका अवयवातून जाईल: आणि प्रत्येक अवयवाचं गणित आपण **छोट्या खऱ्या आकड्यांनी हाताने** करू (Book 7 च्या थेंबू-शैलीत). पेपर 'वाचणं' आणि पेपर 'चालवून बघणं' यांतला फरक हाच.

तीन भागांचा नकाशा: तुम्ही इथे आहात

- PART 1 पेपरआधीचं जग + पेपरची गोष्ट <- तुम्ही इथे
रांगेचं दुखणं, लक्षाचा जन्म, 8 लेखक, abstract
- PART 2 पेपरच्या आत: प्रत्येक समीकरण हाताने
Q-K-V, $\sqrt{d}$ चं गूढ, 8 डोकी, मुखवटा, sin-cos,
सांधे, शिकवण-निकाल
- PART 3 पेपरनंतरचं जग
GPT-BERT वंशावळ, काय टिकलं-बदललं, लेखकांचं
पुढे, मूळ पेपर सोबत-नकाशाने

कपाटावर एक नजर

- | | | | |
|--------|-----------------|---------|--|
| Book 1 | The Machine | Book 2 | The Thinking Machine |
| Book 3 | The Land Game | Book 4 | The Harness |
| Book 5 | The Blueprint | Book 6 | The Engine Room |
| Book 7 | The Lens | Book 8 | The Owner's Mind |
| Book 9 | The Claude Book | Book 10 | The Paper <- हे:
उगम-दस्तावेजाचा
पूर्ण उलगडा |

नाती स्पष्ट: Book 2 (4.2-4.3) ने attention ची **कल्पना** दिली; Book 7 (Part 4) ने त्याचं **गणित** हाताने केलं; हे पुस्तक त्या दोन्हींच्या मुळाशी जाऊन **पेपरच** पूर्ण करतं: तिथून पुढे तुम्ही कुठलाही AI-पेपर स्वबळावर वाचू शकाल (Book 7, 4.5 चं वचन इथे पूर्ण होतं).

एक इशारा, सुरुवातीलाच

पेपरचे सगळे आकडे-तपशील मूळ दस्तावेजातून आणि बाहेरून तपासलेले आहेत; लेखकांच्या-जन्मकथेच्या दंतकथा (ज्या भरपूर आहेत!) जिथे अपुष्ट तिथे तसंच म्हटलंय. आणि नेहमीची शिस्त: देव-पूजा नाही: पेपरमधल्या **अपूर्ण जागाही** दाखवू (लेखकांनाही तेव्हा माहीत नव्हतं की हे इतकं मोठं होईल: तो प्रामाणिकपणा हीच गोष्टीची चव).

विभाग 1: पेपरआधीचं जग आणि पेपरची गोष्ट

कुठलाही क्रांतिकारी दस्तावेज समजायचा तर आधी तो ज्या तुरुंगातून सुटका करतो तो तुरुंग समजावा लागतो. 2017 पूर्वी भाषा-AI एका रांगेत कैद होतं: शब्द एकामागोमाग एक वाचायचे: आणि त्या रांगेची तीन दुखणी जगातल्या सर्वात हुशार प्रयोगशाळांना अडवून बसली होती.

या विभागात चार दारं: **रांगेचं जग** (RNN/LSTM: दुखण्यांसकट), **लक्षाचा जन्म** (2014 ची पहिली ठिणगी: रांगेला जोडलेलं लक्ष), **पेपरची गोष्ट** (आठ माणसं, एक उन्हाळा, एक उद्धट शीर्षक), आणि **पेपर बाहेरून** (abstract चा शब्दागणिक उलगाडा + पुढच्या प्रवासाचा नकाशा). विभाग संपेल तेव्हा पेपरचं पहिलं पान तुम्ही मूळ इंग्रजीत वाचून समजू शकाल.

Chapter 1.1 [SPINE]: रांगेचं जगः RNN/LSTM आणि तीन दुखणी

2017 पूर्वी यंत्राला वाक्य वाचायची एकच मान्य रीत होती: **रांगेने**. RNN (recurrent neural network: Book 2, 3.6 ची आठवण): यंत्र शब्द एकामागोमाग घेतं आणि एक **आठवण-गाठोडं** (hidden state) पुढे-पुढे सरकवत नेतं: प्रत्येक नव्या शब्दाने गाठोडं बदलतं.

उपमा: निरोप्याची साखळी. “मांजर चटईवर बसली” हे वाक्य गावाबाहेर पोहोचवायचंय. रीत अशी: पहिला निरोप्या “मांजर” ऐकतो, आपल्या डोक्यात ठेवून दुसऱ्याला **सारांश** सांगतो; दुसरा त्यात “चटईवर” मिसळून तिसऱ्याला; तिसरा “बसली” मिसळून चौथ्याला. शेवटच्या निरोप्याकडे अख्ख्या वाक्याचं **एकच घुसळलेलं गाठोडं** असतं: त्यातून त्याने भाषांतर करायचं.

दुखणं 1: लांबचं विसरणं. साखळी लांबली (50-100 शब्दांचं वाक्य) की सुरुवातीचे शब्द गाठोड्यात **विरत** जातात: 40 व्या शब्दापर्यंत “मांजर” चा वास फिका. गणिती नाव: vanishing gradients (Book 7, 3.3 चं chain-rule: 40 पायऱ्यांतून मागे जाताना गुणाकारांत संदेश शून्याकडे). LSTM (1997 ची सुधारणा: गाठोड्याला ‘लक्षात-ठेव/विसर’ अशी दारं) ने हे **सौम्य** केलं, **संपवलं नाही**: लांब पल्ल्याची नाती (वाक्याच्या सुरुवातीचा ‘तो’ आणि शेवटचं ‘गेला’ यांची जोडी) अजूनही धूसरच.

दुखणं 2: रांग म्हणजे वेळ. शब्द 7 वाचायच्या आधी शब्द 6 पूर्ण व्हावाच लागतो (त्याचं गाठोडं लागतं!): म्हणजे **समांतर काम अशक्य**. आणि नेमकं याच काळात hardware-जग उलट्या दिशेला गेलं होतं: GPU म्हणजे हजारो हात **एकाच वेळी** काम करणारं यंत्र (Book 6, 3.4). RNN त्या हजार हातांना रांगेत उभं करून एका-एका शब्दाची वाट बघायला लावायचा: विकत घेतलेली समांतर-शक्ती वाया. मोठा data, मोठी models: सगळं **रांगेच्या वेगाने** रखडलेलं.

दुखणं 3: गाठोड्याची चिंचोळी मान. अख्ख्या वाक्याचा अर्थ **एका ठरावीक-आकाराच्या** गाठोड्यात कोंबायचा (seq2seq रचना, 2014: वाचक-RNN ने गाठोडं बांधायचं, लेखक-RNN ने त्यातून भाषांतर काढायचं). 10 शब्दांना ठीक; 60 शब्दांचा परिच्छेद त्याच गाठोड्यात? पाण्याचा टँकर स्ट्रॉ मधून: माहिती **मानेतच** अडते.

आणि तरी हेच राज्य होतं. 2016 ला Google Translate ची मोठी झेप (GNMT) याच LSTM-तंत्रावर: जगातल्या सर्वोत्तम टीमा रांगेची दुखणी **औषधांनी** सांभाळत होत्या (दारं, युक्त्या, थरांवर थर): कुणी विचारत नव्हतं की **रांगच का हवी?** (Book 8, 1.1 आठवा: ‘असंच असतं’ चा वास: first-principles चा प्रश्न विचारायची वेळ भरली होती.)

एका वाक्यावर: आपलं “मांजर चटईवर बसली” रांगेच्या जगात असं जगायचं: ‘मांजर’ -> गाठोडं-1 -> +‘चटईवर’ -> गाठोडं-2 -> +‘बसली’ -> गाठोडं-3 -> त्या एकट्या गाठोड्यातून ‘the cat sat on the mat’ उपसायचं. तीन शब्दांना जमतं; तीस शब्दांना जीव घुसमटतो. **हे वाक्य आता पुस्तकभर आपल्यासोबत राहील: पुढच्या प्रत्येक chapter मध्ये त्याची सुटका टप्प्याटप्प्याने बघू.**

महाग चूक

”RNN ‘चुकीचं’ होतं आणि लेखकांनी ‘बरोबर’ शोधलं.” इतिहास असा साधा नसतो: RNN हा **त्या काळच्या hardware-data-मापाला योग्य सौदा** होता (Book 5 चं सूत्र: रचना-निर्णय = सौदा!): छोट्या data-युगात रांगेची शिस्त उपयोगीही होती. बदललं काय: **मैदान** (GPU-समांतरता स्वस्त, data महापूर): आणि जुन्या सौद्याच्या अटी शिळ्या झाल्या. धडा तांत्रिक कमी, मालकी-नजरेचा जास्त (Book 8, 2.4 चा Grove!): **तुमचं आजचं ‘योग्य’ तंत्र कुठल्या अटींवर उभं आहे, आणि त्या अटी कोण हलवतंय?**

नकाशावर

1.1 रांगेचं जग: RNN/LSTM = निरोप्यांची साखळी; तीन दुखणी:
लांबचं विसरण (vanishing) | समांतर-बंदी (GPU वाया) |
गाठोड्याची चिंचोळी मान (seq2seq)

सूत्रावर: सूत्र म्हणतं “रांग मोडा”: हा chapter सांगतो रांग **का** मोडायची होती: तिन्ही दुखणी रांगेच्याच पोटची. पुढे प्रश्न उरतो: रांगेशिवाय शब्दांचा **क्रम** कसा सांभाळायचा? (उत्तर 2.6 पर्यंत राखून ठेवा: पेपरची सर्वात नाजूक युक्ती तीच.)

स्वतः बघा (5 मिनिटं)

स्वतःवर प्रयोग: कुणाला तरी 25-30 शब्दांचं लांब वाक्य **एकदाच** वाचून दाखवा आणि लगेच भाषांतर/सारांश मागा: सुरुवातीचा भाग हमखास गळेल (माणसाचं गाठोडंही चिंचोळं!). मग तेच वाक्य **लिहून समोर** ठेवा: आता सगळं जमतं: कारण नजर **कुठल्याही शब्दाकडे केव्हाही** परत जाऊ शकते. हा दुसरा अनुभव म्हणजेच: attention. पेपरने यंत्राला नेमकी हीच सोय दिली.

विचार करा

रांगेची दुखणी 2015-16 लाच जगजाहीर होती. मग प्रश्न: क्रांतीच्या **आधीची पायरी** काय होती? म्हणजे: कुणीतरी रांग पूर्ण मोडण्याआधी रांगेला **कुबडी** लावून बघितली असणार: ती कुबडी कुठली, कुणी लावली, आणि तिनेच पुढच्या क्रांतीचा दरवाजा कसा दाखवला?

बरोबर ओळखलंत: लक्ष (attention) ही कल्पना 2017 ची नाही: 2014 चीच: पण **रांगेला जोडलेली मदतनीस** म्हणून. Bahdanau नावाच्या एका विद्यार्थ्याची ती युक्ती, आणि तिच्यातून निघालेला उद्धट प्रश्न: 'मदतनीसच इतकी हुशार, तर मालक कशाला?': पुढचा chapter: लक्षाचा जन्म.

Chapter 1.2 [SPINE]: लक्षाचा जन्म: 2014 ची ठिणगी

क्रांत्या शून्यातून येत नाहीत; **कुबड्यांमधून** येतात. Attention ची कुबडी 2017 च्या तीन वर्ष आधी लागली होती.

Sep 2014: Bahdanau-Cho-Bengio चा पेपर. Dzmitry Bahdanau (तेव्हा विद्यार्थी!) आणि सहकाऱ्यांनी seq2seq च्या चिंचोळ्या मानेवर (1.1 चं दुखणं-3) थेट घाव घातला. त्यांची युक्ती: **लेखक-RNN ला एकाच गाठोड्यावर जगायला लावू नका; त्याला प्रत्येक शब्द लिहिताना मूळ वाक्यातल्या सगळ्या शब्दांकडे मागे वळून बघू द्या: आणि 'आत्ता कुणाकडे किती बघायचं' हे त्याचं त्यालाच शिकू द्या.** हेच पहिलं attention: भाषांतर करताना 'the cat' लिहिण्याच्या क्षणी यंत्राची नजर आपोआप 'मांजर' वर: 'sat' लिहिताना 'बसली' वर: **जिवंत, वळणारी नजर:** गोठवलेल्या गाठोड्याऐवजी.

गणिताची पहिली चव (हाताने, पुढच्या भागाची तालीम): नजर 'वळते' म्हणजे नक्की काय? **वजनांची वाटणी.** 'sat' लिहिण्याच्या क्षणी यंत्र मूळ तीन शब्दांना गुण देतं (जुळणीचे: कसे ते Part 2 त): समजा मांजर=1.0, चटईवर=0.5, बसली=3.0. softmax (Book 7, 2.6) ने गुणांची **टक्केवारी:** 0.11, 0.07, 0.82. मग या टक्क्यांनी तिन्ही शब्दांच्या अर्थ-बाणांची (vectors) **भारित सरासरी:** म्हणजे 'sat' च्या क्षणीचं संदर्भ-गाठोडं 82% 'बसली' चं. **नजर = टक्केवारी. इतकंच.** पुढच्या क्षणी ('on' लिहिताना) टक्केवारी नवी: 'चटईवर' कडे झुकलेली. चिंचोळी मान गेली: प्रत्येक क्षणाला ताजं, त्या-क्षणापुरतं गाठोडं.

निकाल आणि मर्यादा. भाषांतर सुधारलं (लांब वाक्यांवर खासच); 2015 त Luong च्या पेपरने रीती आणखी घासल्या; 2016 च्या Google-Translate-झेपेतही (GNMT) attention-कुबडी होतीच. पण लक्षात घ्या रचना: **मालक अजून RNN च होता:** रांग कायम (दुखणं-2 जिवंत: समांतर-बंदी!), विसरणं सौम्य-पण-हजर, attention फक्त वाचक-लेखक यांना जोडणारा **पूल.** कुबडीने चालणं सुधारलं; रांगेचा तुरंग शाबूत.

आणि मग तो प्रश्न. अशा क्षणी इतिहास वळतो जेव्हा कुणीतरी मदतनीसाकडे बघून विचारतं: **"कामातलं खरं शहाणपण हिच्यातच दिसतंय: मग मालक (RNN) हवाच कशाला?"** first-principles चा शुद्ध क्षण (Book 8, 1.1): 'attention ही RNN ची सोय' हे **मत** होतं; 'शब्दा-शब्दांची जुळणी मोजता येते' हे **मूळ** होतं. मत सोलून फेकलं की उरतो प्रश्न: लक्ष **एकटं** पुरेल का: वाचकातही, लेखकातही, पुलावरही: सगळीकडे फक्त लक्ष? या प्रश्नाचं 15-पानी उत्तर म्हणजे आपला पेपर: आणि त्याचं शीर्षक हा प्रश्नच आहे, उत्तरासकट: **Attention Is All You Need.**

महाग चूक

”क्रांतिकारी कल्पना ‘नवीन’ असते.” Attention 2014 ला जन्मली, 2015-16 त सर्वत्र वापरात होती: **2017 चा पेपर एकही मूलभूत नवी संकल्पना आणत नाही!** त्याची क्रांती **वजा-करण्यात** आहे: सगळे RNN काढून फक्त attention ठेवणं: हे धाडस कल्पनेचं नाही, **विश्वासाचं** (कुबडी मालक होऊ शकते हा विश्वास). इतिहासात हे परत-परत दिसतं: क्रांती बहुधा नव्या तुकड्यात नसते; **जुन्या तुकड्यांच्या उद्धट फेर-मांडणीत** असते (Book 8, 1.1: मुळांची फेर-जुळणी). ‘माझ्याकडे नवं काही नाही’ म्हणून थांबलेल्यांनी हे लक्षात ठेवावं: फेर-मांडणीचं धाडस हीच अनेकदा खरी नवता.

नकाशावर

- 1.1 रांगेचं जग: तीन दुखणी
- 1.2 लक्षाचा जन्म: Bahdanau 2014: लेखकाला मूळ वाक्यभर वळणारी नजर (नजर = softmax-टक्केवारी x भारित सरासरी); पण मालक RNN च; मग प्रश्न: ‘मदतनीसच हुशार, तर मालक कशाला?’

सूत्रावर: “कोण कुणाला किती लागू?” हे सूत्रातलं गणित 2014 लाच जगात आलं: 2017 ने फक्त (फक्त!) ‘तेवढंच पुरेसं आहे’ हे सिद्ध केलं. सूत्राचा पूर्वार्ध Bahdanau चा, उत्तरार्ध पेपरचा.

स्वतः बघा (5 मिनिटं)

तुम्ही स्वतः भाषांतर करताना तुमची नजर बघा: कुठलंही इंग्रजी वाक्य घ्या आणि मराठीत लिहिताना **प्रत्येक मराठी शब्दाच्या क्षणी तुमची नजर इंग्रजीत कुठे आहे** ते टिपा. नजर उड्या मारते (क्रमाने जात नाही!), आणि प्रत्येक क्षणी 1-2 शब्दांवर जड असते: तुम्ही आत्ता स्वतःमधलं attention पकडलंत: softmax-टक्केवारीसकट (जड नजर = मोठं वजन).

विचार करा

प्रश्न विचारला गेला: “लक्ष एकटं पुरेल का?” पण प्रश्न विचारणं आणि 15 पानांत जगाला पटवणं यात अंतर आहे. कुणी विचारला हा प्रश्न? कुठे? आणि आठ नावं पेपरवर आहेत: **आठ जणांनी मिळून एक पेपर कसा घडतो: कुणी काय केलं?**

पुढचा chapter गोष्टीचा: Google च्या इमारतीतले आठ जण, एका boardवरचं वाक्य, तीन महिन्यांची शर्यत, Beatles च्या गाण्यातून आलेलं शीर्षक, आणि ‘योगदान सर्वांचं सारखं: क्रम चिठ्ठ्या टाकून’ ही पेपरवरची अनोखी तळटीप: पेपरची जन्मकथा.

Chapter 1.3 [SPINE]: पेपरची गोष्ट: आठ माणसं, एक शर्यत, एक उद्धृत शीर्षक

जागा: Google, 2017. आठ जण: Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan Gomez, Lukasz Kaiser, Illia Polosukhin. कुणी वरिष्ठ संशोधक, कुणी नुकतेच आलेले: आणि **Aidan Gomez तर Toronto चा शिकाऊ (intern)** होता: पेपरवर त्याचं नाव विद्यापीठाच्या पत्त्यासकट आहे! Polosukhin पेपर छापला जाईपर्यंत Google सोडूनही गेला होता (तळटीप: 'काम Google त असताना केलं'). म्हणजे: इतिहास घडवणारा गट 'निवडलेल्या ताऱ्यांचा' नव्हता: **कल्पनेभोवती जमलेल्या उत्सुकांचा** होता.

कल्पनेचा प्रवाह. 'रांगेशिवाय, फक्त लक्षाने' ही दिशा आतल्या वर्तुळात Jakob Uszkoreit जोरात मांडत होता (self-attention वरचं त्याचं काम 2017 आधीचंच): गंमत म्हणजे त्याचे वडील (प्रसिद्ध भाषा-वैज्ञानिक) यालाही साशंक होते! Vaswani-Shazeer-Parmar आणि बाकीचे जुळत गेले; Shazeer (जुना-मुरलेला engineer) ने यंत्रणा घडवण्यात मोठा वाटा उचलला. मग **NIPS 2017 (आजचं NeurIPS) च्या deadline ची शर्यत: May 19, 2017:** शेवटचे आठवडे रात्र-दिवस: प्रयोग, तक्ते, लिखाण: आणि deadline च्या 'दोन रात्री आधी' Llion Jones ने शीर्षक सुचवलं: Beatles च्या "All You Need Is Love" वरून: **"Attention Is All You Need."** (यंत्राचं नाव 'Transformer' Uszkoreit चं: कारण साधं: त्याला शब्दाचा नाद आवडला!) Jun 12, 2017 ला arXiv वर जगासमोर.

पेपरवरची अनोखी तळटीप. पहिल्याच पानावर: **"Equal contribution. Listing order is random."** (योगदान सर्वांचं सारखं; नावांचा क्रम चिठ्ठीने). शैक्षणिक जगात नाव-क्रम ही युद्धभूमी असते (पहिलं नाव = श्रेय); या आठांनी ती लढाईच रद्द केली. Book 8 (3.3) ची संस्कृती-नजर: **हा छोटा निर्णय गटाच्या आतल्या विश्वासाचं मोठं मोजमाप आहे:** आणि योगायोग नव्हे की अशाच गटातून बिनधास्त 'सगळं RNN फेकून द्या' निघू शकलं (भीतीच्या संस्कृतीत कुणी हे बोललंही नसतं: Nokia आठवा).

निकालाची झलक (तपशील 2.8 त): भाषांतर-स्पर्धेच्या (WMT 2014) दोन्ही मैदानांत नवा विक्रम: आणि **आधीच्या विजेत्यांच्या अंशात्मक खर्चात** (8 GPU वर साडेतीन दिवस: तेव्हाचे विजेते आठवडे जळायचे). पण 2017 त जग 'बरं, छान पेपर' म्हणालं: क्रांती **ओळखली** गेली नव्हती: ती पुढच्या पाच वर्षांत उलगडत गेली (Part 3). आज: **2 लाखांवर citations: या शतकातल्या सर्वात-उल्लेखलेल्या पेपरांच्या पहिल्या दहांत** (गंमत: पहिला नंबर अजूनही ResNet चा: Book 2 च्या जगालाही नमस्कार).

आणि गोष्टीचा काटा (Book 8, 3.5 ची पुनरावृत्ती): हा पेपर Google चा. पण त्याचं सोनं केलं OpenAI ने (GPT-मालिका: 3.1). आणि आठही लेखक **Google सोडून गेले** (शेवटचा Llion Jones, 2023): कुणी स्वतःच्या कंपनी काढल्या, कुणी स्पर्धकांकडे (आजचे पत्ते: 3.3 त: त्यात Anthropic ही आहे!). Kodak-प्रश्न पुन्हा: **शोध घरात, फायदा दारात:** का होतं हे: Part 3 त खोदू.

महाग चूक

”असे पेपर ‘प्रतिभेच्या झटक्यात’ जन्मतात.” गोष्ट उलटी शिकवते: (1) कल्पना **जुनीच** होती (1.2: attention 2014 चं; self-attention वरही आधी काम); (2) गट **खुल्या दाराचा** होता (intern सकट; श्रेय-लढाई रद्द); (3) झटका नव्हे, **deadline-शर्यत** होती: प्रयोग- तक्ते-घासणं. म्हणजे कृती-सूत्र असं: जुन्या कल्पना + मोकळा गट + सक्तीची मुदत = क्रांतीची शक्यता. ‘प्रतिभेची वाट बघणं’ ही सर्वात महाग वाट: **रचना बांधता येते, झटका नाही.**

नकाशावर

- 1.1 रांगेचं जग: तीन दुखणी
- 1.2 लक्षाचा जन्म: Bahdanau 2014 + उद्धट प्रश्न
- 1.3 पेपरची गोष्ट: 8 लेखक (intern सकट), equal-contribution-चिठ्ठी, deadline-शर्यत, Beatles-शीर्षक, 'Transformer' = नादासाठी; आज 200K+ citations; सगळे Google सोडून गेले

सूत्रावर: शीर्षकाचा उद्धटपणा ('तेवढंच पुरेसं!') हा गटाच्या आतल्या मोकळेपणाचं फळ होता: विश्वासाच्या खोलीतच धाडसी वाक्यं जन्मतात: सूत्र यंत्राचं आहे, पण गोष्ट माणसांची.

स्वतः बघा (5 मिनिटं)

पेपरचं पहिलं पान उघडा: नावं वाचा, तळटीपा वाचा (Gomez ची Toronto-टीप, Polosukhin ची 'काम-तेव्हाचं' टीप, equal-contribution- ओळ). मग स्वतःला: तुमच्या कामाच्या जगात 'श्रेयाची चिठ्ठी-वाटणी' चालेल का: आणि न चालण्याने कुठली धाडसी वाक्यं बोलली जात नाहीयेत? (उत्तर अस्वस्थ करेल: तीच किंमत.)

विचार करा

गोष्ट झाली; आता दस्तावेज. पेपरचं पहिलं पान म्हणजे **abstract**: आठ ओळींत अख्खा दावा. पण संशोधन-पेपरची भाषा दाट असते: प्रत्येक शब्द वजनाने भरलेला. ती आठ-ओळी नक्की काय **दावा** करतात: आणि 'दावा' विरुद्ध 'पुरावा' ही पेपरची रचना कशी वाचायची?

पुढचा chapter: abstract चा शब्दागणिक उलगडा + पेपरच्या सात विभागांचा नकाशा + निकालाचे दोन आकडे जे पाठ करण्याजोगे आहेत: 28.4 आणि 3.5 दिवस. विभागाचा शेवट.

Chapter 1.4 [SPINE]: पेपर बाहेरून: abstract चा उलगडा आणि विभाग-नकाशा

संशोधन-पेपर वाचायची पहिली विद्या (Book 7, 4.5 ची उजळणी): **पेपर = दावा + पुरावा**. Abstract म्हणजे दाव्याचं आठ-ओळी रूप. आपल्या पेपरचा abstract वाक्या-वाक्याने मराठीत सोलू (मूळ इंग्रजी सोबत ठेवून वाचा: शब्द जुळवत):

ओळ 1-2 (जुनं जग): "प्रचलित sequence-यंत्रं गुंतागुंतीच्या recurrent/convolutional जाळ्यांवर उभी आहेत: encoder-decoder रचनेत." -> आपला 1.1: रांगेचं जग.
ओळ 3 (कुबडी): "सर्वोत्तम यंत्रं attention ने encoder-decoder जोडतात." -> आपला 1.2: Bahdanau ची कुबडी.
ओळ 4 (दावा!): "आम्ही Transformer ही नवी, साधी रचना मांडतो: फक्त attention वर; recurrence आणि convolutions पूर्ण वगळून." -> 'साधी' (simple) हा शब्द मुद्दाम आहे: अभिमानाचा: गुंतागुंत कापली हीच प्रगती.
ओळ 5-7 (पुरावा-झलक): "दोन भाषांतर-स्पर्धात सरस: EN-DE 28.4 BLEU (जुन्या विक्रमाहून 2+ ने वर, ensembles सकट); EN-FR 41.8: 8 GPU वर 3.5 दिवसांत: साहित्यातल्या सर्वोत्तम यंत्रांच्या खर्चाच्या अंशात." -> दावा दुहेरी: भारी आणि स्वस्त.
ओळ 8 (सामान्यीकरण): "इंग्रजी वाक्य-विश्लेषणावरही चालतं: रचना general आहे." -> भविष्याची चाहूल: फक्त भाषांतर नाही: (केवढी खरी ठरली हे Part 3!)

दोन आकडे पाठ करा: 28.4 (EN-DE BLEU: भाषांतर-गुणवत्तेचं प्रमाण-माप: जुना विक्रम ~26: उडी मोठी) आणि **3.5 दिवस x 8 GPU** (मोठ्या model ची पूर्ण शिकवण: तेव्हाच्या विजेत्यांना आठवडे-महिने). हे दोन आकडे म्हणजे पेपरचा अख्खा दावा: **वर गुणवत्ता, खाली खर्च**: आणि खर्च का कोसळला? रांग गेली म्हणून (1.1 चं दुखणं-2): समांतर GPU-हात पूर्ण कामाला: रचनेचा शोध हा **अर्थशास्त्राचाही** शोध होता (Book 8, 1.4: याच स्वस्ताईने पुढे scaling परवडलं: आजच्या राक्षसांची वाट इथून).

पेपरचा विभाग-नकाशा (7 विभाग, आपले पत्ते):

पेपर-विभाग	आपल्या पुस्तकात
1 Introduction (जुनं जग, दावा)	Part 1 (झालं!)
2 Background (आधीचे प्रयत्न)	1.2 + 2.8 ची complexity-चर्चा
3 Model Architecture (मुख्य!)	2.1-2.7 (पुढचे सात chapters)
4 Why Self-Attention (तुलना-तक्ता)	2.8
5 Training (शिकवण-तपशील)	2.8
6 Results (निकाल + ablations)	2.8
7 Conclusion (भविष्य-दिशा)	Part 3

म्हणजे पेपरचा गाभा **विभाग 3** आहे (साडेतीन पानं, 5 समीकरणं, 2 आकृत्या): आणि आपला अख्खा विभाग 2 त्याचीच सावकाश, हाताच्या-आकड्यांची आवृत्ती. पेपर 15 पानी का, तर: दावा 1 पान, यंत्र 4 पानं, पुरावा-संदर्भ 10: **चांगल्या दाव्याला पुराव्याचं वजन लागतं** (Book 8, 1.7: लिहून-सिद्ध-करण्याची संस्कृती).

महाग चूक

"Abstract वाचला = पेपर कळला." Abstract हा **जाहिरात-दावा** आहे (प्रामाणिक, पण दावाच): 'काय' सांगतो, 'कस-का' नाही. Abstract-वाचनावर मतं बनवणारे (आणि हल्ली शीर्षक-वाचनावर!) गोंधळ पसरवतात: 'attention is all you need' चा शब्दशः अर्थ घेऊन 'बाकी काही लागतच नाही' म्हणणारे विसरतात की पेपरच्या यंत्रात FFN-सांधे-embeddings सगळं आहे (2.7 त बघू: शीर्षक 'रांग-खिडकी लागत नाही' म्हणतं, 'फक्त attention पुरतं' नाही!). शिस्त: **abstract = नकाशाची खूण; प्रवास = आतले विभाग.**

नकाशावर

- 1.1 रांगेचं जग 1.2 लक्षाचा जन्म 1.3 पेपरची गोष्ट
- 1.4 पेपर बाहेरून: abstract = दावा (साधी रचना, फक्त लक्ष;
28.4 BLEU; 3.5 दिवस x 8 GPU); 7-विभाग नकाशा; गाभा =
विभाग 3; शीर्षकाचा नेमका अर्थ: 'रांग-खिडकी नको'

सूत्रावर: abstract चं 'simple' हे विशेषण सूत्राचाच अभिमान आहे: एक प्रश्न ("कोण कुणाला किती लागू?") गुंतागुंतीच्या रांगांची जागा घेतो: साधेपण ही ताकद.

स्वतः बघा (5 मिनिटं)

आता मूळ abstract **इंग्रजीत** वाचा (पेपरचं पान 1): वरच्या मराठी उलगड्याशी ओळ-ओळ जुळवत. न अडता वाचता आला? मग हा विभाग सफल: तुम्ही जगातल्या सर्वात प्रभावी वैज्ञानिक दस्तावेजाचं पहिलं पान **मुळातून** वाचलंत. अडलेले शब्द लिहून ठेवा: विभाग 2 संपेपर्यंत प्रत्येकाचं घर लागलेलं असेल.

विचार करा

विभाग संपला. दावा हातात: “रांगेशिवाय, फक्त लक्षाने: भारी आणि स्वस्त.” आता आतली सफर: पण दाराशीच पहिला प्रश्न अडतो: ‘लक्ष’ या शब्दाचं यंत्र-रूप. 1.2 त टक्केवारी बघितली: पण टक्केवारीआधी **गुण** लागतात: ‘बसली’ ला ‘मांजर’ किती लागू हे यंत्र **कशाने** मोजतं? शब्दांची ‘जुळणी’ मोजणारं गणित नक्की कुठलं?

उत्तर पेपरच्या हृदयात: प्रत्येक शब्दाला तीन रूपं द्यायची: प्रश्न (Query), पत्ता (Key), ऐवज (Value): आणि जुळणी = प्रश्न-पत्त्याचा dot product (Book 7, 1.2 ची सावली परतली!). विभाग 2: ग्रंथालयात भेटू.

विभाग 1 चा हिशोब

चार दारं एका नजरेत

- 1.1 रांगेचं जग RNN/LSTM = निरोप्यांची साखळी; दुखणी: विसरणं | समांतर-बंदी | चिंचोळी मान
- 1.2 लक्षाचा जन्म Bahdanau 2014: वळणारी नजर = softmax-टक्केवारी; पण मालक RNN च; उद्धट प्रश्न
- 1.3 पेपरची गोष्ट 8 लेखक, चिठ्ठी-श्रेय, deadline-शर्यत, Beatles-शीर्षक; 200K+ citations
- 1.4 पेपर बाहेरून abstract = दावा; 28.4 BLEU + 3.5 दिवस; 7-विभाग नकाशा; गाभा = विभाग 3

स्वतःची परीक्षा (आधी उत्तरं, मग खाली)

1. रांगेची तीन दुखणी सांगा: आणि त्यातलं कुठलं दुखणं थेट 'पैशाचं' होतं?
2. Bahdanau च्या attention मध्ये आणि 2017 च्या दाव्यात नेमका फरक काय?
3. "Attention Is All You Need" या शीर्षकाचा नेमका (आणि चुकीचा-लोकप्रिय) अर्थ काय?
4. 28.4 आणि 3.5 हे दोन आकडे कशाचे: आणि दुसरा आकडा पहिल्याइतकाच क्रांतिकारी का?

उत्तरं: (1) लांबचं विसरणं, समांतर-बंदी, चिंचोळी मान; समांतर-बंदी = GPU-गुंतवणूक वाया = थेट पैसा (1.1). (2) Bahdanau: लक्ष ही RNN-मालकाची मदतनीस; 2017: मालकच काढून टाकला: लक्ष एकटं (1.2). (3) नेमका: recurrence आणि convolution लागत नाहीत; चुकीचा-लोकप्रिय: 'attention शिवाय काहीच लागत नाही' (यंत्रात FFN-सांधेही आहेत!) (1.4). (4) EN-DE BLEU 28.4 (गुणवत्ता-विक्रम) आणि 8 GPU x 3.5 दिवस (खर्च-कोसळ): स्वस्त शिकवण = मोठं scaling परवडणं = आजचे राक्षस: दुसरा आकडा भविष्य घडवणारा (1.4).

चाहूल: विभाग 2

आता पेपरचा गाभा: ग्रंथालयाची उपमा घेऊन Q-K-V; आपल्या तीन शब्दांवर पूर्ण हाताचं गणित; $\sqrt{d}$ चं गूढ; आठ डोकी; मुखवटा; sin-cos ची क्रम-जादू; आणि सांधे. पेन तयार ठेवा.

छोटा शब्दकोश (विभाग 1)

RNN/LSTM	रांगेने वाचणारं यंत्र / त्याची दारांवाली सुधारणा
hidden state	निरोप्याचं आठवण-गाठोडं
vanishing gradient	मागे जाताना शिकवण-संदेश विरणं
seq2seq	वाचक-गाठोडं-लेखक ही 2014 ची रचना
attention	'कोण कुणाला किती लागू' ची शिकता-येणारी टक्केवारी-नजर
BLEU	भाषांतर-गुणवत्तेचं प्रमाण-माप (जास्त = चांगलं)
abstract	पेपरच्या दाव्याचं आठ-ओळी रूप
Transformer	पेपरने मांडलेलं रांग-विरहित यंत्र (नाव: Uszkoreit ला नाद आवडला म्हणून!)

विभाग 2: पेपरच्या आत: प्रत्येक समीकरण हाताने

आता मुख्य काम: पेपरचं यंत्र (Transformer) **अवयवागणिक उघडू**: आणि प्रत्येक अवयवाचं गणित छोट्या खऱ्या आकड्यांनी हाताने करू. शिस्त Book 7 चीच: कुठलंही चिन्ह आधी मराठी वाक्य म्हणून, मगच गणित म्हणून.

आठ दारं: **सांगाडा** (6+6 मजल्यांची इमारत), **Q-K-V** (पेपरचं हृदय: हाताने), $\sqrt{d}$ चं गूढ (एका भागाकाराची अख्खी गोष्ट), **8 डोकी** (multi-head), **तीन जागी लक्ष + मुखवटा**, **sin-cos ची जादू** (रांगेशिवाय क्रम), **सांधे** (FFN, residual, LayerNorm), आणि **शिकवण-निकाल** (यंत्र शिकवलं कसं, जिंकलं किती). आपलं वाक्य ("मांजर चटईवर बसली") प्रत्येक दारातून जाईल.

एक धीराचा शब्द: हा विभाग पुस्तकातला सर्वात दाट आहे: पण प्रत्येक पायरी मागच्यावर उभी आहे आणि कुठेही उडी नाही. पेन घ्या: हाताने केलेलं गणित विसरत नाही.

Chapter 2.1 [SPINE]: सांगाडा: 6+6

मजल्यांची इमारत

पेपरच्या पान-3 वरची प्रसिद्ध आकृती (Figure 1) शब्दांत उभी करू. Transformer ची इमारत दोन मनोऱ्यांची आहे:

वाचक-मनोरा (encoder): 6 सारखे मजले, एकावर एक
 काम: मूळ वाक्य ("मांजर चटईवर बसली") पूर्ण समजून
 प्रत्येक शब्दाचं समृद्ध अर्थ-रूप बनवणं
 लेखक-मनोरा (decoder): 6 सारखे मजले
 काम: भाषांतर एक-एक शब्द घडवणं ("the" -> "cat" ->
 "sat"...), प्रत्येक शब्दाच्या क्षणी वाचक-मनोऱ्याकडे
 बघत (cross-attention: 2.5)

प्रत्येक वाचक-मजल्यात दोनच खोल्या: (1) **लक्ष-खोली** (self-attention): शब्द एकमेकांकडे बघून आपापले अर्थ ताजे करतात (पुढचे 4 chapters हिच्याच); (2) **विचार-खोली** (feed-forward: 2.7): प्रत्येक शब्द **एकटा** बसून आपल्या ताज्या अर्थावर प्रक्रिया करतो. लेखक-मजल्यात तिसरी खोली जास्त: **वाचक-मनोऱ्याकडे बघण्याची खिडकी** (cross-attention). आणि प्रत्येक खोलीभोवती दोन सुरक्षा-सोयी: उडी-रस्ता (residual) आणि तराजू (LayerNorm): 2.7 त.

आकड्यांची ओळख (पेपरचा base-साचा): प्रत्येक शब्द इमारतीत **512 आकड्यांचा बाण** ($d_{\text{model}}=512$: Book 7, 1.1 चे vectors) म्हणून फिरतो. मजले $N=6$. हे आकडे 'पवित्र' नाहीत: लेखकांनी प्रयोगाने ठरवलेले सौदे आहेत (मोठा साचा: 1024: महाग-भारी: 2.8). **आणि सर्वात महत्वाचं वाक्य: इमारतीत RNN कुठेच नाही.** कुठल्याही मजल्यावर 'रांग' नाही: लक्ष-खोलीत सगळे शब्द **एकाच वेळी** एकमेकांकडे बघतात, विचार-खोलीत सगळे **एकाच वेळी** एकटे विचार करतात: 1.1 चं दुखणं-2 (समांतर-बंदी) मुळापासून गेलं: GPU चे हजार हात आता खरंच हजार हात.

एका वाक्यावर (इमारत-फेरी): "मांजर चटईवर बसली": तीन शब्द -> तीन 512-बाण इमारतीच्या तळमजल्यावर एकदम शिरतात (अधिक क्रमाची खूण: 2.6 ची sin-cos-मुद्रा: तूर्त 'लावलीये' इतकंच). मजला 1: लक्ष-खोलीत तिघे एकमेकांकडे बघतात ('बसली' ला कळतं की कर्ता 'मांजर' आहे), विचार-खोलीत प्रत्येक स्वतःला घासतो. तेच $\times 6$. वर पोहोचतात तीन **पिकलेले** बाण: प्रत्येकात आता स्वतःसोबत वाक्य-संदर्भही मुरलेला. मग लेखक-मनोरा 'the' पासून सुरुवात करून या पिकलेल्या बाणांकडे बघत-बघत इंग्रजी घडवतो. तपशील पुढे; **इमारतीचा नकाशा हा असा.**

महाग चूक

”6 मजले म्हणजे 6 वेगवेगळी कामं करणारे विभाग असतील.” नाही: सहाही मजले **रचनेने सारखे** (वजनं वेगळी शिकतात): हीच पेपरची सौंदर्य-चाल: एक साधा block, फक्त **पुनरावृत्ती**. खोली येते थरांच्या साचण्यातून (खालचे मजले जवळचे-साधे संबंध टिपतात, वरचे लांबचे-गुंतागुंतीचे: हे शिकण्यातून घडतं, रचनेतून नाही). Book 5 (1.16) ची आठवण: उत्तम रचना ‘हुशार गुंतागुंत’ नसते; **साध्या तुकड्याची शिस्तबद्ध पुनरावृत्ती** असते: आजचे 100-थरांचे राक्षसही (Claude सकट) हाच block थरावर थर रचून बांधलेत.

नकाशावर

2.1 सांगाडा: वाचक 6 + लेखक 6 सारखे मजले; मजला = लक्ष-
खोली + विचार-खोली (+लेखकात खिडकी); शब्द = 512-बाण;
RNN शून्य: सगळं समांतर

सूत्रावर: “ना रांग, ना खिडकी” ची पहिली प्रत्यक्ष भेट: इमारतीत रांगच बांधलेली नाही. उरलेला विभाग एकाच प्रश्नाचा तपशील: लक्ष-खोलीत नक्की घडतं काय?

स्वतः बघा (5 मिनिटं)

मूळ पेपर उघडा (arxiv.org/abs/1706.03762: फुकट) आणि **फक्त Figure 1** बघा (पान 3). या chapter नंतर त्यातलं प्रत्येक खोकं ओळखीचं वाटलं पाहिजे: डावा मनोरा, उजवा मनोरा, Multi-Head Attention चे ठोकळे, Feed Forward, Add & Norm च्या पट्ट्या. न कळलेली खोकी लिहून ठेवा: विभाग संपेपर्यंत प्रत्येकाचं दार उघडणार आहे: ही यादी तुमची प्रगती-पट्टी.

विचार करा

लक्ष-खोलीत “शब्द एकमेकांकडे बघतात” म्हणालो. पण ‘बघणं’ यंत्रात कसं उतरवायचं? 1.2 त टक्केवारी बघितली: पण ती टक्केवारी **कुठून** येते? दोन शब्दांची ‘जुळणी किती’ हे ठरवायला यंत्राकडे नक्की कुठलं गणित आहे: आणि प्रत्येक शब्द ‘बघणारा’, ‘दाखवणारा’ आणि ‘देणारा’ अशा तीन भूमिका एकदम कसा निभावतो?

आलं पेपरचं हृदय: Query, Key, Value: प्रश्न, पत्ता, ऐवज: ग्रंथालयाची उपमा आणि पूर्ण हाताचं गणित: आपल्या तीन शब्दांवर, खऱ्या आकड्यांनी. पुढचा chapter या पुस्तकातला सर्वात महत्त्वाचा आहे.

Chapter 2.2 [SPINE]: Q-K-V: पेपरचं हृदय, हाताच्या आकड्यांनी

ग्रंथालयाची उपमा (एकदा पक्की करा: पुस्तकभर पुरेल). तुम्ही ग्रंथालयात जाता. तुमच्या हातात **प्रश्न-चिठ्ठी** (Query): “स्वयंपाकाची पुस्तकं हवीत.” प्रत्येक कप्प्यावर **पत्ता-पाटी** (Key): “इतिहास”, “स्वयंपाक”, “प्रवास”. आणि कप्प्याच्या आत **ऐवज** (Value): प्रत्यक्ष पुस्तकं. रीत: तुमची चिठ्ठी प्रत्येक पाटीशी **जुळवायची** (जुळणी जास्त = त्या कप्प्याकडे लक्ष जास्त), आणि जुळणीच्या प्रमाणात ऐवज गोळा करायचा. Attention म्हणजे नेमकं हेच: फक्त इथे **प्रत्येक शब्द एकाच वेळी वाचक आणि कप्पा असतो**: त्याची स्वतःची चिठ्ठी (Q), स्वतःची पाटी (K), स्वतःचा ऐवज (V).

तीन रूपं येतात कुठून? प्रत्येक शब्दाच्या अर्थ-बाणाला (embedding: Book 2, 3.2) तीन **शिकलेली रूपांतर-यंत्रं** (matrices W_Q, W_K, W_V : Book 7, 1.3!) लावली की तीन रूपं निघतात. उदाहरणादाखल ‘मांजर’ चा (सोपेपणासाठी) 4-आकडी बाण आणि 4×2 चं W_Q घेऊ: बाण $[1, 0, 1, 0]$ $\times W_Q =$ चिठ्ठी $[1.0, 0.8]$ (Book 7, 1.4 चा गुणाकार). हे **गुणाकार यंत्र शिकतं**: ‘चिठ्ठी कशी लिहावी’ हीच त्याची विद्या. पुढच्या गणितासाठी तिन्ही शब्दांची तयार रूपं (2-आकडी: हाताला पेलतील अशी):

शब्द	चिठ्ठी Q	पाटी K	ऐवज V
मांजर	$[0.9, 0.2]$	$[1.0, 0.8]$	$[2, 0]$
चटईवर	$[0.3, 0.5]$	$[0.2, 0.4]$	$[0, 2]$
बसली	$[1.0, 1.0]$	$[0.6, 0.6]$	$[1, 1]$

आता पेपरचं समीकरण-1, पायरी-पायरीने. ‘बसली’ या शब्दाला वाक्य समजायचंय (कर्ता कोण? कुठे?). त्याची चिठ्ठी $Q=[1,1]$ प्रत्येक पाटीशी जुळवू: जुळणीचं गणित = **dot product** (Book 7, 1.2: सावली-गुणाकार: दिशा जुळल्या तर मोठा):

पायरी 1: गुण (scores)
 बसली-मांजर: $1 \times 1.0 + 1 \times 0.8 = 1.8$ <- सर्वात जुळलं!
 बसली-चटईवर: $1 \times 0.2 + 1 \times 0.4 = 0.6$
 बसली-बसली: $1 \times 0.6 + 1 \times 0.6 = 1.2$
 पायरी 2: $\sqrt{d_k}$ ने भागा ($d_k=2$, $\sqrt{2} = 1.41$: का ते 2.3 त!)
 $1.8/1.41=1.28$ $0.6/1.41=0.43$ $1.2/1.41=0.85$
 पायरी 3: softmax (Book 7, 2.6: गुणांची टक्केवारी)
 $e^{1.28}=3.60$ $e^{0.43}=1.54$ $e^{0.85}=2.34$ (बेरीज 7.48)
 टक्के: 0.48, 0.21, 0.31
 पायरी 4: टक्क्यांनी ऐवजांची भारित बेरीज
 $0.48 \times [2, 0] + 0.21 \times [0, 2] + 0.31 \times [1, 1]$
 $= [0.96+0+0.31, 0+0.42+0.31] = [1.27, 0.73]$

झालं! 'बसली' चं नवं रूप [1.27, 0.73]: त्यात 48% 'मांजर' मुरलंय (कर्ता सापडला!), 21% जागा, 31% स्वतः. **हेच पेपरचं हृदय-समीकरण:** $\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d_k})V$: आपण आता ते हाताने चालवलं. आणि सगळ्यात सुंदर: हेच गणित तिन्ही शब्दांसाठी **एकाच वेळी** होतं (प्रत्येकाची स्वतःची चिठ्ठी: तीन प्रश्न, एकदम): Q, K, V हे तक्ते (matrices) बनवून एकच मोठा गुणाकार: GPU चं आवडतं जेवण (1.1 चं दुखणं-2 इथेच मरतं).

हे 'समज' का आहे (नुसती बेरीज का नाही)? कारण टक्केवारी शिकलेली आहे: W_Q-W_K अशी घडतात की व्याकरणाला जे जुळायला हवं (क्रियापद-कर्ता, सर्वनाम-नाम) त्यांच्या चिठ्ठ्या-पाट्या जुळतात. 'ती बसली' मधल्या 'ती' ची चिठ्ठी 'मांजर' च्या पाटीशी जुळणं: **संदर्भ-समज म्हणजे हीच जुळणी** (Book 2, 4.3 चं 'ambiguity-निवारण' आता समीकरणात दिसलं).

महाग चूक

"Q, K, V ही तीन वेगळी क्लिष्ट यंत्रं आहेत." उलट: तिन्ही **एकाच बाणाची तीन रूपं** आहेत: तीन साधे गुणाकार: आणि संपूर्ण attention म्हणजे फक्त चार पायऱ्या: गुणाकार, भागाकार, टक्केवारी, भारित-बेरीज: **शाळेचं गणित**. पेपरची दहशत वाटते ती चिन्हांमुळे ($QK^T/\sqrt{d_k}$!); चिन्हं सोलली की आत चौथीची आकडेमोड. हा धडा सगळ्या AI-पेपरांचा: **दहशत notation ची असते, गणिताची नसते** (Book 7 चं पूर्ण सूत्र: चष्मा लावा, डोंगर सपाट).

नकाशावर

- 2.1 सांगाडा: 6+6, समांतर
- 2.2 Q-K-V: चिठ्ठी-पाटी-ऐवज; 4 पायऱ्या: dot-गुण $\rightarrow \sqrt{d_k}$ -भाग $\rightarrow \text{softmax}$ -टक्के $\rightarrow$ भारित-बेरीज; 'बसली' = 48% मांजर; सगळं एकाच matrix-गुणाकारात, एकदम

सूत्रावर: "कोण कुणाला किती लागू?" या सूत्र-प्रश्नाचं उत्तर आता नेमकं आहे: **चिठ्ठी x पाटी**. बाकी सगळं पुस्तक या चार पायऱ्यांभोवतीचे मजले आहेत.

स्वतः बघा (5 मिनिटं)

वरचं गणित **स्वतःच्या हाताने** परत करा: पण आता 'चटईवर' साठी ($Q=[0.3, 0.5]$): तिन्ही गुण, भागाकार, softmax (e^x साठी phone-calculator), भारित बेरीज. उत्तर तपासायला Claude ला विचारा. दहा मिनिटांत तुम्ही जगातलं सर्वात प्रभावी समीकरण दोनदा हाताने चालवलेलं असेल: आता ते तुमचं आहे.

—

विचार करा

पायरी 2 गूढ राहिली: $\sqrt{d_k}$ ने भागलं: का? 1.41 ने भागण्याने असं काय घडतं? आणि पेपरचे लेखक इतक्या बारीक गोष्टीला शीर्षक-समीकरणात जागा का देतात: 'scaled' dot-product हे नावच त्यांनी भागाकारावरून ठेवलंय!

कारण भागाकार नसेल तर मोठ्या d_k ला यंत्र शिकणं थोडं त्रुटि: softmax 'गोठतो'. एका भागाकाराची अख्खी गोष्ट: छोटी, सुंदर, आणि 'बारकाव्यांत देव असतो' ची पाठ्यपुस्तकी साक्ष: पुढचा chapter.

Chapter 2.3 [DEPTH]: $\sqrt{d_k}$ चं गूढ: एका भागाकाराची गोष्ट

पेपरमधली सर्वात छोटी युक्ती, सर्वात मोठा धडा. लेखकांनी आपल्या attention ला नाव दिलं ”**scaled dot-product attention**”: म्हणजे नावातच भागाकार. का?

अडचण: आकड्यांची सूज. 2.2 त आपली चिठ्ठी-पाटी 2-आकडी होती: गुण 1.8 पर्यंत आले. पण खऱ्या यंत्रात $d_k=64$: चिठ्ठी-पाटीचा dot product म्हणजे **64 गुणाकारांची बेरीज**. सोपं सत्य: जितकी लांब बेरीज, तितका निकाल मोठा होत जातो (पेपरची नेमकी भाषा: प्रत्येक घटक स्वतंत्र, सरासरी 0, पसरण 1 धरली तर बेरजेची पसरण d_k होते: म्हणजे ‘सूज’ सरासरीने $\sqrt{d_k}$ पट: Book 7, 2.2 ची पसरण-भाषा). $d_k=64$ ला गुण सहज 8-10 पट फुगतात.

फुगले तर काय बिघडतं? softmax गोठतो. हाताने बघू. 2.2 चे गुण (1.8, 0.6, 1.2) **दहा पट** फुगले असते: (18, 6, 12):

```
softmax(1.8, 0.6, 1.2) = 0.53, 0.16, 0.31 <- मऊ वाटणी
softmax(18, 6, 12)    = 0.9975, 0.00001, 0.0025
                        <- जवळजवळ 1, 0, 0: दगड!
```

(गणित: e^{18} हे e^{12} च्या ~400 पट: बाकीचे चिरडले जातात.) याला म्हणतात softmax **saturate** होणं: टक्केवारीची ‘वाटणी’ जाऊन ‘विजेता-सगळं-घेतो’ दगड बनतो. आणि खरा घात पुढे: **शिकणं थांबतं**. Book 7 (3.2-3.3) आठवा: यंत्र शिकतं gradients नी: ‘वजन जरा हलवलं तर निकाल किती हलतो’ या उतारावरून. दगड-झालेल्या softmax मध्ये वजनं हलवली तरी टक्केवारी हलत नाही (0.9975 चं फार तर 0.9976): **उतार जवळजवळ शून्य: शिकवण-संदेश मागे पोहोचतच नाही** (vanishing gradient चं भूत परत: यावेळी रांगेमुळे नाही, सुजेमुळे!).

उपाय: सुजेच्या मापाने भागा. सूज $\sqrt{d_k}$ पट येते: मग $\sqrt{d_k}$ नेच भागा: गुण परत माणसाळलेल्या पट्ट्यात, softmax मऊ, gradients जिवंत. $d_k=64$ ला भाग 8 ने; आपल्या $d_k=2$ ला 1.41 ने (2.2 ची पायरी-2). बस: इतकीच गोष्ट. **पण ही ओळ नसती तर?** मोठ्या d_k चं शिक्षण अडखळतं: पेपरने हे ओळखून आधीच बांधून टाकलं: नाहीतर ‘Transformer चालत नाही’ म्हणून कल्पनाच मेली असती कदाचित: **क्रांत्या कधीकधी एका भागाकारावर तरतात.**

एका वाक्यावर: आपल्या तीन शब्दांचं गणित 2.2 त आधीच scaled होतं: (1.28, 0.43, 0.85) -> (0.48, 0.21, 0.31): बघा किती **मऊ** वाटणी आहे: ‘बसली’ मुख्यत: मांजराकडे बघतो पण जागेचाही 21% कान ठेवतो: भाषेला हेच हवं (अर्थ अनेक धाग्यांनी येतो). दगड-वाटणी (1, 0, 0) असती तर ‘चटईवर’ चा धागाच तुटला असता.

महाग चूक

”असले बारकावे ‘engineering-तपशील’: मुख्य कल्पना महत्वाची.” पेपर-वाचनातली सर्वात पसरलेली उर्मट चूक. सत्य: **मुख्य कल्पना फुकट असते; ती चालवणारे बारकावे महाग** (Book 4 चं सूत्र पुन्हा वेगळ्या रूपात!). Transformer च्या यशात $\sqrt{d_k}$, warmup (2.8), residual (2.7) असे ‘बारकावे’च प्राण आहेत: यातला एक काढा, यंत्र शिकेनासं होतं. म्हणून पेपर वाचताना शिस्त: **समीकरणातल्या प्रत्येक चिन्हाला ‘हे नसतं तर?’ विचारा**: उत्तर ‘काही बिघडत नाही’ असं क्वचितच निघतं: आणि निघालं नाही की तुम्हाला यंत्राची खरी समज आली.

नकाशावर

2.1 सांगाडा 2.2 Q-K-V: 4 पायऱ्या
2.3 $\sqrt{d_k}$: लांब बेरीज = $\sqrt{d_k}$ -पट सूज $\rightarrow$ softmax दगड $\rightarrow$ gradients मरतात $\rightarrow$ शिकणं थांबतं; उपाय: सुजेच्या मापाने भाग; मऊ वाटणी हीच भाषेची गरज

सूत्रावर: “कोण कुणाला किती लागू” ची वाटणी **मऊ** राहणं हीच सूत्राची अट आहे: दगड-वाटणी म्हणजे लक्षच नाही, हट्ट. $\sqrt{d_k}$ हा त्या मऊपणाचा रखवालदार.

स्वतः बघा (5 मिनिटं)

Calculator वर स्वतः अनुभवा: softmax(2, 1) काढा ($e^2=7.39$, $e^1=2.72$: टक्के 0.73/0.27: मऊ). आता दोन्ही 5-पट करा: softmax(10, 5): ($e^{10}=22026$, $e^5=148$: टक्के 0.993/0.007: दगड!). आकडे तेच ‘प्रमाणात’: पण फुगले की वाटणी मेली. आता 10, 5 ला $\sqrt{\cdot}$ -युक्तीने परत खाली आणा: हेच पेपरचं काम.

विचार करा

2.2 चं गणित एकाच ‘नजरे’चं होतं: ‘बसली’ ने एक चिठ्ठी लिहिली, एक वाटणी मिळाली. पण भाषेत एकाच शब्दाला **अनेक** प्रश्न असतात: ‘बसली’ ला कर्ताही हवा (मांजर) **आणि** जागाही हवी (चटईवर) **आणि** काळही: एकाच वाटणीत हे सगळं कोंबलं तर सगळं धूसर होईल. यंत्राला **अनेक स्वतंत्र नजरा** एकदम देता येतील का?

हेच पेपरचं दुसरं रत्न: Multi-Head Attention: आठ डोकी, प्रत्येकाची स्वतःची चिट्ठी-पाटी-ऐवज-यंत्रं, प्रत्येकाची स्वतंत्र वाटणी: आणि मग आठांची एकत्र गुंफण. आपल्या वाक्यावर दोन डोकी हाताने चालवू: पुढचा chapter.

Chapter 2.4 [SPINE]: Multi-Head: आठ डोकी, आठ नजरा

कल्पना एका ओळीत: एक attention = एक नजर = एक जुळणी-प्रकार. भाषेला अनेक जुळणी-प्रकार लागतात (कर्ता-क्रियापद, जागा-क्रियापद, विशेषण-नाम, सर्वनाम-मालक...). मग **एकाच मोठ्या नजरेऐवजी आठ छोट्या स्वतंत्र नजरा** चालवा आणि निकाल गुंफा: हेच multi-head attention.

हाताने: दोन डोकी आपल्या वाक्यावर. प्रत्येक डोक्याला स्वतःची W_Q - W_K - W_V यंत्रं (म्हणजे स्वतःच्या चिठ्या-पाट्या!). 'बसली' साठी:

डोकं 1 (2.2 चंच: 'कर्ता-शोधक' निघालं):
 गुण-> softmax: मांजर 0.48, चटईवर 0.21, बसली 0.31
 निकाल-1 = [1.27, 0.73] <- मांजर-रंगाचं
 डोकं 2 (नवी यंत्रं: वेगळ्या चिठ्या-पाट्या):
 Q' (बसली)=[1,0]; K' (मांजर)=[0.2,1], K' (चटईवर)=[1.4,0],
 K' (बसली)=[0.5,0.5]
 गुण: 0.2, 1.4, 0.5 -> /1.41 -> 0.14, 0.99, 0.35
 softmax: e: 1.15, 2.69, 1.42 (बेरीज 5.26)
 -> मांजर 0.22, चटईवर 0.51, बसली 0.27!
 V' ने भरित बेरीज -> निकाल-2 <- चटई-रंगाचं

बघा काय घडलं: **तेच वाक्य, तोच शब्द, दोन वेगळ्या वाटण्या:** डोकं-1 कर्त्याकडे (मांजर 48%), डोकं-2 जागेकडे (चटईवर 51%): कुणीही त्यांना 'तू कर्ता बघ, तू जागा बघ' शिकवलेलं नाही: वेगवेगळ्या सुरुवाती-वजनांतून **आपोआप वेगळ्या भूमिका** घेतात (शिक्षणाची गंमत: कामाची वाटणी स्वयंभू). खऱ्या यंत्रांत डोक्यांच्या भूमिका अभ्यासकांनी नंतर उघडून बघितल्यात: कुणी व्याकरण-डोकं, कुणी शेजार-डोकं, कुणी दुर्मिळ-शब्द-डोकं (Book 9, 1.2 ची interpretability इथलीच).

गुंफण (पेपरचं गणित): आठ डोक्यांचे निकाल **शेजारी जोडायचे** (concat) आणि एका शेवटच्या यंत्राने (W_O) मिसळायचे. पेपरची हुशार काटकसर: $d_{\text{model}}=512$ चे 8 भाग: **प्रत्येक डोकं फक्त $d_k=64$ आकड्यांत** काम करतं ($512/8=64$): आठही मिळून खर्च जवळजवळ एका मोठ्या नजरेइतकाच: **आठ नजरा जवळजवळ फुकटात** (Book 5 ची नजर: सौदा ओळखा: विविधता घेतली, किंमत नाही वाढवली). 8×64 जोडून परत 512: इमारतीचा बाण-आकार कायम (2.1): मजल्यावर मजला चढवायला हेच लागतं.

पेपरचा पुरावा (Table 3 ची झलक: पूर्ण 2.8 त): लेखकांनी डोकी बदलून बघितली: **1 डोकं: 0.9 BLEU ने वाईट** (एक नजर पुरत नाही: सिद्ध!); 8-16: गोड जागा; **32: परत किंचित घसरण** (खूप डोकी = प्रत्येकाला खूपच अरुंद d_k : नजराच अधू). 'जास्त ते चांगलं' नव्हे: **वाटणीचा सौदा** आहे: विविधता

विरुद्ध प्रत्येक नजरेची खोली.

एका वाक्यावर: 'बसली' आता मजल्यातून बाहेर पडताना त्याच्या 512-बाणात आठ धागे विणलेले: कर्ता-धागा, जागा-धागा, काळ-धागा... पुढच्या मजल्यावर याच समृद्ध बाणावर पुन्हा आठ नजरा: **थरांगणिक समज दाटत जाते** (2.1 चं 'पिकणं' हेच).

महाग चूक

"आठ डोकी म्हणजे यंत्र आठ पट हुशार/महाग." दोन्ही चूक: काटकसरीची रचना बघितलीच (512 चे 8 तुकडे: खर्च ~तोच); आणि हुशारीही 'बेरजेने' येत नाही, **विविधतेने** येते: आठ सारखी डोकी असती तर एकाइतकीच अक्कल (Table 3 चा 32-डोक्यांचा धडाही तोच: संख्या नव्हे, प्रत्येक नजरेची धड-खोली). हा नियम यंत्राबाहेरही ओळखीचा आहे: समितीत आठ **सारखे** विचार = एक विचार; आठ **स्वतंत्र** नजरा = खरी समिती (Book 8, 1.7 चा disagree-लिहून-नोंदवा त्याच जातीचा). विविधता ही रचून आणावी लागते: यंत्रात वेगळ्या W-यंत्रांनी, समितीत वेगळ्या पार्श्वभूमींनी.

नकाशावर

2.1 सांगाडा 2.2 Q-K-V 2.3 $\sqrt{d_k}$
 2.4 multi-head: 8 स्वतंत्र नजरा (स्वतःची W-यंत्रं) -> स्वयंभू
 भूमिका-वाटणी (कर्ता-डोकं, जागा-डोकं) -> concat + W₀;
 512/8=64: विविधता जवळजवळ फुकट; 1 डोकं -0.9 BLEU,
 32 ही घसरण

सूत्रावर: सूत्राचा प्रश्न आता अनेकवचनी झाला: "कोण कुणाला **कुठल्या नात्याने** किती लागू?": प्रत्येक नात्याला स्वतःची नजर. लक्ष पुरेसं आहे: पण **अनेक-अंगी** लक्ष.

स्वतः बघा (5 मिनिटं)

डोकं-2 चं गणित हाताने पूर्ण करा: V' (मांजर)=[0,1], V' (चटईवर)=[2,1], V' (बसली)=[1,0] घेऊन भारित बेरीज काढा (टक्के: 0.22, 0.51, 0.27). मग concat चा अनुभव: निकाल-1 [1.27, 0.73] आणि तुमचा निकाल-2 शेजारी लिहा: ही चार-आकडी ओळ म्हणजेच 'बसली' चं दोन-डोकी रूप. (उत्तर-ताळा: निकाल-2 = [1.29, 0.73]: जुळलं?)

विचार करा

आतापर्यंतचं सगळं लक्ष **आपापसातलं** होतं (वाचक-मनोऱ्यातलं self-attention: मराठी शब्द मराठी शब्दांकडे). पण यंत्राचं काम भाषांतर आहे: लेखक-मनोऱ्याला **दोन** गरजा: इंग्रजी घडवताना मागे लिहिलेल्या इंग्रजीकडे बघणं, **आणि** मूळ मराठीकडे बघणं. आणि तिसरी अडचण: शिकताना यंत्राला उत्तर आधीच दिसलं तर नक्कल करेल: **भविष्य लपवायचं कसं?**

पुढचा chapter: लक्षाच्या तीन जागा (self, masked-self, cross): आणि 'मुखवटा' (mask): भविष्यावर $-\infty$ चा पडदा टाकण्याची पेपरची युक्ती: जिच्यामुळेच आजचे GPT-Claude एक-एक शब्द 'भाकीत' करत लिहितात.

Chapter 2.5 [SPINE]: लक्षाच्या तीन जागा आणि मुखवटा

एकच attention-यंत्र (2.2 च्या चार पायऱ्या) इमारतीत तीन वेगळ्या जागी, तीन वेगळ्या भूमिकांत बसवलंय: फरक फक्त **चिठ्या कुणाच्या, पाट्या-ऐवज कुणाचे** इतकाच:

जागा 1: वाचक-मनोऱ्यातलं आपापसातलं लक्ष (encoder self-attn)

Q, K, V तिन्ही मराठी शब्दांचेच: सगळे सगळ्यांकडे बघतात (मागचे-पुढचे दोन्ही: वाचकाला पूर्ण वाक्य दिसण्यात गैर काहीच नाही). हेच आपण 2.2-2.4 त केलं.

जागा 2: लेखक-मनोऱ्यातलं मुखवटा-लक्ष (masked self-attn)

Q, K, V इंग्रजी (आतापर्यंत लिहिलेल्या) शब्दांचे: पण प्रत्येक शब्द फक्त मागच्यांकडेच बघू शकतो: भविष्यावर मुखवटा (खाली).

जागा 3: खिडकी (cross-attention: encoder-decoder attn)

चिठ्या इंग्रजीच्या; पाट्या-ऐवज मराठीचे! लेखक विचारतो, वाचक पुरवतो: 1.2 चं Bahdanau-लक्ष याच जागेचा पूर्वज.

मुखवटा का लागतो (शिक्षणाची गोम). यंत्र शिकतं कसं: त्याला मराठी वाक्य + तयार इंग्रजी भाषांतर देतात आणि म्हणतात “प्रत्येक जागी पुढचा इंग्रजी शब्द ओळख” (Book 2, 2.2 चं next-word शिक्षण). पण घोटाळा: “the cat ____” ओळखायचंय आणि लेखक- मनोऱ्याच्या हातात पूर्ण “the cat sat on the mat” आहे: लक्ष- खोलीत ‘sat’ **दिसतोच** आहे! न लपवता शिकवलं तर यंत्र ‘ओळखणं’ नाही, ‘**नक्कल करणं**’ शिकतं (उत्तर बघून पेपर सोडवणारा विद्यार्थी: परीक्षेत शून्य). उपाय: **भविष्याच्या गुणांवर -∞ (उणे-अनंत) लिहा:** softmax मध्ये $e^{(-\infty)} = 0$: भविष्याची टक्केवारी आपोआप शून्य: दिसतच नाही.

हाताने (मुखवटा चालवून): लेखक ‘sat’ च्या जागेवर आहे; गुण निघाले (the: 0.5, cat: 1.4, sat: 2.0, on: 1.1...):

मुखवट्याआधी:	0.5	1.4	2.0	1.1	
मुखवट्यानंतर:	0.5	1.4	-∞	-∞	<- स्वतःसकट पुढचं बंद*
softmax:	0.29	0.71	0	0	

(*‘sat’ ओळखायच्या क्षणी ‘sat’ स्वतः आणि पुढचं झाकलेलं: मागचे ‘the’, ‘cat’ तेवढे खुले: आणि यंत्र cat कडे 71% लक्ष देऊन ‘मांजराने पुढे काय केलं असेल’ या दिशेने भाकीत बांधतं.) हा मुखवटा म्हणजे फक्त **गुण-तक्त्यावरचा त्रिकोणी पडदा:** एक ओळ code, पण त्याच्याविना अख्खं शिक्षण फसवं. **आणि**

इतिहास: GPT-मालिका म्हणजे या जागा-2 चाच (मुखवटा-लक्षाचा) एकटा मनोरा (3.2 त पूर्ण):
आज तुम्ही Claude शी बोलता तेव्हा प्रत्येक शब्द असाच, मुखवट्यामागून, एक-एक जन्मतो.

खिडकीत (जागा 3) आपलं वाक्य: 'sat' घडवण्याच्या क्षणी लेखकाची चिठ्ठी खिडकीतून मराठी पाट्यांना भिडते: गुण: मांजर 0.9, चटईवर 0.7, **बसली 2.1:** softmax: 0.17, 0.14, 0.69: लक्ष 'बसली' वर: आणि 'बसली' चा ऐवज (कृती-भूत-एकवचन- स्त्रीलिंग सगळं मुरलेला: वाचक-मनोऱ्याचे 6 मजले आठवा!) उचलून 'sat' उमटतो. 1.2 त हेच 'नजर वळणं' अंधुक बघितलं होतं; आता त्याचं पूर्ण यंत्र-रूप हातात आहे.

महाग चूक

"तीन attention म्हणजे तीन वेगळी तंत्रं शिकायची." पेपर-वाचकांची नेहमीची धास्ती: प्रत्यक्षात **यंत्र एकच** (चार पायऱ्या), बदलतं फक्त 'कोण विचारतो, कोण पुरवतो' हे plumbing: चिठ्ठ्या इकडून, पाट्या तिकडून. हा नमुना सार्वत्रिक आहे: चांगल्या रचना **एकच तुकडा वेगवेगळ्या जोडण्यांत** वापरतात (Book 5, 2.16 ची नजर: रचना वाचताना 'नवा ठोकळा' आणि 'जुना ठोकळा नव्या जागी' वेगळे ओळखा: 90% वेळा दुसरंच असतं: दहशत निम्मी होते).

नकाशावर

2.1 सांगाडा 2.2 Q-K-V 2.3 $\sqrt{d_k}$ 2.4 multi-head
2.5 तीन जागा: वाचक-आपापसात (सगळं खुलं) | लेखक-मुखवटा
(भविष्यावर $-\infty \rightarrow \text{softmax } 0$: नक्कल-बंदी) | खिडकी (Q इंग्रजी, K-V मराठी); GPT = एकटा मुखवटा-मनोरा

सूत्रावर: "ना रांग" म्हणणाऱ्या यंत्रात लेखनाचा **क्रम** मुखवट्याने परततो: पण बघा फरक: रांग **सक्ती** होती (वाचनही रांगेत); मुखवटा **निवड** आहे (फक्त लेखनापुरता, वाचन समांतरच). क्रम हवा तिथेच, नको तिथे नाही: हीच रचनेची प्रगल्भता.

स्वतः बघा (5 मिनिटं)

मुखवट्याचा त्रिकोण कागदावर काढा: 4 शब्दांच्या वाक्यासाठी 4x4 चौकट: ओळी = 'कोण बघतोय', रकाने = 'कुणाकडे': प्रत्येक घरात खुलं/बंद लिहा (ओळ 1: फक्त घर-1 खुलं; ओळ 4: चारही). हा **खालचा-त्रिकोण** (lower-triangular) आकार डोळ्यांसमोर पक्का करा: LLM-जगातल्या प्रत्येक चर्चेत 'causal mask' या नावाने हाच भेटत राहील.

विचार करा

एक विचित्र गोष्ट अजून अनुत्तरित: 2.2 च्या गणितात 'मांजर चटईवर बसली' आणि 'बसली चटईवर मांजर' यांत **फरकच नाही!** dot products शब्द-जोड्यांचे: क्रमाचा उल्लेखच कुठे नाही. रांग काढली आणि क्रमही गेला: पण भाषेत क्रम म्हणजे अर्थ ('मांजराने उंदीर खाल्ला' विरुद्ध 'उंदराने मांजर खाल्ला!'). रांगेशिवाय क्रम यंत्रात **घालायचा** कसा?

पेपरचं तिसरं रत्न, आणि सर्वात काव्यमय: प्रत्येक शब्दाला त्याच्या जागेची 'सुगंधी मुद्रा' लावायची: sin-cos लहरींची: जलद-घड्याळ + संथ-घड्याळ. positional encoding: हाताच्या आकड्यांसकट: पुढचा chapter.

Chapter 2.6 [SPINE]: जागेची मुद्रा: sin-cos ची घड्याळ-जादू

अडचण नेमकी: attention चं गणित क्रम-आंधळं आहे: शब्दांचा गूढा बघतं, रांग नाही. रांगेचं यंत्र (RNN) फेकलं तेव्हा क्रमाची फुकट-सोयही गेली. आता क्रम **माहिती म्हणून** परत घालायचा: प्रत्येक शब्दाच्या बाणात 'मी जागा क्रमांक अमुक' ही खूण मिसळायची.

पहिली कल्पना (आणि तिचं दुखणं): जागा-क्रमांकच मिसळा: 1, 2, 3... दुखणं: 100-शब्दी वाक्यात '100' हा आकडा बाणांतल्या 0.5-1.2 च्या नाजूक आकड्यांना **चिरडेल**; आणि यंत्राने 40 जागांवर शिकलं तर जागा-41 त्याला परकी. लागते अशी खूण जी (अ) मर्यादित पट्ट्यात राहते (कधीच फुगत नाही), (ब) प्रत्येक जागेला वेगळी, (क) आणि 'दोन जागांतलं **अंतर**' गणिताला सहज दिसेल अशी.

पेपरचं उत्तर: घड्याळांची रांग. भिंतीवर अनेक घड्याळं: पहिलं **जलद** (दर शब्दाला काटा खूप फिरतो), दुसरं हळू, तिसरं आणखी हळू... शेवटचं **अति-संथ** (हजार शब्दांत जरा हलतं). प्रत्येक जागेची खूण = **त्या क्षणी सगळ्या घड्याळांच्या काट्यांची स्थिती**. जलद घड्याळ शेजारच्या जागा वेगळ्या करतं (जागा 5 वि. 6: जलद काटा खूप वेगळा); संथ घड्याळ लांबचा पत्ता देतं (वाक्याच्या सुरुवातीला की शेवटी). आणि काटे **गोल फिरतात**: स्थिती नेहमी -1 ते +1 च्या पट्ट्यात: कधीच फुगत नाही (अट अ पूर्ण). काट्याची स्थिती गणितात = sin आणि cos: म्हणून सूत्र:

```
PE(जागा, 2i)   = sin(जागा / 10000^(2i/d_model))
PE(जागा, 2i+1) = cos(जागा / 10000^(2i/d_model))
(i = घड्याळ-क्रमांक: i वाढेल तसं घड्याळ 10000-च्या
घातांनी संथ; प्रत्येक घड्याळ बाणाचे दोन आकडे भरतं:
sin-कोन आणि cos-कोन: काट्याची पूर्ण स्थिती)
```

हाताने (d_model=4: दोन घड्याळं: जलद x1, संथ x1/100):

जागा 0 (मांजर):	[sin 0,	cos 0,	sin 0,	cos 0	]
	= [0,	1,	0,	1	]
जागा 1 (चटईवर):	[sin 1,	cos 1,	sin 0.01,	cos 0.01]	
	= [0.84,	0.54,	0.010,	1.000	]
जागा 2 (बसली):	[sin 2,	cos 2,	sin 0.02,	cos 0.02]	
	= [0.91,	-0.42,	0.020,	1.000	]

बघा: पहिले दोन आकडे (जलद घड्याळ) जागोजागी झपाट्याने बदलतात; शेवटचे दोन (संथ) रांगत सरकतात. ही चार-आकडी मुद्रा शब्दाच्या अर्थ-बाणात **मिसळायची** (बेरीज): 'चटईवर' चा बाण = चटईवरचा-अर्थ + जागा-1-ची-मुद्रा. आता 'मांजर चटईवर बसली' आणि 'बसली चटईवर मांजर' चे बाण **वेगळे**: क्रम परतला: रांगेशिवाय.

आणि अट (क) ची जादू: sin-cos ची शाळेतली ओळख आठवा: कोन k ने पुढे सरकवणं हे **फिरवण्याचं** (rotation) साधं गणित आहे: म्हणजे 'जागा $p+k$ ची मुद्रा' ही 'जागा p च्या मुद्रे'चं ठरावीक वळण: '**k अंतरावरचा शब्द**' ही कल्पना यंत्राला एका सोप्या रूपांतराने शिकता येते: पेपरने घड्याळं निवडली ती नेमकी यासाठी. (लेखकांनी 'शिकलेल्या मुद्रा' पण तपासल्या: निकाल जवळजवळ सारखा: Table 3: पण sin-cos ला शिकवावं लागत नाही आणि न-बघितलेल्या लांबीलाही चालतं: म्हणून तेच ठेवलं. गंमत: पुढच्या युगाने हीच कल्पना आणखी घासून RoPE बनवली: 3.2 त.)

महाग चूक

"sin-cos ही 'जादूची' निवड: असंच काहीतरी गूढ." उलट प्रवास खरा: **गरजा आधी लिहिल्या** (फुगू नये, प्रत्येक जागा वेगळी, अंतर गणिती-सोपं, कुठल्याही लांबीला चालावं), मग त्या गरजा पूर्ण करणारं **सर्वात साधं** गणित शोधलं: त्रिकोणमिती. पेपर- वाचनाची खोल शिस्त इथे शिका: विचित्र-दिसणाऱ्या प्रत्येक निवडीमागे गरजांची यादी असते: **निवड पाठ करू नका; यादी शोधा** (Book 8, 1.1: मुळं). यादी सापडली की निवड 'जादू' न राहता 'अपरिहार्य' वाटू लागते: तीच समजेची खूण.

नकाशावर

2.1-2.5 सांगाडा | Q-K-V | $\sqrt{d_k}$ | multi-head | तीन जागा+मुखवटा
 2.6 जागेची मुद्रा: घड्याळांची रांग (जलद->संथ); sin-cos = काट्यांची स्थिती: फुगत नाही, प्रत्येक जागा वेगळी, अंतर = फिरवणं; मुद्रा अर्थ-बाणात मिसळा; learned आणि sin-cos जवळजवळ सारखे

सूत्रावर: "रांग मोडा" चं शेवटचं देणं फेडलं: रांग मोडूनही क्रम शाबूत: कारण क्रम आता **रचनेची सक्ती** नाही, **बाणांतली माहिती** आहे: आणि माहितीवर लक्षाचं गणित चालतंच.

स्वतः बघा (5 मिनिटं)

Calculator (radian mode!) घेऊन जागा 3 ('बसली' नंतर चौथा शब्द असता तर) ची मुद्रा काढा: $[\sin 3, \cos 3, \sin 0.03, \cos 0.03]$. मग वरच्या तक्त्याखाली लिहा आणि नमुना बघा: जलद-जोडी उड्या मारतेय, संध-जोडी रांगतेय. (ताळा: $[0.14, -0.99, 0.030, 1.000]$.) चार जागांची चार-आकडी मुद्रा-सारणी तुम्ही हाताने बांधलीत.

विचार करा

लक्ष-खोली आता पूर्ण कळली. पण मजल्यात दुसरी खोलीही होती (2.1): 'विचार-खोली' (feed-forward): आणि खोल्यांभोवती 'उडी-रस्ता' आणि 'तराजू'. लक्षच सगळं करतं तर या **बिन-लक्षाच्या** भागांचं काम काय: आणि ते नसते तर काय बिघडलं असतं?

पुढचा chapter: यंत्राचे सांधे: FFN (गोळा केलेल्याचं पचन), residual (ResNet कडून घेतलेला उडी-रस्ता: तोच ResNet जो citations मध्ये आपल्या पेपरच्याही वर आहे!), आणि LayerNorm (थरांचा तराजू): 6 मजले कोसळू न देणारी त्रयी.

Chapter 2.7 [SPINE]: सांधे: FFN, उडी-रस्ता, तराजू

शीर्षक 'attention is all you need' म्हणतं: पण यंत्रात लक्षाइतकेच महत्त्वाचे तीन बिन-लक्षाचे भाग आहेत (1.4 ची शीर्षक-तंबी आठवा). तिघांची कामं नेमकी:

भाग 1: विचार-खोली (Feed-Forward Network). लक्ष-खोलीचं काम **गोळा करणं** आहे (इतरांकडून घेणं: 'बसली' त मांजर-चटई मुरली); पण गोळा केलेल्याचं **पचन** कोण करणार? FFN: प्रत्येक शब्द **एकटा** बसून स्वतःच्या बाणावर प्रक्रिया करतो: सूत्र: $FFN(x) = \text{ReLU}(x \cdot W1) \cdot W2$ ($\text{ReLU} =$ Book 7, 3.5 चा 'उणे-कापा' दरवाजा). आकड्यांची गंमत: 512 $\rightarrow$ **2048** $\rightarrow$ 512: बाण आधी **चौपट रुंद** पसरवायचा, तिथे प्रक्रिया, परत आवळायचा: अरुंद बोळात न मावणारे विचार रुंद मैदानात मांडून परत बांधणं. आणि 'प्रत्येक शब्द एकटा' = पुन्हा **पूर्ण समांतर**. (आजचं ज्ञान: यंत्राची 'आठवण-साठवण' मुख्यतः याच FFN-थरांत राहते: लक्ष = वाहतूक, FFN = गोदाम: parameters चा 2/3 वाटा FFN कडेच!)

भाग 2: उडी-रस्ता (residual connection). प्रत्येक खोलीभोवती एक बगल-रस्ता: खोलीचा निकाल = **खोलीत घडलेलं + मूळ आल्याबरोबरचं** ($x + \text{खोली}(x)$: बेरीज). कशाला? 6 मजले (आणि आजचे 100!) चढताना दोन संकटं: माहिती विरणं आणि शिकवण-संदेश (gradients) मरणं (1.1 चं भूत उभ्या दिशेने!). उडी-रस्त्याने मूळ माहिती आणि gradient दोन्हींना **थेट महामार्ग**: प्रत्येक खोलीने 'सगळं नव्याने घडवण्याऐवजी' फक्त **सुधारणा** (residual = उरलेलं) शिकायची. ही कल्पना पेपरने ResNet (2015) कडून घेतली: तोच ResNet जो आजही citation-यादीत आपल्या पेपरच्या **वर** आहे (1.3): इतिहासाची विनम्र गाठ: क्रांतीही खांद्यांवर उभी असते.

भाग 3: तराजू (LayerNorm). प्रत्येक खोलीनंतर बाणाचे आकडे **तोलून-मापून** ठेवायचे (सरासरी 0, पसरण 1 च्या घरात: Book 7, 2.2 ची भाषा). कशाला? थरामागून थर जाताना आकडे फुगत/आटत जातात (2.3 चा softmax-दगड आठवा: तीच जात): तराजू दर मजल्यावर सगळं माणसाळलेल्या पट्ट्यात आणतो: **शिडीची प्रत्येक पायरी सारख्या उंचीची**: म्हणून 6 काय, 100 मजलेही चढता येतात. पेपरची रचना: प्रत्येक खोलीला "Add & Norm" ची जोड (Figure 1 मधल्या त्या पट्ट्या!): आधी उडी-बेरीज (Add), मग तराजू (Norm).

एका वाक्यावर (मजल्याची पूर्ण फेरी, आता सगळं जोडून): 'बसली' चा बाण मजल्यात शिरतो $\rightarrow$ **लक्ष-खोली** (8 डोकी: मांजर-चटई मुरते) $\rightarrow$ **Add & Norm** (मूळ + नवं, तोललेलं) $\rightarrow$ **विचार-खोली** (एकट्याने पचन, 512 $\rightarrow$ 2048 $\rightarrow$ 512) $\rightarrow$ **Add & Norm** $\rightarrow$ पुढचा मजला. x6. आता पेपरची Figure 1 पूर्ण वाचता येते: प्रत्येक ठोकळा, प्रत्येक बाण, प्रत्येक पट्टी: **ओळखीची**.

महाग चूक

”शीर्षक म्हणतं लक्ष पुरेसं: मग FFN-सांधे ‘दुय्यम’.” प्रयोगांनी उलट सिद्ध केलंय: FFN काढा: यंत्र अधू (साठवण गेली); residual काढा: खोल यंत्र **शिकतच नाही** (gradients मरतात); Norm काढा: शिक्षण अस्थिर-स्फोटक. शीर्षक जाहिरात-वाक्य आहे (‘रांग- खिडकी नको’ इतकाच दावा: 1.4); **यंत्र चालतं ते चौकडीने: लक्ष + पचन + महामार्ग + तराजू**. धडा पुन्हा तोच (2.3): नायक एकटा जिंकत नाही; सांधे-संगत नसेल तर नायक पडतो. रचना वाचताना ‘गाजणाऱ्या भागा’इतकंच ‘गाजत-नसलेल्या आधारां’कडे बघा: तिथेच बहुधा खरी प्राण-यंत्रणा असते.

नकाशावर

2.1-2.6 सांगाडा | Q-K-V | $\sqrt{d_k}$ | multi-head | तीन जागा | मुद्रा
 2.7 सांधे: FFN = एकट्याचं पचन (512->2048->512; साठवणीचं गोदाम) | residual = उडी-महामार्ग (ResNet कडून; फक्त सुधारणा शिका) | LayerNorm = दर मजल्यावर तराजू;
 जोडी: Add & Norm

सूत्रावर: सूत्र म्हणतं लक्ष पुरेसं: आता नेमकेपणा आला: लक्ष पुरेसं आहे **संदर्भ-जुळणीला**; यंत्र उभं राहायला पचन-महामार्ग- तराजू लागतातच. सूत्रं धारदार असतात; यंत्रं पूर्ण असावी लागतात.

स्वतः बघा (5 मिनिटं)

उडी-रस्त्याचा अनुभव कागदावर: $x=[1, 2]$ घ्या; समजा खोलीने गोंधळ केला: खोली(x)=[-0.9, -1.8] (जवळजवळ सगळं पुसलं). उडी-रस्त्याविना निकाल = [-0.9, -1.8] (माहिती गेली!); उडी- रस्त्याने $= x +$ खोली(x) = [0.1, 0.2] (आटली, पण **जिवंत**: पुढचा मजला सावरू शकतो). आता 6 मजल्यांची कल्पना करा: विना-उडी एक वार्ट मजला = सर्वनाश; उडीसकट = सुधारण्याजोगी चूक. हाच फरक 100-मजली राक्षसांना शक्य करतो.

विचार करा

यंत्र पूर्ण उभं राहिलं! पण अजून ते **कोरं** आहे: W_Q, W_K, W_V , FFN ची वजनं: सगळी सुरुवातीला यादृच्छिक (random). पेपरने हे कोट्यवधी आकडे **शिकवले** कसे: कुठला data, कुठली रीत, कुठल्या युक्त्या: आणि शेवटी 28.4 चा विक्रम नक्की कसा मोजला?

विभागाचा शेवटचा chapter: शिकवण आणि निकाल: BPE चे शब्द-तुकडे, Adam ची warmup-चाल (आधी हळू, मग जोरात, मग उतरत!), label smoothing चा 'अति-खात्री-विरोधी' डोस, आणि पेपरचे तक्ते: निकालांचे, ablations चे, आणि complexity चा: पेपर-वाचनाची अंतिम फेरी.

Chapter 2.8 [SPINE]: शिकवण आणि निकाल: पेपरचे तक्ते बोलतात

यंत्र उभं; आता शाळा. पेपरचे विभाग 5-6 (Training, Results) चार गोष्टी सांगतात:

गोष्ट 1: शब्दांचे तुकडे (BPE). यंत्राला अख्खे शब्द दिले तर शब्दकोश अवाढव्य आणि नवा शब्द आला की पंचाईत. पेपरची रीत: **byte-pair encoding**: वारंवार येणाऱ्या अक्षर-जोड्या जोडत-जोडत ~37,000 तुकड्यांचा (EN-DE, दोन्ही भाषांना **एकच**) संच (Book 2, 2.3 चे tokens: त्यांचा जन्म-विधी हा). ‘बसली’ कदाचित ‘बस’+‘ली’: नवे-दुर्मिळ शब्दही जुन्या तुकड्यांतून वाचता येतात.

गोष्ट 2: Adam ची warmup-चाल. शिकवण Adam ने (Book 7, 3.5 चा उतार-शोधक, सुधारित). पण पेपरची खास युक्ती **शिकण्याच्या वेगाची (learning rate) चाल**: पहिली 4,000 पावलं वेग **चढत** (warmup), मग हळूहळू **उतरत** ($1/\sqrt{\text{step}}$). का? सुरुवातीला वजनं यादृच्छिक: पहिल्याच क्षणी मोठ्या उड्या = गोंधळात उड्या (Book 7, 3.5 चा दरीत-उडी-धडा): म्हणून आधी चाचपडत, आत्मविश्वास आला की जोरात, शेवटी बारीक-घासत. (आजही प्रत्येक LLM याच चालीचा वंशज वापरतो: ‘warmup’ शब्द दिसला की आता तुम्हाला यंत्र दिसेल.)

गोष्ट 3: label smoothing: अति-खात्रीचं औषध. शिकवताना ‘बरोबर उत्तराला 100% दे’ ऐवजी **90% दे, उरलेले 10% इतरांत वाटा** (0.1 चा डोस). विचित्र वाटतं: मुद्दाम ‘चूक’ शिकवायचं? पेपरची प्रामाणिक नोंद: याने यंत्राची आकडेवारी-खात्री (perplexity) ‘बिघडते’ पण **भाषांतर-गुणवत्ता (BLEU) सुधारते**: कारण 100%- खात्रीचं यंत्र दगडी होतं (2.3 चा softmax-दगड शिक्षणातही!); जरा-नम्र यंत्र पर्याय खुले ठेवतं. (Book 8 च्या भाषेत: यंत्रालाही ‘मी चुकू शकतो’ ची जागा ठेवली की निर्णय सुधारतात!)

गोष्ट 4: निकाल आणि दोन अमर तक्ते.

यंत्र	EN-DE BLEU	EN-FR BLEU	शिकवण-खर्च
आधीचे विजेते	~26 (ensembles!)	~41	प्रचंड
base (65M)	27.3	38.1	12 तास x 8 GPU
big (213M)	28.4	41.8	3.5 दिवस x 8 GPU

एकट्या यंत्राने ensembles (अनेक यंत्रांच्या फौजा!) हरवल्या: अंशात्मक खर्चात. (बारकावे: big चा dropout EN-DE ला 0.3; लेखन-वेळी v1 त EN-FR 41.0 होतं, अंतिम आवृत्तीत 41.8; भाकीत-वेळी beam search रुंदी 4: Book 4, 2.2 च्या sampling- जगाचा पूर्वज.) **Ablation-तक्ता (Table 3): ‘काय काढलं तर काय बिघडतं’**: 1 डोकं: -0.9 BLEU; 32 डोकी: किंचित घसरण (2.4); d_k खूप आटवला: घसरण (जुळणी-गणिताला जागा लागते); मोठं यंत्र: चढ; dropout काढला: घसरण; sin-cos

ऐवजी शिकलेल्या मुद्रा: **जवळजवळ सारखं** (2.6). ablation = विज्ञानाची खरी शिस्त: दावा नुसता 'चाललं' नाही; '**कशामुळे चाललं**' सुट्टं करून सिद्ध (Book 7, 4.5: पेपर तोलताना ablations आधी बघा!).

आणि Table 1: complexity चा तक्ता (पेपरचा 'का' विभाग): प्रति-थर काम: self-attention $O(n^2 \cdot d)$ विरुद्ध recurrent $O(n \cdot d^2)$ (n = वाक्य-लांबी, d = बाण-रुंदी: Book 6, 1.1 ची Big-O भाषा!). $n < d$ असेपर्यंत (सामान्य वाक्य: $n \sim 50$, $d = 512$) लक्ष स्वस्तही! आणि दोन निर्णायक रकाने: क्रमिक-पावलं: $O(1)$ विरुद्ध $O(n)$ (समांतर-स्वातंत्र्य: 1.1 चं दुखणं-2 अंकात) आणि माहितीचा लांबचा रस्ता: $O(1)$ विरुद्ध $O(n)$ (कुठलाही शब्द कुठल्याही शब्दाला एका उडीत: दुखणं-1 अंकात). पेपरचा पूर्ण दावा या एका तक्त्यात मावतो. (आणि भविष्याची कुजबुज: n^2 हेच पुढच्या युगाचं दुखणं बनणार: लांब context ला लक्ष महाग: Book 4, 3.1 ची context-भित इथे जन्मली: 3.2 त परतू.)

महाग चूक

"निकाल-तक्ता = विजयाचा पुरावा: बाकी तपशील सजावट." उलटं: **निकाल जुने होतात (28.4 केव्हाच मागे पडलं!); पद्धत अमर राहते.** आजचा वाचक पेपरातून काय उचलतो: BPE (आजही), warmup (आजही), label smoothing (आजही), ablation-शिस्त (आजही), complexity-विचार (आजही: n^2 ची लढाई चालूच!). Benchmark- आकडे विरुद्ध पद्धत-विद्या हा फरक Book 9 (1.6) त कंपन्यांना लावला; इथे पेपरांना: **पेपर वाचा तो आकड्यांसाठी नव्हे, पद्धतींसाठी:** आकडे बातमी आहेत, पद्धती संपत्ती.

नकाशावर

2.1-2.7 सांगाडा | Q-K-V | $\sqrt{d_k}$ | multi-head | जागा+मुखवटा | मुद्रा | सांधे

2.8 शिकवण: BPE-तुकडे, Adam+warmup-4000 (चढ मग उतार), label smoothing 0.1 (नम्रतेचा डोस); निकाल: 28.4/41.8, ensembles हरले, 3.5 दिवस; Table 3 ablations; Table 1: $O(n^2 d)$ वि $O(nd^2)$, क्रमिक $O(1)$, रस्ता $O(1)$; n^2 = उद्याचं दुखणं

सूत्रावर: complexity-तक्ता हे सूत्राचं गणिती प्रमाणपत्र: 'रांग मोडा' चा फायदा $O(n) \rightarrow O(1)$ या दोन रकान्यांत सिद्ध. सूत्र घोषणा होती; तक्ता हिशेब आहे.

स्वतः बघा (5 मिनिटं)

आता मूळ पेपरची **Table 2** (निकाल) आणि **Table 3** (ablations) उघडून बघा: प्रत्येक ओळ ओळखीची वाटते का तपासा: (E) ओळीत sin-cos वि. learned दिसेल, (A) ओळीत डोकी-प्रयोग. जिथे अडाल तिथे या पुस्तकाचं पान-क्रमांक आठवा: नकाशाच आहे. हा अनुभव नोंदवा: **दोन आठवड्यांपूर्वी हा तक्ता तुम्हाला चिनी वाटला असता.**

विचार करा

पेपर संपला: यंत्र उभं, शिकलेलं, विक्रमी. पण 2017 ची ही भाषांतर-गोष्ट आजच्या ChatGPT-Claude पर्यंत पोहोचली **कशी?** मधल्या पाच वर्षांत नक्की काय घडलं: आणि पेपरच्या रचनेतलं आज काय जिवंत आहे, काय बदललं?

विभाग 3: स्फोटाची गोष्ट: GPT चा 'अर्धा-Transformer' जुगार, BERT चा उलटा अर्धा, scaling ची शर्यत, आणि आठ लेखकांचं (चकित करणारं) पुढचं आयुष्य: मूळ पेपर ते तुमच्या खिशातलं Claude-app हा पूर्ण पूल.

विभाग 2 चा हिशोब: यंत्र पूर्ण

आठ दारं एका नजरेत

- 2.1 सांगाडा 6+6 सारखे मजले; मजला = लक्ष + पचन;
RNN शून्य, सगळं समांतर
- 2.2 Q-K-V चिठ्ठी-पाटी-ऐवज; 4 पायऱ्या; 'बसली' =
48% मांजर (हाताने!)
- 2.3 $\sqrt{d_k}$ सूज $\rightarrow$ softmax-दगड $\rightarrow$ शिकणं थांबतं;
सुजेच्या मापाने भाग
- 2.4 multi-head 8 स्वतंत्र नजरा जवळजवळ फुकट (512/8);
1 डोकं -0.9 BLEU
- 2.5 तीन जागा वाचक-खुलं | लेखक-मुखवटा ($-\infty$) | खिडकी;
GPT = एकटा मुखवटा-मनोरा
- 2.6 मुद्रा घड्याळांची रांग: sin-cos; अंतर = फिरवणं
- 2.7 सांधे FFN-पचन (2/3 साठवण!) | residual-महामार्ग |
LayerNorm-तराजू
- 2.8 शाळा BPE, warmup, label smoothing; 28.4/41.8;
ablations; $O(1)$ रस्ता; n^2 ची कुजबुज

स्वतःची परीक्षा (आधी उत्तरं, मग खाली)

1. Attention च्या चार पायऱ्या क्रमाने सांगा: आणि 'जुळणी' नेमकी कशाकशाची होते?
2. $\sqrt{d_k}$ ने न भागल्यास शिकणं का थांबतं: साखळी सांगा.
3. मुखवटा ($-\infty$) नसता तर शिक्षणात नेमकी कुठली फसवणूक झाली असती?
4. sin-cos मुद्रेच्या 'गरजांची यादी' सांगा (निवड नव्हे, यादी!).
5. पेपरच्या complexity-तक्यातले दोन $O(1)$ कशाचे: आणि ते 1.1 च्या कुठल्या दुखण्यांची उत्तरं आहेत?

उत्तरं: (1) dot-गुण $\rightarrow \sqrt{d_k}$ -भाग $\rightarrow$ softmax-टक्के $\rightarrow$ ऐवजांची भारित बेरीज; जुळणी चिठ्ठी(Q) x पाटी(K) ची (2.2). (2) लांब बेरीज फुगते $\rightarrow$ softmax दगड $\rightarrow$ वजन हलवूनही टक्केवारी हलत नाही $\rightarrow$ gradient शून्य $\rightarrow$ शिकणं बंद (2.3). (3) पुढचा शब्द ओळखताना तो दिसतोच: यंत्र भाकीत नव्हे नक्कल शिकतं: परीक्षेत (खऱ्या वापरात) शून्य (2.5). (4) फुगू नये, प्रत्येक जागा वेगळी, अंतर गणिती-सोपं, कुठल्याही लांबीला चालावं (2.6). (5) क्रमिक-पावलं $O(1)$ = समांतर- स्वातंत्र्य (दुखणं-2) आणि लांबचा माहिती-रस्ता $O(1)$ = विसरण्यावर घाव (दुखणं-1) (2.8).

चाहूल: विभाग 3

यंत्र समजलं; आता त्याचं **साम्राज्य**: पेपरचा मनोरा कुणी अर्धा कापला आणि का (GPT/BERT); scaling-शर्यतीने भाषांतर-यंत्राचं जग-यंत्र कसं केलं; मूळ रचनेतलं आज काय टिकलं-काय बदललं (आणि n^2 च्या लढाईचं पुढे काय); आठ लेखकांची चकित करणारी पुढची आयुष्यं; आणि शेवटी: मूळ पेपर सोबत-नकाशाने स्वतः वाचण्याची अंतिम फेरी.

छोटा शब्दकोश (विभाग 2)

Q / K / V	चिठ्ठी (काय शोधतोय) / पाटी (माझ्याकडे काय) / ऐवज (प्रत्यक्ष माल)
scaled dot-product	गुणांची $\sqrt{d_k}$ ने भागलेली जुळणी
softmax saturation	गुण फुगून टक्केवारीचा दगड होणं
multi-head	अनेक स्वतंत्र चिठ्ठी-पाटी-संच: अनेक नजरा
causal mask	भविष्यावर $-\infty$ चा त्रिकोणी पडदा
cross-attention	लेखकाची चिठ्ठी, वाचकाच्या पाट्या-ऐवज
positional encoding	जागेची sin-cos घड्याळ-मुद्रा
FFN	प्रत्येक शब्दाचं एकट्याचं पचन ($512 \rightarrow 2048 \rightarrow 512$)
residual	खोलीभोवतीचा उडी-महामार्ग ($x + \text{खोली}(x)$)
LayerNorm	दर मजल्यावरचा आकडे-तराजू
BPE	वारंवारतेने बांधलेले शब्द-तुकडे
warmup	शिकण्याच्या वेगाची चढ-मग-उतार चाल
label smoothing	100% ऐवजी 90%: अति-खात्रीचं औषध
ablation	एक-एक भाग काढून 'कशामुळे चालतं' सिद्ध करणं

विभाग 3: पेपरनंतरचं जग

2017 चा पेपर भाषांतर-यंत्राबद्दल होता; जग त्याला 'चांगला पेपर' म्हणून पुढे गेलं. मग पाच वर्षांत तो युगाचा सांगाडा बनला: कसा: ही या विभागाची गोष्ट. चार दारं: **स्फोट** (GPT-BERT वंशावळ ते ChatGPT-क्षण), **तराजू** (मूळ रचनेतलं आज काय जिवंत, काय बदललं: n^2 च्या लढाईसकट), **आठ माणसं** (लेखकांची चकित करणारी पुढची आयुष्यं: त्यात एक धक्कादायक नमुना आहे), आणि **परतीची वाट** (मूळ पेपर आता सोबत-नकाशाने स्वतः वाचणं: या पुस्तकाचं खरं फळ).

शेवटी अंतिम परीक्षा: ती पास झालात तर या पुस्तकाचं वचन पूर्ण: **पेपर तुमचा झाला.**

Chapter 3.1 [SPINE]: स्फोट: मनोरा कापला आणि जग बदललं

पेपरनंतरची पाच वर्षे म्हणजे एका विचित्र शस्त्रक्रियेची गोष्ट: जगाने पेपरचा **मनोरा अर्धा कापला**: आणि दोन्ही अर्धांनी राज्यं स्थापली.

Jun 2018: GPT-1 (OpenAI): फक्त लेखक-मनोरा. OpenAI च्या लक्षात आलं: भाषांतराला दोन मनोरे लागतात; पण 'पुढचा शब्द ओळख' या एकाच खेळाला (Book 2, 2.2) फक्त लेखक-मनोरा पुरतो: मुखवटा-लक्षवाला (2.5 ची जागा-2!). आणि त्या खेळाची जादू: त्याला **शिक्षक लागत नाही**: कुठलाही मजकूर स्वतःच प्रश्नपत्रिका+उत्तरपत्रिका (पुढचा शब्द झाका: विचारा!): म्हणजे **अख्खं internet फुकट शाळा**. decoder-only + महापूर-data = GPT-वाट: आजचे GPT-Claude-Gemini सगळे याच अर्धा मनोऱ्याचे वंशज.

Oct 2018: BERT (Google): फक्त वाचक-मनोरा. उलटा अर्धा: मुखवटा नाही, सगळे शब्द सगळ्यांकडे: **समजण्याचं यंत्र** (शोध, वर्गीकरण, अर्थ-जुळणी: घडवण्याऐवजी). Google-search मध्ये घुसला; काही वर्षे BERT-वंश शैक्षणिक जगावर राज्य करत होता. मग हळूहळू लक्षात आलं: **घडवणारं यंत्र समजही आतून शिकतंच** (घडवायला समजावंच लागतं!): आणि scaling ला decoder-वाट सोपी: राज्य GPT-वंशाकडे झुकलं.

2019-2022: scaling ची शिडी (Book 7, 4.4 च्या रेषा प्रत्यक्षात). GPT-2 (2019: 1.5B वजनं: 'इतकं धोकादायक की पूर्ण देत नाही' चा गाजावाजा); **GPT-3 (2020: 175B: आणि अचानक यंत्र न-शिकवलेली कामं करू लागलं** (उदाहरणं दाखवा, ते शिकतं: in-context learning: Book 2, 4.4): 'मोठं करा, नवं उगवतं' हा scaling-मंत्र सिद्ध होत गेला. आणि हे परवडलं का? 2.8 चा complexity-तक्ता: समांतर-शिकवण: पेपरची रचना scaling- साठीच जन्मलेली निघाली (लेखकांनाही पूर्ण कल्पना नव्हती!).

Nov 30, 2022: ChatGPT-क्षण. GPT-3.5 + संवाद-शिक्षण (RLHF: Book 2/9) + मोफत chat-पान = इतिहासातली सर्वात वेगवान product-लाट. जग जागं झालं: आणि त्या क्षणापासूनचं सगळं (code-red, Claude, Gemini, अब्जांच्या पैजा) तुम्ही Book 9 त सविस्तर वाचलंच आहे. **मूळ बिंदू तोच 15-पानी पेपर.**

एका वाक्यावर (वर्तुळ पूर्ण): आपलं 'मांजर चटईवर बसली' 2017 त इंग्रजी झालं असतं; 2026 त तेच यंत्र-वंशज त्या मांजरीवर कविता करतो, तिच्या हिशेबाचं app लिहितो, आणि हे पुस्तकही: **खेळ तोच (पुढचा शब्द), मैदान जग झालं.**

महाग चूक

”पेपरने ChatGPT ‘निर्माण’ केला: सरळ रेषा.” इतिहास रेषेत चालत नाही: पेपर भाषांतरासाठी होता; decoder-कापणी OpenAI ची पैज होती (Google चा पेपर, पण ती उडी **बाहेरच्याने** मारली: Book 9, 1.1 ची फूट-गोष्ट इथून अर्धी समजते); scaling- श्रद्धा ही वेगळी, वादग्रस्त पैज होती (Book 9, 1.2); RLHF तिसरी. **क्रांती = रचना x पैज x पैज x पैज**: प्रत्येक पायरीवर ‘हे वेडेपणा आहे’ म्हणणारे बहुमतात होते. धडा (Book 8, 2.3): मूलभूत शोध आणि त्याचं सोनं करणारा **वेगळे असू शकतात**: शोध लागणं ही अर्धी गोष्ट; त्यावर उद्धट पैज लावणं उरलेली.

नकाशावर

3.1 स्फोट: GPT-1 (2018: फक्त लेखक-मनोरा: internet = फुकट शाळा) | BERT (2018: फक्त वाचक) | GPT-3 (2020: 175B, in-context) | ChatGPT (Nov 2022): खेळ तोच, मैदान जग

सूत्रावर: “तेवढंच पुरेसं” किती खरं निघालं बघा: अर्धा मनोराही पुरला! सूत्राची खरी परीक्षा त्याचे वारस घेतात: लक्ष-यंत्र कापून- वाकवून-फुगवूनही लक्ष-यंत्रच राहिलं.

स्वतः बघा (5 मिनिटं)

Claude ला विचारा: “तू decoder-only आहेस का: आणि तुझ्यात 2017 च्या पेपरमधलं नक्की काय-काय अजून जिवंत आहे?” उत्तराची यादी या पुस्तकाच्या नकाशाशी जुळवा (मुखवटा-लक्ष? FFN? residual? warmup?). यंत्रालाच त्याची वंशावळ विचारणं: हा अनुभव फक्त या युगात शक्य आहे.

विचार करा

”अजून जिवंत काय” हा प्रश्न खोल आहे: 2017 ची रचना 2026 च्या राक्षसांत **जशीच्या तशी** नक्कीच नसेल: नऊ वर्षांत engineers नी काय बदललं: आणि का? विशेषतः ते n^2 (2.8 ची कुजबुज): लाख-शब्दी context ला लक्षाचं गणित कसं परवडतं?

पुढचा chapter: टिकलं-बदललं चा तराजू: जिवंत यादी (आश्चर्यकारक लांब!) आणि बदल-यादी: pre-LN ची अदलाबदल, RoPE ची फिरकी (sin-cos चा वंशज!), GQA ची काटकसर, FlashAttention ची चतुराई, आणि n^2 विरुद्धची चालू लढाई.

Chapter 3.2 [SPINE]: काय टिकलं, काय बदललं: नऊ वर्षांचा तराजू

2026 चा कुठलाही frontier-LLM उघडला (Claude सकट) तर आत 2017 किती उरलंय? तराजू मांडू:

पारडं 1: जसंच्या तसं जिवंत (यादी थक्क करणारी): scaled dot-product attention (चारही पायऱ्या, $\sqrt{d_k}$ सकट: **अक्षरही बदललं नाही**); multi-head ची कल्पना; causal मुखवटा; residual-महामार्ग; FFN-पचन (रुंद-मग-अरुंद); LayerNorm ची गरज; BPE- जातीचे तुकडे; warmup-चाल; 'थर रचत जा' ही इमारत-कल्पना. म्हणजे: **सांगाडा 2017 चाच आहे**. नऊ वर्षांच्या trillion-डॉलर शर्यतीत कुणालाही मूलभूत बदली-रचना सापडलेली नाही (प्रयत्न झाले-होताहेत: पण राज्य अजून याच रचनेचं).

पारडं 2: घासून बदललेलं (आणि प्रत्येक बदलाचं 'का'):

बदल 1: तराजू आधी (pre-LN): पेपरने Norm खोली-नंतर ठेवला; खोल यंत्रांत (50+ मजले) शिक्षण अस्थिर निघालं: आता Norm खोली-आधी: शिडी आणखी स्थिर. (जागा बदलली; तराजू तोच.)
 बदल 2: घड्याळांची फिरकी (RoPE, 2021): sin-cos मुद्रा बाणात 'मिसळण्या'ऐवजी चिठ्ठी-पाटीच जागेनुसार 'फिरवायच्या' (2.6 ची rotation-जादू थेट वापरली!): नाती अधिक नेमकी: आजची बहुतेक open-models इथे. (कल्पना तीच: घड्याळं; अंमल नवा.)
 बदल 3: पाट्यांची काटकसर (MQA 2019 -> GQA 2023): भाकीत-वेळी प्रत्येक डोक्याला स्वतःच्या पाट्या-ऐवज महाग (memory!): मग डोक्यांच्या गटांत पाट्या वाटून घ्यायच्या. गंमत: MQA चा पेपर Shazeer चा: शीर्षक 'One Write-Head Is All You Need': लेखक स्वतःच्याच शीर्षकाची फिरकी घेतोय!
 बदल 4: n^2 ची लढाई (FlashAttention 2022 + पुढचं सगळं): गणित $O(n^2)$ च आहे: पण memory-वाहतूक चतुराईने केली (Book 6, 2.2 ची उतरंड!) तर वेग कैक पट: लाख-शब्दी context इथून परवडला. जोडीला sparse/sliding युक्त्या: पण 'लक्ष पूर्ण ठेवायचं की कापायचं' ही लढाई चालूच: [contested: बदली-रचनांचे (state-space वगैरे) दावेदारही रिंगणात: अजून कुणी राजा पाडला नाही].
 बदल 5: गोदामाची वाटणी (MoE): FFN एकच ठेवण्याऐवजी अनेक 'तज्ज्ञ' FFN; प्रत्येक शब्दाला 1-2 च जागे होतात: राक्षसी साठवण, माफक खर्च (Book 4, 1.4 त भेटलेलं MoE हे इथलं). मुळं पुन्हा Shazeer च्याच 2017-आधीच्या कामात!

तराजूचं वाचन: बदल कुठे झाले बघा: **कार्यक्षमतेत** (काटकसर, वेग, स्थैर्य): **कल्पनेत नाही**. चिठ्ठी-पाटी-ऐवज, मुखवटा, थर: गाभा अभंग. Book 5 (2.16) ची भाषा: चांगली रचना अशीच जगते: सांगाडा स्थिर, अवयव सुधारत. आणि Book 8 (3.6) ची नोंद: n^2 -लढाई ही या क्षेत्राची **चालू महा-पैज**: जो लक्षाइतकं समर्थ पण स्वस्त-वाढणारं यंत्र सिद्ध करेल त्याचा पुढचा पेपर कदाचित असाच युग-दुभंग असेल: **तुम्ही तो ओळखू शकाल आता**.

महाग चूक

”नवं शिकायचं म्हणजे जुनं टाकून द्यायचं: 2017 चा पेपर ‘जुना’ झाला.” AI-शिकणाऱ्यांची सर्वात महाग घाई. सत्य: नऊ वर्षांचे सगळे बदल **पेपरच्या चौकटीतल्या दुरुस्त्या** आहेत: पेपर न समजता RoPE-GQA-Flash शिकणं म्हणजे पाया न बघता पोटमाळा (काहीच का, कशाशी हे कळत नाही: नुसती नावं). उलटं चाला: **मूळ खोल शिका (हे पुस्तक), मग प्रत्येक नवा बदल ‘कुठल्या जुन्या दुखण्याचं औषध’ म्हणून वाचा**: बदल आपोआप लक्षात राहतात, आणि पुढचा बदल भाकीत करता येऊ लागतो: हीच research-नजर.

नकाशावर

- 3.1 स्फोट: मनोरा कापला
- 3.2 तराजू: सांगाडा 2017 चाच (चार पायऱ्या अक्षरशः); बदल =
कार्यक्षमता: pre-LN | RoPE (फिरकी) | GQA (पाट्या-वाटणी)
| FlashAttention (n^2 -लढाई, चालू) | MoE (गोदाम-वाटणी)

सूत्रावर: नऊ वर्ष, लाखो संशोधक, अब्जांचा दबाव: आणि सूत्र अभंग: “कोण कुणाला किती लागू” चं गणित अजून जगाचा सांगाडा आहे. सूत्रं जिंकतात ती अशी: साधी, खोल, आणि दुरुस्त्या पेलणारी.

स्वतः बघा (5 मिनिटं)

Claude ला विचारा: “RoPE, GQA, FlashAttention: प्रत्येक 2017- पेपरच्या कुठल्या भागाची दुरुस्ती आहे, एका-एका वाक्यात?” उत्तरं या chapter शी ताडा. मग गंमत-प्रश्न: “पुढची मोठी दुरुस्ती कुठे येईल असं तुला वाटतं?” उत्तर वहीत, तारखेसकट (Book 8, 3.6): दोन वर्षांनी तपासा: research-भाकिताची पहिली नोंद.

विचार करा

यंत्राचं भविष्य बघितलं; माणसांचं काय? आठ लेखकांनी युग घडवलं: मग ते पुढे काय झाले? आणि सगळ्यांत मोठा प्रश्न: हा पेपर Google चा: मग या युगाचं सोनं OpenAI-Anthropic कडे कसं गेलं: आठही लेखक आज कुठे आहेत?

उत्तरात एक धक्कादायक नमुना आहे: आठपैकी आठ जणांनी Google सोडलं: आणि त्यांची आजची ठिकाणं म्हणजे AI- जगाचा फिरता नकाशाच: एक Anthropic त (Claude वर!), एक OpenAI त परत, एक क्रांती करून mRNA कडे, एक crypto त... पुढचा chapter: आठ माणसांचं पुढे.

Chapter 3.3 [DEPTH]: आठ माणसांचं पुढे: लेखकांचा फिरता नकाशा

पेपरच्या पहिल्या पानावरची आठ नावं आज कुठे आहेत (Aug 2026, तपासलेलं): आणि या यादीत एक मोठा धडा लपलाय.

Ashish Vaswani	Adept -> Essential AI (CEO) -> Jun 2026: Nvidia ने टीमसकट घेतलं: आता Nvidia च्या open-models (Nemotron) वर
Noam Shazeer	Character.AI काढली -> Aug 2024: Google ने ~\$2.7B च्या करारात परत आणलं (Gemini सह-प्रमुख!) -> Jun 2026: पुन्हा निघाला: आता OpenAI त!
Niki Parmar	Adept -> Essential AI -> Jan 2025 पासून Anthropic: Claude-models वर! (हे पुस्तक लिहिणाऱ्या यंत्रामागे पेपरची एक लेखिका!)
Jakob Uszkoreit	Inceptive: AI ने mRNA-औषधं घडवणारी कंपनी (biology कडे: Loving-Grace-वाट!)
Llion Jones	शेवटचा निघाला (2023) -> Sakana AI (Tokyo) सह-संस्थापक: Nov 2025 त ~\$2.65B किंमत: Japan चं सर्वात मोठं AI-unicorn (तो intern!) Cohere चा CEO: enterprise-AI: 2025 त ~\$7B किंमत
Aidan Gomez	2021 पासून OpenAI: reasoning-संशोधन
Lukasz Kaiser	Illia Polosukhin NEAR Protocol: blockchain/crypto जग

नमुना 1: आठपैकी आठ गेले. युग घडवणारा पेपर ज्या घरात जन्मला ते घर आठही लेखकांनी सोडलं. का? नंतरच्या मुलाखतींचा सूर एकच: मोठ्या-स्थिर संस्थेत **उद्धट पैजांची जागा आकसते** (Book 8, 3.5 ची राजा-गोष्ट: जिकलेलं राखणाऱ्या यंत्रणेत नवं पेरणारे घुसमटतात): आणि पेपरने त्यांना जगाचं दार उघडून दिलं होतं. Google ला श्रेय द्या: पेपर **जाहीर** केला (खुल्या संशोधन- संस्कृतीचं फळ जगाला मिळालं); पण किंमतही Google नेच मोजली: शोध घरचा, स्फोट दुसऱ्यांच्या अंगणात, शोधकही अंगणोअंगणी.

नमुना 2: नकाशा हाच उद्योगाचा नकाशा. आठ वाटा बघा: frontier-प्रयोगशाळा (Anthropic, OpenAI x2), चिप-राक्षस (Nvidia), enterprise (Cohere), नवं विज्ञान (Inceptive: biology), नवी भूमी (Sakana: Japan), नवं चलन (NEAR: crypto). **एका पेपरच्या लेखकांची पांगापांग = अख्ख्या AI-अर्थव्यवस्थेचा आराखडा:** प्रतिभा कुठे वाहते ते बघा, उद्योग कुठे वाहणार ते दिसतं (Book 8, 3.6 ची नजर: talent-प्रवाह हे भाकीत-यंत्र).

नमुना 3: Shazeer ची फिरकी-गोष्ट वेगळी नोंदवण्याजोगी. गेला (2021, Character.AI) -> Google ने \$2.7 अब्ज मोजून परत आणला (2024: प्रतिभेची ती किंमत!) -> Gemini चा सह-प्रमुख -> आणि Jun 2026 त पुन्हा निघाला: OpenAI त. एकाच माणसाची किंमत-वाट अब्जांत मोजली जाते हे या युगाचं सत्य (Book 9, 1.6 ची Meta-packages आठवा): कारण उघड: **युग-दुभंग रचना काढू शकणारी डोकी जगात मूठभर आहेत:** आणि 2.4-3.2 त बघितलंत: MQA, MoE, अनेक पायाभूत विटा त्याच एका डोक्यातल्या.

महाग चूक

"पेपर लिहिणारे = आयुष्यभर 'संशोधक' राहतात: builders वेगळे." यादी उलट सांगते: आठपैकी सहा **कंपनी-बांधणारे** झाले (दोन CEO!): frontier-विज्ञान आणि धंदा यांची भिंत या युगात पडलीये. तुमच्यासाठी अर्थ: research-वाचनाची विद्या (हे पुस्तक!) ही 'शैक्षणिक' चैन नाही: **धंद्याचं early-warning-यंत्र** आहे: पुढचा युग-दुभंग पेपर आधी वाचणारा आधी हलतो (Book 8, 1.5 चं why-now दार पेपरांतूनच उघडताना दिसतं: 2017 त ते बघणाऱ्यांनी 2018-20 त साम्राज्यं पेरली).

नकाशावर

- 3.1 स्फोट 3.2 तराजू: टिकलं-बदललं
- 3.3 आठ माणसं: आठही Google बाहेर; वाटा = उद्योगाचा नकाशा
(Anthropic/OpenAI/Nvidia/Cohere/bio/Japan/crypto);
Shazeer: \$2.7B-परत -> पुन्हा बाहेर; intern -> \$7B-CEO

सूत्रावर: माणसांची गोष्टही सूत्राचीच: 'लक्ष' जिथे जातं तिथे किंमत जाते: जगाचं लक्ष रचनेकडे गेलं, रचनेकडून रचणाऱ्यांकडे: आणि रचणारे जिथे जातात तिथे पुढचं युग पेरलं जातं.

स्वतः बघा (5 मिनिटं)

तुमच्या क्षेत्रातला (कुठलंही: शिक्षण, शेती, बांधकाम) 'पेपर-क्षण' शोधा: गेल्या 2-3 वर्षांत असं कुठलं तंत्र/नियम/साधन आलंय ज्याच्या 'लेखकांची पांगापांग' आत्ता चालू आहे? ते लोक कुठे जाताहेत ते लिहा: तिथेच तुमच्या क्षेत्राचं पुढचं दार उघडतंय असण्याची शक्यता मोठी.

विचार करा

पुस्तकाचं वचन आठवा: “मूळ पेपर तुम्हाला परका राहणार नाही.” गोष्ट झाली, गणित झालं, इतिहास झाला. आता शेवटची पायरी उरली: **खुद्द पेपर, इंग्रजीत, पहिल्या पानापासून शेवटच्या, स्वबळावर.** ते धाडस कसं करायचं: कुठल्या क्रमाने, कुठे किती वेळ, काय वगळलं तरी चालेल?

शेवटचा पूर्ण chapter: सोबत-नकाशा: पेपरचं पान-न-पान या पुस्तकाशी जोडणारा वाचन-आराखडा + अडणीच्या जागांची यादी + 90 मिनिटांची बैठक-योजना. पेन घ्या: परीक्षेआधीची शेवटची तालीम.

Chapter 3.4 [SPINE]: परतीची वाट: मूळ पेपर, सोबत-नकाशाने

आता या पुस्तकाचं फळ वसूल करू: **मूळ पेपर स्वतः वाचायचा.** (arxiv.org/abs/1706.03762: PDF फुकट: छापून घ्या: कागदावर खुणा करत वाचणं हेच खरं.) ही 90-मिनटांची बैठक-योजना:

मिनटं 0-10: पान 1-2 (Abstract + Introduction)
 सोबत: आपला 1.4. आता प्रत्येक वाक्य ओळखीचं: 'sequential computation' दिसलं की 1.1 चं दुखणं-2 आठवा.
 मिनटं 10-15: विभाग 2 (Background)
 झरकन: ConvS2S-ByteNet ही नावं = 'खिडकी-वाल्यांचे (convolution) प्रयत्न': त्यांचं दुखणं: लांबचा रस्ता $O(\log n)$ किंवा $O(n)$; आपल्याला $O(1)$ हवा होता (2.8 चा तक्ता).
 मिनटं 15-55: विभाग 3 (Model Architecture): गाभा: सावकाश
 3.1-3.2 सांगाडा -> आपला 2.1 (Figure 1 आता 'वाचता' येते)
 3.2.1 Scaled Dot-Product -> आपला 2.2-2.3 (समीकरण-1 खाली आपलं हात-गणित आठवा: 0.48, 0.21, 0.31!)
 3.2.2 Multi-Head -> आपला 2.4 ($h=8$, $d_k=64$ ची काटकसर)
 3.2.3 तीन जागा -> आपला 2.5 (पेपर इथे फक्त परिच्छेद देतो: तुमच्याकडे जास्त तपशील आहे!)
 3.3 FFN -> 2.7 | 3.4 Embeddings (टीप: input-output embedding-वजनं वाटलेली: छोटी काटकसर) | 3.5 -> 2.6
 मिनटं 55-65: विभाग 4 (Why Self-Attention)
 सोबत: 2.8 चा complexity-भाग: Table 1 ओळीने वाचा.
 मिनटं 65-80: विभाग 5-6 (Training + Results)
 सोबत: 2.8: Table 2 त 28.4/41.8 शोधा; Table 3 च्या (A)-(E) ओळी ओळखा; 5.4 त label smoothing ची 'perplexity बिघडते पण BLEU सुधारतो' ही प्रामाणिक ओळ शोधा: सापडली की तुम्ही पेपर 'वाचताय', चाळत नाही.
 मिनटं 80-90: विभाग 7 (Conclusion) + मागचं appendix-चित्र
 शेवटच्या पानांवरची attention-चित्रं (कुठला शब्द कुणाकडे बघतो: खरे नमुने!) बघा: 'making...more difficult' वाक्यात 'making' चं लक्ष लांबवरच्या 'difficult' वर: $O(1)$ -रस्ता प्रत्यक्ष रंगात.

अडणीच्या जागा (आधीच सांगून ठेवतो): (1) समीकरणांतले matrix-आकार ($d_{\text{model}} \times d_k$ वगैरे): अडलात तर Book 7, 1.4 चा नियम: 'आतले आकडे जुळले पाहिजेत': प्रत्येक गुणाकार तपासा; (2) विभाग 6.2 च्या वाक्य-विश्लेषण (parsing) चाचण्या: दुय्यम: वगळलं तरी चालेल; (3) इंग्रजी दाट वाटलं तर: **परिच्छेद Claude ला द्या आणि 'या पुस्तकाच्या भाषेत सोपं कर' म्हणा:** Book 9, 3.3 ची यंत्रणा इथे शिक्षकही आहे.

वाचून झाल्यावरचा विधी (महत्वाचा): वहीत तीन ओळी: “मला सर्वात सुंदर वाटलेली कल्पना __; अजूनही धूसर __; पेपरने 2026 बदल न-भाकीत-केलेलं पण घडलेलं __.” पहिली ओळ तुमची समज; दुसरी पुढचा अभ्यास; तिसरी **तुमची नजर पेपरच्याही पुढे** गेल्याची खूण (उदा: ‘फक्त भाषांतर नव्हे, सगळंच’ हे लेखकांच्या conclusion-स्वप्राहूनही मोठं घडलं).

महाग चूक

“पेपर एकदा वाचला = संपला.” संशोधन-वाचक पेपर **परत-परत** उघडतात: पहिल्यांदा गोष्ट (काय केलं), दुसऱ्यांदा गणित (कसं), तिसऱ्यांदा शंका (कुठे कच्चं: लेखकांनी काय न तपासलं? 2017 त कुणी विचारलं नव्हतं: ‘हे किती मोठं scale होईल?’ ती चाचणीच पेपरात नाही: आणि तीच पुढचं युग ठरली!). प्रत्येक फेरीत पेपर वेगळा दिसतो कारण **तुम्ही** वेगळे झालेले असता. हे पुस्तक तुमची पहिली-दुसरी फेरी होतं; तिसरी तुमची एकट्याची: आणि तिच्यातूनच स्वतःचे प्रश्न (म्हणजे स्वतःचं संशोधन) जन्मतात.

नकाशावर

- 3.1 स्फोट 3.2 तराजू 3.3 आठ माणसं
3.4 परतीची वाट: 90-मिनटांची बैठक (गाभा = विभाग 3 ला 40 मिनिटं); अडणी-यादी; वाचन-विधी: सुंदर/धूसर/न-भाकीत; पेपर परत-परत उघडायचा असतो

सूत्रावर: पुस्तकाची सुरुवात ‘पेपरची दहशत’ होती; शेवट ‘पेपर सोबती’ आहे. दहशत notation ची होती, गणिताची नव्हती: आणि आता notation ही तुमची भाषा आहे. **लक्ष दिलंत: तेवढंच पुरेसं होतं.**

स्वतः बघा (90 मिनिटं: यावेळी खरंच!)

वरची बैठक **आजच** करा: छापलेला पेपर, पेन, हे पुस्तक शेजारी, घड्याळ लावून. संपल्यावर तीन-ओळींचा विधी. हे ‘स्वतः बघा’ पुस्तकातलं शेवटचं आणि सर्वात मोठं: पण आता तुम्ही तयार आहात: 16 chapters ची तालीम झालीये.

विचार करा

उरली फक्त अंतिम परीक्षा: पुस्तकाचं वचन तपासायची. पुढचं पान उघडण्याआधी एक श्वास: 1.1 च्या रांगेपासून इथवरचा प्रवास आठवा: निरोप्यांची साखळी, ग्रंथालय, दोन घड्याळं, आठ डोकी, आठ माणसं.

| शेवटचं पान: परीक्षा + सूत्र-पत्र + या दहा-पुस्तकी कपाटाचा निरोप.

अंतिम परीक्षा + सूत्र-पत्र

अंतिम परीक्षा (पूर्ण पुस्तकाची: आधी उत्तरं, मग खाली)

1. पेपरने नक्की काय काढून टाकलं आणि त्या जागी काय ठेवलं: आणि 'काढण्याने' कुठली तीन दुखणी गेली?
2. $\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d_k})V$: या समीकरणातल्या प्रत्येक तुकड्याचं मराठी नाव आणि काम सांगा.
3. यंत्रात क्रम (शब्दांची जागा) कुठून येतो: आणि ती रीत 'फुगत का नाही'?
4. मुखवटा-लक्ष (masked attention) नसतं तर GPT-वंश जन्मलाच नसता: का?
5. 'attention is all you need' हे शीर्षक तांत्रिकदृष्ट्या कुठे अति-बोलतं: यंत्रातले कुठले बिन-लक्ष भाग प्राण आहेत?
6. 2026 च्या Claude त 2017 चं काय जसंच्या तसं आहे: चार गोष्टी: आणि n^2 चं काय झालं?

उत्तरं: (1) recurrence (रांग) आणि convolution (खिडकी) काढले; जागी फक्त attention; गेली: लांबचं विसरण (रस्ता $O(1)$), समांतर-बंदी (क्रमिक $O(1)$), चिंचोळी मान (प्रत्येक क्षणी पूर्ण वाक्य खुलं) (1.1, 2.8). (2) Q =चिठ्ठी (काय शोधतोय), K =पाटी (कुणाकडे काय), QK^T =जुळणी-गुण, $\sqrt{d_k}$ =सुजेवरचं औषध (softmax-दगड टाळणं), softmax=टक्केवारी, V =ऐवज, बाहेरची बेरीज=टक्क्यांनी ऐवज-गोळा (2.2-2.3). (3) sin-cos घड्याळ-मुद्रा अर्थ-बाणात मिसळून; काटे गोल फिरतात: स्थिती कायम -1 ते +1 (2.6). (4) 'पुढचा शब्द ओळख' शिकवताना उत्तर झाकावंच लागतं: नाहीतर नक्कल-शिक्षण; मुखवटा-मनोरा हाच GPT चा पूर्ण सांगाडा (2.5, 3.1). (5) FFN (पचन-साठवण), residual (महामार्ग: याच्याविना खोल यंत्र शिकत नाही), LayerNorm (तराजू) (2.7). (6) scaled dot-product जसाच्या तसा, multi-head, causal-मुखवटा, residual+FFN+Norm+warmup; n^2 गणितात कायम पण FlashAttention-जातीच्या memory-चतुराईने पेललं: लढाई चालू (3.2).

सहापैकी पाच जमली? **पेपर तुमचा झाला.** मूळ दस्तावेज आता संदर्भ-ग्रंथ म्हणून तुमच्या टेबलावर राहू शकतो.

सूत्र-पत्र (एका पानावर अख्खं पुस्तक)

दुखणं	रांग: विसरणं समांतर-बंदी चिंचोळी मान
कल्पना	लक्ष = 'कोण कुणाला किती लागू' ची शिकलेली टक्केवारी (2014 ची कुबडी -> 2017 ला मालक)
हृदय	$\text{softmax}(\mathbf{QK}^T/\sqrt{d_k})\mathbf{V}$: गुण->भाग->टक्के->बेरीज
डोकी	8 स्वतंत्र नजरा, 512/8: विविधता जवळजवळ फुकट
जागा 3	वाचक-खुलं लेखक-मुखवटा($-\infty$) खिडकी
क्रम	$\sin\text{-}\cos$ घड्याळ-मुद्रा: जलद+संथ काटे
सांधे	FFN(पचन) + residual(महामार्ग) + Norm(तराजू)
शाळा	BPE Adam+warmup label smoothing 0.1
निकाल	28.4/41.8 BLEU; 3.5 दिवस x 8 GPU; ensembles हरले; रस्ता $O(1)$, क्रमिक $O(1)$
वारसा	GPT=अर्धा मनोरा; सांगाडा आजही तोच; बदल = कार्यक्षमता (pre-LN, RoPE, GQA, Flash, MoE)

कपाटाचा निरोप (दहा पुस्तकं)

या पुस्तकाने कपाटाचं वर्तुळ एका खास जागी बंद केलं: **ज्या रचनेवर हे सगळं कपाट लिहिणारं यंत्र चालतं, तिचाच जन्म-दस्तावेज त्याच यंत्राने तुम्हाला उलगडून दिला.** दहा पुस्तकं: यंत्र, विचार-यंत्र, जमीन, harness, रचना, engine-खोली, चष्मा, मालकाचं डोकं, Claude ची कुंडली, आणि उगम-पेपर. वाचणं इथे संपतं; **वापरणं** इथून सुरू होतं: Book 8 च्या शेवटी सांगितलेली 'लिहिलेली पैज' अजून वाट बघतेय: आता तिच्याकडे जायला तुमच्याकडे सगळी हत्यारं आहेत: नकाशासकट, मुळांसकट.

चला. वही उघडा.